

**Pró-Reitoria Acadêmica
Programa de Pós-Graduação Stricto Sensu em
Governança, Tecnologia e Inovação**

***Machine Learning* e Análise Preditiva em saúde: um
estudo de caso sobre detecção de anomalias em contas
médicas do Exército**

**Autor: Sergio Ricardo Pacheco da Vitoria
Orientador: Prof. Dr. Matheus S. de Paiva**

**Brasília - DF
2022**

SERGIO RICARDO PACHECO DA VITORIA

***Machine Learning* e Análise Preditiva em saúde: um estudo de caso sobre
detecção de anomalias em contas médicas do Exército**

Dissertação apresentada ao Programa de Pós-Graduação *Stricto Sensu* em Governança, Tecnologia e Inovação da Universidade Católica de Brasília, como requisito parcial para obtenção do Título de Mestre em Governança, Tecnologia e Inovação

Orientador: Prof. Dr. Matheus S. de Paiva

**Brasília - DF
2021**

V845m Vitoria, Sergio Ricardo Pacheco da.
Machine learning e análise preditiva em saúde : um estudo de caso
sobre detecção de anomalias em contas médicas do Exército / Sergio
Ricardo Pacheco da Vitoria. – 2022.

96 f. : il. ; 30 cm.

Dissertação (mestrado) – Universidade Católica de Brasília, Programa
de Pós-Graduação em Governança, Tecnologia e Inovação, 2022.

Orientação: Prof. Dr. Matheus S. de Paiva.

1. Contas médicas. 2. Assistência à saúde. 3. Plano de saúde. 4.
Machine learning. I. Paiva, Matheus S. de. II. Título.

CDU 004:61


Dissertação de autoria de Sérgio Ricardo Pacheco da Vitória, intitulada "Machine Learning e Análise Preditivas em Saúde: Um estudo de caso sobre detecção de anomalias em contas médicas do Exército", apresentada como requisito parcial para obtenção do grau de Mestre em Governança, Tecnologia e Inovação da Universidade Católica de Brasília, em 04 de março de 2022, defendida e aprovada pela banca examinadora abaixo assinada:



Prof. Dr. Matheus Silva de Paiva
Orientador
Universidade Católica de Brasília – UCB



Prof. Dr. Gilberto Clóvis Josemin
Universidade Católica de Brasília – UCB



Prof. Dr. Rogério Mazali
Universidade de Brasília – UnB

AGRADECIMENTOS

A Deus, pela dádiva da vida. À minha querida esposa, que tanto me ajudou nesse momento com apoio emocional e sempre esteve torcendo por mim. Esta conquista também é dela. Ao meu filhão João Miguel, por me confortar e me motivar para que eu chegasse ao bom termo. Aos meus pais, João Silvestre e Maria Elena, que sempre me servirão de exemplo, minha gratidão. Ao meu irmão, minha irmã, meu cunhado, minha cunhada e meus sobrinhos, amo todos vocês. Ao meu orientador, Prof. Dr. Matheus S. de Paiva, por toda a generosidade e paciência, pela oportunidade do aprendizado, dividindo seu notório conhecimento e, sobretudo, por acreditar em mim. À Diretora de Saúde EB, que aqui faço representar pelo meu Chefe TC Med Echart, pelo apoio que me foi prestado em todo momento. E aos meus amigos de trabalho, meu muito obrigado. Levo vocês todos comigo para todo o sempre.

Muito obrigado a todos.

SUMÁRIO

1. INTRODUÇÃO	13
1.1 PROBLEMA DE PESQUISA	15
1.2 SOLUÇÃO PROPOSTA.....	15
1.3 MOTIVAÇÃO.....	16
1.4 JUSTIFICATIVA	17
1.5 HIPÓTESE DE PESQUISA.....	18
1.6 OBJETIVOS	18
1.6.1 Objetivos específicos.....	18
1.7 METODOLOGIA	19
1.7.1 Metodologia de pesquisa.....	19
1.7.2 Ferramentas utilizadas	20
1.7.3 Procedimentos metodológicos.....	21
1.8 ESTRUTURA DA DISSERTAÇÃO.....	21
2. REVISÃO DE LITERATURA.....	22
2.1 DESCOBERTA DE CONHECIMENTO EM BASE DE DADOS - KDD	23
2.2 FRAMEWORK CRISP-DM.....	25
2.3 DETECÇÃO DE ANORMALIDADES E FRAUDES	27
3. REFERENCIAL TEÓRICO	38
3.1 AUDITORIA EM CONTAS HOSPITALARES	39
3.2 AUDITORIA EM CONTAS HOSPITALARES NO EXÉRCITO BRASILEIRO	40
3.3 SISTEMAS TRANSACIONAIS EM SAÚDE DO EXÉRCITO BRASILEIRO .	42
3.4 DESCOBERTA DE CONHECIMENTO EM BASES DE DADOS	44
3.4.1 Compreensão do Negócio	45
3.4.2 Compreensão dos Dados	46
3.4.3 Preparação dos Dados	46
3.4.4 Modelagem.....	46
3.4.5 Avaliação.....	46

3.4.6	Implantação.....	47
3.5	MACHINE LEARNING	47
3.5.1	Aprendizado supervisionado.....	48
3.5.2	Aprendizado não supervisionado.....	50
3.6	BIBLIOTECA SCIKIT-LEARN	51
3.6.1	Algoritmo DBSCAN.....	53
3.6.2	Algoritmo <i>Isolation Forest</i>	54
3.7	MODELOS PARA DETECÇÃO DE OUTLIERS NA ÁREA DA SAÚDE	55
4.	DESENVOLVIMENTO.....	57
4.1	ANÁLISE DAS NECESSIDADES DO NEGÓCIO	58
4.2	COMPREENSÃO DE DADOS	59
4.3	PREPARAÇÃO DOS DADOS.....	66
4.3.1	Exploração dos dados	67
4.4	CRIAÇÃO DO MODELO.....	72
4.4.1	Modelo preliminar DBSCAN de clusterização.....	72
4.4.2	Configuração e ajuste do algoritmo DBSCAN.....	79
4.4.3	Modelo preliminar <i>Isolation Forest</i> para detecção de anomalias.....	82
4.5	ANÁLISE DOS RESULTADOS	85
4.5.1	Resultados	86
5.	CONSLUÇÃO E OPORTUNIDADES DE TRABALHOS FUTUROS	88
	REFERÊNCIAS BIBLIOGRÁFICAS	90

RESUMO

Os custos médicos têm a tendência de aumentar mais do que a inflação medida para o período, o que impacta diretamente nos serviços prestados e valores repassados aos beneficiários dos planos de saúde. Além do crescimento da inflação médica, medida pelo índice de Variação de Custo Médico-Hospitalar (VCMH), outras preocupações têm afligido os planos de saúde, como fraudes ou inconsistências em cobranças realizadas por parte de prestadores de serviços privados ou públicos. O Exército Brasileiro possui um plano de assistência à saúde (SAMMED) que é similar a um plano de saúde privado, possuindo: contribuição mensal; cobertura ambulatorial e hospitalar; abrangência de atendimento nacional; atendimento 24 horas de urgência e emergência; cobertura de exames, etc. Contudo, não é regulado pela Agência Nacional de Saúde Suplementar (ANS). A responsabilidade de gestão desse plano de assistência fica a cargo da Diretoria de Saúde (D Sau) do Exército. O SAMMED tem por finalidade atender aos militares, pensionistas e seus dependentes, totalizando cerca de 730 mil beneficiários em todo o território nacional. Para esse fim, utiliza como apoio uma rede formada por 62 hospitais militares, aproximadamente 3.000 hospitais civis conveniados e 2.000 profissionais de saúde autônomos. Todos os atendimentos externos são avaliados pela seção de auditoria de contas médicas, com o objetivo de verificar a existência de algum tipo de anomalia, seja ela intencional ou não. Caso achado, é realizado o pagamento da fatura enviada pelos prestadores. Hoje no Exército Brasileiro o processo de auditoria é feito de forma manual, não existe um sistema automatizado para apoio ao auditor nesse propósito. Sendo assim, essa pesquisa teve como objetivo construir um modelo capaz de identificar pontos anômalos em contas médicas, fruto do atendimento externo aos beneficiários do SAMMED em unidades credenciadas com o EB, levando em consideração valores determinados em contratos. Para esse fim, essa pesquisa se propôs a aplicar e comparar dois algoritmos de aprendizado de máquina, *DBSCAN* e *ISALATION FOREST*, com o intuito de verificar qual melhor se adapta à correção do problema do estudo, além de refutar a hipótese de que novas tecnologias podem auxiliar os auditores nesse processo de auditoria de contas médicas. Para esse fim, será utilizado o método hipotético/dedutivo, apoiado em pesquisa bibliográfica sobre o assunto. Foi concluído neste estudo que o modelo não supervisionado utilizando o algoritmo *ISOLATION FOREST*, em uma base de dados constando de 4 (quatro) OCS/PSA e somente um procedimento, obteve quase 100% de acertos ao encontrar pontos com valor fora da curva normal. Para trabalhos futuros, recomenda-se a construção de uma aplicação WEB para que os auditores façam os filtros necessários para melhorar a capacidade de busca do modelo em questão.

Palavras-chave: *DBSCAN*; *ISOLATION FOREST*; contas médicas; SAMMED; auditoria; *Machine Learning*.

ABSTRACT

Medical costs tend to increase more than inflation measured for the period, which has a direct impact on services provided and amounts transferred to beneficiaries of health plans. In addition to the growth in medical inflation, measured by the Medical-Hospital Cost Variation Index (VCMH), other concerns have plagued health plans, like fraud or inconsistencies in charges made by private or public service providers. The Brazilian Army has a health care plan (SAMMED), which is very similar to a private health plan, with: monthly contribution; outpatient and hospital coverage; nationwide coverage; 24-hour urgent and emergency service; exam coverage, etc. However, it is not regulated by the National Supplementary Health Agency (ANS). The responsibility for managing this assistance plan is the responsibility of the Health Directorate (D Sau) of the Army. The purpose of SAMMED is to serve the military, pensioners and their dependents, totaling about 730 thousand beneficiaries throughout the national territory. For this purpose, it uses as support a network formed by 62 military hospitals, approximately 3,000 contracted civil hospitals and 2,000 Autonomous Health Professionals. All external services are evaluated by the medical bills auditing section, with the objective of verifying the existence of some type of anomaly, whether intentional or not, if found to be in order, pay the invoice sent by the providers. Today in the Brazilian Army the audit process is done manually, there is no automated system to support the auditor for this purpose. Therefore, this research aimed to build a model capable of identifying anomalous points in medical bills, the result of external assistance to SAMMED beneficiaries in units accredited with the EB, taking into account values determined in contracts. To this end, this research proposed to apply and compare two machine learning algorithms, DBSCAN and ISALATION FOREST, in order to verify which best fits the correction of the study problem, in addition to refuting the hypothesis that new technologies may or may not assist auditors in this process of auditing medical accounts, for this purpose, the hypothetical/deductive method will be used, supported by bibliographic research on the subject. It was concluded in this study that the unsupervised model using the ISOLATION FOREST algorithm, in a database consisting of 4 (four) OCS/PSA and only one procedure obtained almost 100% of correct answers when finding points with values outside the normal curve. For future work, it is recommended to build a WEB application for auditors to make the necessary filters to improve the search capability of the model in question.

Keywords: DBSCAN; ISOLATION FOREST; medical bills; SAMMED; auditing; Machine Learning.

LISTA DE FIGURAS

Figura 1: Passos que compõem o processo KDD.....	44
Figura 2: Fases que compõem a metodologia CRISP-MD.....	4545
Figura 3: Algoritmos supervisionados e não supervisionados.....	48
Figura 4: Agrupamento realizado por densidade pelo DBSCAN.....	5353
Figura 5: Divisões para encontrar dados anômalos de normais com <i>Isolation Forest</i>	5454
Figura 6: Modelo proposto do processo de identificação de <i>outliers</i>	5555
Figura 7: Tabelas do SIRE que serão utilizadas no estudo.....	6262
Figura 8: Atributos iniciais importados.....	67
Figura 9: Código Python para converter tipos de atributos	68
Figura 10: <i>Boxplot</i> grupo de beneficiários por valor gasto	69
Figura 11: <i>Boxplot</i> demonstrando possíveis <i>outliers</i> para o atributo valor	7070
Figura 12: Concentração de encaminhamentos no grupo 1.....	70
Figura 13: Maiores gastos com procedimentos no grupo 1.....	7171
Figura 14: Valores dos contratos por OCS/PSA.....	71
Figura 15: Distribuição de valores para dois procedimentos por OCS/PSA.....	7474
Figura 16: DBSCAN - mostra de valores com ruídos (<i>outliers</i>) e sem ruídos	8282
Figura 17: <i>Isolation Forest</i> - amostra de valores com ruídos (<i>outliers</i>) e sem ruídos	85.85

LISTA DE TABELAS

Tabela 1: Seleção de alguns trabalhos correlatos.....	Erro! Indicador não definido.
Tabela 2: Descrição dos atributos do <i>dataset</i>	599
Tabela 3: Divisão dos beneficiários por classes.....	64
Tabela 4: Análise descritiva de alguns atributos do <i>dataset</i>	6969
Tabela 5: Resultado descritivo da análise preliminar do método <i>silhouette_score</i>	7373
Tabela 6: Consulta realizada ao banco de dados com procedimento 5496	7474
Tabela 7: Consulta realizada ao banco de dados com procedimento 5526	7575
Tabela 8: Amostra da tabela resultante da avaliação do algoritmo DBSCAN	7676
Tabela 9: Divisão em <i>clusters</i> pelo DBSCAN.....	7777
Tabela 10: Registros de contas médicas por OCS/PSA do mesmo procedimento	7777
Tabela 11: Divisão pelo DBSCAN em <i>clusters</i> do <i>dataset</i> para 4 OCS/PSA	7878
Tabela 12: Primeira análise do resultado do DBSCAN com a Métrica Euclidiana.....	79
Tabela 13: Matriz de confusão do DBSCAN usando Métrica Euclidiana.....	80
Tabela 14: Primeira análise do resultado do DBSCAN com a métrica de <i>Canberra</i>	80
Tabela 15: Matriz de confusão do DBSCAN usando a Métrica de <i>Canberra</i>	81
Tabela 16: Primeira análise do resultado do DBSCAN com a métrica de <i>Manhattan</i>	8181
Tabela 17: Matriz de confusão usando a métrica de <i>Manhattan</i>	8181
Tabela 18: Dados classificados como anormalidade pelo <i>Isolation Forest</i>	8383
Tabela 19: Análise do resultado com o algoritmo <i>Isolation Forest</i>	8484
Tabela 20: Matriz de confusão do <i>Isolation Forest</i>	8484
Tabela 21: Comparação das métricas dos algoritmos	8888

LISTA DE GRÁFICOS

Gráfico 1: Distribuição dos beneficiários encaminhados para OCS/PSA por RM	63
Gráfico 2: Distribuição de atendimentos por mês/ano	64
Gráfico 3: Distribuição da amostra por gênero	65
Gráfico 4: Divisão do <i>dataset</i> por faixa etária e gênero	65
Gráfico 5: Possíveis gastos com valores pagos a maior	78
Gráfico 6: Contas com valores errados classificados pelo <i>Isolation Forest</i>	8484

LISTA DE ABREVIATURAS E SIGLAS

CMH – Custo Médico-Hospitalar

VCMH – Variação de Custo Médico-Hospitalar

IESS – Instituto de Estudos de Saúde Suplementar

IPCA – Índice Nacional de Preços ao Consumidor Amplo

IBGE – Instituto Brasileiro de Geografia e Estatística

SUS – Sistema Único de Saúde

ANS – Agência Nacional de Saúde Suplementar

SAMMED – Sistema de Atendimento Médico-Hospitalar aos Militares do Exército e seus Dependentes

DSAU – Diretoria de Saúde

OCS/PSA – Organização Civil de Saúde ou Profissional de Serviço Autônomo

UG-FUSEx – Unidade Gestora dos Fundos de Recursos do FUSEx

FUSEx – Fundo de Saúde do Exército

IOT – Internet das Coisas

EB – Exército Brasileiro

SIRE – Sistema de Registros e Encaminhamentos

ML – *Machine Learning*

CRISP-DM – *CRoss Industry Standard Process for Data Mining*

SMOTE – Técnica de Sobreamostragem de Minoria Sintética

TPR – *True Positive Rate*

OPS – Operadores de Planos de Saúde

OMS – Organização Militar de Saúde

OM – Organização Militar

GE – Guia de Encaminhamento

EBNet – Rede de dados interna do EB

SIH-EB – Sistema de Informações Hospitalares do EB

SQL – *Standard Query Language*

1. INTRODUÇÃO

O custo médico hospitalar (CMH) é uma medida importante para a gestão financeira dos hospitais. Ele mensura os valores que incluem exames, atendimentos médicos, honorários médicos, materiais, etc. É determinado pelas despesas médicas hospitalares de um grupo de beneficiários de planos de saúde durante um período específico e, a partir dele, é possível conhecer o valor da assistência médica hospitalar. O índice de Variação de Custo Médico-Hospitalar (VCMH), também chamado de inflação médica, expressa a variação do custo das operadoras de planos de saúde, comparando dois períodos consecutivos de 12 meses. Exemplificando, para uma amostra de 734,2 mil beneficiários de planos individuais, a Variação dos Custos Médico-Hospitalares (VCMH/IESS) para o período de 12 meses, compreendidos entre dezembro de 2019 e dezembro de 2020, foi de -1,9%. Ou seja, os custos per capita caíram 1,9%. A VCMH/IESS foi inferior à inflação medida pelo IPCA/IBGE, que foi de 4,5% para o mesmo período. Nesse período, o ritmo de variação das despesas passou de positivo para negativo, passando de 14,5% para -1,9%, muito provavelmente devido à pandemia, que levou as pessoas a adiarem procedimentos eletivos. Contudo, vale ressaltar que a gestão dos custos hospitalares é uma área que necessita de muita atenção, pois os custos médicos tendem a aumentar muito mais que a inflação (IESS, 2021).

Além do aumento nos custos hospitalares medido pelo índice VCMH/IESS, existe a preocupação com possíveis fraudes ou inconsistências em cobranças realizadas por parte de prestadores de serviços aos planos de saúde, quando há necessidade de recorrerem a serviços de terceiros conveniados.

Um exemplo notável da prática de terceirização de serviços médicos hospitalares é o Sistema Único de Saúde do Brasil (SUS), que por vezes utiliza a estrutura de hospitais e clínicas particulares como parceiros para prestar algum tipo de serviço específico para suprir demandas reprimidas, ou quando há falta de profissionais, equipamentos, ou ainda quando as suas disponibilidades são insuficientes para garantir a cobertura assistencial à população de uma determinada área. Após a prestação do serviço por um conveniado privado ao SUS, a conta hospitalar é gerada e a fatura a ser paga é encaminhada para a quitação.

O SUS tem um dos maiores programas de assistência médica e odontológica gratuita do mundo, que atende mais de 190 milhões de pessoas, sendo que 80% delas dependem exclusivamente dele para qualquer atendimento de saúde (ARAÚJO, 2017).

O Exército Brasileiro (EB) possui um plano de assistência à saúde que é similar a um plano de saúde privado, possuindo: contribuição mensal; cobertura ambulatorial e hospitalar; abrangência de atendimento nacional; atendimento 24 horas de urgência e emergência; cobertura de exames, etc. Contudo, não é regulado pela Agência Nacional de Saúde Suplementar (ANS). Esse plano assistencial do EB é chamado de SAMMED, Sistema de Atendimento Médico-Hospitalar aos Militares do Exército e seus Dependentes e dos Servidores Civis da Força Terrestre. Vale ressaltar que assim como qualquer outro plano de saúde, ele necessita de gerenciamento e controle para mitigar custos e aumentar a qualidade dos serviços prestados. A responsabilidade de gerir o sistema de saúde do EB fica a cargo da Diretoria de Saúde (DSAU), sendo sua responsabilidade planejar, orientar, controlar, coordenar, supervisionar, gerir, avaliar e auditar as atividades relativas ao Sistema de Saúde do Exército (DSAU, 2021).

O SAMMED tem por finalidade atender aos militares, pensionistas e seus dependentes, totalizando cerca de 730 mil beneficiários em todo o território nacional. Para esse fim, utiliza como apoio uma rede formada por 62 hospitais militares, aproximadamente 3.000 hospitais civis conveniados e 2.000 Profissionais de Saúde Autônomos (BRASIL, 2021a).

Como acontece no SUS, quando há demanda reprimida por falta de profissionais ou equipamentos, o beneficiário é encaminhado para uma Organização Civil de Saúde (OCS) ou Profissional de Serviço Autônomo (PSA) que o EB possua convênio ou contrato. Quando a consulta ou exame é realizado, a fatura é enviada para a seção FUSEx da Organização de Saúde que encaminhou o beneficiário para atendimento externo, e a sessão de contas médicas realiza a glosa, se for o caso, audita e, por fim, liquida a fatura.

Sabe-se que a auditoria de contas hospitalares é uma atividade muito importante dentro do processo de gestão de contas médicas, e é nesse momento que se verifica a existência de algum tipo de anomalia, seja ela intencional ou não. Sendo assim, vale ressaltar que auditar e investigar todos os dados de contas médicas de forma manual é muito oneroso e ineficiente quando comparado ao

aprendizado de máquina ou ao uso de abordagens de mineração de dados, pois o volume de dados a serem analisados cresce proporcionalmente ao número de pacientes que utilizam os serviços médicos hospitalares. Além do crescimento das bases de dados com informações de usuários e dos serviços prestados, a digitalização de registros médicos, a telemedicina, a Internet das Coisas (IOT) e os Sistemas de Informações Médicas cada vez mais confusos tendem a deixar esses dados muitos mais complexos (YAN, 2016).

1.1 PROBLEMA DE PESQUISA

A auditoria de contas médicas no EB é um processo muito complexo e oneroso para os auditores militares, pois a disponibilidade de recursos humanos está muito aquém da necessária e atualmente é um processo executado de forma não automatizada, trazendo com isso algumas complicações ao processo, como por exemplo:

- Atrasos em pagamentos aos prestadores;
- Possíveis falhas na detecção de anomalias;
- Pagamentos de faturas com valores a maior ou a menor;
- Introdução de erros no processo;
- Possíveis falhas na detecção de possíveis fraudes.

1.2 SOLUÇÃO PROPOSTA

Antes da modelagem da solução, foi levantado em biografia de trabalhos correlatos quais as soluções mais aplicáveis para problemas de clusterização na detecção de *outliers* e fraudes em contas médicas e outras bases de dados, com o intuito principal de verificar quais delas poderiam servir como base para este trabalho.

Diante disso, este trabalho apresenta um estudo para criar um modelo de detecção de anomalias em contas médicas hospitalares prestadas por conveniados civis. O escopo foi delimitado da seguinte forma:

- Serão identificadas quais bases de dados podem ser utilizadas na análise inicial;
- Serão identificados quais atributos caracterizam um contrato entre a UG_FUSEx e OCS/PSA;
- Serão aplicados dois algoritmos de *Machine Learning* não supervisionados, com o intuito de encontrar anomalias identificadas na literatura de apoio;
- O resultado deverá ser carregado em base de dados para a avaliação dos auditores militares.

O intervalo temporal de dados utilizado foi um recorte da base do Sistema de Registro e Encaminhamento do EB do ano de 2020 e 2021.

Para trabalhos futuros, após a devida validação dos resultados pelos auditores militares, será construído um portal com o objetivo de permitir ao usuário escolher filtros específicos para refinar a busca.

1.3 MOTIVAÇÃO

A aprendizagem de máquina ou *Machine Learning* (ML) refere-se a sistemas capazes de aprender e modificar comportamentos para responder aos estímulos externos através de aprendizado autônomo agregado durante a execução de determinadas atividades (ALPAYDIN, 2016).

Do exposto, a principal motivação do presente trabalho consiste em fazer uso de técnicas de ML aplicadas à Base de Dados do Sistema de Registro e Encaminhamento do Exército (SIRE) para identificar padrões não usuais em valores de cobranças em atendimentos médicos, no que se refere aos atendimentos por prestadores de serviços contratados, com a finalidade de auxiliar os auditores militares em sua tarefa na procura de possíveis irregularidades em contas médicas.

Uma limitação importante que deve ser levada em consideração é que cada Unidade Gestora dos Recursos do Fundo de Saúde do Exército (UG-FUSEx) tem autonomia para firmar seus contratos, caracterizando valores diferentes para os procedimentos médicos em cada contrato e, ainda, vale ressaltar que os valores de contratos ficam disponíveis somente para a contratada e a UG-FUSEx contratadora.

Outro ponto limitador é que não existe um contrato corporativo nacional com valores pré-determinados, podendo ter variações em contratos celebrados mesmo dentro da mesma região militar ou divisão administrativa.

1.4 JUSTIFICATIVA

Hoje no EB já existem alguns sistemas de gestão hospitalar distribuídos pelas Organizações Militares de Saúde, nos quais se tem algumas funcionalidades implementadas com os seguintes objetivos: realizar uma primeira análise básica para evitar que exames exclusivos de um gênero sejam realizados por outro; evitar que exames que só poderiam ser realizados em determinadas faixas etárias sejam realizados por outras; exames secundários para investigação e estadiamento de doença que na verdade não poderiam ser realizados sem prévia investigação inicial, entre outros. Porém, nem todas as regras podem ser realizadas em sistemas, principalmente no que tange a auditorias de contas médicas, nas quais os valores e procedimentos cobrados estão diretamente vinculados a contratos celebrados entre as partes, além de depender exclusivamente de auditores treinados com conhecimentos específicos nessa atividade. Outra informação importante que vale apenas ser destacada é que para que o prestador receba o pagamento pelo serviço, é necessário que os serviços constantes na nota fiscal sejam auditados pela equipe de auditoria o mais rápido possível, o que torna o trabalho muito difícil e factível a erros devido à celeridade e à forma manual na qual são feitos.

Sendo assim, este trabalho tem sua justificativa, pois disponibilizará uma ferramenta tecnológica de aprendizado de máquina para auxiliar os auditores na detecção de possíveis anomalias em contas hospitalares de forma automatizada, possibilitando identificar pontos focais para análise individual, otimizando os custos e diminuindo o trabalho manual. Dessa forma, será proporcionado o melhor aproveitamento de tempo do auditor, gerando ainda a possibilidade da diminuição da equipe de auditoria.

1.5 HIPÓTESE DE PESQUISA

A bibliografia e os estudos recentes mostram que as fraudes são recorrentes em diversos segmentos do setor público e do setor privado e causam muitos prejuízos a setores específicos, entre os quais está a área da saúde assistencial. É inviável e muito oneroso encontrar fraudes com analistas auditores humanos em sistemas que processam milhares de dados todos os dias.

Assim, facilmente erros podem ocorrer e algumas fraudes podem ser facilmente implementadas. Dessa forma, uma hipótese pode surgir: É possível que novas tecnologias, como *Machine Learning*, possam auxiliar os auditores no processo de identificação de dados com comportamentos anômalos?

1.6 OBJETIVOS

O objetivo principal desta pesquisa é construir um modelo capaz de identificar pontos anômalos em contas médicas levando em consideração valores determinados em contratos, fruto do atendimento externo aos beneficiários do SAMMED em unidades credenciadas com o EB.

1.6.1 Objetivos específicos

1. Identificar e analisar bases de dados específicas com informações relacionadas a contas e atendimentos médicos por prestadores de serviços contratados;
2. Exportar dados para um esquema de banco de dados específico para realizar a análise exploratória inicial no *dataset*;
3. Identificar os atributos principais para essa análise, que podem caracterizar um contrato;
4. Identificar através de Linguagem SQL valores com maior apresentação em base de dados, caracterizando possível valor do contrato para um determinado procedimento;

5. Utilizar a biblioteca *scikit-learning* do Python para apoio no desenvolvimento;
6. Testar a eficiência de 2 algoritmos de aprendizado não supervisionado para detectar valores anômalos;
7. Criar o modelo;
8. Detalhar possíveis trabalhos futuros.

1.7 METODOLOGIA

Nesta seção apresenta-se a metodologia de pesquisa e os procedimentos que foram adotados neste trabalho, bem como as ferramentas utilizadas no apoio à criação do modelo.

1.7.1 Metodologia de pesquisa

Por se tratar da aplicabilidade de dois algoritmos de ML com o intuito de verificar qual melhor que se adapta ao estudo, será utilizado o método comparativo. A investigação é feita por meio da análise da taxa de erros ou acertos entre eles (MARCONI, 2017).

Uma vez que este trabalho tem como objetivo a análise de dados e geração de conhecimento, trata-se de uma pesquisa aplicada e exploratória, visto que a área de pesquisa é bem específica e particular. Grande parte do trabalho utilizou a pesquisa bibliográfica em artigos científicos, teses e dissertações, pois a maioria dos trabalhos relacionados estavam disponíveis nesses tipos de publicação. Quanto aos procedimentos técnicos, a pesquisa tem característica bibliográfica com base em material já elaborado, constituído principalmente de livros e artigos científicos. Para isso, foi realizado um levantamento bibliográfico com o objetivo conceituar temas como auditoria e auditoria em contas médicas no EB.

Em relação à abordagem, pode-se dizer que é quantitativa, pois foi necessário utilizar técnicas e ferramentas estatísticas através de ML como principal meio de análise dos dados obtidos. Diferentemente da pesquisa qualitativa, os

resultados da pesquisa quantitativa podem ser quantificados (GERHARDT e SILVEIRA, 2009).

1.7.2 Ferramentas utilizadas

A linguagem de programação utilizada para criar os modelos foi o Python, que trata-se de uma linguagem que permite o desenvolvimento de qualquer tipo de algoritmo de ML, tanto para aprendizado supervisionado quanto para não supervisionado.

O ambiente de desenvolvimento utilizado foi o kernel do *Google Colab*, uma plataforma on-line para escrever e executar códigos em Python diretamente no *browser web*, com nenhuma configuração especial, acesso *free* a GPUs (*Graphics Processing Unit*), TPU (*Tensor Processing Unit*), memória RAM disponível e alta performance (GOOGLE, 2021).

A linguagem de programação utilizada foi Python 3.7.12 (já instalada no ambiente do *Google Colab*). As bibliotecas utilizadas no ambiente podem ser divididas nas seguintes categorias: I) manipulação de dados; II) modelos de *Machine Learning*; III) detecção de *features*; IV) plotagem de dados.

Os pacotes utilizados para o desenvolvimento foram:

- a) *Scikit-learn*: pacote de métodos de aprendizagem de máquina;
- b) *Numpy*: pacote para trabalhar com arranjos, listas e matrizes de forma mais eficiente;
- c) *Sys*: pacote que permite utilizar funções específicas do Sistema;
- d) *Matplotlib*: pacote que permite a geração de gráficos em 2D;
- e) *Pandas*: pacote para manipulação e análise de dados.

Em relação aos algoritmos utilizados na criação do modelo de *Machine Learning*, todos fazem parte da biblioteca *Scikit-learn*. Para a plotagem e visualização dos dados foi utilizada a biblioteca *Matplotlib*.

O local de armazenamento do *dataset* importado e das planilhas com os resultados gerados foi o *Google Drive*, no qual a ferramenta *Google Colab* tem conexão nativa com o repositório.

Para apresentação dos dados analisados e dos resultados, o EB possui disponível a plataforma de BI e *Analytics* da *MicroStrategy*, com o objetivo de auxiliar

a construção de aplicativos *HyperIntelligence* em nuvem, além de permitir a construção de muitos tipos de visualização de dados a partir de diferentes de fontes. Ele faz praticamente tudo o que existe para ser feito em termos de visualização, exploração de dados e distribuição de resultados (MICROSTRATEGY, 2021).

1.7.3 Procedimentos metodológicos

Nesta seção, serão apresentados os procedimentos metodológicos que foram utilizados para atingir os objetivos definidos nesta pesquisa. Foram subdivididas em:

- Pesquisa bibliográfica: considerou-se a busca por livros, teses, revistas, dissertações e artigos científicos nas seguintes fontes especializadas: *PubMed*, *Scopus*, *Web of Science*, *lans.org*, google acadêmico e outras bases de dados científicas. Foram levadas em consideração nesta pesquisa as seguintes palavras-chave para a busca: "*medical*", "*health*", "*Machine Learning*", "*detection*", "*audit*", "*account*", "*payment*", "*fraud*", "*outliers*", "*CIRSP-DM*", "*Unsupervised Learning*", "Descoberta de conhecimento em Base de Dados" e "contas médicas" – essas últimas na Biblioteca Digital Brasileira de Teses e Dissertações (BDTD). Um limitador definido foi filtro por datas, no qual prioritariamente foram usadas somente publicações científicas após o ano de 2010.
- Desenvolvimento: nessa etapa foram aplicados os algoritmos de aprendizado de máquina não supervisionados em uma amostra da base de dados preparada previamente.
- Avaliação: avaliação e comparação dos algoritmos escolhidos com a mensuração de taxas de acertos e erros.
- Publicidade: publicidade dos resultados para análise final dos auditores militares.

1.8 ESTRUTURA DA DISSERTAÇÃO

Esta seção apresenta a estrutura deste trabalho acadêmico, que foi organizado em 5 capítulos.

O capítulo 1 é composto pelo item principal “Introdução” e os subitens:

- Problema de pesquisa;
- Solução proposta;
- Motivação;
- Justificativa;
- Hipótese de pesquisa;
- Objetivo geral e objetivos específicos;
- Metodologia da pesquisa;
- Procedimentos metodológicos.

O capítulo 2 é composto pelo estado da arte da pesquisa e foi dividido em 3 subtópicos.

O capítulo 3 é composto pelo referencial teórico, no qual constam os levantamentos que vão substanciar a pesquisa.

No capítulo 4 foi tratado o desenvolvimento da pesquisa e foram apresentadas as etapas do desenvolvimento da pesquisa, iniciando com a análise da necessidade do negócio, criação e exploração do *dataset* e aplicação de dois algoritmos não supervisionados.

O capítulo 5 versou sobre a conclusão e oportunidades para trabalhos futuros.

2. REVISÃO DE LITERATURA

Este capítulo foi dividido em 3 subtópicos para facilitar o entendimento do estado da arte sobre os temas de interesse na pesquisa.

Para iniciar este processo de revisão de literatura foi necessário estabelecer qual é o cerne da pesquisa para que essa busca fosse devidamente norteadada. Sendo assim, foram estabelecidos direcionadores, a saber:

- Classificar o que é Descoberta de Conhecimento em Base de Dados e a sua aplicabilidade em Base de Dados em Saúde;
- Identificar quais os melhores algoritmos de *Machine Learning* aplicados em auditoria de contas médicas com o objetivo de encontrar possíveis fraudes ou *outliers* em Base de Dados;
- Quais os resultados alcançados.

2.1 DESCOBERTA DE CONHECIMENTO EM BASE DE DADOS - KDD

O conhecimento é o bem mais importante das organizações atualmente. Dessa forma, recuperar informações espalhadas em base de dados tem se tornado o grande objetivo empresarial. Diante desse cenário, surgiram ferramentas tecnológicas e modelos para auxiliar na extração do conhecimento em base de dados, com o objetivo de encontrar padrões ou anomalias que seriam difíceis de serem encontradas em uma mera avaliação visual, ou por técnicas convencionais de análise de dados. Essas ferramentas tecnológicas são frequentemente referenciadas na literatura como *Knowledge Discovery in Database* (KDD).

Nos próximos parágrafos serão detalhados alguns estudos e aplicações nos quais foram utilizados modelos e técnicas de extração de conhecimentos em Bases de Dados.

Inicialmente, para Costa (2019), KDD é caracterizado por ser um processo que não é trivial, que busca gerar novo conhecimento potencialmente útil para aumentar os ganhos e reduzir os custos através da busca e da identificação de padrões em base de dados corporativas. Em seu estudo, ele demonstrou que o processo KDD pode ser subdividido em seis fases: seleção de dados, limpeza, enriquecimento, transformação ou codificação, *Data Mining* e construção dos relatórios de apresentação.

A fase cerne desse processo é a de mineração de dados, que compreende várias tarefas como o objetivo primário, a predição e/ou a descrição. A predição parte dos atributos que estão disponíveis para prever os valores de uma ou mais variáveis de interesse. A descrição contempla o que foi descoberto nos dados sob o ponto de vista da interpretação humana (ARAYA, 2016).

Nessa fase principal, geralmente alguns algoritmos de aprendizado de máquina têm mais relevância. São eles: **árvores de decisão, Redes Neurais, algoritmos de classificação, algoritmo de regras de indução**, entre outros, podendo ser utilizados de forma não combinada ou em conjunto. Quando utilizados em conjunto, melhoram a capacidade de revelar padrões desconhecidos, tendências e comportamentos de determinadas variáveis estratégicas.

Por se tratar de um processo bem genérico, pode ser utilizado com maestria em várias áreas diferentes de conhecimento. Por exemplo, na pesquisa de Sulino (2020), o processo KDD foi utilizado ao explorar dados produzidos pelo aplicativo

Strava para criar um novo aplicativo denominado *Fitness Tools*, com a finalidade de auxiliar aos profissionais de educação física em análises referentes às atividades desenvolvidas por seus clientes.

Em outra análise, no estudo de Branquinho, Baracho e Almeida (2018), o processo de KDD foi utilizado para desenvolver um modelo que faz uso de ontologias biomédicas de doenças e testes laboratoriais, resultando na recuperação eficiente da informação sobre o comportamento de prescrição de testes laboratoriais relacionados às hepatites virais. Com os resultados obtidos, foi possível verificar que a inclusão de embasamento semântico (ontologias) permite que as informações estratégicas sejam encontradas e transformadas em conhecimento relevante para entender o comportamento do médico quando da solicitação de testes complementares ao diagnóstico.

Pode-se constatar atualmente o crescimento expressivo de dados produzidos em todas as áreas, alavancado principalmente pelo crescimento e barateamento dos custos tecnológicos, facilidade de uso, e sua disponibilidade. Nesse contexto, a utilização de técnicas de mineração de dados tem crescido muito na área da saúde.

Em sua pesquisa, Escobar (2019) descreve a necessidade urgente da utilização de técnicas analíticas avançadas para prover aos especialistas mecanismos que os permitam explorar e detectar itens de interesse em grande volume de dados, combinando de forma simples o potencial da análise estatística com a descoberta de padrões de forma ágil. Dessa forma, a tomada de decisão em saúde seria a mais rápida possível, uma vez que a descoberta de novos padrões pode levar a novas informações relevantes relacionadas a novos tratamentos, aumentando, com isso, a possibilidade de melhorar os atendimentos médicos hospitalares, além de disponibilizar aos gestores em saúde novos modelos para auxiliar no planejamento de ações preventivas no que tange ao controle da saúde populacional.

Para Gomes (2019), a mineração de dados é uma ferramenta muito eficaz para o auxílio na tomada de decisões na área da enfermagem e na área da saúde em geral, uma vez que o método tradicional de análise de dados se tornou inviável pelo alto volume de dados armazenados.

Analisar todos esses dados gerados de forma manual tornou-se uma tarefa impossível e, por isso, técnicas de aprendizado de máquina, processos de

mineração de dados e *Big Data* têm se tornado promissoras nesse cenário (ARAÚJO, 2017).

Podem ser listados outros benefícios da aplicabilidade do processo de mineração de dados na área da saúde. Além de sua aplicabilidade na assistência, pode-se relacionar diretamente à melhoria no controle e trazer outros benefícios, como a detecção de fraudes, cobranças indevidas, bem como abusos em números de exames indicados por médicos (AHMAD e QAMAR e RIZVI, 2015).

2.2 *FRAMEWORK CRISP-DM*

A adoção de uma ferramenta no apoio de um processo de descoberta de conhecimento em base de dados é de extrema importância, pois auxilia no norteamento dos passos dessa atividade. De acordo com a literatura, existem vários *frameworks* propostos por autores. Segundo Neves (2003), os mais citados são: CRISP-DM; o de Fayad; o de Piatetsky-Shapiro; a de Smyth; e I-MIN. Contudo, os mais citados em literaturas são o CRISP-DM e a metodologia de Fayad.

Assim, nos próximos parágrafos serão detalhadas algumas aplicabilidades da metodologia CRISP-DM e uma evolução do método proposto por Fayad, alinhado à aplicabilidade de técnicas de aprendizado de máquinas.

Jamjoom (2021), em seu estudo, utilizou técnicas de mineração de dados para investigar o uso da extração de conhecimento em base de dados para prever a rotatividade de clientes em seguradoras. Três técnicas de mineração de dados foram utilizadas para a modelagem: *regressão logística, rede neural e K-Means*. O algoritmo de árvore de decisão foi usado na fase de modelagem do CRISP-DM para identificar os atributos de clientes cancelados. Os resultados do estudo mostraram que os procedimentos de mineração de dados podem ser muito bem-sucedidos na extração de informações ocultas, além de entender melhor as características dos clientes.

Ramos (2020) propôs em seu estudo uma adaptação do modelo de mineração de dados CRISP-DM com algumas especificidades para dados educacionais, sejam eles provenientes de plataformas de ensino on-line ou de outras fontes. As fontes de dados para aplicação dos modelos foram as de exames nacionais de curso e nos sistemas de gestão acadêmica. O modelo, depois de

desenvolvido e testado em duas teses de doutorado aprovadas, obteve resultados muito promissores.

Já no estudo de Poh, Ubeynarayana e Goh (2017), a metodologia CRISP-DM foi utilizada na indústria da construção juntamente a técnicas de *Machine Learning*, com o objetivo de desenvolver indicadores para rotular obras em construção de acordo com o nível do risco envolvido. O *dataset* utilizado foi obtido de uma grande empresa de construção em Cingapura, compreendido entre anos de 2010 a 2016. Cinco algoritmos de ML foram usados para treinar modelos para prever a ocorrência e gravidade do acidente. Durante a validação, a *Random Forest* (RF) forneceu o melhor desempenho de predição com uma precisão de 0,78, demonstrando um resultado promissor.

Em outro estudo, Hillerman (2015) analisou reclamações de planos de saúde, com o propósito de encontrar contas com valores excessivos. Foi utilizada a metodologia CRISP-DM com o algoritmo *K-Means*. Em sua conclusão, verificou-se que algoritmo foi capaz de fornecer uma forma mais eficiente e objetiva de identificar *outliers*, podendo ser usado para futuras investigações em conjuntos de dados semelhantes.

Em outro estudo sobre o assunto, Schwenzfeier e Gruhn (2018) descrevem que um processo bem modelado é uma ferramenta muito importante para a engenharia de software, especialmente quando aplicado na utilização de técnicas de *Machine Learning* na detecção de *outliers*. Eles apresentaram uma visão customizada do modelo CRISP-DM para o desenvolvimento de sistemas de detecção de anomalia, pois os maiores problemas desse modelo estão relacionados à generalidade do modelo CRISP-DM em relação à detecção de anomalias, por se tratar de um modelo muito complexo.

Chen e Oztekin (2017) descreveram, em sua pesquisa, uma abordagem de análise exploratória de dados híbrida (DEA) combinada à metodologia de processo padrão de indústria para mineração de dados (CRISP-DM) para verificar a evasão dos alunos no ensino médio e outros que não concluíram o ensino superior. Para esse fim, foi utilizado um estudo de caso em uma universidade pública. O método CRISP-DM foi utilizado para balizar o modelo na identificação dos preditores de graduação. No estudo foi mostrado que a média de notas do semestre, situação habitacional, curso de ensino médio e GPA do semestre da primavera foram os quatro fatores determinantes mais elevados para a evasão dos alunos, enquanto as

variáveis monetárias e a origem étnica do aluno foram reveladas como as menos importantes. Os resultados também indicaram que os alunos que moram no campus têm maior probabilidade de concluir em seis anos.

Em outro estudo na área acadêmica, os autores utilizaram a metodologia CRISP-DM com aprendizado supervisionado para analisar os perfis das instituições de ensino superior de Pernambuco. Devido à complexidade dos dados e ao amplo escopo do Censo da Educação Básica (CEB) e do Censo da Educação Superior (CES), foi necessário criar quatro cenários específicos, contendo subgrupos de atributos, com o objetivo de obter informações mais precisas. Para a mineração dos dados foi utilizada a plataforma WEKA, software *open source* que contém uma coleção de algoritmos para a mineração de dados. Esse trabalho utilizou os algoritmos: Árvore de Decisão (J48) e Classificação *Bayesiana* (*Naive Bayes*), aplicados em quatro cenários diferentes. Em todos os cenários os algoritmos contribuíram para boas análises entre os perfis analisados (CARVALHO; CRUZ, 2017).

Uma questão muito importante para este estudo é aplicação de técnicas de descoberta de conhecimento em base de dados para detectar possíveis fraudes em contas médicas. Uma amostra dessa aplicabilidade foi detalhada no estudo de Joudaki et al. (2015), no qual foi feita uma revisão de literatura sobre técnicas de detecção de fraudes em contas médicas e, com o uso de técnicas KDD, foram identificados pagamentos inapropriados por seguradoras a terceiros devido a erros, abusos e fraudes. A maioria dos estudos disponíveis concentrou-se na mineração de dados com aplicação de algoritmo de aprendizado de máquina sobre os valores da apólice de seguro de saúde.

Na próxima seção deste trabalho serão pormenorizadas algumas formas de procedimentos de detecção de anomalias em base de dados.

2.3 DETECÇÃO DE ANORMALIDADES E FRAUDES

Às vezes, em meio aos dados normais, pode haver dados anormais, que estatisticamente podem induzir a análises equivocadas, necessitando que sejam retirados, pois se desviam consideravelmente dos demais dados. Porém, em outras áreas específicas de negócio, esses dados anormais podem ser dados importantes,

tratando-se de informações valiosas que necessitam de análises mais específicas, como por exemplo algum tipo de fraude, invasão em sistemas informatizados, anomalias em redes de computadores, falhas mecânicas e condição clínica crítica de um paciente.

Ainda vale ressaltar que, em uma amostra, os dados anormais são bem menores que os dados reais, tornando a identificação de forma manual praticamente impossível e, mesmo que identificada, em muitos casos pode ser difícil determinar se uma alegação é fraudulenta ou não sem a análise de um especialista.

Nos dados referentes aos cuidados à saúde, o combate à fraude continua sendo um grande desafio, pois a presença de pagamentos de serviços a terceiros de forma equivocada, contas inexistentes pagas e exames realizados desnecessariamente maximizam o problema dentro do setor de saúde.

Para Araújo (2017), as principais formas de fraudes que impactam financeiramente a saúde são:

- Faturamento por serviços não prestados;
- Desvio de verbas destinadas à saúde;
- Falsificação de documentos para adiantar consultas em detrimento de outrem;
- Faturamento para serviços não cobertos;
- Procedimentos realizados ou utilização de órtese/prótese com qualidade inferior à declarada;
- Corrupção;
- Entre outras.

Na saúde assistencial, dados com anormalidades podem surgir pela realização de exames específicos por pacientes fora dos chamados Grupos de Diagnósticos Homogêneos (GDH) da seguinte forma: exames ginecológicos em homens, atendimentos pediátricos para adultos, entre outros. Essa prática foi detalhada na pesquisa de Pimenta (2019), que utilizou técnicas de *Data Mining* (DM) na identificação de discrepâncias de dados de atendimentos médicos hospitalares entre hospitais semelhantes para encontrar possíveis anormalidades. O objetivo central foi tentar descobrir erros de codificação clínica, ou seja, erros no grupamento de pacientes dentro GHD correto, já que a classificação errada pode acarretar pagamentos incorretos. O *dataset* escolhido foi de dados clínicos dos anos 2015,

2016 e 2017 relacionados aos episódios de internamentos em seis hospitais públicos portugueses. Ao aplicar os modelos escolhidos, puderam ser verificadas discrepâncias significativas na codificação do GHD entre os hospitais analisados.

Além dos dados anormais inseridos em base de dados por alguma inconsistência sistêmica ou involuntária, alguns podem ser dados fraudulentos que foram inseridos por uma pessoa ou grupo de pessoas de algum setor para o aumento dos benefícios individuais ou mesmo de um determinado grupo (RANGEL, 2018).

Para o Tribunal de Contas da União (TCU), atividades fraudulentas são definidas como atos ilícitos cometidos por indivíduos ou órgãos da esfera privada ou pública para obter vantagens de qualquer tipo (BRASIL, 2016c).

Empresas e governos reconhecem que as fraudes representam um obstáculo à capacidade de competir em cenário globalizado, tentando a todo tempo adotar mecanismos para prevenir/detectar a situação fraudulenta precocemente. Nessa linha de pensamento, Nascimento (2020), em sua pesquisa, fez uso da regressão logística para dados em painel com o intuito de investigar as contribuições da introdução dos *red flags* a partir da teoria de riscos de fraude, desenvolvida por Cressey. Os *red flags* descrevem a capacidade de identificar uma situação fraudulenta ainda em estágio inicial através de relatórios financeiros corporativos. Para essa análise, foram selecionadas as companhias que não são financeiras, têm capital aberto com ações negociadas na bolsa de valores brasileira, denominadas B3, totalizando em 277 empresas. Para a seleção das empresas, foram considerados os anos entre 2008 e 2018. Já para a seleção dos atributos, o período foi de 2006 a 2018, possibilitando coletar dados antes do acontecimento da fraude. Em análise final, foi verificado que o tamanho do passivo tem associação positiva ao risco de fraude. Porém, em relação aos outros atributos, as *red flags* não indicaram significâncias estatísticas que sugerissem possíveis contribuições para essa finalidade.

Em relação aos sistemas de cuidados com a saúde, Matloob et al. (2020) detalha em seu estudo que a detecção de transações fraudulentas nesses sistemas é uma tarefa árdua e muito complexa, devido a relações muito interligadas entre elementos dinâmicos que estão envolvidos diretamente no processo de geração de contas médicas. E são eles: médicos, pacientes e os serviços prestados. Nesse estudo foi gerado um modelo que utiliza *bit* de similaridade para detectar fraudes.

Após a aplicabilidade do modelo sobre uma base de dados devidamente validada por funcionários do hospital e já classificada anteriormente como dados fraudulentos, foram identificados com sucesso oito casos de fraude diretamente ligados ao elemento paciente, dois casos ligados ao elemento de serviço prestado e três casos ligados ao elemento médico.

No SUS as fraudes acontecem com informações falsas de pacientes correlacionados a procedimentos que não foram executados e que são fornecidas como dados verdadeiros, ou registros médicos falsos com um laudo em condições de saúde que o paciente não está acometido ou, ainda, informando que um procedimento foi executado quando na verdade ele só existe de forma digital e/ou manuscrita. Tudo isso é feito para que o sistema do SUS efetue pagamentos inexistentes. Outros gastos identificados, mesmo que verdadeiros, acontecem quando o usuário do SUS é atendido por um prestador de serviço privado e os custos desses procedimentos são maiores que os custos quando realizados em hospitais públicos (DRUCK, 2016).

De acordo com as definições e estudos acima, atividades fraudulentas em saúde são muitos onerosas e difíceis de identificar manualmente, visto que elas representam um pequeno número de transações dentro do universo de todas as transações verdadeiras realizadas. Sendo assim, uma estratégia para identificá-las de maneira eficiente, segundo a literatura, é com a introdução de técnicas de ML.

Abaixo serão detalhados alguns estudos que têm como objetivo principal a detecção de dados fraudulentos ou anormais com o apoio de modelos de ML.

Nunes (2019) constatou em seu estudo que no ano de 2015 houve uma perda de mais de 12 bilhões de reais somente em contas hospitalares e de mais de 10 bilhões de reais em exames laboratoriais. Os planos de saúde, em sua maioria, não possuem recursos suficientes para examinar todas as transações produzidas diariamente. Sendo assim, ele desenvolveu um sistema baseado em regras e aprendizado de máquina para a descoberta de fraudes em seguros de saúde, que respondeu com relativa eficácia ao problema apresentado.

Em outro estudo sobre fraudes em saúde, Zang, Xiau e Wu (2020) identificaram que 10% dos gastos em cuidados com a saúde são despendidos em fraudes ou anomalias em contas hospitalares. Segundo os autores, a relação paciente versus tratamentos é muito difícil de ser supervisionada, e mesmo com a implantação de sistema de liquidação de contas médicas, erros intencionais não são

fáceis de serem mapeados. Para amenizar esse problema, eles desenharam um modelo que utiliza redes neurais para detecção de anomalias, fraudes e abusos médicos em base de dados em saúde. O modelo desenhado detectou registros anormais na área da saúde, utilizando detecção de dados com anomalias juntamente a um método de previsão de múltiplos marcadores de ponta a ponta para pontuações de correlação de prescrição de doença. Por último, os auditores de dados médicos verificaram novamente os registros suspeitos que foram identificados pelo modelo. O resultado do experimento mostrou que o modelo melhorou a taxa de descoberta de comportamento anormal em registros em saúde.

Em sua pesquisa, Dua e Bais (2013) verificaram que as fraudes em saúde vêm crescendo nos últimos anos, afligindo diretamente o Governo dos Estados Unidos, causando falta de atendimento nos serviços médico-hospitalares para quem realmente precisa. Para eles, a auditoria de dados de forma manual é impossível. O objetivo do seu trabalho foi comprovar a aplicação de técnicas de mineração de dados conjuntamente à aprendizagem de máquina supervisionada. Nesse trabalho foram testados vários algoritmos, e o de Redes Neurais e de regras de associação foram os que performaram melhor.

Sem dúvida, o processo de detecção de fraude ou qualquer outra anomalia torna-se um processo muito desafiador e, por consequência, vem ganhando muita visibilidade no meio acadêmico. No Brasil a circunstância não é diferente. Segundo Araújo (2017), a saúde no Brasil vive uma situação precária com poucos investimentos ou, quando há, são investidos de forma errada, o que influencia diretamente na gestão do maior sistema de saúde público no mundo, o SUS. Em seu trabalho, foi utilizado o modelo de aprendizado de máquina aplicado em dados simulados de atendimentos odontológicos seguindo o padrão do SUS, com o objetivo de separar os registros que tem indícios de fraude. Para atingir esse objetivo, foram avaliados os algoritmos *Isolation Forest*, *K-Nearest Neighbors* e *Mahalanobis Distance* e em todos os testes houve sucesso em separar os *clusters* de dados normais dos anômalos demonstrando, com isso, a possibilidade de utilização dessas ferramentas na detecção de fraudes de forma eficiente.

No estudo de Bauder e Khoshgoftaar (2017) foram usados os dados de 2015 do *Medicare* rotulados como fraude. Para isso, foi utilizada a lista de Indivíduos/Entidades excluídas da relação de entidades que podem prestar serviços ao sistema de saúde americano. Mesmo que tais profissionais sofram as sanções

devidas, eles não são impedidos de continuar a exercer a profissão. Então, para isso, foi necessário encontrar mecanismos que pudessem detectar o perfil de tais profissionais nas atividades que permeiam o plano de saúde, e a ideia principal era traçar as características dos fraudadores utilizando ML. Foram desenhados modelos supervisionados, não supervisionados e híbridos usando ML aplicados no *dataset*. Os modelos supervisionados obtiveram melhor desempenho que os outros. Os algoritmos que obtiveram os melhores resultados em um *dataset* dividido em percentual de 80:20 foram: *decision tree* e a *logistic regression*. A média de AUC teve uma pontuação de 0.883 e 0.882, respectivamente, com baixo número de falsos positivos.

A pesquisa de Bauder, Rosa e Khoshgoftaar (2018) teve como objetivo avaliar os possíveis aspectos de médicos atendentes fraudulentos que prestam serviços ao *Medicare*. Para isso, foram utilizados algoritmos não supervisionados de Aprendizado de Máquina juntamente a algoritmos de aprendizado de máquina para verificar quais deles demonstrariam o melhor resultado. Os algoritmos utilizados foram: *Isolation Forest*, *Unsupervised Random Forest*, *Local Outliers*, *autoencoder* e *k-Nearest Neighbors*. Os algoritmos foram aplicados a um *dataset* de 1,8 milhões de registros, compreendendo o intervalo entre os anos de 2012 a 2015 da base de fornecedores e de dados de contas médicas do *Medicare*. A pesquisa analisou o desempenho de cada algoritmo através do *Receiver Operating Characteristic* (ROC) e *Area Under the ROC Curve*. Para validar o desempenho na detecção de fraudes, foi usada pelos autores a Lista de Banco de Dados de Indivíduos/Entidades Excluídos (LEIE), que contém informações sobre fornecedores excluídos. Além disso, fizeram uso da rotulagem anterior de fraudes LEIE para realizar a comparação a novas classificações que serão geradas pelos algoritmos de aprendizagem supervisionada. O melhor desempenho foi alcançado com 63% de acurácia pelo método *Local Outlier*. Já o pior desempenho coube ao *K-Means*, com 51,9% de acurácia.

Segundo alguns trabalhos sobre o tema, a utilização de técnicas de ML para detecção de anomalias em bases de dados em saúde é de grande valia e grande eficácia. Por exemplo, em sua pesquisa, Johnson e Khoshgoftaar (2019) fizeram uso de técnicas de ML com o intuito de automatizar a detecção de fraude no *Medicare*, sistema de saúde gratuito americano. Para substanciar a construção dos modelos, foram utilizados dados com reclamações de atendimentos médicos no *Medicare*. No

trabalho, foram criados seis modelos de *Deep Learning* com redes neurais aplicados à base de dados do *Medicare* já rotulados como fraudes pelo LEIE. Os desafios encontrados estavam no desbalanceamento dos dados (classes), visto que somente 0,03% dos dados foram considerados dados anormais ou fraudulentos. As técnicas para balanceamento das classes foram técnicas de *oversampling* aleatória (ROS), *undersampling* aleatória (RUS) e um híbrido ROS – RUS. Após o balanceamento, foram obtidas maiores pontuações da curva ROC AUC.

Com o intuito de melhorar o modelo anteriormente criado, no qual pode-se classificar corretamente 67% das fraudes do *Medicare*, Bauder, Khoshgoftaar, Richter e Herland (2017) utilizaram três estratégias para melhorar o desempenho do modelo, que foram: recursos (para o ajuste de desequilíbrio de classe); agrupamento de especialidades médicas; e a remoção de especialidades específicas que se sobrepõem. Nessa nova pesquisa foi utilizada uma base de dados do *Medicare* dos anos de 2013 e 2014, disponíveis ao público juntamente à lista de Banco de Dados de Indivíduos e Entidades Excluídas (LEIE), divulgado pelo Escritório do Inspetor-Geral, bem como a base com os casos de fraudes já rotulada. Com as estratégias utilizadas, surtiram algumas melhorias, porém a estratégia de agrupamento de especialidades semelhantes mostrou melhorias mais significativas sobre os resultados.

No estudo de Garcia (2020), foram utilizadas técnicas de ML e *Blockchain* com o objetivo encontrar *clusters* que representam possível anomalia ou possível fraude no conjunto de dados de prescrições médicas. Foi utilizado o algoritmo *K-Means*, juntamente à aprendizagem não supervisionada na detecção de fraudes e anomalias. Os resultados demonstraram que a partir das técnicas e algoritmos de aprendizado de máquina é possível, em combinação à tecnologia *Blockchain*, o desenvolvimento de um sistema para detecção e prevenção de fraudes em prescrições médicas.

Em outro estudo, como no trabalho de Ferreira (2020), no qual há técnicas de Mineração de Dados que foram utilizadas para identificar dados anormais ou fraudes em contas hospitalares, teve-se como objetivo desenvolver um método de detecção de indícios de fraudes no Programa Farmácia Popular do Brasil. As técnicas de mineração de dados utilizadas se mostraram uma metodologia muito útil e promissora para detectar indícios de fraudes. Para esse propósito, o estudo aproveitou os métodos de DM utilizando técnicas não supervisionadas de detecção

de *outliers* aplicadas a dados empíricos. Os resultados são comparados e mostram que o Método *Mahalanobis* mesclado à técnica de histograma teve o melhor desempenho na detecção de indícios de fraudes.

A proposta do trabalho de Freitas (2019) foi apresentar um estudo comparativo entre técnicas de detecção de dados anormais através de uma metodologia que permitia uma análise uniforme e objetiva baseada em métodos estatísticos de proximidade e distância. Como resultado, foi possível analisar com efetividade o desempenho das técnicas de detecção de *outliers* para diferentes domínios de dados. Esse estudo comprovou que é possível comparar efetivamente o desempenho das técnicas de detecção de dados anormais em diferentes domínios. Foram selecionadas 14 bases distintas, usadas para detecção de dados anormais, diagnóstico médico, detecção de intrusos, processamento digital de imagens, detecção de anomalias em redes de computadores e detecção de falhas, e em todas elas o modelo aplicado teve efetividade.

Em seu trabalho, Santos (2020) construiu uma solução de aprendizagem supervisionada para detecção de fraude em saúde. O *dataset* era constituído pelos pedidos de reembolso em plano de saúde nos anos de 2017 e 2018, devidamente rotulados pelos auditores como legítimos ou suspeitos. Vale ressaltar que o *dataset* estava totalmente desbalanceado e que o método SMOTE foi utilizado para balanceamento de classes, revelando ser importante para o aumento da precisão do modelo. Foram consideradas 4 famílias de classificadores: Regressão Logística, *Random Forest*, *Support Vector Machine* e *XGBoost*, sendo os seus desempenhos medidos e comparados entre si. Os resultados obtidos evidenciaram a utilidade desses classificadores, tendo o *Random Forest* e o *XGBoost* apresentado os melhores resultados para a detecção dos dados fraudulentos na base de dados em questão.

Zamini e Montazer (2018) propuseram, em seu trabalho, a utilização de dois tipos de aprendizagem: a não supervisionada, que abrange algoritmos que não necessitam de dados rotulados previamente; e a semi-supervisionada, que necessita apenas de poucas amostras rotuladas anteriormente. Respectivamente, em relação às classes selecionadas, foram escolhidos os algoritmos *K-Means* e *autoencoder* para a detecção de possíveis fraudes em transações financeiras. Os algoritmos foram testados em 284.807 transações de bancos europeus. Com base nos

resultados, a acurácia desse método foi de 98,9%, assim como a *True Positive Rate* (TPR) de 81%, que supera os demais.

Em seu estudo, Kazemi e Zarrabi (2017) propuseram a utilização de dois algoritmos de *Machine Learning* para identificar possíveis fraudes em transações financeiras com a utilização de cartões de crédito. Para treinar toda a rede foram utilizadas 900 transações financeiras de cartões de crédito e, entre elas, 100 amostras foram selecionadas para os testes. O *deep autoencoder* foi escolhido, pois obteve 81,5% de precisão em comparação ao algoritmo KNN, que obteve 76,1% de precisão. Ou seja, o modelo baseado em *deep autoencoder* tem 5% a mais de precisão.

Na pesquisa escrita por Shakya e Makwana (2017), foi proposta a utilização de um método híbrido para a detecção de intrusão de redes, que consistia na utilização *DBSCAN*, *K-Means* e *SMO Classifier*. Com a utilização dos três algoritmos em conjunto, a precisão média do método ficou em 96,92%.

Em sua pesquisa, Ada, Harsono e Basuki (2018) propuseram a utilização dos algoritmos *K-Means* e *DBSCAN* para analisar imagens meteorológicas de nuvens, para avaliar a possibilidade de detectar a forma delas. O *K-Means* separou as nuvens baseado em sua área, e o *DBSCAN* separou as nuvens com base nas densidades dos *clusters* que elas formaram. Isso permitiu contar quantos grupos de nuvens existiam.

No estudo de Rayan (2019), foi utilizado um modelo híbrido para detectar fraudes em dados de seguros de saúde, no qual fez uso de aprendizado não supervisionado e aprendizado supervisionado. No aprendizado não supervisionado foram utilizados os algoritmos *K-mens* e *ouliers analysis*; já para o aprendizado supervisionado, os algoritmos utilizados foram árvores de decisão e *Average Perceptron*.

Em outro estudo sobre aprendizado não supervisionado, Kanksha et al. (2021) fez uma análise de vários algoritmos de *Machine Learning*, com o intuito de verificar qual deles teria melhor performance para identificar fraudes na base de dados de contas médicas do *Medicare*, compreendida entre os anos de 2012 a 2014. Foram comparados 3 algoritmos de aprendizado não supervisionado, o *K-Means*, *Local Outliers* e *Isolation Forest*. Como resultado, o modelo com o algoritmo *Isolation Forest* obteve o melhor desempenho geral. Os resultados obtidos

mostraram-se promissores em comparação às técnicas já existentes, e o modelo alcançou cerca de 98,76% de precisão.

Custódio (2018) construiu um modelo que foi capaz de realizar clusterização de segmentar classificação de inventários através de técnicas de aprendizado não supervisionado. Para essa finalidade, foi utilizado o algoritmo DBSCAN que, segundo a autora, obteve uma boa taxa de sucesso. Em comparação à técnica tradicional, o algoritmo foi capaz de agrupar artigos em grupos semelhantes comparáveis a uma classificação ABC para gestão de inventário. O algoritmo mostrou, inclusive, melhores resultados quando comparado à abordagem clássica da classificação ABC.

Depois da análise preliminar, alguns artigos foram selecionados como *baseline* para esta pesquisa.

Abaixo, uma tabela com os principais atributos de trabalhos considerados úteis para a construção de inferências que contribuíram para este estudo. A tabela está dividida em 3 partes: título, algoritmos e fontes de dados.

Tabela 1: Seleção de alguns trabalhos correlatos

TÍTULO	ALGORITMOS	FONTE DE DADOS
Aprendizado de máquina para detecção de comportamento fraudulento em dados simulados do sistema odontológico do SUS (Araújo, 2017)	• <i>Isolation Forest</i>; • K-Means; e • <i>Mahalanobis Distance</i>.	✓ Base de Dados do SUS
<i>Medicare fraud detection using ml methods</i> (Bauder e Khoshgoftaar, 2017)	• Árvore de decisão; e • Regressão Logística.	✓ Medicare
<i>Identifying medicare provider fraud with unsupervised machine learning</i> (Bauder, Rosa e Khoshgoftaar, 2018)	• <i>Isolation Forest</i>; • Unsupervised Random forest	✓ Medicare
<i>Feature selection-based intrusion detection system using the combination of DBSCAN, k-mean++ and smo algorithms</i> (Shakya e Makwana, 2017)	• DBSCAN; • K-Means; e • SMO	✓ KDD intrusion dataset (KDDCUP)

<i>Cloud satellite image segmentation using meng hee heng k-means and DBSCAN clustering</i> (Harsono e Basuki (2018))	• DBSCAN; e • K-Means.	✓ Satélite meteorológico da Indonésia (Himawari 8 image)
RAYAN, N.; Framework for Analysis and Detection of Fraud in Health Insurance. IEEE 6th International Conference on Cloud Computing and Intelligence Systems (CCIS), 2019	• K-Means; e • Ouliers Analysis.	✓ Banco de dados de Seguro em saúde.
KANKSHA, B. A.; et al. An intelligent unsupervised technique for fraud detection in health care systems. Intelligent Decision Technologies, 2021.	• K-Means; • Local Outliers; e • Isolation Forest.	✓ Medicare
CUSTÓDIO, C. M. Algoritmos de segmentação para classificação de inventários: DBSCAN. 2018.	• DBSCAN.	✓ base de dados Adventure Works OLTP.

Fonte: O autor.

Esse tópico apresentou uma breve revisão de literatura com o objetivo de substanciar e auxiliar na pesquisa sobre o tema “*Machine Learning* para Análise Preditiva em saúde: aplicabilidade na tomada de decisões estratégicas da Diretoria de Saúde do Exército – um estudo de caso sobre a detecção de anomalias de auditoria em contas médicas”.

Com base nos artigos em destaque no quadro acima e relacionando-os diretamente ao problema de pesquisa, pode-se afirmar que 2 testes podem ser executados para verificar se realmente os algoritmos podem ajudar os auditores a encontrarem pontos anômalos de valores. Duas abordagens podem ser utilizadas: a primeira, de agrupamento (clusterização); e a segunda, de detecção de anomalias. Sendo assim, foram escolhidos para a pesquisa dois algoritmos: o DBSCAN, algoritmo de clusterização; e o *Isolation Forest*, algoritmo para detecção de anomalias.

A escolha do DBSCAN se deu pelo fato de ser bastante utilizado em ciência de dados e não ser preciso saber anteriormente o número de *clusters* para melhor configuração do algoritmo, diferentemente do algoritmo *K-Means*. No caso da pesquisa em questão, o agrupamento de valores para atributos comuns é essencial.

O fator preponderante da escolha do algoritmo *Isolation Forest* se deu pelo fato de sua facilidade de uso e velocidade na detecção de discrepâncias, além de ser muito referenciado na literatura para encontrar fraudes em base de dados.

Após a aplicação dos algoritmos em base de dados, foram aplicadas algumas métricas para verificar qual foi o que melhor identificou pontos anormais – que, no caso do estudo, podem ser classificados como possíveis fraudes.

Após análise do estado da arte sobre o tema, abaixo foram descritos os assuntos que fazem parte do contexto da pesquisa.

3. REFERENCIAL TEÓRICO

Os custos em saúde tendem a aumentar muito mais que a inflação. Dessa forma, é necessário que os planos de saúde e os administradores dos serviços de saúde façam gestões para impedir ao máximo transações fraudulentas, buscando sempre a excelência da administração dos recursos para evitar perdas ou prejuízos desnecessários.

Para Casimiro (2016), o Brasil é o maior mercado de saúde privada na América do Sul. Somente em 2012, os custos com saúde representaram cerca de 8% do PIB. Nesse mercado, muitas empresas Operadoras de Planos de Saúde (OPS) encontram-se em situação de desequilíbrio financeiro, caracterizada pelo fato das despesas somadas representarem um valor maior que as receitas. Fraudes e abusos na utilização de serviços em saúde são dois fatores que influenciam diretamente nesse desequilíbrio, uma vez que correspondem a despesas que poderiam ser eliminadas, sem prejuízo à qualidade dos serviços prestados.

Como descrito acima, os desequilíbrios financeiros tendem a ser mitigados com processos de auditoria em contas médicas. Vale ressaltar que o processo de auditoria em uma massa de dados que vem crescendo anualmente se torna quase impossível de ser realizado de forma manual. Por isso, a tecnologia da informação para apoio a esse processo deve ser utilizada sempre que possível.

3.1 AUDITORIA EM CONTAS HOSPITALARES

A auditoria é um processo sistemático, documentado e independente para se avaliar objetivamente uma situação ou condição com o intuito de determinar a extensão na qual critérios são atendidos, obter as evidências quanto a esse atendimento e relatar os resultados dessa avaliação a um destinatário predeterminado (SILVA, 2018).

Para Da Silva, Gonçalves e Santos (2017), a auditoria é uma ferramenta de grande importância no controle e gestão de processos em instituições de saúde. Tem como objetivo principal avaliar a qualidade e os custos decorrentes da prestação do serviço.

Como descrito acima, é de grande importância o trabalho do auditor, visto que é de sua responsabilidade realizar os ajustes necessários para corrigir possíveis erros nas contas médicas. Esse ajuste é chamado de glosa. As glosas hospitalares consistem em anulação da fatura da conta hospitalar analisada pelo auditor da operadora quando este considera que a cobrança é indevida ou ilegal (ATAIDE, 2019).

De um modo geral, as atividades de auditoria são conduzidas, predominantemente, por médicos e enfermeiros. A auditoria médica e a auditoria de enfermagem avaliam o balanceamento entre a qualidade da assistência e os custos associados a ela, mas com características inerentes a cada profissão. A auditoria de enfermagem foca no processo de trabalho de enfermagem. Na auditoria médica o foco é o atendimento médico e os procedimentos correlatos associados à avaliação crítica da relação entre diagnósticos, procedimentos e exames específicos solicitados (DE OLIVEIRA, DE OLIVEIRA, 2020).

Em sua pesquisa, Rodrigues et al. (2017) descreve que a auditoria de custos tem como finalidade conferir e gerenciar o faturamento enviado para os planos de saúde, verificar exames e procedimentos realizados, efetuar visitas de rotina a pacientes internados e cruzar as informações recebidas com as que constam no prontuário do paciente. Visa também investigar os gastos e os processos de pagamentos, analisar as estatísticas e os indicadores hospitalares, conferir os sistemas de faturamento das contas médicas e, ainda, elaborar processos de glosas contratuais e administrativas, se for o caso.

Abaixo, será detalhado o processo de auditoria no EB com o propósito de explicitar algumas atividades, características, e tipos de auditoria realizadas.

3.2 AUDITORIA EM CONTAS HOSPITALARES NO EXÉRCITO BRASILEIRO

A auditoria de contas hospitalares no EB segue algumas diretrizes padronizadas nas normas técnicas e no Manual de Auditoria Médica do Exército Brasileiro, e tem como objetivo orientar os procedimentos no processo de auditoria das contas médicas geradas pelos encaminhamentos para as OCS/PSA e pelas despesas médico-hospitalares geradas dentro das próprias OMS.

Mendonça e Carvalho (2016), em seu estudo, evidenciaram que a boa condução nas atividades de auditoria em contas hospitalares melhorou circunstancialmente à aplicação dos recursos financeiros, trazendo para a Organização Militar de Saúde (OMS) resultados positivos na economia do FUSEx.

Em diversas oportunidades, os valores apresentados pelos OCS/PSA foram glosados e com isso, reduzidos, havendo economia e realocação dos recursos para outros fins.

Em relação às normas que regem os procedimentos de auditoria de contas médicas no EB, conforme descrito no parágrafo acima, está a NTAM (2021, p.6), que tem como objetivos os seguintes:

- I - Organizar sistematicamente as etapas a serem cumpridas durante o processo de Auditoria Médica, incluindo didaticamente a Auditoria Prévia, a Auditoria Concorrente e a Auditoria Retrospectiva;
- II - Direcionar a análise e a auditoria individual das contas médicas geradas e autorizadas por intermédio das Guias de Encaminhamento e dos Comprovantes de Despesas Médicas do Sistema SAMMED/PASS para cada paciente;
- III - Verificar a conformidade entre os serviços autorizados aos beneficiários do Sistema SAMMED/PASS e aqueles efetivamente realizados, através da comparação entre os itens apresentados e os parâmetros acordados com as OCS/PSA e nas OMS conforme previsto no Catálogo de Indenizações dos Serviços de Saúde das Forças Armadas, nos protocolos de procedimentos cirúrgicos e clínicos aprovados pela Diretoria de Saúde e na Norma Técnica sobre Atendimento Domiciliar;
- IV - Possibilitar aos Serviços de Auditoria Médica Externa e Interna a emissão do Relatório Mensal de Auditoria Técnica (RMAT), a partir dos Relatórios de Conformidade (CONFORM) e dos Relatórios de Não Conformidade (INCONFORM) auxiliando, através daquele instrumento, os gestores do Sistema SAMMED/PASS, o Comandante da OM ou Diretor da OMS e os Escalões Superiores na adoção das medidas necessárias para os ajustes, adequações, correções e negociações julgadas pertinentes, em benefício da qualidade dos serviços de saúde prestados à família militar;

V - Oferecer subsídios técnicos e dados estatísticos para servir como base para a negociação de contratos (tabelas e preços), OPME e pacotes de procedimentos junto às OCS/PSA, visando minimizar as diferenças existentes entre as realidades regionais e buscando uniformizar as condutas e rotinas adotadas pelos serviços e setores envolvidos com as contas médicas.

Existem três tipos de auditoria médica, e a sua classificação depende da fase em que se encontra o tratamento que está sendo dispensado ao usuário, conforme descrito no item I da citação acima. São detalhadas na instrução geral EB10-IG-02.031, conforme Brasil (2021a, p.6, grifo nosso), a saber:

Auditoria médica – é a atividade da Organização Militar (OM) / Organização Militar de Saúde (OMS) que, por meio de atos médicos, destina-se a controlar e avaliar os recursos e procedimentos adotados, visando a adequabilidade, correção, qualidade, eficácia e economicidade dos serviços prestados, em consonância com o Código de Ética Médica e a legislação vigente;

Auditoria concorrente ou concomitante – é a auditoria feita enquanto o paciente estiver hospitalizado ou sendo atendido de forma ambulatorial, enfocando os custos e a adequação dos serviços prestados;

Auditoria prospectiva ou auditoria prévia – é a auditoria realizada de forma preliminar, cuja análise das solicitações de procedimentos e exames compete aos profissionais de saúde habilitados, a fim de desencadear o processo de autorização, mediante emissão da correspondente guia de encaminhamento (GE);

Auditoria retrospectiva ou auditoria a posteriori – é a auditoria feita após a alta do paciente ou ao término de seu atendimento, utilizando-se da análise dos documentos e de relatórios diversos, incluindo os provenientes das auditorias concorrente e prévia, bem como das contas médicas propriamente ditas, a fim de identificar as respectivas conformidades.

Para garantir que as OMS do EB realizem atividades de auditoria de contas médicas, é obrigatória a instauração de comissões especiais para efetuar o acompanhamento contábil e técnico das contas médicas procedentes de colaboradores e prestadores de serviços médicos ambulatoriais. A responsabilidade da comissão é zelar pelo criterioso emprego dos recursos financeiros.

Essa comissão será composta, no mínimo, por 3 oficiais médicos e deverá ter apoio de pessoal auxiliar em quantitativa variável disponível. Essa comissão tem como principais atribuições e competências: verificar a existência da documentação de encaminhamento ou de caracterização de emergência/urgência, conferir de acordo com tabelas apropriadas medicamentos e materiais cobrados com os que foram prescritos, verificar se os honorários médicos estão de acordo com o

estabelecido nos contratos ou, em casos específicos, verificar se os atos praticados são compatíveis com a prática médica, ou no emprego de material de alto custo, ou se o preço é compatível com o praticado no mercado e, por fim, verificar se o que está sendo cobrado está em acordo com o que foi celebrado no contrato. Uma vez constatado um valor indevido na cobrança de conta, o médico auditor deve sugerir uma glosa, isto é, a retificação do valor cobrado (BRASIL, 2021b).

Ao realizar o atendimento médico ou exames em clínicas conveniadas, os valores dos atendimentos são lançados em Sistemas Médico-Contábeis, que estão disponíveis na Rede de Intranet do Exército (EBNet).

O principal sistema informatizado para esse fim será apresentado no próximo capítulo.

3.3 SISTEMAS TRANSACIONAIS EM SAÚDE DO EXÉRCITO BRASILEIRO

O Sistema de Registros e Encaminhamento (SIRE) é a ferramenta pela qual o EB emite Guias de Encaminhamento para realização de consultas e procedimentos médico-hospitalares conveniados em OCS ou PSA. O SIRE tem como objetivo realizar o controle informatizado do atendimento médico-hospitalar efetuado pelo Sistema de Saúde do Exército, com a função principal de controlar os recursos financeiros de saúde, trazendo transparência e auxiliando aos auditores no melhor controle orçamentário (BRASIL, 2021d).

O SIRE permite ainda:

- a) acompanhar as despesas desde a sua origem;
- b) acompanhar o desempenho das OM subordinadas em cada escalão de comando;
- c) alocar recursos;
- d) visualizar os registros de guias pelo nome dos usuários e dos fornecedores dos serviços.

Além do SIRE, o EB está implantando um Sistema Informação Hospitalar (SIH) como projeto piloto no ano de 2021 em algumas OMS pelo Brasil. O SIH-EB foi concebido para informatização da maioria dos processos assistenciais e administrativos das OMS. O Aplicativo de Gestão Hospitalar (AGHUse),

desenvolvido pelo Hospital de Clínicas de Porto Alegre, é o sistema computacional adotado. Ele será totalmente integrado ao SIRE, ou seja, o atendimento médico com as características de SIH totalmente integrado à parte financeira no SIRE (BRASIL, 2021e).

Abaixo, seguem algumas características do SIH-EB que irão possibilitar melhorias nos atendimentos médicos hospitalares:

- a) reduzir custos com a otimização dos estoques, racionalização de emprego dos recursos materiais, humanos e financeiros disponíveis e melhoria na gestão de serviços e bens contratados;
- b) incrementar a produtividade dos profissionais de saúde e o faturamento das contas médicas;
- c) aumentar a satisfação dos beneficiários, proporcionada pela melhoria de qualidade da assistência à saúde da família militar e pela redução das filas no atendimento ao paciente;
- d) permitir a avaliação periódica do desempenho técnico e administrativo das OMS;
- e) instituir o prontuário eletrônico do paciente, único no âmbito do EB, para: atender às provas judiciais; facilitar a continuidade de tratamento; permitir pesquisa epidemiológica e a investigação de antecedentes de uma condição mórbida corrente; evitar a repetição desnecessária de exames complementares; e mitigar o risco, em casos de atendimento de urgência, de se administrar tratamento inadequado aos pacientes, por falta de informações;
- f) aumentar a segurança dos pacientes, uma vez que os sistemas de informações hospitalares são amplamente citados na literatura especializada mundial como fator de redução dos erros médicos.

Tratando-se de sistemas informatizados, existem muitas informações disponíveis em base de dados que precisam ser devidamente extraídas e disponibilizadas aos gestores para dar subsídios à tomada de decisões. Hoje há tecnologias que podem ser utilizadas para recuperar informações em base de dados. Na seção abaixo serão apresentados alguns temas importantes para a fundamentação da pesquisa.

3.4 DESCOBERTA DE CONHECIMENTO EM BASES DE DADOS


O uso da informação de maneira eficiente se torna um elemento essencial para o sucesso das grandes organizações. Hoje, a informação é o bem mais precioso, e a Descoberta de Conhecimento em Banco de Dados, conhecido originalmente como KDD, é o processo que tem como principal objetivo extrair conhecimento de uma ampla base de dados.

De acordo com Fayyad et al. (1996, p.40), o KDD é “o processo não-trivial de identificar, em dados, novos padrões válidos e potencialmente úteis e recentemente compreensíveis”. KDD é o processo iterativo para identificar nos dados novos padrões que sejam válidos.

Em sua pesquisa, Gomes (2019) conclui que para a recuperação de informações, estejam elas estruturadas ou não, o uso da Tecnologia da Informação e Comunicação tem se tornado imprescindível, pois através de tais tecnologias o processo de KDD pode ser utilizado. Para ele, esse processo é constituído de três passos básicos, que são: o pré-processamento, a mineração propriamente dita e o pós-processamento ou interpretação dos resultados. A Mineração de Dados (MD), é o cerne do processo de descobrimento de conhecimento em bancos de dados, pois é nela que são encontrados padrões escondidos com potencial para auxiliar os gestores na tomada de decisões estratégicas.

Levando em consideração as fases do processo de descoberta de conhecimento em base de dados, abaixo temos a imagem do processo KDD, segundo Fayyad.

Figura 1: Passos que compõem o processo KDD.




Fonte: Fayyad (1996, et al., p. 41).

Uma evolução ao processo KDD, sugerido por Fayyad para mineração de dados, é a metodologia CRISP-DM (*Cross-Industry Standard Process for Data Mining*). CRISP-DM é um *framework* não-proprietário, neutro, documentado e disponível livremente, construído para guiar um processo de *Data Mining* com *Machine Learning* (POH, UBEYNARAYANA e GOH, 2018). A metodologia é dividida em seis fases: entendimento do negócio, compreensão dos dados, preparação dos dados, modelagem, avaliação e implantação.

Na imagem abaixo estão as fases do modelo CRISP-MD:

Figura 2: Fases que compõem a metodologia CRISP-MD.



Fonte: Audy, (2018).

3.4.1 Compreensão do Negócio

A primeira etapa consiste no conhecimento do domínio do negócio, ou seja, identificar o problema/tema a ser abordado e definir os objetivos e requisitos do projeto a partir da perspectiva do negócio. Essa etapa é considerada uma das mais importantes do processo, a partir da qual é desenvolvido um plano preliminar do projeto para busca dos objetivos. É nessa fase que serão especificadas quais etapas

serão executadas durante todo o projeto, incluindo a seleção inicial de ferramentas e técnicas, além de qual ou quais bases de dados serão exploradas (RAMOS, 2020).

3.4.2 Compreensão dos Dados

Nessa fase é selecionada e analisada a base de dados – a estrutura dos dados, os relacionamentos, os problemas e a identificação de quais dados são importantes para o projeto. Essa fase soma-se à base da compressão do negócio (HILLERMAN, CARVALHO, REIS, 2015).

3.4.3 Preparação dos Dados

A fase de preparação dos dados geralmente tem maior esforço envolvido, pois nela são preparados os conjuntos de dados. Pode-se dizer que essa fase compreende três subprocessos: a seleção de dados, a limpeza de dados, a construção de dados e, caso haja necessidade, a junção a outras bases de dados. Ao final, tem-se um conjunto de dados limpo e em condição para aplicabilidade de algoritmos de ML (CARVALHO, CRUZ e GOUVEIA, 2017).

3.4.4 Modelagem

Na fase de modelagem é definido o modelo, parâmetros de entrada e planos de teste. O plano do modelo é utilizado para definir *set* de treinamento, de teste e a calibração das variáveis. Trata-se da aplicação de uma ou mais técnicas de modelagem de dados, podendo ser algoritmos de aprendizado supervisionado ou não supervisionado (MOTURI, 2019).

3.4.5 Avaliação

Nessa fase é verificado se o modelo construído condiz com as expectativas e objetivos do negócio que foi definido na fase inicial do processo, ou seja, antes da

implantação definitiva do modelo construído é importante avaliar mais profundamente e rever a sua construção para ter certeza que atinge todos os objetivos planejados. É a etapa principal, que visa garantir que a organização pode utilizar os resultados obtidos e os conhecimentos descobertos. É nesse momento que especialistas do negócio são necessários (RAMOS, et al., 2020).

3.4.6 Implantação

A última fase é a implantação. Nela, os novos conhecimentos descobertos são utilizados para proporcionar melhorias na organização, na qual se desenvolvem e distribuem os resultados obtidos, sendo necessário que todos os envolvidos conheçam os resultados. Nessa etapa, todo o conhecimento adquirido deve ser organizado e apresentado de forma que o cliente possa usá-lo efetivamente dentro dos processos de tomada de decisão (ARAUJO, 2018).


3.5 MACHINE LEARNING

A Inteligência Artificial (IA) ou ML é um campo da ciência da computação que imita o pensamento humano na capacidade de aprender e tomar decisões, classificar, gerar e armazenar conhecimento. Atualmente, a medicina tem utilizado ML para aprimorar o diagnóstico, prognóstico e auxiliar os médicos nos tratamentos em diversas especialidades como: neurologia, oncologia, cardiologia e dermatologia (BRAGA, 2018).

Para Santos (2020), ML é uma ferramenta muito útil na construção, armazenamento, gestão, análise e visualização de dados. Por exemplo, um determinado algoritmo pode, numa perspectiva de produção de dados, ser usado na identificação de um *outlier* em *real time*; ou na captura de dados dos sensores de monitoração dos pacientes; ou no armazenamento e tratamento de dados de tipos, formatos e tamanhos diferentes. ML é, portanto, uma ferramenta que serve à ciência de dados, que tem apresentado grande crescimento, suscitando interesse nas últimas décadas e em várias áreas de estudo.

Dependendo do projeto e do conjunto de dados, é necessário escolher um tipo de estratégia de aprendizado, podendo ser supervisionado ou não supervisionado. Para cada categoria de aprendizado, existem diversos algoritmos para atender à estratégia de necessidade de negócio. A subdivisão dos algoritmos conforme áreas de aprendizado está demonstrada na figura abaixo:

Figura 3: Algoritmos supervisionados e não supervisionados.



Fonte: Santos (2020, p. 18).

O que separa esses grupos de algoritmos é a existência de uma variável específica de desfecho para problemas de algoritmos supervisionados, o que não acontece para os algoritmos não supervisionados, que são treinados com base em um conjunto de dados que não tem um desfecho específico a ser predito (MENDES, 2021).

3.5.1 Aprendizado supervisionado

Segundo Neves (2003), aprendizagem supervisionada é aquela em que são fornecidas as classes, ou seja, os atributos de entrada e as saídas preditas. Esse aprendizado parte do princípio de que as entradas são conhecidas assim como o domínio da resposta, isto é, quando além dos preditores está disponível também uma resposta de interesse que será responsável por guiar a análise.

Em sua análise, Russel e Norvig (2013) descrevem o aprendizado supervisionado da seguinte forma: dado um conjunto de dados rotulados, no qual as classes metas já são conhecidas, o objetivo é encontrar melhores alternativas para classificar novas observações entre as classes que não estão rotuladas.

Já para Araújo (2017), no aprendizado supervisionado, as entradas e saídas são devidamente mapeadas, tendo como objetivo principal gerar um conjunto de pares entrada-saída. Com o intuito de treinar o modelo, o *dataset* é dividido em dois conjuntos, treinamento e teste. Cada entrada de treinamento é um vetor. No ambiente hospitalar, por exemplo, os dados poderiam representar as seguintes informações: batimentos cardíacos, temperatura, pressão, idade, entre outros. Esses são os chamados atributos, podendo ser dados simples ou complexos. Da mesma forma, o formato da variável de saída pode ser qualquer coisa. Quando a entrada é categórica, o problema é conhecido como classificação ou reconhecimento de padrões; quando entrada é valor real, o problema é conhecido como regressão.

O objetivo central do aprendizado supervisionado é verificar qual é o modelo que, a partir de dados rotulados anteriormente em treinamentos, permita fazer previsões sobre os dados futuros, ou seja, o conjunto de dados de treinamento funciona como um professor no processo de aprendizagem, no qual todas as previsões são corrigidas pelo professor a cada interação e os problemas relacionados ao aprendizado supervisionado estão relacionados à classificação e à regressão, em sua maioria (BROWNLEE, 2016).

Para Santos (2018), alguns problemas com aprendizagem supervisionada sobre classificação e regressão podem ser resolvidos com alguns algoritmos, como descrito abaixo:

- Regressão linear;
- Árvore de decisão ou *Random Forest*;
- Árvore Simples;
- *Bagging*;
- *Cubist*;
- Suporte a máquinas de vetores (SVM);
- KNN;
- *Naive Bayes*;
- Regressão logística;
- Redes Neurais.

3.5.2 Aprendizado não supervisionado

Araújo (2017), em sua pesquisa, define que aprendizagem não supervisionada pode ser exemplificada, no caso da saúde, com algoritmos que encontram padrões de doenças coronarianas num exame de ECG, aprendendo padrões de forma autônoma.

Ao contrário do aprendizado supervisionado, os dados não têm rótulos identificadores, apenas os preditores estão disponíveis no conjunto de dados e não as saídas especificadas. Algoritmos não supervisionados procuram fazer inferências, análises sobre os dados preditores, sem terem recebido instruções ou classificações prévias, permitindo que o modelo possa aprender e se adaptar aos dados, sem a necessidade prévia de supervisão humana (MENDES, 2021).

De acordo com Russel e Norvig (2013), a aprendizagem não supervisionada é aquela que em um conjunto de observações ou dados não rotulados, o objetivo central é tentar estabelecer a correlação entre grupos ou similaridades desse *dataset*. Diferentemente do aprendizado supervisionado descrito na seção acima, não há respostas.

Para Raduenz (2020), em vez de dizer à máquina que irá realizar a análise para prever Y para os nossos dados X, na verdade estamos perguntando: “O que se pode dizer sobre o X?”

Os principais problemas de aprendizagem não supervisionadas envolvem, em sua maioria, análise de clusterização – agrupamentos – e associação (BROWNLEE, 2016).

Abaixo, seguem alguns algoritmos para aprendizagem não supervisionada elencados por Raduenz (2020) em seu estudo:

- *K-Means*;
- *Isolation Forest*;
- *DBSCAN*;
- *LOF*.

3.6 BIBLIOTECA *SCIKIT-LEARN*

A biblioteca gratuita *Scikit-Learn* é focada em aplicações de algoritmos de ML, amplamente utilizada e desenvolvida com a linguagem de programação Python, sendo a biblioteca mais comum nesse contexto. A biblioteca abrange dezenas de algoritmos, classes e funcionalidades. Entre os algoritmos, podemos destacar: *K-Means*, *Random Forest*, Regressão Linear, SVM, *Mean Shift*, DBSCAN, PCA, UMAP, etc (MENDES, 2021).

Além de ser gratuita, ela é uma biblioteca de aprendizado de máquina de código aberto que oferece suporte ao aprendizado supervisionado e não supervisionado (SCIKIT-LEARN, 2021).

A *Scikit-Learn* é escrita em Python e permite o uso de algoritmos de aprendizado de máquina conhecidos e importantes para pré-processamento, seleção de recursos, seleção de atributos e *pipelining*.

Uma característica dessa biblioteca é poder avaliar o desempenho de um estimador e selecionar parâmetros usando validação cruzada, distribuindo um *dataset* em vários núcleos.

Ela permite auxiliar o analista a escolher os melhores modelos e parâmetros para serem usados, em um determinado caso, dependendo da necessidade de momento (KRAMER, 2016).

Conforme descrito por Velásquez (2021) em seu artigo, os problemas de *Machine Learning* são divididos em três subáreas principais:

- Classificação: baseia-se em tentar prever um dado de desfecho para uma determinada observação dada. Procura-se estimar um “classificador” que gere como saída a classificação qualitativa de um dado não observado com base em dados de entrada;
- Exemplo: um classificador que utilize dados não observados de um paciente e classifique-o como doente ou não doente;
- Regressão: bem parecido com os métodos de classificação, pois utiliza dados de entrada já observados para prever uma resposta. A diferença, nesse caso, é que procura-se estimar um valor numérico e não uma classificação de uma observação;

- Agrupamento: também conhecido como “Clustering”, tem como objetivo agrupar observações em grupos conhecidos como “*clusters*”. Esses dados apresentam similaridades dentro de seu determinado *cluster* e diferenças em relação aos demais *clusters*. Diferente da Classificação, no Agrupamento não é realizada a rotulação dos *clusters*; dessa forma, não existe uma clusterização errada ou certa.

A clusterização – ou agrupamento – utiliza métodos para agrupar dados diferentes em determinados tipos de *clusters*, e a escolha dessas técnicas deve ser previamente analisada pelo pesquisador.

Os métodos de agrupamento são divididos nas seguintes categorias:

- a) Método Baseado em Particionamento: é a categoria mais básica de agrupamento. Primeiramente, o centro de cada *cluster* é selecionado e chamado de centroide. Os centroides podem ser gerados de maneira aleatória ou podem ser escolhidos a partir de um ponto qualquer do conjunto de dados. À medida que o algoritmo é executado, os dados são associados aos *clusters* mais próximos, de acordo com o critério de analogia. Após os dados estarem associados aos seus *clusters*, os centroides são atualizados (NETO, 2015);
- b) Método Hierárquico: enquanto algoritmos particionais geram partições, algoritmos hierárquicos produzem uma sequência de partições rígidas aninhadas, parecidas com uma árvore de relacionamentos entre os dados do conjunto de dados, conhecida como dendrograma de *cluster*;
- c) Método Baseado em Densidade: os algoritmos baseados em densidade consideram que os grupos de dados comuns estão concentrados na parte mais densa do conjunto de dados. Esse método é bastante utilizado para encontrar *outliers* (OLIVEIRA, 2021);
- d) Método de *Ensemble*: são algoritmos de ML que combinam decisões de diversos grupos de algoritmos para melhorar a performance geral (SCIKIT-LEARN, 2021).


Na próxima seção serão descritas algumas características dos algoritmos de aprendizado não supervisionados que serão utilizados neste estudo.

3.6.1 Algoritmo DBSCAN

O DBSCAN é um método de agrupamento fundamentado em densidade de dados, cujo objetivo principal é encontrar agrupamentos de elementos espacialmente próximos, procurando por grupos definidos como regiões de alta densidade de artefatos, separados por regiões de baixa densidade. Uma das principais vantagens desse algoritmo em relação ao *K-Means* é que não é necessário comunicar o número de grupos desejado com antecedência (LARINNI, 2017).

Os agrupamentos são definidos pelo algoritmo da seguinte forma: pontos que têm mais do que um limite de vizinhos dentro de um determinado raio são pesquisados. Quando os pontos de um *cluster* atingem os pontos de outro *cluster*, eles são conectados. Isso acontece repetidamente até que os pontos estejam todos acessíveis, e então as regiões são criadas. O DBSCAN recebe dois parâmetros de entrada: *minPoints* e *eps*. Enquanto o algoritmo *K-Means* reúne todos os pontos, o algoritmo DBSCAN pode não reagrupar alguns elementos. Esses elementos são chamados de ruídos ou *outliers* (PADILHA; CARVALHO, 2021).

Figura 4: Agrupamento realizado por densidade pelo DBSCAN.



Fonte: Scikit-Learn (2021).

O próximo algoritmo que será utilizado neste estudo será detalhado na próxima seção.

3.6.2 Algoritmo *Isolation Forest*

Esse algoritmo tem como característica identificar instâncias de dados que não estão em conformidade com o restante dos dados considerados normais. Diferente dos algoritmos descritos anteriormente, que identificam anomalias, o *Isolation Forest* primeiramente define um conjunto de dados normais e, em seguida, identifica as instâncias de dados que não estão em conformidade com o perfil normal dos dados. Sendo assim, o método *Isolation Forest* propõe um isolamento explícito das anomalias em vez de definir perfis normais no conjunto de dados (POLIZELI, 2019).


O *Isolation Forest* é baseado na lógica de árvore de decisão, por conta de sua suscetibilidade ao isolamento. As anomalias são isoladas mais próximas à raiz da árvore, enquanto pontos normais são isolados na extremidade mais profunda da árvore. Sendo assim, para detectar *outliers* tem-se menos divisões (PINA, 2019).

Pode-se dizer também que o *Isolation Forest* é um algoritmo mais eficiente que os métodos baseados em distância e densidade (ARAUJO, 2017).

Esse método constrói um conjunto de árvores para um conjunto de dados e, em seguida, os *outliers* são classificados como as instâncias que têm comprimentos de caminho curtos. Existem somente duas variáveis para esse método: o número de árvores a serem construídas e o tamanho das subamostras (POLIZELI, 2019).

Abaixo temos uma figura que descreve um exemplo de números de divisões sucessivas necessárias para separar um ponto normal x_i , do ponto x_0 , um *outlier*. Pode-se verificar que em somente 3 partições o *Isolation Forest* conseguiu identificar o *outlier* x_0 , e em 9 divisões conseguiu identificar o dado normal x_i .

Figura 5: Divisões para encontrar dados anômalos de normais com *Isolation Forest*.




Fonte: Susto (2017, p.3).

Uma das vantagens mais importantes desse método é que nenhuma distância ou medidas de densidade são empregadas para detectar anomalias (SUSTO; BEGHI; MCLOONE, 2017).

3.7 MODELOS PARA DETECÇÃO DE *OUTLIERS* NA ÁREA DA SAÚDE

O modelo proposto por Araya (2016) foi baseado nas necessidades cotidianas levantadas junto aos profissionais de auditoria de uma Operadora de Planos de Saúde (OPS) da Região Sul do Brasil. Ele foi fundamentado em regras descobertas de conhecimento em base de dados a partir do método KDD, e foi usado para a identificação de possíveis registros a serem auditados. Com a sua implantação, o esforço despendido no processo de auditoria foi minimizado, e permitiu destacar os itens com possíveis *outliers*. Abaixo, segue o a figura do modelo proposto:

Figura 6: Modelo proposto do processo de identificação de *outliers*.



Fonte: Araya (2016, p. 52).

Em sua pesquisa, Mesquita (2017) descreve a utilização de ML para interpretação eletrocardiográfica. Ele conseguiu que padrões eletrocardiográficos fossem reconhecidos automaticamente com acurácia de 88% para classificação dos ritmos anormais.

Araújo (2017), em seu trabalho, utilizou ML em dados simulados de atendimentos odontológicos do SUS para separar os que têm indícios de fraude. Os algoritmos avaliados foram: *Isolation Forest*; *K-Nearest Neighbors* e *Mahalanobis*

Distance. Em todos os testes houve sucesso em separar os *clusters* de dados normais dos dados anômalos, demonstrando a possibilidade de utilizar essas ferramentas na detecção e avaliação de fraudes de forma muito eficiente.

Em sua pesquisa, Johnson e Khoshgoftaar (2019) utilizaram ML para detectar possíveis fraudes no *Medicare*, Sistema de Saúde Público dos EUA. Nesse estudo foram utilizados algoritmos de Redes Neurais. Os resultados mostraram um desempenho muito bom, com pontuações médias de AUC de 0,8505 e 0,8509 depois do balanceamento do *dataset*. Inicialmente o *dataset* estava desbalanceado, o que acabava causando problemas na avaliação do modelo. Para corrigir tais problemas, foram utilizadas técnicas de sobreamostragem aleatória (ROS), subamostragem aleatória (RUS) e um híbrido ROS-RUS.

Em sua pesquisa, Bauder et al. (2017) utilizaram três estratégias para melhorar modelos de seus trabalhos anteriores. São elas: seleção de recursos (para o ajuste do desequilíbrio de classe); agrupamento de especialidades médicas; e remoção de especialidades específicas que se sobrepõem. Foram usados dados do *Medicare* disponíveis ao público, divulgados pelo *Center for Medicare and Medicaid Services*, juntamente à Lista do Banco de Dados de Indivíduos e Entidades Excluídas (LEIE), divulgada pelo Escritório do Inspetor-Geral, como também dados de dois outros casos de fraude já identificados e documentados para construir e testar os modelos. O intervalo temporal do *dataset* para a construção do modelo ficou compreendido entre os anos de 2013 e de 2014. O algoritmo utilizado para a construção do modelo foi o *Multinomial Naïve Bayes*. Ao executar o modelo, foi constatado que houve melhora do desempenho em comparação ao modelo aplicado na pesquisa anterior.

Casimiro (2016), em seu estudo, utilizou ML para detectar fraudes em 3 bases de dados originadas dos serviços de regulação de duas operadoras de planos de saúde distintas. Antes de aplicar os modelos, foi necessário balancear as bases, visto que as classes desbalanceadas afetariam diretamente o processo de classificação. Depois de balancear devidamente as bases, os algoritmos *Random Forest* e *Naive Bayes* foram os que apresentaram valores constantes de AUC no intervalo de distribuição de classes entre dados de teste e treinamento, que foram de 20/80 e 50/50.

Susto, Beghi e Mcloone (2017) fizeram uso de ML em sua pesquisa para detecção de anomalias em dados de produção industrial. O algoritmo utilizado foi o

Isolation Forest, que foi aplicado em um conjunto de dados real da indústria. O monitoramento dos algoritmos foi feito explorando dados de espectroscopia óptica. O desempenho do algoritmo *Isolation Forest* sobre os outros algoritmos tradicionais, baseado em gráficos de controle univariados para AD e com outra abordagem multidimensional chamada ABOD, foi melhor, atingindo a performance de 82,84% de precisão e de 92,50 de *Recall*, enquanto os tradicionais não conseguiram 80% de precisão.

Na próxima seção serão descritos os passos para o desenvolvimento do modelo deste estudo.

4. DESENVOLVIMENTO

Este capítulo apresenta as etapas do desenvolvimento da pesquisa em questão da seguinte forma:

- Análise da necessidade do negócio;
- Criação e exploração do *dataset*;
- Aplicação de dois algoritmos não supervisionados;
- Apresentação dos resultados.

Em relação ao *dataset* analisado, vale ressaltar que para fins deste estudo entende-se que qualquer UG-FUSEx pode celebrar contratos com quaisquer entidades de saúde que atendam à necessidade de exames, procedimentos, consultas, etc. necessárias para suprir demandas reprimidas.

Entende-se que para caracterizar um contrato no modelo aplicado abaixo, serão utilizados atributos como: ano (representando a vigência); UG-FUSEx (representando a unidade com autonomia administrativa que pode celebrar contratos em saúde); código da OCS/PSA (código da entidade que presta serviço para o EB); o procedimento (caracteriza o objeto que está no contrato que deverá ser celebrado entre o EB e a contratada); e, por fim, o valor (valor acordado para os serviços prestados).

Com a finalidade de auxiliar nas métricas de avaliação da performance dos modelos, foi criada uma variável fictícia alvo para realizar essas comparações. Essa variável foi alimentada com o possível valor de contrato, extraído de uma contagem

de maior concentração de valor para um ano e mesmo procedimento para a mesma OCS/PSA e a mesma unidade gestora o FUSEx.

Vale ressaltar que todos esses passos serão automatizados em sistema próprio para essa finalidade.

Abaixo, foram detalhados os passos que serviram como base para o desenvolvimento do modelo deste estudo.

4.1 ANÁLISE DAS NECESSIDADES DO NEGÓCIO

Entre as reponsabilidades da DSAU, estão as de gerir e auditar as contas médicas hospitalares. Essa tarefa é muito árdua, pois atualmente esse trabalho é feito de forma manual, sem um sistema automatizado para auxiliar os auditores militares em sua tarefa de analisar contas médicas. Por se tratar de muitos registros diários com dados de contas médicas encaminhados pelas contratadas para serem auditados, sem um modelo para auxiliar nesse processo fica quase impossível encontrar dados com anormalidade ou possíveis fraudes nessas faturas. São nelas que são detalhadas a prestação de serviços de atendimentos médicos, exames e acolhimento hospitalar, etc. e os valores desses serviços.

Vale ressaltar que o número de atendimentos varia entre 600.000 (seiscentos mil) a 1 milhão de registros por mês/ano. Cada registro corresponde a um valor vinculado a um procedimento realizado por um beneficiário e prestado ao EB. Dentre esses serviços, alguns são mais expressivos e necessitam de mais atenção em razão do valor, dos cuidados envolvidos ou da demanda reprimida (que, nesse caso, são realizados em Unidades Prestadoras de Serviço - OCS/PSA). É nesse momento que o auditor militar realiza a auditoria nessa conta enviada pela prestadora. Essa tarefa de auditoria pode demorar até 180 dias devido à falta de mão de obra especializada para essa atividade. Essa demora pode causar sérios problemas para o Sistema de Saúde do EB, pois as contratadas podem recusar realizar os atendimentos dos militares e seus beneficiários devido à demora de pagamento de suas faturas.

Uma questão relevante é que cada UG-FUSEx pode ter um valor específico para o seu contrato, ou seja, um mesmo procedimento com valor diferente para outras OCS/PSA no mesmo ano.

Algumas questões importantes ao negócio devem ser levadas em consideração na construção do modelo, que são:

- A base será composta de contas médicas ainda não auditadas na fase denominada auditoria retrospectiva ou auditoria a posteriori;
- Os auditores militares, além das atividades inerentes à auditoria, estão envolvidos em outras atividades ligadas à profissão assistencial de atendimento ao público; sendo assim, não foi possível rotular a base a priori;
- Como fator crítico de sucesso, espera-se que com a aplicabilidade dos algoritmos de clusterização no *dataset*, tenha-se uma faixa de sucesso de aproximadamente 75% dos dados corretamente rotulados.

Após a aplicação do modelo e os dados devidamente classificados como *outliers*, todos foram carregados em base de dados e disponibilizados aos auditores para que fossem validados.

Em primeira análise, foram utilizados 2 algoritmos com o intuito de analisar qual deles teve a melhor performance no conjunto de dados escolhido. Após a rotulação realizada pelo algoritmo, os dados rotulados foram repassados à seção de auditoria para avaliação final e, depois, à publicidade através de relatórios técnicos para organização.

4.2 COMPREENSÃO DE DADOS

A base escolhida para a aplicação do modelo foi a base do Sistema de Registro e Encaminhamento (SIRE), extraída via comandos SQL no SGBD SQL SERVER da Microsoft.

Abaixo, uma pequena descrição sobre os atributos e o domínio correspondente:

Tabela 2: Descrição dos atributos do *dataset*.

Nome da Coluna	Domínio do atributo	Descrição
enc_cod	longint	Chave primária da tabela de encaminhamento.
dataguia	datetime	Data da emissão da Guia ou do Comprovante de despesa Médica (CDM)

enc_ug_cod	int	Código identificador da unidade gestora do FUSEx
enc_OCS/PSA	int	Código identificador da OCS ou PSA onde foi gerada a fatura
titular	int	Identificar se o beneficiário que realizou o procedimento foi o titular
enc_nd	int	Natureza da despesa, elementos de despesa que apresentam as mesmas características
dependente	int	Identificar se o beneficiário que realizou o procedimento foi o dependente
enc_pi	int	Plano interno, instrumento de planejamento e de acompanhamento da ação programada
enc_grupo	int	1 Exército Brasileiro - FUSEX 2 Servidor Civil EB 3 Estrangeiro 4 Força Aérea Brasileira 5 Marinha do Brasil 6 Exército Brasileiro - Isentos 7 Outros 8 Aguardando PREC CP/Matrícula 9 Traslado e Evacuação 11 SAMU 12 PASS - EB 13 PASS - EB - Isento 14 OCS Nacional 15 Ex-Combatente 18 Dependente Estatuto 100%
RM	int	Número da Região Militar onde foi realizada a emissão da guia ou atendimento médico
sexo	int	Identifica qual é o gênero do beneficiário: 1 Masculino; e 2 Feminino
proc_valor	money	Valor do procedimento
cod_procedimento	int	Código identificador do procedimento
cod_especialidadeo	int	Código identificador da especialidade
idade	int	Idade do beneficiário
cond_dep	Varchar(2)	Indica a condição de dependência do beneficiário para com o Sistema de Assistência de Saúde do EB
codom	varchar(6)	Código identificador da OMS/OM

Fonte: O autor.

O SIRE utiliza a Classificação Brasileira Hierarquizada de Procedimentos Médicos (CBHPM). A CBHPM é adotada como padrão mínimo e ético de remuneração dos procedimentos médicos para o Sistema de Saúde Suplementar. São definidos nela os valores relativos aos portes de procedimentos, que deverão

ser determinados pelas entidades médicas nacionais por intermédio da Comissão Nacional de Honorários Médicos.

A imagem abaixo mostra um recorte das tabelas do SIRE que serão utilizadas no estudo. Vale ressaltar que os dados das tabelas demonstradas abaixo foram exportadas do Banco de Dados do Sistema em produção e as atualizações são mensais.

O *dataset* é composto pelos dados no intervalo disponível desde o mês de janeiro de 2020 até dezembro de 2021, totalizando 15.216.082 (quinze milhões, duzentos e dezesseis mil e oitenta e dois) registros que cumpriram alguns critérios para serem selecionados. São eles:

- Somente dados dos beneficiários contribuintes do FUSEx/SAMMED;
- Dados de procedimentos realizados em OCS/PSA;
- Somente serão utilizados nessa pesquisa procedimentos de valores fixados em contrato, ou seja, valores que não podem sofrer alteração no contrato vigente;
- Não foram selecionados os registros das guias de consultas internas geradas nas Organizações Militares de Saúde (OMS), somente registros de encaminhamentos a entidades externas contratadas;
- Dados de contas médicas de apenas de uma UG-FUSEx, localizada na 11^a RM.

Após a extração da totalidade dos dados, verificou-se que alguns procedimentos iniciavam o valor fixo em tabela. Porém, em decorrência da evolução do paciente, eles aumentavam sem parâmetros. Um exemplo disso é a consulta de emergência em conveniado ou procedimentos cirúrgicos que necessitam de algumas intervenções médicas em decorrência da evolução clínica do paciente. Sendo assim, alguns desses dados não foram levados em consideração para a análise no modelo.

Figura 7: Tabelas do SIRE que serão utilizadas no estudo.

ME_PESSOA_BENEFICIARIO * PRECCP SEQ_FAM NOME SEXO DT_NASC COND_DEP BI UA_VINC DT_INCL DT_VAL PREESCOLAR CATEGORIA TIP_VAL COBRANCA PG EMISSAO ALT IDENT CPF DATA_NASCIMENTO PG_VCTO	ME_Base_SIRE enc_data enc_ug_cod enc_auditado enc_cod enc_ocs_psa enc_titular enc_nd enc_dependente enc_pi enc_grupo enc_cotista enc_mapa enc_auditado_data enc_fatura enc_em_lisura enc_em_glosa enc_cdm enc_internacao enc_falecido proc_valor proc_quantidade proc_valor_inicial cod_procedimento ocs_psa_ocs_psa ug_sigla ug_rm prog_sigla prog_pi	ME_PROCEDIMENTOS_SIRE Cod_Espec Cod_Proced descricao proced_exame proced_ativo proced_a_custo proced_tratamento proced_md_usm proced_cod_dgp proced_clinica proced_hgeb proced_md	ME_TB_BASE_ANALISE enc_ug_cod enc_ocs_psa enc_nd enc_pi enc_grupo proc_valor cod_procedimento rm Titular Dependente masculino feminino idade dataguia
	ME_Especialidade_SIRE cod_espec descricao grupo espec_internacao espec_odonto espec_tratamentos espec_md		

Fonte: O autor.

Através dos relacionamentos entre as tabelas acima demonstradas, foi gerada uma tabela resultado com os atributos necessários para a aplicação do modelo.


Com o intuito de apresentar algumas informações importantes e mais detalhadas, os gráficos que seguem logo abaixo contêm visualizações para a melhor compreensão da amostra, bem como de sua distribuição pelas Regiões Militares (Áreas Administrativas do EB) espalhadas estrategicamente pelo território nacional.

A Região Militar com jurisdição sobre a área em que está localizada serve para gerenciar as atividades relativas ao Apoio Logístico, Serviço Militar, Mobilização, Patrimônio e Obras, Justiça Militar e outras atividades estabelecidas em normas específicas, ou seja, atividades puramente administrativas de gestão e controle.

Os beneficiários, para fins de atendimento e gestão, são vinculados a uma das 12 (doze) Regiões Militares espalhadas pelo Brasil.

O gráfico abaixo demonstra a divisão numérica de grupos de beneficiários que são atendidos em OCS/PSA por Região Militar.

Gráfico 1: Distribuição dos beneficiários encaminhados para OCS/PSA por RM.



Fonte: O autor.

O gráfico acima demonstra que a maior concentração de beneficiários atendidos em OCS/PSA contratadas estão na 11ª RM, que fica geograficamente no Centro-Oeste do Brasil. Vale destacar que a maioria dos beneficiários do Sistema de Saúde do EB estão na cidade do Rio de Janeiro. Porém, o número de beneficiários encaminhados para OCS/PSA contratadas é bem menor, visto que lá está situado o hospital de referência do EB – Hospital Central do EB (HCE). Por isso, nessa guarnição, todos os atendimentos são realizados por esse grande Hospital.

A tabela abaixo tem a divisão de beneficiários por grupos para atendimento pelo Sistema de Saúde do EB. A divisão se dá da seguinte forma:

- FUSEx – Grupo composto por militares da ativa, inativa, pensionista e seus dependentes;
- Ex-combatentes – Militares pracinha que foram à 2ª Guerra, ou que foram mobilizados;
- PASS – Servidores civis que prestam serviço para o EB e que escolheram usar o Plano de Assistência do EB.
- Estatuto – Beneficiários que contribuem 100% dos valores dos procedimentos, atendimentos etc., de acordo com o que prevê o estatuto dos militares;
- Isentos – Recrutas e alunos dos cursos de formação de Oficiais da Reserva.


Tabela 3: Divisão dos beneficiários por classes.

RM	FUSEx	EX-COMBATENTES	PASS	ESTATUTO (BDGP)	ISENTOS	TOTAL
01ª RM	131.107	4.332	5.933	1.696	9.601	152.669
02ª RM	47.653	2.184	1.284	927	4.674	56.722
03ª RM	86.603	994	1.856	1.904	11.513	102.870
04ª RM	31.607	1.391	1.411	628	2.658	37.695
05ª RM	46.274	2.099	1.357	863	5.416	56.009
06ª RM	15.392	630	929	340	1.769	19.060
07ª RM	44.637	4.031	1.489	736	4.877	55.770
08ª RM	27.429	376	827	721	2.423	31.776
09ª RM	40.244	262	736	985	3.759	45.986
10ª RM	19.435	349	1.204	294	1.679	22.961
11ª RM	72.333	412	2.741	1.578	5.029	82.093
12ª RM	47.400	66	1.362	1.897	4.117	54.842

Fonte: O autor.


Além da divisão geográfica, é importante demonstrar o número de atendimentos realizados por mês e ano. O maior número de atendimentos em hospitais conveniados nos anos de 2020 e 2021 também está concentrado na 11ª RM, o que facilmente pode ser verificado no detalhamento do gráfico abaixo.

Chama a atenção o aumento do número de atendimentos no ano de 2021, o que pode estar diretamente ligado à pandemia da COVID-19.

Gráfico 2: Distribuição de atendimentos por mês/ano.

Fonte: O autor.

No gráfico seguinte é demonstrada a distribuição entre gêneros. Verificou-se que existe praticamente o mesmo número de beneficiários tanto do sexo masculino como do sexo feminino na amostra analisada.

Gráfico 3: Distribuição da amostra por gênero.

Fonte: O autor.

No gráfico abaixo tem-se o número de atendimentos médicos segmentados por faixas etárias, da seguinte forma: 0 a 20 anos; 21 a 40 anos; 41 a 60 anos; 61 a 80; e maior que 80 anos.

Gráfico 4: Divisão do *dataset* por faixa etária e gênero.

Fonte: O autor.

Com isso, verificou-se que os dados estavam balanceados, e a maior diferença encontrada foi na faixa etária compreendida entre 41 e 60 anos, na qual os atendimentos ao público masculino foram bem mais elevados. A maior concentração de atendimento também é nessa faixa.

Na próxima seção serão detalhadas as atividades de limpeza e preparação dos dados para aplicação do modelo proposto.

4.3 PREPARAÇÃO DOS DADOS

Para Eigner, Bodendorf e Wickramasinghe (2019), antes de iniciar o desenvolvimento dos modelos, é de extrema importância que os dados sejam limpos e organizados, o que facilita o entendimento dos atributos e domínios que compõem o *dataset*.

Nessa atividade foi utilizada a Linguagem SQL, e é geralmente nessa fase em que há maior esforço para ajuste dos dados.

Os dados foram divididos por Regiões Militares (RM). Na preparação inicial, foi realizado um processo de limpeza, com o intuito de melhorar a performance e consistência dos dados, removendo informações incompletas e nulas.

Com o apoio do SQL, verificou-se que na origem dos dados existiam algumas inconsistências, que nesse tratamento inicial foram retiradas/corrigidas da seguinte forma:

- Foram identificados alguns registros com atributos com valores nulos, como data de nascimento e gênero; sendo assim, foram excluídos da amostra, visto que eram somente 244 registros;
- Foi verificado que alguns beneficiários estavam com o valor do atributo “sexo” igual a 3, evidenciando um *outlier*, visto que só deve existir em base de dados o 1 para masculino e o 2 para feminino; como eram poucos atributos, foram corrigidos manualmente através de atualização em base de dados. Para isso, utilizou-se o comando DML chamado de *update*;
- Foi criado o atributo derivado chamado de “idade” através de cálculo utilizando como base o atributo “data de nascimento”.

Após esses ajustes, houve a necessidade de diminuir o escopo da pesquisa para melhor controle e análise. Assim, foram escolhidos somente os contratos celebrados com OCS/PSA do Hospital Militar de Área de Brasília, localizado na 11ª RM no ano de 2021.

Depois de todos os filtros e ajustes, o total de registros ficou em 294.503 (duzentos e noventa e quatro mil, quinhentos e três). Para o teste inicial, somente foram separados 10 procedimentos que mais são encaminhados.

Na próxima seção, são apresentadas as etapas de importação, visualização e exploração dos dados no *Google Colab*.

4.3.1 Exploração dos dados

Após a importação, foi possível verificar inicialmente as 5 (cinco) linhas de valores para cada atributo.

Conforme figura abaixo, pode-se verificar os atributos importados e alguns valores iniciais.

Figura 8: Atributos iniciais importados.

Index	enc_cod	enc_ug_cod	enc_ocs_psa	enc_nd	enc_pl	enc_grupo	Valor	cod_procedimento	rm	sexo	idade	ano	cod_espec	id_especialidade	id_procedimento	clusters_proc
0	96877397	160088	21574	339039	93	1	254.0000	40901106	11	1	108	2021	40901	220	5496	19
1	95689821	160088	6303	339039	93	1	254.0000	40901106	11	2	84	2021	40901	220	5496	19
2	92979420	160088	21596	339039	93	1	254.0000	40901106	11	1	16	2021	40901	220	5496	19
3	96691753	160088	7328	339039	93	1	254.0000	40901106	11	1	73	2021	40901	220	5496	19
4	98288824	160088	21596	339039	93	1	254.0000	40901106	11	1	11	2021	40901	220	5496	19

Fonte: O autor.

Depois da importação, foi necessário verificar em quais tipos de domínio de dados estavam distribuídos os atributos. Para essa finalidade, foi necessário utilizar o método *dtypes*.

Para utilizar os algoritmos de ML, é requisito ter padrão “dados numéricos”, não podendo ser utilizado “dados categóricos”. Todos os atributos que estavam nesse formato foram convertidos para números inteiros ou ponto flutuante.

Figura 9: Código Python para converter tipos de atributos.

```
df["proc_valor"] = df["proc_valor"].astype(float)
df["sexo"] = df["sexo"].astype(int)
```

Fonte: O autor.

Com o intuito de apresentar os atributos em detalhes, realizou-se a análise descritiva do *dataset*. A linguagem de programação Python oferece um método chamado *describe*, que permite fazer essa análise descritiva de forma fácil e amigável.

Então, foi gerada a Tabela 4, na qual detalhes de alguns atributos foram observados. Para essa amostra, os grupos que estão presentes são necessariamente o 1, representando os dependentes contribuintes do FUSEx; 15 para atendimentos exclusivos a ex-combatentes; e 18 para dependentes contribuintes do estatuto dos militares. Com contribuição exclusiva de 100% do valor de contrato, existem procedimentos a custo R\$0,01 e outros com valores máximos de aproximadamente 3 mil reais. Existem beneficiários que são recém-nascidos, bem como outros com 104 anos. A maioria dos encaminhamentos foram realizados no ano de 2021, o que pode estar ligado à COVID-19.

Foi recuperado o id dos procedimentos para correlacionar aos dados dos atendimentos. Outra questão importante é o atributo equivalente ao *clusters_proc*, correspondendo ao agrupamento do código de procedimento, ano, valor, código da OCS/PSA e da UG-FUSEx. Essa atividade de agrupamento foi feita via comandos SQL.


Essa visualização é importante para caracterizar os atributos mais relevantes para o estudo, que são: *enc_ug_cod*; *enc_OCS/PSA*; *enc_grupo*; *valor*; *id_procedimento*; *id_especialidade*; e *ano*, pois é dessa forma que foi caracterizado um contrato neste estudo. Outra questão importante é que existem atributos com valores constantes, por exemplo: *enc_pi*, RM e *enc_nd*. Sendo assim, esses atributos não têm relevância no modelo.

Tabela 4: Análise descritiva de alguns atributos do *dataset*.

VARIÁVEIS	count	mean	std	min	25%	50%	75%	max
enc_cod	294.503	94.681.545,11	3.942.181,12	85.920.876	91.732	95.259	97.961	100.628
enc_ug_cod	294.503	160088	0	160088	160088	160088	160088	160088
enc_OCS/PSA	294.503	1.895.435.943	1.077.123.062	6302	6409	21574	31525	42376
enc_nd	294.503	3.390.390.046	0.4975093026	339039	339039	339039	339039	339093
enc_pi	294.503	9.327.288.686	6.488.713.714	93	93	93	93	249
enc_grupo	294.503	1.000.458.399	0.08328820098	1	1	1	1	18
valor	294.503	1.089.876.152	6.743.943.233	0.01	77.08	80	105.72	3.078,80
cod_procedimento	294.503	28563437.9	15092516.38	10101161	10101173	40901114	40901203	40901386
RM	294.503	11	0	11	11	11	11	11
sexo	294.503	1.516.731.578	0.4997208243	1	1	2	2	2
idade	294.503	4.073.427.096	2.213.416.712	0	21	43	54	104
ano	294.503	2.020.693.867	0.4608863126	2020	2020	2021	2021	2021
cod_espec	294503	2.856.324.181	1.509.249.643	10101	10101	40901	40901	40901
id_especialidade	294.503	1.326.743.089	1.068.235.137	2	2	220	220	220
id_procedimento	294.503	3.377.545.889	2.605.203.848	180	192	5497	5506	5526
clusters_proc	294.503	115.220.054	5.208.577.902	1	8	13	16	19

Fonte: O autor.


Continuando a análise exploratória dos dados, foram correlacionados os valores de cobranças aos grupos de beneficiários. Verificou-se, inicialmente, que o maior número de encaminhamentos e, portanto, maiores gastos, estão vinculados ao grupo 1 e depois ao grupo 15, conforme figura abaixo:

Figura 10: *Boxplot* grupo de beneficiários por valor gasto.

Fonte: O autor.

Abaixo, segue outro *boxplot*, somente com o atributo valor. Nele, nota-se que existem alguns pontos em extremidades fora do quartis do atributo, caracterizando possivelmente *outliers* ou alguma evolução clínica do paciente que necessitou de alteração no valor da conta.


Figura 11: *Boxplot* demonstrando possíveis *outliers* para o atributo valor.



Fonte: O autor.

Pode-se verificar a existência de uma concentração maior nos atendimentos em OCS/PSA para o grupo 1, que corresponde aos militares do EB na ativa, na reserva e os pensionistas de militares, como mostra a Figura 12.


Figura 12: Concentração de encaminhamentos no grupo 1.



Fonte: O autor.

De forma correlata, como a maior concentração de atendimentos em OCS/PSA está concentrada no grupo 1, os maiores valores gastos com encaminhamentos também estão concentrados nesse grupo, conforme mostra a figura abaixo.


Figura 13: Maiores gastos com procedimentos no grupo 1.



Fonte: O autor.

Em outra análise, foi verificada a tendência dos valores estarem agrupados, representando valores com pouca variação por procedimentos contratados, como é demonstrado na figura abaixo. Pode-se notar que os dados estão agrupados de forma mais coesa e, por outro lado, os pontos mais afastados podem caracterizar *outliers*.

Figura 14: Valores dos contratos por OCS/PSA.



Fonte: O autor.

Na próxima seção será descrito passo a passo dos modelos criados e executados para identificar possíveis anomalias nos dados de encaminhamentos para OCS/PSA.

4.4 CRIAÇÃO DO MODELO

Após a fase de pré-processamento, limpeza e análise descritiva da base de dados, o seguinte passo foi aplicar dois algoritmos de detecção não supervisionada para avaliar possíveis dados fora do valor preconizado pelo contrato.

Após aplicar tal conjunto de algoritmos, foi possível compará-los na tarefa de detecção não supervisionada de *outliers* em uma base de dados com valores de atendimentos médicos em saúde prestados por OCS/PSA contratadas na 11ª RM.

Foram utilizadas técnicas de clusterização e detecção de anormalidade do aprendizado não supervisionado com características distintas: um algoritmo por densidade e o outro utilizando técnicas de profundidade de árvores.

A seleção de um algoritmo de clusterização apropriado para um determinado conjunto de dados costuma ser difícil devido ao número de opções disponíveis. Alguns fatores importantes que afetam essa decisão incluem as características dos *clusters*, os recursos do conjunto de dados, o número de *outliers* e o número de objetos de dados. Como não é possível quantificar quantos *clusters* existem por contrato, foram escolhidos algoritmos que fazem essa análise de forma inteligente e automática.

Inicialmente, na seção abaixo, os algoritmos foram aplicados para verificar resultados preliminares. Somente depois houve um ajuste mais preciso, através do qual se chegou em melhores resultados.

4.4.1 Modelo preliminar DBSCAN de clusterização

Esse algoritmo é conhecido por implementar o conceito de densidade, ou seja, pontos densamente conectados. Para esse fim, o DBSCAN usa 2 (dois) parâmetros: a distância máxima entre duas amostras (*eps*) e o número mínimo de

pontos necessários para formar uma região densa (minPts) (ADA; HARSONO; BASUKI, 2018).

Os valores para os procedimentos no mesmo contrato tendem a ser muito próximos e pouco dispersos. Isso pode ser visualizado na figura de número 15. Nesse caso, o raio do parâmetro eps deve ser muito bem ajustado.

Existe, no Python, o método *silhouette_score* que pode ser útil no ajuste dos hiperparâmetros. Abaixo, segue a tabela com os parâmetros sugeridos pelo método no *dataset* completo.

Tabela 5: Resultado descritivo da análise preliminar do método *silhouette_score*.

eps	2	2	3	3	4	4
Min Samples	7	8	7	8	7	8
Clusters presentes	-1; 0 e 1	-1; 0 e 1	-1; 0 e 1	-1; 0 e 1	0 e 1	0 e 1
Tamanho dos clusters	2 clusters para -1; 13908 clusters para 0 e 17339 clusters para 1	2 clusters para -1; 13908 clusters para 0 e 17339 clusters para 1	2 clusters para -1; 13908 clusters para 0 e 17339 clusters para 1	2 clusters para -1; 13908 clusters para 0 e 17339 clusters para 1	13910 clusters para 0 e 17339 clusters para 1	13910 clusters para 0 e 17339 clusters para 1
Pontuação para o método Silhueta	0.6901562086	0.6901562086	0.6901562086	0.6901562086	0.72253212672	0.72253212672

Fonte: O autor.


Foi verificado que à medida que o eps aumenta, juntamente ao número de amostras no mesmo raio, perde-se a capacidade de encontrar *outliers*.

Por esse motivo, houve a necessidade de ajustes manuais nesses hiperparâmetros, provavelmente devido à coesão dos dados e por não apresentarem crescimento contínuo.

Dadas algumas considerações, abaixo segue o modelo proposto com a utilização do algoritmo DBSCAN.

Na criação do modelo, foram seguidos os seguintes passos:

Passo 1: inicialmente, o algoritmo foi executado somente com dois procedimentos (Ecodopplercardiograma transtorácico, Doppler colorido de órgão ou estrutura isolada) para todas as OCS/PSA, totalizando 31.249 (trinta e um mil, duzentos e quarenta e nove) registros com 16 (dezesesseis) atributos;

Figura 15: Distribuição de valores para dois procedimentos por OCS/PSA.

Fonte: O autor.

Pode-se notar na figura acima que existem alguns *outliers* com valores para esses procedimentos variando de R\$1.100,00 até aproximadamente R\$2.000,00, muito fora da curva padronizada.

Outra análise facilmente identificada é que os valores para os procedimentos estão concentrados aproximadamente entre R\$180,00 e R\$260,00.

Para corroborar o que foi demonstrado pela figura acima, foi realizada uma consulta ao banco de dados e, como resultado, foram geradas as 2 tabelas abaixo.

Tabela 6: Consulta realizada ao banco de dados com procedimento 5496.

LINHAS	VALOR	PROCEDIMENTO (ID = 5496)
16.300	254	Ecodopplercardiograma transtorácico
475	0	Ecodopplercardiograma transtorácico
16	0	Ecodopplercardiograma transtorácico
9	178	Ecodopplercardiograma transtorácico
8	197	Ecodopplercardiograma transtorácico
7	190	Ecodopplercardiograma transtorácico
6	444	Ecodopplercardiograma transtorácico
6	387	Ecodopplercardiograma transtorácico
6	320	Ecodopplercardiograma transtorácico
6	200	Ecodopplercardiograma transtorácico

Fonte: O autor.

Tabela 7: Consulta realizada ao banco de dados com procedimento 5526.

LINHAS	VALOR	PROCEDIMENTO (ID = 5526)
21.912	190	Doppler colorido de órgão ou estrutura isolada
3.205	114,68	Doppler colorido de órgão ou estrutura isolada
2.826	0.00	Doppler colorido de órgão ou estrutura isolada
325	163	Doppler colorido de órgão ou estrutura isolada
196	191,99	Doppler colorido de órgão ou estrutura isolada
69	186,46	Doppler colorido de órgão ou estrutura isolada
67	263,54	Doppler colorido de órgão ou estrutura isolada
66	133	Doppler colorido de órgão ou estrutura isolada
66	100	Doppler colorido de órgão ou estrutura isolada
61	200	Doppler colorido de órgão ou estrutura isolada

Fonte: O autor.

Ao analisar a figura 15, foi verificado que existia uma concentração de valores entre R\$180,00 a R\$250,00 para os procedimentos em questão. Para verificar se realmente esses valores são confirmados como possivelmente o maior agrupamento, foi realizada uma consulta em banco de dados, através da qual foi possível constatar uma concentração para os valores desses procedimentos: R\$254,00 para o procedimento de ID=5496 e R\$190,00 para o procedimento de ID=5526, conforme constatado nas tabelas 6 e 7.

Passo 2: nesse passo foram identificados os atributos que caracterizavam um contrato. Isso foi feito de forma empírica visto que, entende-se que um contrato tem vigência anual para um procedimento para uma mesma OCS/PSA com um mesmo valor específico, gerido pela mesma UG-FUSEx.

Com esse entendimento, esses foram os atributos utilizados no modelo.

Depois de algumas verificações e análises, os melhores parâmetros preliminares foram: para o *eps* (raio de *Epsilon*), 0.09 e para *min_samples*, 40. Nessa configuração, o algoritmo classificou o *dataset* em 7 *clusters*. Os valores classificados com -1 (ruídos), contabilizaram 134 registros.

Contudo, verificou-se que existem dois grupos de valores classificados como ruído pelo algoritmo: o valor de R\$254,00 e R\$190,00, que possuem maior representação em banco de dados, o que sugeriu que esses valores podem ser os valores dos contratos. Com isso, certamente não poderiam ser classificados como

ruídos. Pôde-se caracterizar que a análise deve ser feita de forma mais especializada, por OCS/PSA e procedimento. A seguir, primeiro agrupamento e identificação feitos pelo DBSCAN.

Tabela 8: Amostra da tabela resultante da avaliação do algoritmo DBSCAN.

	ENC_OCS_PSA	VALOR	ANO	ID_ESPECIALIDADE	ID_PROCEDIMENTO	ENC_COD	ENC_UG_COD
125	41938	254	2021	220	5496	98760765	160088
154	31891	1969,97	2021	220	5496	96726065	160088
538	16889	254	2021	220	5496	99822797	160088
954	12959	254	2021	220	5496	97367372	160088
1229	40199	254	2021	220	5496	99701650	160088
1304	25701	54	2021	220	5496	97404638	160088
1567	32409	580	2021	220	5496	93023289	160088
2111	21596	741,7	2021	220	5496	99372399	160088
2396	41862	254	2021	220	5496	100360644	160088
2439	23705	0,01	2021	220	5496	95134301	160088
2543	31602	400	2021	220	5526	100356586	160088
2553	21574	406,54	2021	220	5526	92768232	160088
2680	16222	254	2021	220	5496	99125557	160088
2775	21596	1.110,99	2021	220	5496	96095930	160088
2795	21596	578,39	2021	220	5496	98036618	160088
2916	41264	254	2021	220	5496	99223392	160088
2999	21596	653	2021	220	5496	95409027	160088
3190	21596	1.110,99	2021	220	5496	96095930	160088
3628	21574	406,54	2021	220	5526	92768232	160088
3647	40199	254	2021	220	5496	98781112	160088
3917	26001	190	2021	220	5526	98381780	160088
4015	26001	190	2021	220	5526	98878141	160088
4227	16890	444	2021	220	5496	98316490	160088
4769	12959	254	2021	220	5496	96425872	160088
4833	16566	190	2021	220	5526	100528268	160088
4845	38925	190	2021	220	5526	95800935	160088

Fonte: O autor.

Na primeira aplicação do modelo DBSCAN, foram definidos os pontos abaixo como ruídos.

A seguir, tem-se a tabela com a divisão preliminar realizada pelo algoritmo.

Tabela 9: Divisão em clusters pelo DBSCAN.

Grupos de Clusters	Contagem
0	7480
1	4144
2	2185
3	5486
4	4694
5	6958
6	169
-1	133

Fonte: O autor.

Passo 3: uma melhoria foi introduzida para mitigar o problema descrito no passo 2. O *dataset* foi dividido novamente da seguinte forma: o mesmo procedimento para 4 (quatro) OCS/PSA no mesmo ano, caracterizando um contrato. Nessa nova consulta, foram recuperados 10.413 (dez mil, quatrocentos e treze) registros com 16 (dezesesseis) atributos, divididos em OCS/PSA, conforme detalhado na tabela abaixo.

Tabela 10: Registros de contas médicas por OCS/PSA do mesmo procedimento.

Registros	OCS/PSA
1725	6303
2194	7328
3763	21574
2731	21596

Fonte: O autor.

Os parâmetros de configuração do algoritmo, para o *dataset* descrito acima, foram de 0.5 para *eps* e de 20 para o *min_samples*. Com essa configuração, foram recuperados alguns valores classificados como ruídos, como pode ser visto na tabela abaixo.


Tabela 11: Divisão pelo DBSCAN em *clusters* do *dataset* para 4 OCS/PSA.

OCS/PSA	Grupos de Clusters	Contagem
6303	0	1710
	-1	25
7328	0	2175
	-1	19
21574	0	3728
	-1	35
21596	0	2717
	-1	44
TOTAL	-1	123

Fonte: O autor.

Esses valores foram novamente reajustados na seção seguinte, de configuração do algoritmo DBSCAN.

Abaixo, foi mostrada a apresentação dos dados classificados como ruído na análise inicial feita pelo algoritmo DBSCAN. Foi possível verificar que no ano de 2021, somente para um procedimento e 4 OCS/PSA dentre todas as 720 com contrato ativo em 2021 que prestaram esse tipo de serviço, foram gastos mais de R\$30.000,00 (trinta mil reais) com possíveis contas com dados inconsistentes.

Gráfico 5: Possíveis gastos com valores pagos a maior.

Fonte: O autor.

4.4.2 Configuração e ajuste do algoritmo DBSCAN

Para melhorar a análise e detecção de possíveis *outliers* pelo algoritmo DBSCAN, novamente foi realizada a manipulação dos hiperparâmetros. Nessa atividade foi utilizado o método silhueta, procurando diminuir ao máximo o raio entre os valores e aumentando o número de amostras. Nessa nova aplicação do algoritmo, foram ajustados os parâmetros com todas as métricas de distância (*euclidean*, *manhattan* e *canberra*) para verificar quais melhorias esse ajuste poderia trazer para o estudo.

Foi utilizada a variável de interesse recém-construída chamada de alvo, usada somente para auxiliar na avaliação da performance capturado pelo modelo. Essa variável tem exclusivamente a função de auxiliar na validação do modelo. Nessa variável está contido o valor de maior apresentação em base de dados do procedimento escolhido para o mesmo ano e para a mesma OCS/PSA.

4.4.2.1 DBSCAN com Métrica de Distância Euclidiana

Os melhores resultados apresentados pelo algoritmo na detecção de *outliers* na Métrica Euclidiana foram no ajuste do eps para 0.02 e de amostras para 12. Com isso, verificou-se que o algoritmo teve uma boa capacidade de encontrar e classificar *outliers*.

Com a Métrica Euclidiana, o algoritmo acertou 125 dados com ruídos, o que representou 85,61% de todos os possíveis *outliers*, precisão de 100% e acurácia de 99,76%, entre outras métricas. Esses dados tabulados seguem demonstrados na tabela 12.

Tabela 12: Primeira análise do resultado do DBSCAN com a Métrica Euclidiana.

DATASET	EPS	AMOSTRAS	FRAUDES DETECTADAS	ACURÁCIA	PRECISÃO	REVOCAÇÃO	F1- SCORE	OUTLIERS NA BASE
10413	0.02	12	85,61%	99,79%	100%	86%	92%	146

Fonte: O autor.

DBSCAN: matriz de confusão com Métrica de Distância Euclidiana.

Tabela 13: Matriz de confusão do DBSCAN usando Métrica Euclidiana.

PREDITO REAL	-1	0	ALL
-1	125	21	146
1	0	10267	10267
ALL	125	10288	10413

Fonte: O autor.

4.4.2.2 DBSCAN com Métrica de Distância de *Canberra*

Para a métrica de *Canberra*, os melhores resultados apresentados pelo algoritmo na detecção de *outliers* foi no ajuste do eps para 0.3 e o número de amostras foi de 48. Nesse ajuste, pôde-se verificar que o algoritmo teve uma boa capacidade de encontrar e classificar *outliers* nessa base.

Nessa primeira execução do modelo com a Métrica *Canberra*, o algoritmo recuperou 129 dados com ruídos. Porém, na análise da matriz de confusão, nota-se que somente 46 deles são realmente *outliers*, o que representa apenas 31,50% de todos os possíveis *outliers*, conforme demonstrado na tabela 14.

Tabela 14: Primeira análise do resultado do DBSCAN com a Métrica de *Canberra*.

DATASET	EPS	AMOSTRAS	FRAUDES DETECTADAS	ACURÁCIA	PRECISÃO	REVOCAÇÃO	F1-SCORE	OUTLIERS NA BASE
10413	0.3	48	31,50 %	98,24%	36%	32%	33%	146

Fonte: O autor.

DBSCAN: avaliação geral do modelo usando a Métrica de Distância de *Canberra*.

Tabela 15: Matriz de confusão do DBSCAN usando a Métrica de *Canberra*.

PREDITO REAL	-1	0	ALL
-1	46	100	146
1	83	10184	10267
ALL	129	10284	10413

Fonte: O autor.

4.4.2.3 DBSCAN com Métrica de Distância de *Manhattan*

Para a Métrica de *Manhattan*, os melhores resultados apresentados pelo algoritmo na detecção de *outliers* foram no ajuste do eps para 0.02 e o número de amostras foi de 12. Nesse ajuste, pôde-se verificar que o algoritmo teve uma boa capacidade de encontrar e classificar *outliers* nessa base.

Nessa primeira execução do modelo com a Métrica *Manhattan*, o algoritmo recuperou 125 dados com ruídos, o que representa 85,61% de todos os possíveis *outliers*, conforme demonstrado na tabela 16.

DBSCAN: percentual de fraudes detectadas pelo modelo usando a Métrica de distância de *Manhattan*.

Tabela 16: Primeira análise do resultado do DBSCAN com a métrica de *Manhattan*.

DATASET	EPS	AMOSTRAS	FRAUDES DETECTADAS	ACURÁCIA	PRECISÃO	REVOCAÇÃO	F1-SCORE	OUTLIERS NA BASE
10413	0.02	12	85,61 %	99,79%	100%	86%	92%	146

Fonte: O autor.

DBSCAN: avaliação geral do modelo usando a Métrica de Distância de *Manhattan*.


Tabela 17: Matriz de confusão usando a métrica de *Manhattan*.

PREDITO REAL	-1	0	ALL
-1	125	21	146
1	0	10267	10267
ALL	125	10288	10413

Fonte: O autor.

Na figura abaixo, foi mostrada a comparação entre valores classificados como *outliers* e dados normais. Ao lado esquerdo, foram demonstrados os valores classificados como corretos e, ao lado direito, foram classificados como ruído. O algoritmo utilizado foi o DBSCAN, usando a Métrica de Distância de *Manhattan*. Vale ressaltar que o algoritmo acima referenciado errou algumas observações, e isso pode ser visto com facilidade na matriz de confusão.

Figura 16: DBSCAN - mostra de valores com ruídos (*outliers*) e sem ruídos.



Fonte: O autor.

Abaixo, segue o modelo com o algoritmo *Isolation Forest*. Após as análises preliminares, foram feitos ajustes na base e avaliação por métricas.

4.4.3 Modelo preliminar *Isolation Forest* para detecção de anomalias

Foi utilizada a mesma base de dados do algoritmo DBSCAN. Esse algoritmo é diferente do DBSCAN, pois não necessita calcular distância ou medidas de densidade, o que minimiza a complexidade e custos computacionais.

Para esse modelo preliminar, foram considerados *outliers* os dados classificados com o numeral -1.

Assim como no algoritmo DBSCAN, foram definidos alguns atributos de interesse – nesse caso, os que caracterizam um contrato. Foi feito da seguinte forma: o mesmo procedimento para 4 (quatro) OCS/PSA no mesmo ano, caracterizando um contrato. Nessa nova consulta, foram recuperados 10.413 (dez

mil, quatrocentos e treze) registros com 16 (dezesesseis) atributos, divididos em OCS/PSA, conforme já demonstrado na tabela 9.

Para esse procedimento, entende-se que o valor do contrato gira em torno de R\$180,00 a R\$250,00, como demonstrado na figura de número 17 e ratificado na tabela de número 6. Isso é produto de uma consulta em banco de dados, na qual se visualiza que a maior concentração do atributo valor foi em R\$254,00.

Na execução do algoritmo, foram encontrados 146 registros classificados como dados anômalos. Na tabela abaixo, foi demonstrado apenas uma amostra dos dados classificados pelo algoritmo.


Tabela 18: Dados classificados como anormalidade pelo *Isolation Forest*.

enc_cod	enc_ug_cod	enc_OCS/PSA	Valor	id_procedimento	scores	anomaly
95610809	160088	21574	165.0	5496	-0.35770744473581495	-1
93943211	160088	21596	254.03	5496	-0.01177601549749585	-1
94796327	160088	21574	132.7	5496	-0.372821843653219	-1
96816793	160088	6303	221.59	5496	-0.28424323248962813	-1
92834870	160088	21596	231.16	5496	-0.2104848574289192	-1
95360878	160088	21574	0.01	5496	-0.42911227526034534	-1
93853520	160088	21574	254.6	5496	-0.042675189820278236	-1
99372399	160088	21596	741.7	5496	-0.2814689322039068	-1
95035184	160088	21574	316.66	5496	-0.19476370628305506	-1
99285689	160088	6303	190.0	5496	-0.3408188104628579	-1
95409670	160088	6303	200.0	5496	-0.33568738266433196	-1
93354670	160088	21596	197.0	5496	-0.33671089262187714	-1
95043160	160088	21574	319.66	5496	-0.19476370628305506	-1
94182581	160088	21596	177.8	5496	-0.35770744473581495	-1
93253512	160088	21596	197.0	5496	-0.33671089262187714	-1

Fonte: O autor.

Todos esses dados foram carregados em base de dados para serem avaliados por auditores.

Abaixo, é mostrada a apresentação dos dados classificados como ruído pelo algoritmo *Isolation Forest*. Foi possível verificar que no ano de 2021, somente para um procedimento e 4 OCS/PSA dentre todas as 720 com contrato ativo que prestaram esse tipo de serviço, foram gastos mais de R\$40.000,00 (quarenta mil reais), com possíveis dados inconsistentes. Assim como no gráfico de número 5 (cinco), que foi classificado pelo algoritmo DBSCAN, as proporções se mantiveram as mesmas, ficando claro que os mesmos *outliers* foram capturados. Porém, esse algoritmo classificou mais dados como ruído.

Gráfico 6: Contas com valores errados classificados pelo *Isolation Forest*.

Fonte: O autor.

4.4.3.1 *Isolation Forest*: configuração e resultados

Nesta seção, o algoritmo *Isolation Forest* foi ajustado para detectar mais anomalias.

Abaixo, segue o resultado do modelo com aplicação do algoritmo. Foi utilizada a variável de interesse recém-construída chamada de alvo, usada somente para verificar a performance capturada pelo modelo.

Tabela 19: Análise do resultado com o algoritmo *Isolation Forest*.

DATASET	FRAUDES DETECTADAS	ACURÁCIA	PRECISÃO	REVOCAÇÃO	F1-SCORE	OUTLIERS NA BASE
10413	99,31 %	99,31%	100%	99%	100%	146

Fonte: O autor.

Isolation Forest: avaliação geral do modelo usando a Matriz de Correlação.

Tabela 20: Matriz de confusão do *Isolation Forest*.


PREDITO REAL	-1	0	ALL
-1	145	1	146
1	0	10267	10267
ALL	145	10268	10413

Fonte: O autor.

Pode-se verificar que o algoritmo *Isolation Forest* é muito mais efetivo, errou apenas uma classificação dos 146 pontos classificados como dados anormais.

Assim como foi feito com o algoritmo DBSCAN, abaixo segue a demonstração de como o algoritmo *Isolation Forest* dividiu o *dataset*, à esquerda os pontos sem ruídos e à direita os pontos com ruídos. Vale ressaltar que esse algoritmo obteve 100% de acerto, diferentemente do DBSCAN.

Figura 17: *Isolation Forest* - amostra de valores com ruídos (*outliers*) e sem ruídos.



Fonte: O autor.

Depois da execução dos dois algoritmos que servirão de base para a criação do modelo, na próxima seção avaliam-se as suas performances em atendimento à necessidade de negócio apresentada. A variável-alvo fictícia foi utilizada na medição da acurácia e performance do modelo.

4.5 ANÁLISE DOS RESULTADOS

Por fim, aqui serão apresentados os resultados obtidos ao aplicar técnicas de detecção de *outliers* em contas médicas dos beneficiários do EB da 11ª RM. Os dois algoritmos foram comparados nas mesmas condições de infraestrutura e mesma base de dados.

A base de dados é composta de dados que caracterizam contratos e são extraídos do sistema SIRE no ano de 2020 e 2021. Foram aplicados alguns filtros específicos para servir como teste inicial do modelo com o objetivo de melhorar a qualidade da pesquisa. Deu-se da seguinte forma:

- Foi utilizado um único procedimento para 4 OCS/PSA;
- Foram selecionados somente os atributos que caracterizam um contrato (ano, enc_OCS/PSA; enc_ug; valor; grupo; id_procedimento; id_especialidade). Após a identificação desses atributos, foi realizada uma consulta em banco de dados para verificar quais as maiores concentrações de valores para o procedimento em questão;
- Foi criada uma variável para auxiliar na medida da performance do modelo, e essa variável “alvo” recebeu valor 1 para valores válidos do contrato e -1 para *outliers*;
- Foi criada uma lista auxiliar, na qual todos os dados que foram agrupados em *clusters* maiores do que 1, foram realocados dentro do grupo de número 1; essa manipulação foi feita somente para poder realizar testes de métricas e aferição do modelo.

4.5.1 Resultados

Para avaliar o resultado através de métricas de classificação, o Python oferece alguns indicadores para essa finalidade, que são:

- Acurácia: basicamente o número de acertos (positivos) dividido pelo número total de exemplos;
- Precisão: uma métrica que avalia a quantidade de verdadeiros positivos sobre a soma de todos os valores positivos;
- Revocação: o número de vezes que uma classe foi predita corretamente (TP) dividido pelo número de vezes que a classe aparece no dado de teste (FN);
- F1 Score: F-score ou score F1 é uma média harmônica calculada com base na precisão e na revocação.

Além das métricas acima, também será analisada a matriz de confusão, que na verdade é uma tabela que mostra as frequências de classificação para cada classe do modelo. Ela oferece uma medida da efetividade do modelo de classificação e, através dela, é possível ter a informação da quantidade de falsos negativos e falsos positivos. Os resultados foram sumarizados em uma matriz de

duas dimensões, na qual as frequências são divididas em: Verdadeiro positivo (true positive - TP); Falso positivo (false positive - FP); Falso verdadeiro (true negative - TN); e Falso negativo (false negative - FN) (LIMA, 2020).

Nota-se pela Tabela 21 que os resultados indicam que o modelo que usou o algoritmo *Isolation Forest* apresenta indicadores superiores quando comparado ao modelo que utilizou o algoritmo DBSCAN. Outra questão importante é que o custo computacional para esse modelo é muito menor que o modelo com o algoritmo DBSCAN.

Outros resultados podem ser descritos ao analisar os resultados das métricas, por exemplo:

1. Observando a matriz de confusão, nota-se que os verdadeiros positivos são maiores no *Isolation Forest* do que no modelo DBSCAN, ou seja, a recuperação de casos anormais capturados é maior no *Isolation Forest*;
2. Taxa de Falsos Positivos (FP) é parecida, porém, o *Isolation Forest* foi superior na classificação de casos que não são anomalias;
3. Para o indicador de Precisão, em quase todas as métricas o *Isolation Forest* foi melhor; somente na Distância Euclidiana que o DBSCAN foi comparado em igualdade;
4. Para o indicador acurácia, a medida entre os modelos de cada algoritmo está bem parecida;
5. Para o resultado do *F1-score*, o algoritmo *Isolation Forest* é melhor.

Em termos de qualidade, facilidade, eficiência, custo computacional e ajuste, considera-se o resultado do *Isolation Forest* melhor para a criação do modelo, pois para a identificação de anomalias de um mesmo procedimento, em 4 OCS/PSA distintas, o algoritmo teve quase 100% de acertos.

Para avaliar melhor os resultados acima e melhorar a visualização dos dados, segue abaixo uma tabela de comparação das melhores métricas para cada algoritmo descrito acima.

Tabela 21: Comparação das métricas dos algoritmos.

DATASET	ALGORITMO	FRAUDES DETECTADAS	ACURÁCIA	PRECISÃO	REVOCAÇÃO	F1- SCORE	OUTLIERS NA BASE
10413	<i>DBSCAN</i>	85,61 %	99,79%	100%	86%	92%	146
	<i>Isolation Forest</i>	99,31%	100%	100%	99%	100%	146

Fonte: O autor.

Através da tabela resumida acima, pode-se notar que o algoritmo *Isolation Forest* foi melhor em todas as métricas de comparação. Sendo assim, o modelo foi apontado como o algoritmo de melhor performance.

5. CONCLUSÃO E OPORTUNIDADES DE TRABALHOS FUTUROS

O tema desenvolvido neste trabalho de mestrado teve como objetivo principal construir um modelo capaz de identificar pontos anômalos em contas médicas, fruto do atendimento externo aos beneficiários do SAMMED, levando em consideração valores determinados em contratos. Também teve como objetivo oferecer uma ferramenta automatizada para auxiliar os auditores militares na identificação desses dados.

Inicialmente foi realizado um estudo sobre clusterização e detecção de anomalias em base de dados, além do levantamento de literatura correlata ao assunto. Por fim, foram comparados 2 algoritmos para verificar qual deles apresentava mais eficiência para o problema de pesquisa.

O modelo sugerido utiliza aprendizado de máquina com algoritmo não supervisionado, com o objetivo de identificar dados fora da normalidade. Ao encontrá-los, é gerado um arquivo *.csv para ser importado em base de dados para que logo depois seja disponibilizado aos gestores através de ferramenta de *Business Intelligence BI*.

Na primeira fase de criação do modelo, foi realizada uma consulta no banco de dados do Sistema SIRE, com o objetivo de gerar o *dataset* para análise preliminar dos dados – fase em que se inicia a etapa de análise exploratória dos dados. Depois da análise preliminar, foi gerado um arquivo com o *dataset*, que foi importado para o *Google Colab*, através do qual foi feita a análise descritiva – fase

com intuito de conhecer os tipos de dados, seus respectivos domínios e a relação existente entre as variáveis. A fase seguinte foi a da aplicação de 2 algoritmos não supervisionados ao *dataset* escolhido. Como resultado, foi verificado que o algoritmo *Isolation Forest* teve melhor poder assertivo sobre o algoritmo DBSCAN, mesmo alterando as métricas de distância e o número de observações nas amostras. Outra questão importante que foi levada em consideração para a escolha do algoritmo foi a capacidade computacional, pois o DBSCAN consome muito mais memória do que o *Isolation Forest*.

Para avaliação do modelo, foram utilizadas métricas de acurácia e matriz de confusão, com o objetivo de verificar qual algoritmo classificava de maneira correta dados com anomalias. Porém, vale ressaltar que em um modelo não supervisionado não existe uma variável rotulada para a comparação de classificações corretas. Dessa forma, foi proposta a construção de uma variável de interesse baseada no possível valor do contrato, atribuindo valores 1 e -1, em que os dados com valores diferentes do valor de contrato receberam -1 e os que teoricamente são iguais ao valor de contrato receberam 1.

Sugere-se para trabalhos futuros, em complemento ao modelo em questão, a criação de um sistema de apoio à auditoria com o objetivo de auxiliar os auditores militares nessa atividade. O sistema deve permitir a escolha da UG-FUSEx e OCS/PSA que celebram o contrato, ano de vigência, e os procedimentos, tudo de forma simples e dinâmica. Nesse protótipo, os dados são recuperados e gravados via comando SQL, o que não é viável para usuários sem a capacitação específica.

REFERÊNCIAS BIBLIOGRÁFICAS

ADA, N.; HARSONO, T.; BASUKI, A. Cloud satellite image segmentation using meng hee heng *K-Means* and *DBSCAN* clustering. **International Electronics Symposium on Knowledge Creation and Intelligent Computing (IES-KCIC)**, v. 2018, n. 5, p. 367–371, 2018.

AHMAD, P.; QAMAR, S.; RIZVI, S. Q. A. Techniques of data mining in healthcare: a review. **International Journal of Computer Applications**, v. 120, n. 15, 2015.

ALPAYDIN, E. **Introduction to Machine Learning**. 3. ed. Massachusetts (EUA): MIT Press, 2016.

ARAUJO, Ê. J. B. de. **Aprendizado de máquina para detecção de comportamento fraudulento em dados simulados do Sistema Odontológico do SUS**. 2017. 79f. Dissertação (Programa de Pós-Graduação Profissional em Ciência e Tecnologia em Saúde - PPGCTS) - Universidade Estadual da Paraíba, Campina Grande, 2017.

ARAUJO, E. O. de. Sistema de Mineração de Dados para Apoiar a Tomada de Decisão em uma Instituição de Ensino Superior: o problema da evasão escolar no IFTM. 2018. 86f. Dissertação de Mestrado (Instituto Superior de Contabilidade e Administração do Porto Instituto Politécnico do Porto). Porto, 2018

ARAYA, A. M. P. et al. Sistema inteligente para apoio em auditoria de contas médicas. **Journal of Health Informatics**. v.8, n.2, 2016.

ATAIDE, V. M. S. A auditoria como ferramenta importante nas contas hospitalares. 2019

AUDY, J. K. Data Driven Mindset – O modelo de mineração CRISP-DM. Disponível em: <https://jorgeaudy.com/2021/01/29/data-driven-mindset-o-modelo-de-mineracao-crisp-dm/> Acesso em: 20 ago. 2021.

BAUDER, R.; KHOSHGOFTAAR, M. T.; RICHTER, T.; HERLAND, M. Predicting Medical Provider Specialties to Detect Anomalous Insurance Claims. In: **2016 IEEE 28th international conference on tools with artificial intelligence (ICTAI)**. IEEE, 2016. p. 784-790

BAUDER, R.; KHOSHGOFTAAR, T. Medicare Fraud Detection Using ML Methods. p. 858-865, 2017.

BAUDER, R.; ROSA, R.; T. KHOSHGOFTAAR, M. T. Identifying Medicare Provider Fraud with Unsupervised Machine Learning, **IEEE International Conference on Information Reuse and Integration (IRI)**. pp. 285-292, 2018.

BRAGA, A. V. et al. Inteligência artificial na medicina. **CIPEEX**, v.2, p. 937-941, 2018

BRANQUINHO, L. P.; BARACHO, R. M. A.; ALMEIDA, M. B. Modelo para suporte à descoberta de conhecimento em base de dados (KDD): aplicação em estratégias no mercado de medicina diagnóstica. **Pesquisa Brasileira em Ciência da Informação e Biblioteconomia**; v. 10, n 2 (2015), v. 24, n. 2, 2018.

BRASIL. PORTARIA Nº 850 DE 12 DE JUNHO DE 2019. Disponível em: http://www.centraldeservicos.dsau.eb.mil.br/images/leis/Portaria_850_Cmt_Ex_12_JUN_19Comissao.pdf. Acesso em: 01 jun. 2021a.

BRASIL. PORTARIA Nº 492 DE 19 DE MAIO DE 2020. Disponível em: http://www.agsp.eb.mil.br/arquivos/legislacao/PORTARIA_492_19_MAIO_2020.pdf. Acesso em: 20 mar. 2021b.

BRASIL. Referencial de combate à fraude e à corrupção. Tribunal de Contas da União (TCU), p. 164, 2016c.

BRASIL. SIRE e SIRE 2.0. disponível em: <http://www.centraldeservicos.dsau.eb.mil.br/index.php/pt-br/sire>. Acesso em: 01 jun. 2021d.

BRASIL. SIH-EB. disponível em: <https://ebsaude.dgp.eb.mil.br/index.php/publicacoes> Acesso em: 01 jun. 2021e.

BROWNLEE, J. Master Machine Learning Algorithms Discover How They Work and Implement Them From Scratch. **Machine Learning Mastery With Python**, v. 1, n. 1, p. 11, 2016.

CARDOSO, E. C. F. **Análise da relação público-privada e a utilização de OPME no SUS – Brasília**. Trabalho de conclusão de curso (Monografia – Graduação) – Universidade de Brasília, 2019.

CARVALHO, J.; CRUZ, L.; GOUVEIA, R. Descoberta de conhecimento com aprendizado de máquina supervisionado em dados abertos dos censos da educação básica e superior. In: **Anais dos Workshops do Congresso Brasileiro de Informática na Educação**. v. 6, n. 1, p. 674, 2017.

CHEN, Y; OZTEKIN, A. A hybrid data envelopment analysis approach to analyse college graduation rate at higher education institutions. **INFOR: Information Systems and Operational Research**, v. 55, n. 3, p. 188-210, 2017.

CHRIS, P. *K-Means*. disponível em: <https://stanford.edu/~cpiech/cs221/handouts/kmeans.html>. Acessado em: 19 set 2021.

COSTA, C. N.; et al. Descoberta de conhecimento em bases de dados. **Revista Eletrônica: Faculdade Santos Dumont**, v. 2, 2019.

CUSTÓDIO, C. M. **Algoritmos de segmentação para classificação de inventários: DBSCAN**. 2018. Tese de Doutorado.

DA SILVA, S. B.; GONÇALVES, N. S.; SANTOS, D. C. Implantação de um modelo de descentralização de auditoria de contas hospitalares em um hospital de grande porte na região sul do Brasil. **Revista de Administração em Saúde**, v.17, n.69, 2017.

DE OLIVEIRA, R. L.; DE OLIVEIRA, E. M. N. Auditoria médica em hospital geral de médio porte: análise das glosas hospitalares. **Revista de Administração em Saúde**, v. 20, n.78, 2020.

DSAU. COMPETÊNCIAS DA DIRETORIA. Brasília: DF. 2021. Disponível em: <http://www.dsau.eb.mil.br/index.php/competencia>. Acessado em: 21 mar. 2021

DRUCK, G. A Terceirização na Saúde Pública: formas diversas de precarização do trabalho. **Trabalho, Educação e Saúde**, v. 14. p.15-43, 2016.

DUA P., BAIS S. Supervised Learning Methods for Fraud Detection in Healthcare Insurance. **Intelligent Systems Reference Library**, v. 56, p. 261-285, 2013.

EIGNER, I.; BODENDORF, F. WICKRAMASINGHE, N. Predicting high-cost patients by Machine Learning: A case study in an Australian private hospital group. **EPiC Series in Computing**. v. 60, p. 94–103. 2019.

ESCOBAR, L. F. A. et al. Descoberta de padrões para identificação de casos de alto custo em operadoras de planos de saúde. **Revista Stricto Sensu**, v. 4, n. 1, 2019.

FAYYAD, U. et al. The KDD Process for Extracting Useful Knowledge from Volumes of Data. In: **Communications of the ACM**, p.27-34, 1996

FERREIRA, J. A. M. **Detecção de indícios de fraudes no Programa Farmácia Popular do Brasil**. 2020. Dissertação (Mestrado) - Universidade Federal do Rio Grande do Sul – UFRGS, Porto Alegre, RS, 2020.

FERREIRA, R. P.; et al. Descoberta de conhecimento em base de dados de absenteísmo trabalhista com uso de inteligência computacional. **Revista Gestão & Tecnologia**, v.20, n.4, p- 108-135, 2020.

FREITAS, I. W. S. **Um estudo comparativo de técnicas de detecção de outliers no contexto de classificação de dados**. 2019. Dissertação (Mestrado) - Universidade Federal Rural do Semi-árido, Mossoró, 2019.

GARCIA, R. D. **Detecção de Fraudes em Prescrições Médicas para Aplicação em Blockchain**. Instituto de Ciências Matemáticas e de Computação, Universidade de São Paulo, São Carlos, São Paulo, Brasil, 2020.

GERHARDT, T. E; SILVEIRA, T. D. **Métodos de pesquisa**. coordenado pela Universidade Aberta do Brasil – UAB/UFRGS e pelo Curso de Graduação Tecnológica – Planejamento e Gestão para o Desenvolvimento Rural da SEAD/UFRGS. – Porto Alegre: Editora da UFRGS, 2009.

GOMES, R. J.; SILVA, I. S.; RACHED, C. D. A. O uso da mineração de dados como ferramenta para tomada de decisões em enfermagem. **Revista Eletrônica Acervo Saúde**, v. 11, n. 9, p. 375, 2019.

GOOGLE, INC.. *Google Colab*. Disponível em: <https://colab.research.google.com/notebooks/intro.ipynb>. Acesso em: 18 ago. 2021

HILLERMAN, T. P.; CARVALHO, R. N.; REIS, A. C. B. Analyzing suspicious medical visit claims from individual healthcare service providers using K-Means clustering. In: **International Conference on Electronic Government and the Information Systems Perspective**. Springer, Cham, p. 191-205, 2015.D

IESS - Instituto de Estudos de Saúde Suplementar. Variação de Custos Médico-Hospitalares. Disponível em: https://www.iess.org.br/cms/rep/vcmh-ago-2021-v2_pdf. Acesso em: 18 ago. 2021

JAMJOOM, A. A. The use of knowledge extraction in predicting customer churn in B2B. **Journal of Big Data**, v. 8, n. 1, p. 1-14, 2021.

JOHNSON, J.; KHOSHGOFTAAR, T. Medicare fraud detection using neurais networks. **Journal of Big Data**. p. 6-63, 2019.

JOUDAKI, H.; et al. Using data mining to detect health care fraud and abuse: a review of literature. **Global journal of health science**, v. 7, n. 1, p. 194, 2015.

KANKSHA, B. A.; et al. An intelligent unsupervised technique for fraud detection in health care systems. **Intelligent Decision Technologies**, 2021.

KAZEMI, Z.; ZARRABI, H. Using deep networks for fraud detection in the credit card transactions. **IEEE International Conference on Knowledge-Based Engineering and Innovation (KBEI)**, v. 2017, n. 4, p. 0630–0633, 2017.

KRAMER, O. Scikit-learn. In Machine learning for evolution strategies, **Springer, Cham**. p. 45-53, 2016.

LARINNI, M. **Detecção de Posição e Quedas Corporais Baseado em KMeans Clustering e Threshold**. Dissertação de Mestrado em Engenharia Elétrica, Publicação 684/2017, Departamento de Engenharia Elétrica, Universidade de Brasília, Brasília, DF, 2017, 58p.

LIMA, L. B. **Mapeamento do uso e cobertura da terra no assentamento Jacaré-Curituba, SE com o uso da imagem de alta resolução espacial**. Dissertação (mestrado em Desenvolvimento e Meio Ambiente) - Universidade Federal de Sergipe, 2020

MATLOOB, I.; et al. Medical Health Benefit Management System for Real-Time Notification of Fraud Using Historical Medical Records. **Applied Sciences**, v.10, n.15, p.5144, 2020.

MARCONI, Marina de Andrade. Fundamentos de metodologia científica. 7. ed. São Paulo: Atlas, 2017.

MENDES, L.R. **Utilização de Data Mining e Deep Learning para Business Intelligence em estrutura integrada de Sistema Smart Parking**. Dissertação apresentada à Escola Superior de Tecnologia e de Gestão de Bragança para obtenção do Grau de Mestre em Sistemas de Informação no âmbito da dupla diplomação com a Universidade Tecnológica Federal do Paraná. Bragança, 2021

MENDONÇA, A. C.; CARVALHO, V. R. J. Auditoria de Contas Médicas. Interação - **Revista De Ensino, Pesquisa E Extensão**, v.18, n.1, p. 9 – 20, 2016

MESQUITA, C. T. Inteligência Artificial e Machine Learning em Cardiologia - Uma Mudança de Paradigma. **International Journal of Cardiovascular Sciences**, v.30, n.3, p.187-188, 2017.

MICROSTRATEGY. **MicroStrategy Intelligence Everywhere**. Disponível em: <https://www.microstrategy.com/pt>. Acesso em: 28 dez. 2021

MOTURI, C. A. **Use Of Data Mining To Detect Fraud Health Insurance Claims**. Tese de Doutorado. Faculdade de Ciências Biológicas e Físicas (CBPS). 2019.

NASCIMENTO, M, R. **Contribuições de red flags para detecção de fraudes corporativas**. 2020. 70 f. Dissertação (Mestrado em Ciências Contábeis) - Universidade Federal de Goiás, Goiânia, 2020.

NETO, A. C. A. **G2P-DBSCAN: Estratégia de Particionamento de Dados e de Processamento Distribuído fazer DBSCAN com MapReduce**. Dissertação (Mestrado em Ciência da Computação) — Universidade Federal do Ceará, Ceará, 2015.

NEVES, R. C. D. **Pré-Processamento no Processo de Descoberta de Conhecimento em Banco de Dados**. Dissertação (Instituto de Informática) – Universidade Federal do Rio Grande do Sul, Porto Alegre: PPGC da UFRGS, 2003.

NTAM. Manual de Auditoria Médica do Exército Brasileiro. Disponível em: <http://www.dsau.eb.mil.br/index.php/contas-medicas>. Acesso em: 31 mai. 2021

NUNES, J. W. Protótipo baseado em regras de produção e aprendizado de máquina para descoberta de fraudes em seguros de saúde. In: **Anais da V Escola Regional de Alto Desempenho do Rio de Janeiro**. SBC. p. 6-10, 2019.

OLIVEIRA, A. S. S. Macro SOSstream: **um algoritmo evolutivo para agrupamento auto organizado baseado em densidade**. 2021. 72f. Dissertação (Mestrado em Engenharia Elétrica e de Computação) - Centro de Tecnologia, Universidade Federal do Rio Grande do Norte, Natal, 2021.

PIMENTA, D. P. **Data mining na detecção de outliers na codificação clínica: estudo em internamentos com pneumonia**. Dissertação de Mestrado. 2019.

PINA, M. **Automatic detection of anomalous user access patterns to sensitive data**. Tese de mestrado, Informática, Universidade de Lisboa, Faculdade de Ciências, 2019

POH, C. Q. UBEYNARAYANA, C. U. GOH, Y. M. Safety leading indicators for construction sites: A machine learning approach. **Automation in construction**, v. 93, p. 375-386, 2018.

POLIZELI, M. V. **Aplicação de algoritmos não supervisionados em dados eleitorais**. Dissertação de mestrado em Engenharia de Produção, Área de Pesquisa Operacional – Instituto Tecnológico de Aeronáutica e Universidade Federal de São Paulo, São José dos Campos, 2019.

PUGGINI, L.; MCLOONE, S. An enhanced variable selection and *Isolation Forest* based methodology for anomaly detection with oes data. **Engineering Applications of Artificial Intelligence**, v. 67, p. 126-135, 01 2018.

RADUENZ, J. C. **Machine Learning na Auditoria de Contas Médicas. Auditoria de contas na saúde suplementar**. Dissertação apresentada como requisito parcial à obtenção do grau de Mestre em Computação Aplicada. Universidade do Vale do Itajaí - Curso de mestrado Acadêmico em Computação Aplicada, São José, Santa Catarina, 2020

RAMOS, J. S. et al. CRISP-EDM: uma proposta de adaptação do Modelo CRISP-DM para mineração de dados educacionais. **IX Congresso Brasileiro de Informática na Educação**. 2020

RANGEL, J. A.; **Jogo sério para ensino e prática de detecção de Outliers**. Dissertação (Mestrado) - Universidade Tecnológica Federal do Paraná. Programa de Pós-graduação em Computação Aplicada, Curitiba, 2018.

RAYAN, N.; Framework for Analysis and Detection of Fraud in Health Insurance. **IEEE 6th International Conference on Cloud Computing and Intelligence Systems (CCIS)**, 2019

RODRIGUES, J. A. R. M. et al. Glosas em contas hospitalares: um desafio à gestão. **Revista Brasileira de Enfermagem**, v. 71, n.5, p.2511-2518, 2017.

RUSSEL, S.; NORVIG, P. **Inteligência Artificial**. 3. ed. Rio de Janeiro: Campus, 2013.

SANTOS, H. G. **Comparação da performance de algoritmos de machine learning para a análise preditiva em saúde pública e medicina**. 2018. 206f. Tese (Doutorado) – Faculdade de Saúde Pública, Universidade de São Paulo, São Paulo, 2018.

SANTOS, J. R. R. **Ciência de dados e políticas públicas de saúde: exemplos práticos**. 2020. Tese (Doutorado) – Faculdade de Saúde Pública, Universidade de São Paulo, São Paulo, 2020

SCHWENZFEIER, N.; GRUHN, V. Towards a practical process model for anomaly detection systems. **Proceedings of the 1st International Workshop on Software Engineering for Cognitive**. 2018

SCIKIT-LEARN. Disponível em: https://scikit-learn.org/stable/getting_started.html. Acesso em 07 jun. 2021.

SHAKYA, V.; MAKWANA, R. R. S. Feature selection based intrusion detection system using the combination of *DBSCAN*, *k-mean++* and *smo* algorithms. **International Conference on Trends in Electronics and Informatics (ICEI)**, v. 2017, n. 1, p. 928–932, 2017.

SILVA, A. C. C. D. Auditoria como ferramenta de gestão para eficiência alocativa de recursos financeiros no SUS: o caso da prefeitura de Campos dos Goytacazes, Rio de Janeiro. 2018.

SULINO, R. M. Mineração de dados e descoberta de conhecimento a partir de dados de atividade física, saúde, clima e qualidade de vida. 2020.

SUSTO, G. A.; BEGHI, A.; MCLOONE, S. Anomaly detection through on-line *Isolation Forest*: An application to plasma etching. **28th Annual SEMI Advanced Semiconductor Manufacturing Conference (ASMC)**. 2017

VELASQUEZ, L. H. UMA VISÃO GERAL SOBRE MACHINE LEARNING – CLASSIFICAÇÃO. Disponível em: <https://operdata.com.br/blog/uma-visao-geral-sobre-machine-learning>. Acesso em 07 jun. 2021.

YAN, K. et al. A Hybrid Outlier Detection Method for Health Care Big Data. p. 157-162, 2016

ZAMINI, M.; MONTAZER, G. Credit card fraud detection using autoencoder based clustering. **International Symposium on Telecommunications (IST)**, v. 2018, n. 9, p. 486–491, Dec 2018.