

Uálaci dos Anjos Júnior

Mineração de dados na base de dados de SRAG

São Mateus - ES

2024

Uálaci dos Anjos Júnior

Mineração de dados na base de dados de SRAG

Projeto de graduação apresentado ao DCEL
como parte dos requisitos exigidos para a
obtenção do título de Bacharel em Engenharia
da Computação



Universidade Federal
do Espírito Santo

Orientador: Professora Dra. Luciana Lee

São Mateus - ES

2024

Editável
Uálaci dos Anjos Júnior

Mineração de dados na base de dados de SRAG

Projeto de graduação apresentado ao DCEL
como parte dos requisitos exigidos para a
obtenção do título de Bacharel em Engenharia
da Computação

Trabalho aprovado. São Mateus - ES, 6 de outubro de 2024:

Professora Dra. Luciana Lee
Universidade Federal do Espírito Santo
Orientador

**Professora Dra. Silvia das Dores
Rissino**
Universidade Federal do Espírito Santo
Membro Interno

Professor Dr. Oberlan Christo Romão
Universidade Federal do Espírito Santo
Membro Interno

São Mateus - ES
2024

Resumo

Este trabalho de conclusão de curso aplicou técnicas de mineração de dados para analisar a base de dados da Síndrome Respiratória Aguda Grave (SRAG), fornecida pelo Ministério da Saúde do Brasil, com o objetivo de identificar padrões clínicos e fatores preditivos relacionados à evolução dos casos. A metodologia incluiu algoritmos de aprendizado de máquina, como árvores de decisão, FP-Growth e redes neurais, além de análises de correlação entre parâmetros demográficos, clínicos e desfechos. As árvores de decisão apontaram o diagnóstico da doença, a necessidade de ventilação mecânica e a idade como os principais preditores da evolução clínica. O FP-Growth identificou associações relevantes entre sintomas, comorbidades e tratamentos hospitalares, enquanto a rede neural alcançou 77% de precisão na predição da evolução dos casos. Também foi desenvolvida uma plataforma interativa para visualização de dados, permitindo uma análise detalhada das relações entre variáveis. O estudo demonstra o potencial dessas técnicas para melhorar a gestão de saúde pública e a resposta a surtos, além de avaliar riscos em populações vulneráveis. No entanto, limitações como a exclusividade de dados brasileiros e possíveis inconsistências nos registros foram identificadas. Pesquisas futuras podem incluir dados internacionais, fatores socioeconômicos e modelos mais avançados de aprendizado de máquina.

Palavras-chave: Mineração de dados, Síndrome Respiratória Aguda Grave (SRAG), Árvore de decisão, Análise de subgrupos, Correlação de parâmetros, Progressão de casos, Saúde pública, Classificação de casos, Algoritmos de aprendizado de máquina, Predição clínica, Bases de dados abertas, Correlação de Pearson.

Abstract

This graduation project applied data mining techniques to analyze the Severe Acute Respiratory Syndrome (SARS) database provided by the Brazilian Ministry of Health, aiming to identify clinical patterns and predictive factors related to case outcomes. The methodology included machine learning algorithms such as decision trees, FP-Growth, and neural networks, as well as correlation analyses between demographic, clinical, and outcome parameters. The decision trees highlighted disease diagnosis, the need for mechanical ventilation, and age as the main predictors of clinical evolution. FP-Growth revealed significant associations between symptoms, comorbidities, and hospital treatments, while the neural network achieved 77% accuracy in predicting case outcomes. An interactive data visualization platform was also developed, allowing detailed analysis of the relationships between variables. The study demonstrates the potential of these techniques to improve public health management and outbreak response, as well as to assess risks in vulnerable populations. However, limitations such as the exclusive use of Brazilian data and possible inconsistencies in records were noted. Future research may include international data, socioeconomic factors, and more advanced machine learning models.

Keywords: Data mining, Severe Acute Respiratory Syndrome (SARS), Decision tree, Subgroup analysis, Variable correlation, Case progression, Public health, Case classification, Machine learning algorithms, Clinical prediction, Open databases, Pearson correlation.

Lista de ilustrações

Figura 1 – Mineração de dados como um passo no processo de descobrimento de conhecimento (HAN; KAMBER; PEI, 2011)	16
Figura 2 – Exemplo de uma árvore de decisão para o conceito "compra computador".(HAN; KAMBER; PEI, 2011)	19
Figura 3 – Funções de ativação tanh e ReLu (JURAFSKY; MARTIN, 2024)	23
Figura 4 – Rede neural de camadas densas (GURNEY, 1997)	24
Figura 5 – Amostra de Dicionário de dados base SRAG (SAUDE, 2024)	32
Figura 6 – Valores ausentes em cada parâmetro (Autor).	35
Figura 7 – Distribuição por faixa de idade (Autor).	36
Figura 8 – Distribuição de evolução dos casos para crianças de até 5 anos (Autor)	36
Figura 9 – Distribuição de casos por cada mês de cada ano da base de dados (Autor)	37
Figura 10 – Porcentagem de Casos com evolução para cura em cada mês de cada ano estudado. (Autor)	38
Figura 11 – <i>heatmap</i> , destaque dos fatores de risco. (Autor)	40
Figura 12 – FP-Growth. (Autor)	40
Figura 13 – FP-Growth, regras associadas ao desfecho de não recuperação. (Autor)	41
Figura 14 – Tabela de regras FP-Growth. (Autor)	44
Figura 15 – Tabela FP-Growth, regra de HOSPITAL_1. (Autor)	44
Figura 16 – Tabela FP-Growth, regra de TOSSE_1. (Autor)	44
Figura 17 – Tabela FP-Growth, regra de DESC_RESP_1. (Autor)	44
Figura 18 – Descrição populacional por idade. (Autor)	45
Figura 19 – Relação entre faixa etária infantil e evolução dos casos. (Autor)	46
Figura 20 – Distribuição percentual de casos por faixa etária e evolução. (Autor)	46
Figura 21 – Ocorrências de sintomas em função de um sintoma específico. (Autor)	47
Figura 22 – Frequência de ocorrência do fator clínico selecionado. (Autor)	48
Figura 23 – Frequência de classificação final dos casos. (Autor)	49
Figura 24 – Frequência de ocorrência de fatores clínicos dado que o fator clínico CLASSI_FIN_5.0 ocorreu. (Autor)	49
Figura 25 – Probabilidade de ocorrência de fatores clínicos dado que o fator clínico selecionado ocorreu. (Autor)	50
Figura 26 – Matriz de Confusão do modelo final de predição da evolução dos casos. (Autor)	55
Figura 27 – Dica de dicionário de dados. (Autor)	59

Lista de tabelas

Tabela 1 – Correlação entre os parâmetros na base de dados. (Autor)	34
Tabela 2 – Importância dos parâmetros na predição da evolução dos casos.	39
Tabela 3 – Experimentos realizados com o Optuna.	53
Tabela 4 – Relatório de Classificação	54

Sumário

1	INTRODUÇÃO	10
1.1	Considerações Gerais	10
1.2	Descrição do Problema	10
1.3	Objetivos	11
1.3.1	Objetivos Gerais	11
1.3.2	Objetivos Específicos	11
1.3.3	Organização do trabalho	12
2	FUNDAMENTAÇÃO TEÓRICA	14
2.1	Dados Abertos	14
2.2	Bases de dados abertas	14
2.3	Base de dados aberta de Síndrome Respiratória Aguda Grave (SRAG)	15
2.4	Mineração de dados e KDD (Processo de descoberta de conhecimento em bases de dados)	15
2.4.1	Principais conceitos da mineração de dados	17
2.5	Correlação Linear de Pearson	17
2.6	Árvores de Decisão	18
2.6.1	Conceito e Funcionamento	18
2.7	FP-Growth: Abordagem de Crescimento de Padrões Frequentes	20
2.7.1	Desafios do Algoritmo Apriori	20
2.7.2	Abordagem FP-Growth	20
2.7.3	Vantagens do FP-Growth	21
2.7.4	Aplicação à Base de Dados de SRAG	21
2.8	Redes Neurais Artificiais	22
2.8.1	Introdução às Redes Neurais	22
2.8.2	Estrutura Básica de uma Rede Neural	22
2.8.3	Funções de Ativação	22
2.8.4	Camadas Densas	23
2.8.5	Função de Ativação Sigmoide	24
2.8.6	Função de Perda Binary Crossentropy	24
2.8.7	Algoritmo RMSprop	24
3	TRABALHOS CORRELATOS	26
4	DESENVOLVIMENTO E METODOLOGIA	30
4.1	Ferramentas de trabalho	30

4.2	Ambiente e Coleta dos Dados	31
4.3	Mineração de dados aplicada às bases de dados	33
4.3.1	Unificação de Dados e Eliminação de Colunas Irrelevantes	33
4.4	Análise da Correlação entre parâmetros de Geolocalização	33
4.4.1	Análise de Valores Ausentes e Processamento de Datas	34
4.4.2	Análise da Distribuição por Idade	35
4.4.3	Análise de subgrupos	36
4.4.3.0.1	Crianças de até 5 anos	36
4.4.4	Análise temporal	37
4.5	Aplicação da Árvore de Decisão de Classificação	38
4.5.1	<i>Heatmap</i>	40
4.5.2	<i>Insights</i> obtidos a partir da aplicação do FP-Growth	41
4.5.3	Tabela FP-Growth	42
4.6	Análises específicas	45
4.6.1	Análise da Faixa Etária	45
4.6.2	Análise de Correlação entre Sintomas	46
4.7	Análise de Regras de Associação entre parâmetros	47
4.8	Aplicação de Redes Neurais na Previsão da Evolução dos Pacientes de SRAG	50
4.8.1	Transformação dos Dados	51
4.8.2	Resultados Obtidos	54
4.8.3	Avaliação do Desempenho do Modelo	54
4.8.3.1	Resultados Finais	54
4.8.4	Considerações Finais	56
5	APRESENTAÇÃO DAS DASHBOARDS	57
5.1	<i>Dashboard</i> de Análise de Distribuição Populacional	57
5.2	<i>Dashboard</i> de <i>Heatmap</i> de Correlação	57
5.3	<i>Dashboard</i> de Análise de Sintomas, Comorbidades e Informações Hospitalares	57
5.4	<i>Dashboard</i> de Análise de Regras de Associação (FP-Growth)	58
5.5	<i>Dashboard</i> de Gráficos das Métricas do FP-Growth	58
5.6	Visualização interativa do dicionário de dados	59
6	CONCLUSÃO	60
6.1	Trabalhos Futuros	61
	REFERÊNCIAS	63

APÊNDICE A – DASH DE ANÁLISE DE DISTRIBUIÇÃO POPULACIONAL. (AUTOR)	65
APÊNDICE B – HEATMAP DE CORRELAÇÃO DOS PARÂMETROS. (AUTOR)	66
APÊNDICE C – DASH DE ANÁLISE DE SINTOMAS. (AUTOR)	67
APÊNDICE D – DASH DE ANÁLISE DE COMORBIDADES E INFORMAÇÕES HOSPITALARES. (AUTOR)	68
APÊNDICE E – DASH TABELA FP-GROWTH. (AUTOR)	69
APÊNDICE F – DASH GRAFICOS FP-GROWTH. (AUTOR)	70

1 Introdução

1.1 Considerações Gerais

A Síndrome Respiratória Aguda Grave (SRAG) é um conjunto de sintomas respiratórios graves que podem ser causados por diversas etiologias. Segundo ([STRAUSBAUGH et al., 2004](#)), "O pródromo inclui sintomas semelhantes aos da gripe, como febre, mialgias, dor de cabeça e diarreia". A SRAG é mais notavelmente associada a infecções virais, como o vírus Influenza ou o coronavírus, responsável pela COVID-19 (SARS-CoV-2). Esta síndrome é caracterizada por uma rápida progressão de sintomas respiratórios, podendo levar a complicações sérias e, em casos mais graves, à insuficiência respiratória aguda e morte.

A primeira incidência de infecção por SARS-CoV foi notificada em 16 de Novembro de 2002, na província costeira de Guangdong, no sudeste da China, na fronteira com Hong Kong e Macau. Em 12 de março de 2003, a Organização Mundial da Saúde (OMS) emitiu um relatório global de alerta para esses casos e casos semelhantes em Hong Kong e no Vietnã. Posteriormente, tal síndrome clínica, ficou conhecida como “síndrome respiratória aguda grave” (SARS ou SRAG).

A SRAG pode ser desencadeada por vários agentes patogênicos incluindo vírus, bactérias e fungos. Entre os vírus mais comuns associados à SRAG destaca-se o Influenza, no entanto, a emergência de novos vírus respiratórios, como o coronavírus SARS-CoV-2, aumentou significativamente a atenção global para esta síndrome.

A SRAG se destacou como um grave problema de saúde pública durante a pandemia da COVID-19, apresentando números alarmantes de mortalidade. Segundo ([MALIK et al., 2020](#)), "até maio de 2020, foram registrados, somente no Brasil, 271.628 contágios, levando a 17.971 óbitos".

Podemos observar que a SRAG é uma síndrome que afeta os seres humanos há mais de duas décadas e, com base nos últimos acontecimentos, é coerente de se esperar que essa síndrome permeie por algum tempo na sociedade.

1.2 Descrição do Problema

A Síndrome Respiratória Aguda Grave (SRAG) é uma condição de saúde que representa um desafio significativo para os sistemas de saúde em todo o mundo, demandando estratégias eficazes de monitoramento, gestão e prevenção. No Brasil, a disponibilidade da Base de Dados SRAG do OpenData SUS oferece uma oportunidade interessante para a

aplicação de técnicas de mineração de dados com o objetivo de aprimorar a compreensão e a resposta a essa síndrome. Partindo dessa oportunidade e da importância de compreensão e prevenção dessa síndrome, foram estudadas nesse projeto, utilizando análises de mineração de dados e análises estatísticas, as bases de dados abertas da SRAG no período de 2017 a 2023. Esse período foi escolhido pois permite uma compreensão da situação da população brasileira com relação a essa síndrome antes da pandemia COVID-19, os impactos ocorridos durante a pandemia e a situação atual após a pandemia.

1.3 Objetivos

1.3.1 Objetivos Gerais

O projeto de mineração de dados na base de Síndrome Respiratória Aguda Grave (SRAG) visa aprofundar a compreensão dessa síndrome, explorando extensivamente conjuntos de dados para identificar padrões epidemiológicos, características clínicas e fatores de risco associados. O objetivo central é oferecer uma visão abrangente da SRAG, validando hipóteses existentes e revelando novas correlações que possam influenciar diretamente a prática clínica e as estratégias de saúde pública.

Outro objetivo foi desenvolver e disponibilizar uma plataforma de visualização de dados interativa e abrangente, que facilite a exploração das relações entre os parâmetros e as informações presentes na base de dados, com o intuito de permitir a profissionais de saúde, pesquisadores e outros interessados, uma análise mais intuitiva e acessível dos dados e apoiando a tomada de decisões informadas.

O projeto também visa contribuir ativamente para a pesquisa médica, proporcionando uma caracterização detalhada dos casos de SRAG, identificando subgrupos específicos e fatores de risco. Esses *insights* não apenas aprimoram a classificação de riscos, personalizando abordagens terapêuticas, mas também têm o potencial de otimizar protocolos clínicos, guiar estratégias preventivas e influenciar a atualização de diretrizes de saúde pública.

1.3.2 Objetivos Específicos

- Realizar uma análise exploratória de dados sob a base de dados SRAG do SUS, buscando obter *insights* sobre a SRAG.
- Fazer uma redução de dimensionalidade e ajuste da base de dados para obter melhores resultados ao aplicar técnicas de *Machine Learning*.
- Identificar relações e correlações entre os diferentes parâmetros e a evolução final dos casos.

- Obter *insights* e possíveis previsões a respeito da evolução dos casos de SRAG.
- Avaliar e otimizar métricas de classificação visando obter o melhor resultado a partir dos modelos disponíveis.
- Desenvolver uma plataforma de visualização interativa para facilitar a exploração dos dados da SRAG, proporcionando uma análise mais acessível e transparente das informações.

1.3.3 Organização do trabalho

Este projeto foi organizado em várias fases para garantir uma abordagem estruturada e metódica na análise do banco de dados da Síndrome Respiratória Aguda Grave (SRAG). As fases são as seguintes:

- **Coleta e Pré-processamento dos dados:** A fase inicial envolveu a coleta do banco de dados da SRAG a partir do portal OpenDataSUS, que oferece acesso aberto a diversos conjuntos de dados relacionados à saúde. Os dados foram então pré-processados, incluindo o tratamento de valores ausentes, a remoção de parâmetros irrelevantes e a transformação dos dados em um formato adequado para análise.
- **Análise Exploratória dos Dados:** Foi realizada uma análise exploratória dos dados para obter *insights* sobre as características do conjunto de dados, identificar padrões e entender as relações entre as diferentes parâmetros. Esta fase envolveu técnicas como análise de correlação, visualização e análise de subgrupos.
- **Seleção de Recursos e Desenvolvimento do Modelo:** Com base nos *insights* obtidos na análise exploratória, foram selecionados recursos relevantes para o desenvolvimento de modelos e técnicas de aprendizado de máquina. Alguns algoritmos de aprendizado de máquina, incluindo árvores de decisão, mineração de regras de associação e redes neurais, foram utilizados para construir modelos preditivos para a evolução dos casos e identificar fatores críticos que influenciam os resultados dos pacientes.
- **Avaliação e Refinamento do Modelo:** Os modelos desenvolvidos foram avaliados utilizando métricas de desempenho apropriadas, como acurácia, precisão e *recall*. Refinamentos iterativos foram realizados para melhorar o desempenho do modelo, incluindo ajuste de hiperparâmetros e incorporação de recursos adicionais relevantes.
- **Interpretação dos Resultados e Relatório:** A fase final envolveu a interpretação dos resultados obtidos a partir dos modelos e análises, a formulação de conclusões significativas e a documentação das descobertas em um relatório abrangente.

Visualizações e painéis interativos foram criados para facilitar a comunicação e a disseminação dos resultados do projeto.

2 Fundamentação Teórica

2.1 Dados Abertos

A mineração de dados representa um processo relativamente novo, que vem se demonstrando altamente relevante para extrair padrões, tendências e conhecimentos importantes de bases de dados em geral. Atualmente, com o aumento de iniciativas de disponibilidade de dados, como as bases de dados abertas que são disponibilizadas por diversos órgãos governamentais surge, por consequência, um incentivo a busca de métodos eficazes de analisar de forma mais profunda essas bases de dados.

2.2 Bases de dados abertas

As bases de dados abertas são conjuntos de informações que são disponibilizadas ao público sem restrições significativas. Segundo o ([Open Data Handbook, 2023](#)) “Dados abertos são dados que podem ser usados, reutilizados e redistribuídos livremente por qualquer pessoa - sujeitos apenas, no máximo, à exigência de atribuição e compartilhamento semelhante.”

Essas bases de dados representam informações relevantes em diversas áreas, como por exemplo, educação, saúde, economia, desenvolvimento e negócios, e seguem alguns pilares que representam suas principais características. Dentre esses, os principais são: disponibilidade de acesso, reutilização, redistribuição e participação universal. Esses parâmetros são descritos abaixo:

- Disponibilidade de Acesso: os dados devem estar disponíveis na sua totalidade e a um custo de reprodução não superior ao razoável, preferencialmente através de *download* através da Internet. Os dados também devem estar disponíveis de forma conveniente e modificável.
- Reutilização e redistribuição: os dados devem ser fornecidos sob termos que permitam a reutilização e redistribuição, incluindo a mistura com outros conjuntos de dados.
- Participação Universal: todos devem ser capazes de usar, reutilizar e redistribuir. Não deve haver discriminação contra áreas de atuação ou contra pessoas ou grupos.

([Open Data Handbook, 2023](#))

Algumas das principais motivações para o uso de dados abertos, segundo ([ARZBERGER et al., 2004](#)), são que "o acesso aberto aos dados financiados publicamente proporciona maiores retornos do investimento público, e podem gerar riqueza através da utilização a jusante de resultados, fornece aos decisores políticos os dados necessários para resolver problemas complexos". Pode-se concluir a partir dessa observação, que os dados

abertos governamentais podem influenciar positivamente em medidas públicas, permitindo decisões mais informadas, o que reduz possíveis adversidades e prejuízos.

2.3 Base de dados aberta de Síndrome Respiratória Aguda Grave (SRAG)

Nas últimas décadas o governo brasileiro tem se esforçado para adotar a utilização de bases de dados abertas em diversas áreas da gestão pública. Atualmente, o governo brasileiro disponibiliza uma série de bases de dados a respeito dos mais variados setores da economia e qualidade de vida dos brasileiros. Uma dessas bases de dados, é a base de dados de Síndrome Respiratória Aguda Grave (SRAG). Nela, o governo vem se empenhando em fornecer informações sobre a epidemiologia dessa síndrome. Segundo ([Ministério da Saúde, 2023](#)),

O governo brasileiro vem disponibilizando o legado dos bancos de dados (BD) epidemiológicos de SRAG, da rede de vigilância da Influenza e outros vírus respiratórios, desde o início da sua implantação (2009) até os dias atuais (2023), com a incorporação da vigilância da COVID-19. Atualmente, o sistema oficial para o registro dos casos e óbitos por SRAG é o Sistema de Informação da Vigilância Epidemiológica da Gripe (SIVEP-Gripe).

2.4 Mineração de dados e KDD (Processo de descoberta de conhecimento em bases de dados)

A mineração de dados compreende um conjunto de técnicas e métodos para descobrir padrões e informações úteis em grandes volumes de dados. Segundo ([HAN; KAMBER; PEI, 2011](#)), "A mineração de dados é o processo de descobrir conhecimento e padrões interessantes a partir de grandes quantidades de dados". Esta prática está intrinsecamente ligada ao processo de Descoberta de Conhecimento em Bancos de Dados (KDD, do inglês *Knowledge Discovery in Databases*). A Figura 1 ilustra essa relação, destacando a mineração de dados como um passo crucial no processo de descoberta de conhecimento.




Figura 1 – Mineração de dados como um passo no processo de descobrimento de conhecimento (HAN; KAMBER; PEI, 2011)

O KDD, conforme elucidado por (HAN; KAMBER; PEI, 2011), é dividido em diversas etapas que proporcionam uma estrutura organizada para a exploração de conhecimento em dados. Essas etapas (1) são:

- **Limpeza de dados:** Onde são removidos ruídos e dados inconsistentes.

- **Integração de dados:** onde várias fontes de dados podem ser combinadas.
- **Seleção de dados:** onde dados relevantes para a tarefa de análise são recuperados do banco de dados.
- **Transformação de dados:** onde os dados são transformados e consolidados em formas apropriadas para mineração, realizando operações de resumo ou agregação.
- **Mineração de dados:** um processo essencial onde métodos inteligentes são aplicados para extrair padrões de dados.
- **Avaliação de padrões:** para identificar padrões verdadeiramente interessantes que representam conhecimento, com base em medidas de interesse.
- **Apresentação do conhecimento:** Onde técnicas de visualização e representação de conhecimento são usadas para apresentar o conhecimento minerado ao usuário.

Essas etapas não são lineares e muitas vezes envolvem retrocessos, ajustes e refinamentos, formando um ciclo iterativo no processo de KDD. A mineração de dados, como componente essencial desse processo, desempenha um papel crucial na revelação de padrões ocultos e na extração de informações relevantes, contribuindo significativamente para a tomada de decisões informadas em diversas áreas, incluindo a saúde, como evidenciado no presente projeto de análise da SRAG.

2.4.1 Principais conceitos da mineração de dados

O processo de mineração de dados possui diferentes abordagens, as mais comuns são:

- **Aprendizado de Máquina:** O aprendizado de máquina é uma subcategoria da inteligência artificial e oferece algoritmos capazes de aprender a partir dos dados, identificando padrões e fazendo previsões. No contexto da SRAG, modelos de aprendizado de máquina podem ser utilizados para classificar casos, identificar fatores de risco e prever a evolução da síndrome.
- **Agrupamento (*Clustering*):** O agrupamento é uma técnica que organiza dados em grupos com base em similaridades, o agrupamento pode auxiliar na identificação de diferentes perfis de pacientes ou na categorização de casos de SRAG com características semelhantes.
- **Regras de Associação:** Essa técnica revela relações entre parâmetros, permitindo identificar associações frequentes nos dados. Na SRAG, as regras de associação podem ser aplicadas para entender a coocorrência de sintomas, comorbidades e outros parâmetros relevantes.

2.5 Correlação Linear de Pearson

A Correlação Linear de Pearson é uma medida estatística que avalia a força e direção da relação linear entre dois parâmetros. Essa correlação é amplamente utilizada na

mineração de dados e se demonstra muito útil para compreender a natureza e intensidade das associações entre diferentes parâmetros em conjuntos de dados.

Essa correlação é representada pelo coeficiente r . A fórmula para o cálculo da correlação linear de Pearson entre dois parâmetros, A e B (HAN; KAMBER; PEI, 2011), é dada por:

$$r_{A,B} = \frac{Cov(A, B)}{\sigma_A \sigma_B}$$

Onde σ_A and σ_B são os desvios padrões de A e B , respectivamente, e $Cov(A, B)$ é a covariância entre A e B .

A interpretação do coeficiente de correlação r permite compreender a natureza da relação entre os parâmetros. Um r próximo de 1 indica uma forte correlação positiva, sugerindo que, à medida que um parâmetro aumenta, o outro também tende a aumentar. Um r próximo de -1 indica uma forte correlação negativa, indicando que à medida que um parâmetro aumenta, o outro tende a diminuir. Um r próximo de 0 sugere uma correlação fraca ou inexistente.

2.6 Árvores de Decisão

As Árvores de decisão são uma técnica poderosa na mineração de dados, inclusive quando se trata de classificação. Este método é frequentemente empregado para analisar padrões e tomar decisões com base em condições específicas presentes nos dados.

2.6.1 Conceito e Funcionamento

As árvores de decisão são estruturas hierárquicas compostas por nós de decisão e folhas. Cada nó de decisão representa uma escolha entre possíveis caminhos, e as folhas representam as decisões ou classificações finais. O algoritmo constrói a árvore de forma iterativa, selecionando as características que melhor dividem os dados em cada nível.

Um exemplo típico de árvore de decisão é ilustrado na Figura 2, retirado de (HAN; KAMBER; PEI, 2011). Neste exemplo, a árvore representa o conceito "compra computador", ou seja, ela prevê se um cliente na *AllElectronics* tem probabilidade de comprar um computador. Os nós internos são representados por retângulos, e as folhas são representadas por círculos. Cada nó interno representa um teste em um parâmetro específico, enquanto cada folha representa uma classe, como "compra computador = sim", ou, "compra computador = não".

O processo de construção de uma árvore de decisão envolve a escolha de parâmetros que proporcionam uma divisão eficaz dos dados, para isso, é utilizado o ganho de informação




Figura 2 – Exemplo de uma árvore de decisão para o conceito "compra computador".(HAN; KAMBER; PEI, 2011)

numa abordagem de implementação desse algoritmo. O ganho de informação é uma métrica que quantifica a redução na incerteza ou entropia dos dados após a aplicação de um determinado parâmetro para particionar o conjunto de dados. Quanto maior o ganho de informação, mais relevante é o parâmetro para a construção da árvore.

Na *Árvore de decisão*, utiliza-se o ganho de informação para encontrar o parâmetro que minimiza a informação necessária para classificar as tuplas nas partições resultantes, garantindo um processo eficiente de classificação. A informação necessária para classificar as tuplas é medida pela Entropia, representada por $\text{Info}(D)$, que é expressa matematicamente pela equação abaixo (HAN; KAMBER; PEI, 2011):

$$\text{Info}(D) = - \sum_{i=1}^m p_i \log_2(p_i).$$

Onde p_i representa a probabilidade de uma tupla aleatória pertencer à classe C_i . Essa probabilidade é calculada pela razão entre o número de tuplas que pertencem a C_i no conjunto D ($|C_{i,D}|$) e o tamanho total do conjunto D ($|D|$).

Quando o conjunto de dados D é dividido com base em um parâmetro A com v valores distintos, o algoritmo calcula a informação adicional necessária após a divisão, representada por $\text{Info}_A(D)$. Representada matematicamente abaixo (HAN; KAMBER; PEI, 2011):

$$\text{Info}_A(D) = \sum_{j=1}^v \frac{|D_j|}{|D|} \cdot \text{Info}(D_j).$$

A expressão $\frac{|D_j|}{|D|}$ atua como o peso da j -ésima partição.

O ganho de informação ($\text{Gain}(A)$) é então definido como a diferença entre a informação original ($\text{Info}(D)$) e a informação após a divisão ($\text{Info}_A(D)$). O parâmetro

com o maior ganho de informação é escolhido como critério de divisão no nó. O ganho de informação ($\text{Gain}(A)$) é representado matematicamente por (HAN; KAMBER; PEI, 2011):

$$\text{Gain}(A) = \text{info}(D) - \text{info}_A(D).$$

2.7 FP-Growth: Abordagem de Crescimento de Padrões Frequentes

O algoritmo FP-Growth (*Frequent Pattern Growth*) é uma técnica eficiente para mineração de padrões frequentes em grandes conjuntos de dados. Ele foi desenvolvido como uma alternativa ao Apriori, superando suas principais limitações, como a geração excessiva de candidatos e a necessidade de múltiplas varreduras no banco de dados (HAN; KAMBER; PEI, 2011).

2.7.1 Desafios do Algoritmo Apriori

O Apriori é conhecido por ser uma solução tradicional para mineração de *itemsets* frequentes¹, mas sua eficiência sofre com dois problemas principais:

- **Geração excessiva de candidatos:** Quando o número de *itemsets* frequentes é elevado, o Apriori pode gerar uma quantidade massiva de candidatos para *itemsets* de tamanhos maiores, o que aumenta exponencialmente o custo computacional (HAN; KAMBER; PEI, 2011).
- **Múltiplas varreduras no banco de dados:** Para verificar a frequência dos candidatos, o algoritmo precisa realizar várias leituras da base de dados, o que torna o processo mais lento em grandes volumes de dados (HAN; KAMBER; PEI, 2011).

2.7.2 Abordagem FP-Growth

O algoritmo FP-Growth resolve esses desafios adotando uma abordagem diferente, conhecida como *divide-and-conquer*². Ele funciona em duas fases principais:

1. **Construção da FP-Tree:** O FP-Growth começa com uma varredura do banco de dados para identificar os *itemsets* frequentes de tamanho 1 (*1-itemsets*). Esses itens são ordenados de forma decrescente com base na frequência e, a partir dessa ordenação,

¹ Um *itemset* é um conjunto de itens. Se a frequência de um *itemset* em uma base de dados satisfaz um limite mínimo predefinido, ele é chamado de *itemset* frequente (HAN; KAMBER; PEI, 2011).

² *Divide-and-conquer* é uma estratégia de resolução de problemas que consiste em dividir um problema maior em subproblemas menores e mais simples, resolvê-los de forma independente e, em seguida, combinar suas soluções para formar a solução final.

uma árvore compactada chamada FP-tree é construída. Cada transação é mapeada para um caminho na árvore, agrupando itens com prefixos comuns. Assim, os itens que aparecem juntos nas transações formam ramificações compartilhadas, resultando em uma estrutura compacta que representa o banco de dados sem armazenar todas as transações individualmente (HAN; KAMBER; PEI, 2011).

2. **Mineração da FP-Tree:** A segunda fase envolve a mineração da árvore gerada. Em vez de gerar e testar candidatos como no Apriori, o FP-Growth extrai padrões frequentes explorando subárvores chamadas de FP-trees condicionais. O algoritmo realiza essa mineração de forma recursiva, começando pelos itens menos frequentes e gerando uma nova FP-tree para cada *itemset* condicional, permitindo encontrar padrões frequentes ao longo das ramificações da árvore (HAN; KAMBER; PEI, 2011).

2.7.3 Vantagens do FP-Growth

O FP-Growth traz diversas vantagens em comparação ao Apriori, como explicado em (HAN; KAMBER; PEI, 2011):

- **Evita a geração explícita de candidatos:** O algoritmo não precisa gerar todos os possíveis candidatos de *itemsets*, o que reduz drasticamente o número de combinações a serem processadas.
- **Redução no número de varreduras do banco de dados:** Apenas duas varreduras são necessárias—uma para identificar os *itemsets* frequentes e outra para construir a FP-tree, o que torna o processo mais eficiente em termos de desempenho.
- **Escalabilidade:** O FP-Growth é altamente escalável, sendo capaz de processar grandes volumes de dados e se adaptar a bancos de dados que não cabem na memória.

2.7.4 Aplicação à Base de Dados de SRAG

No contexto da análise da base de dados de Síndrome Respiratória Aguda Grave (SRAG), o FP-Growth é utilizado para explorar padrões frequentes nos parâmetros clínicos, como sintomas e comorbidades. Esses padrões podem revelar associações importantes, como a coocorrência de sintomas ou a combinação de fatores que influenciam a evolução dos pacientes, como a cura ou o óbito. Ao aplicar essa técnica, foi possível identificar inter-relações complexas entre parâmetros que seriam difíceis de captar por meio de análise manual.

2.8 Redes Neurais Artificiais

2.8.1 Introdução às Redes Neurais

As redes neurais artificiais (RNAs) são modelos computacionais inspirados na estrutura e funcionamento do cérebro humano. Suas origens remontam ao modelo de neurônio proposto por McCulloch e Pitts em 1943, que sugeriu que um neurônio biológico poderia ser modelado como um sistema binário capaz de realizar cálculos lógicos (JURAFSKY; MARTIN, 2024). Com o tempo, as redes neurais evoluíram e se tornaram uma das principais ferramentas para problemas complexos de aprendizado de máquina, sendo amplamente utilizadas em várias áreas, como reconhecimento de padrões, previsão e classificação de dados (JURAFSKY; MARTIN, 2024).

2.8.2 Estrutura Básica de uma Rede Neural

Uma rede neural é composta por uma série de unidades computacionais chamadas **neurônios** ou **unidades**, que processam informações e produzem saídas. Cada neurônio recebe um conjunto de entradas ponderadas, realiza uma soma dessas entradas e aplica uma função de ativação para produzir uma saída. A função de ativação é uma parte crucial do processo, pois introduz a não-linearidade necessária para que a rede neural possa aprender padrões complexos (JURAFSKY; MARTIN, 2024).

Um neurônio pode ser representado pela seguinte equação:

$$z = \sum_i w_i x_i + b$$

onde w_i são os pesos associados a cada entrada x_i e b é o termo de *bias*³. Após calcular essa soma ponderada, o valor z é passado por uma função de ativação, como a função sigmoide, ReLu (Unidade Linear Retificada) ou tanh (função tangente hiperbólica) (JURAFSKY; MARTIN, 2024). A saída y de um neurônio seria, então:

$$y = f(z)$$

onde f é a função de ativação aplicada ao valor ponderado.

2.8.3 Funções de Ativação

As funções de ativação são essenciais para determinar se um neurônio deve ser ativado ou não. Três das funções mais comuns são:

³ O *bias* é um termo adicional em uma unidade neural que é somado à ponderação das entradas. Ele permite que o modelo faça ajustes na saída, mesmo que todas as entradas sejam zero, ajudando a deslocar a função de ativação (JURAFSKY; MARTIN, 2024).

- **Sigmoide**: Mapeia os valores de entrada para um intervalo entre 0 e 1, sendo útil para problemas de classificação binária.
- **tanh** (Figura 3): Semelhante à sigmoide, mas mapeia os valores de entrada para um intervalo entre -1 e 1, o que pode ser útil para centralizar os dados.
- **ReLU** (Figura 3): A função de ativação mais popular em redes neurais modernas, que retorna 0 para valores negativos e o próprio valor de entrada para valores positivos, introduzindo uma simplicidade computacional e mitigando problemas como o gradiente desvanescente (JURAFSKY; MARTIN, 2024).




Figura 3 – Funções de ativação tanh e ReLu (JURAFSKY; MARTIN, 2024)

2.8.4 Camadas Densas

Uma **camada densa**, também conhecida como *fully connected layer*, é uma camada na qual cada neurônio está conectado a todos os neurônios da camada anterior e também a todos os neurônios da camada subsequente. Esse tipo de camada é essencial em redes neurais, pois permite que o modelo capture interações complexas entre os neurônios em diferentes camadas. Um exemplo de rede neural com camadas densas é ilustrado na Figura 4.

Nas redes totalmente conectadas (*fully connected networks*), cada neurônio de uma camada recebe entradas de todos os neurônios da camada anterior e transmite suas saídas para todos os neurônios da camada seguinte, formando camadas densas. Essa arquitetura garante que cada unidade da rede contribua integralmente para o processo de aprendizado, sem limitações de conectividade, o que pode ser benéfico para a modelagem de dados complexos e de alta dimensionalidade. (GURNEY, 1997).




Figura 4 – Rede neural de camadas densas (GURNEY, 1997)

2.8.5 Função de Ativação Sigmoid

A função sigmoide é amplamente utilizada em redes neurais, principalmente em tarefas de classificação binária. Ela é uma função de ativação que transforma o valor de entrada em um valor entre 0 e 1, mapeando os números reais para esse intervalo. Isso a torna particularmente útil para modelar probabilidades, pois a saída de um neurônio que usa a função sigmoide pode ser interpretada como a probabilidade de uma determinada classe (JURAFSKY; MARTIN, 2024). A fórmula da função sigmoide é dada por:

$$\sigma(z) = \frac{1}{1 + e^{-z}}.$$

onde z é a soma ponderada das entradas do neurônio.

2.8.6 Função de Perda Binary Crossentropy

A *binary crossentropy* é uma função de perda usada em problemas de classificação binária. Essa função mede a diferença entre a probabilidade prevista pelo modelo e o valor real da classe. Quanto menor o valor da função de perda, mais próximo o modelo está de fazer previsões precisas. A fórmula da *binary crossentropy* para uma única previsão é:

$$L = -[y \cdot \log(\hat{y}) + (1 - y) \cdot \log(1 - \hat{y})].$$

onde y é o valor verdadeiro (0 ou 1) e $\hat{y}$ é a probabilidade prevista pelo modelo. Essa função penaliza fortemente grandes discrepâncias entre o valor verdadeiro e a previsão, incentivando o modelo a ajustar seus pesos para melhorar suas previsões (JURAFSKY; MARTIN, 2024).

2.8.7 Algoritmo RMSprop

O RMSprop (*Root Mean Square Propagation*) é um algoritmo de otimização amplamente utilizado em redes neurais e aprendizado de máquina que ajusta a taxa

de aprendizado para cada parâmetro individualmente, o que contribui para a estabilização do treinamento. As principais características incluem:

- **Adaptação da Taxa de Aprendizado:** O RMSprop ajusta a taxa de aprendizado com base na média móvel dos quadrados dos gradientes⁴. Isso significa que parâmetros com gradientes maiores terão uma taxa de aprendizado reduzida, enquanto parâmetros com gradientes menores terão uma taxa de aprendizado aumentada.
- **Fórmula de Atualização:**

A atualização dos parâmetros no algoritmo RMSprop é descrita pela seguinte fórmula:

$$E|g^2|(t) = \beta E|g^2|(t-1) + (1-\beta) \left(\frac{\partial c}{\partial w} \right)^2$$

$$w_{ij}(t) = w_{ij}(t-1) - \frac{\eta}{\sqrt{E|g^2|(t)+\epsilon}} \frac{\partial c}{\partial w_{ij}}$$

Onde:

- $E|g^2|(t)$ é a média móvel dos quadrados dos gradientes.
- β é o fator de decaimento para a média móvel.
- η é a taxa de aprendizado.
- ϵ é um termo de suavização para evitar divisão por zero.

Nesta fórmula (UNIVERSITY, 2024), a atualização do parâmetro w_{ij} é ajustada dinamicamente com base na média móvel dos quadrados dos gradientes, o que garante que gradientes grandes resultem em atualizações menores, enquanto gradientes pequenos resultam em atualizações maiores. Isso ajuda a manter uma taxa de aprendizado eficiente e estável ao longo do treinamento.

- **Vantagens:** O RMSprop é eficaz em lidar com gradientes variáveis e ajusta a taxa de aprendizado dinamicamente, o que melhora a estabilidade e pode acelerar a convergência durante o treinamento.

⁴ O gradiente de uma função $f(x, y)$ é o vetor formado pelas derivadas parciais da função, apontando na direção de maior crescimento, sendo representado por ∇f e dado por $\left(\frac{\partial f}{\partial x}, \frac{\partial f}{\partial y} \right)$. (STEWART, 2012)

3 Trabalhos Correlatos

A busca por compreensão aprofundada e soluções inovadoras no contexto da mineração de dados na base de dados SRAG é um processo que possui conhecimento acumulado por trabalhos correlatos já realizados. A revisão destes trabalhos permite uma análise mais abrangente do estado das metodologias e descobertas que contribuíram para o avanço no estudo dessa síndrome no contexto de mineração de dados. Nesta seção, serão explorados trabalhos com campo de estudo similares que abordam temas relacionados à mineração de dados em contextos epidemiológicos, com foco especial em síndromes respiratórias agudas graves.

O estudo ([LAZZARINI et al., 2022](#)) aborda a importância de identificar pacientes com COVID-19 com maior propensão a desenvolver infecções graves, visando otimizar a gestão de cuidados e melhorar as chances de sobrevivência. O foco central é um modelo de aprendizado de máquina que prevê casos graves da doença, especialmente aqueles acompanhados pela Síndrome do Desconforto Respiratório Agudo (SDRA). O trabalho destaca diferentes fatores de risco que desempenham um papel crucial na progressão da COVID-19.

Para isso, foi formada uma coorte¹ com 289.351 pacientes diagnosticados em abril de 2020, utilizando dados de reivindicações administrativas dos EUA entre outubro de 2015 e julho de 2020. O estudo analisou 817 diagnósticos por paciente, obtidos do histórico médico prévio à infecção por COVID-19. O desfecho principal foi a presença de SDRA nos 4 meses após a infecção, e a coorte foi dividida em conjuntos de treinamento, teste e validação.

Avaliando três classificadores de aprendizado de máquina, a Árvore de Decisão de Impulso Gradiente destacou-se com uma *area under curve* (AUC) de 0,695 e uma (*Area Under the Precision-Recall Curve*) AUPRC de 0,0730, representando um aumento significativo de desempenho em relação aos classificadores de referência. Além disso, a comparação com um painel de cinco clínicos, um grupo de especialistas médicos utilizado como padrão de comparação para validar a eficácia de modelos preditivos, indicou que o modelo supera ou é equivalente às previsões dos especialistas, em termos de precisão e *recall*.

No estudo ([HUH; HAN; YOON, 2021](#)), foram analisadas as sequências de aminoácidos e códons do SARS-CoV-2, SARS-CoV e MERS-CoV por meio de diferentes programas estatísticos, buscando compreender suas características. O foco específico reside

¹ Grupo de pessoas, usado em estudos ou em investigação, que possuem características em comum, como a idade, a classe social, a condição médica, etc.

nas variações das sequências de aminoácidos e códons e sua relação com os períodos de incubação e surtos. A pergunta inicial foi a comparação do SARS-CoV-2 com diversos vírus da família coronavírus, utilizando o programa BLAST do NCBI e algoritmos de aprendizado de máquina.

Os resultados dos experimentos com BLAST, Apriori e Decision Tree indicaram que o SARS-CoV-2 apresenta alta semelhança com o SARS-CoV, enquanto possui uma similaridade relativamente baixa com o MERS-CoV. Uma análise dos códons do SARS-CoV-2 e do MERS-CoV revelou diferenças significativas. Apesar da semelhança aparente nos experimentos de BLAST e Apriori, o SVM demonstrou eficácia na classificação usando *kernels* não lineares. O experimento com Decision Tree destacou propriedades notáveis na sequência de aminoácidos do SARS-CoV-2 ausentes na sequência do MERS-CoV.

O propósito central do estudo foi mitigar os danos causados pelo SARS-CoV-2 à humanidade. Portanto, foram propostos estudos adicionais focados na comparação do vírus SARS-CoV-2 com outros que também podem ser transmitidos durante períodos latentes. Essa abordagem visou contribuir para estratégias preventivas mais eficazes e uma compreensão aprofundada da variabilidade viral.

Para concluir, o estudo apresentou um modelo de aprendizado de máquina que utiliza o histórico de reivindicações para prever a SDRA em pacientes com COVID-19. Os fatores de risco considerados estão amplamente vinculados à gravidade da doença, e o modelo proposto destacou-se como uma ferramenta promissora para otimizar o cuidado de pacientes infectados, permitindo uma triagem precoce e eficaz.

Já o estudo ([BARROS; SANTOS; OULEE, 2022](#)) teve como objetivo analisar dados de saúde pública do SARS-CoV-2 entre 2009 e 2022, dividindo-os em períodos pré e pós COVID-19. Foram explorados três modelos de arquitetura de *data warehouse*: BI, Data Science e Data Lake. O modelo BI foi escolhido devido à familiaridade dos participantes.

A modelagem incluiu a criação de um *data warehouse* no Azure, com dados sobre pacientes, fatores de risco e sintomas. Utilizando Power BI, o projeto resultou em um painel interativo publicado no *site*, abordando informações detalhadas sobre números absolutos, frequência de sintomas e dados sobre óbitos/recuperações. A arquitetura do *data warehouse* foi projetada para respostas interativas às solicitações dos usuários, com atualizações diárias e notificações de erros.

O projeto alcançou sucesso na implementação de um *data warehouse* eficiente, conectado a um painel interativo, proporcionando uma solução abrangente e amigável para usuários de BI.

No estudo ([SILVA, 2021b](#)), o projeto teve como objetivo utilizar mineração de dados para analisar e prever a recuperação de pacientes com síndrome respiratória aguda grave (SRAG) na região nordeste do Brasil. Utilizando a Plataforma Integrada de Dados

do Ministério da Saúde, técnicas de pré-processamento e o RapidMiner, foram aplicados algoritmos para prever a recuperação de pacientes, destacando a eficácia da Árvore de Decisão.

O estudo, fundamentado no KDD, analisou dados do Ministério da Saúde, revelando que a COVID-19 foi a causa mais influente. A Árvore de Decisão destacou-se, prevendo o número máximo de dias para a recuperação e a faixa etária de alto risco. A precisão do modelo foi maior em pacientes mais idosos, com uma taxa mais baixa de óbitos em pacientes jovens.

O desempenho foi avaliado considerando especificidade, sensibilidade e precisão, destacando a superioridade da Árvore de Decisão na previsão de óbitos por COVID-19. O estudo contribuiu para a descoberta de conhecimentos em SRAG e saúde, embora apresentasse limitações nos dados de 2021 e no foco no nordeste brasileiro.

Apesar das limitações, o estudo sugere que pesquisas futuras explorem novas abordagens, consolidando-se como base para análises mais aprimoradas em casos semelhantes de SRAG.

O estudo (RIBEIRO; CORDEIRO; ALVES, 2022) utilizou modelagem preditiva via árvore de decisão para analisar casos de Síndrome Respiratória Aguda Grave (SRAG), com foco na COVID-19 no Brasil (2020-2022). Utilizando dados do OpenDataSUS, a pesquisa destacou o desenvolvimento da vigilância de SRAG e a integração da vigilância da COVID-19 à rede existente. O estudo empregou três conjuntos de dados, validação cruzada e o *software* RapidMiner.

A árvore de decisão revelou as probabilidades de recuperação e óbito para diferentes condições de comorbidade em pacientes com SRAG. A análise considerou casos gerais de SRAG e casos específicos relacionados à COVID-19. Os resultados indicaram que certas comorbidades, como doença renal crônica e asma, influenciam significativamente as chances de cura. O estudo concluiu que a modelagem preditiva por árvore de decisão é uma ferramenta valiosa para análise de dados de SRAG, sugerindo seu uso em configurações regionais e estaduais para explorar correlações e entender as motivações por trás dos resultados.

Por fim, o estudo (SILVA, 2021a) realiza uma análise exploratória da base de dados SRAG do SUS e emprega métodos de aprendizagem supervisionada para prever a evolução dos casos (óbito ou cura). Duas bases foram comparadas: uma contendo parâmetros clínicos e outra incluindo parâmetros demográficos. Diversos classificadores foram utilizados, com destaque para o XGBoost, que obteve a melhor área sob a curva (AUC) de 0,86. A análise identificou parâmetros-chave, como suporte ventilatório invasivo, idade acima de 70 anos, internação na UTI e morar nas regiões nordeste ou norte. A inclusão de parâmetros demográficos melhorou os resultados. O estudo destaca a importância da colaboração entre

epidemiologistas e especialistas em análise de dados para aprimorar a compreensão e gestão de epidemias, especialmente em contextos de desigualdade social. O trabalho conclui que modelos de classificação são eficientes para direcionar ações e pesquisas, oferecendo *insights* relevantes sobre a evolução da COVID-19 no Brasil.

4 Desenvolvimento e Metodologia

4.1 Ferramentas de trabalho

As análises e manipulações de dados foram conduzidas utilizando a linguagem de programação Python, uma escolha amplamente reconhecida pela sua versatilidade e extensa variedade de bibliotecas especializadas em mineração de dados. Dentre as ferramentas empregadas, destacam-se:

- Python: A linguagem de programação principal que serviu como a espinha dorsal de todo o processo de análise. Sua sintaxe clara e a vasta comunidade de desenvolvedores contribuíram para a eficiência e flexibilidade do projeto.
- Pandas: Uma biblioteca essencial para a manipulação e análise de dados em Python. A biblioteca Pandas foi útil no processo de combinação dos conjuntos de dados, e manipulações relevantes, como a eliminação de colunas irrelevantes e realização de operações de limpeza e processamento.
- NumPy: A biblioteca Numpy é utilizada para operações numéricas eficientes em Python, o NumPy facilitou o trabalho com vetores e matrizes, contribuindo para a análise estatística e o processamento eficaz dos dados.
- Matplotlib e Seaborn: Essas bibliotecas foram empregadas para a criação de visualizações gráficas, oferecendo uma gama variada de representações dos dados de forma clara e informativa. O Matplotlib proporcionou flexibilidade quando foi necessário, enquanto o Seaborn simplificou a criação de gráficos estatísticos relevantes.
- mlxtend: A biblioteca mlxtend foi empregada para a aplicação do algoritmo FP-Growth, facilitando a aplicação e execução do algoritmo e permitindo a descoberta de padrões frequentes e associações relevantes nos dados.
- Scikit-learn: A biblioteca Scikit-learn foi essencial para a construção e treinamento do modelo de árvore de decisão. Esta biblioteca forneceu ferramentas eficazes para a análise de correlações entre parâmetros e a identificação das mais impactantes na predição da evolução dos casos, sem a necessidade de implementar algoritmos de *machine learning* do zero.
- TensorFlow: A biblioteca TensorFlow foi utilizada para a aplicação de redes neurais, permitindo a construção e o treinamento de modelos complexos com foco em predições mais precisas do desfecho final do paciente para a evolução do caso. Sua capacidade

de lidar com grandes volumes de dados e realizar cálculos em paralelo foi crucial para a eficiência do processo de aprendizado de máquina.

- **Power BI:** O Power BI foi utilizado para a criação de *dashboards* interativos e relatórios visuais, facilitando a análise e a apresentação dos resultados de forma dinâmica. A ferramenta possibilitou a integração de dados provenientes de diversas fontes, além da criação de gráficos e relatórios que permitiram *insights* rápidos e eficientes sobre as tendências e padrões encontrados nos dados de SRAG.
- **Optuna:** A biblioteca Optuna foi utilizada para automatizar a otimização de hiperparâmetros da rede neural. Optuna oferece uma abordagem eficiente e automatizada para a busca de hiperparâmetros ideais, utilizando técnicas de otimização baseadas em algoritmos de busca avançada, como o algoritmo de otimização Bayesiana. Isso permitiu melhorar o desempenho da rede neural e obter melhores resultados preditivos de forma mais eficiente e automatizada.

Ao utilizar essas ferramentas em conjunto com a linguagem Python, foi possível obter uma abordagem eficiente e satisfatória na análise dos registros de SRAG, permitindo a obtenção de *insights* valiosos sobre os padrões e fatores associados à evolução dos casos.

4.2 Ambiente e Coleta dos Dados

Os dados utilizados neste trabalho foram extraídos do portal do Ministério da Saúde (MS), especificamente da Secretaria de Vigilância em Saúde (SVS). Estes dados estão disponíveis no portal [OPENDATASUS](#). O banco de dados de Síndrome Respiratória Aguda Grave (SRAG) cobre o período de 2017 a setembro de 2023 e inclui informações sobre síndromes respiratórias graves em decorrência da COVID-19, Influenza e outras doenças respiratórias.

Os dados são fornecidos em formato CSV (*comma-separated values*) e são atualizados semanalmente. Os arquivos disponíveis são divididos por ano e incluem:

- **SRAG 2017:** Dados referentes ao ano de 2017.
- **SRAG 2018:** Dados referentes ao ano de 2018.
- **SRAG 2019:** Dados referentes ao ano de 2019.
- **SRAG 2020 – 01/05:** Dados referentes ao ano de 2020.
- **SRAG 2021 – 01/05:** Dados referentes ao ano de 2021.
- **SRAG 2022 – 03/04:** Dados referentes ao ano de 2022.

- **SRAG 2023 – 02/09:** Dados referentes ao ano de 2023.

A coleta dos dados, como mostrado na Figura 5, inclui o uso de dicionários de dados que acompanham os arquivos CSV. Estes dicionários fornecem informações detalhadas sobre a estrutura dos dados, as definições dos parâmetros e os códigos utilizados para categorizar as informações. Os dicionários de dados são essenciais para a correta interpretação e utilização das bases e estão disponíveis em formato PDF no portal OPENDATASUS juntamente com os arquivos csv.

Dicionário de Dados

FICHA DE REGISTRO INDIVIDUAL – CASOS DE SÍNDROME RESPIRATÓRIA AGUDA GRAVE HOSPITALIZADOS

Este documento tem como finalidade descrever as variáveis exportadas para o banco de dados em DBF.

CAMPO OBRIGATÓRIO é aquele cuja ausência de dado impossibilita a inclusão do registro no sistema.
CAMPO ESSENCIAL é aquele que, apesar de não ser obrigatório, registra dado necessário à investigação do caso ou ao cálculo de indicador epidemiológico ou operacional.
CAMPO INTERNO é aquele que apesar de não constar na ficha e não aparecer no display da tela, é preenchido automaticamente pelo sistema.
CAMPO OPCIONAL é aquele que só deve ser preenchido caso seja necessário, aparece no display da tela e consta no banco de dados.

Nome do campo	Tipo	Categoria	Descrição	Características	DBF
Nº	Varchar2(12)		Número do registro	Campo Interno Número sequencial gerado automaticamente pelo sistema. Utilizar o padrão: 320120000123 Dígito 1: caracteriza o tipo da ficha (1=SG, 2=SRAG-UTI e 3=SRAG Hospitalizado). Dígitos 2 a 12: número sequencial gerado automaticamente pelo sistema.	NU_NOTIFIC
1-Data do preenchimento da ficha de notificação	Date DD/MM/AAAA		Data de preenchimento da ficha de notificação.	Campo Obrigatório Data deve ser <= a data da digitação.	DT_NOTIFIC
Semana Epidemiológica do preenchimento da ficha de notificação	Varchar2(6)		Semana Epidemiológica do preenchimento da ficha de	Campo Interno Calculado a partir da data dos Primeiros Sintomas. (SS)	SEM_NOT

SIVEP Gripe- Sistema de Informação da Vigilância Epidemiológica da Gripe. Página 1

Figura 5 – Amostra de Dicionário de dados base SRAG (SAUDE, 2024)

O tratamento dos dados inclui anonimização, em conformidade com a Lei 13.709/2018, garantindo a privacidade dos indivíduos. Os dados são disponibilizados com granularidade temporal diária e granularidade geográfica municipal, cobrindo todo o território nacional. Estes arquivos estão sujeitos a atualizações e correções de erros conforme os processos de revisão e investigação das equipes de vigilância epidemiológica.

A coleta e o tratamento desses dados são fundamentais para a análise e descoberta de padrões relacionados a surtos de SRAG e COVID-19, possibilitando a formulação de políticas de saúde pública e estratégias de mitigação. É importante observar que os dados utilizados provêm de fontes que passaram por diferentes processos de tratamento, o que pode resultar em variações nos parâmetros e na inclusão de novos parâmetros em bases de dados subsequentes, o que foi tratado durante o desenvolvimento do estudo.

Para garantir a consistência nas análises deste projeto, foi importante considerar as variações nos parâmetros e os campos que divergiram em versões distintas da base

de dados. Os dicionários de dados forneceram informações altamente relevantes para compreender essas variações e assegurar a correta interpretação dos dados.

4.3 Mineração de dados aplicada às bases de dados

Iniciou-se a análise com a importação das bibliotecas essenciais para manipulação e visualização de dados, como Pandas, Numpy, Seaborn, Matplotlib e Scikit-learn. Diversos conjuntos de dados relacionados aos registros de casos de SRAG de diferentes anos foram obtidos para a análise subsequente.

4.3.1 Unificação de Dados e Eliminação de Colunas Irrelevantes

Inicialmente, os dados abertos utilizados consistiam em sete *datasets* distintos, contendo as informações associadas ao contágio de SRAG em cada ano de 2017 a 2023. Foi feita, então, uma combinação dos *datasets*, formando um *dataset* único, com as informações de todos os anos. Para isso, foram feitos ajustes devido a algumas diferenças entre parâmetros de um *dataset* para outro.

Em seguida, foi realizada uma limpeza da base de dados, retirando colunas consideradas irrelevantes para os objetivos da análise. Informações como IDs, detalhes geográficos específicos redundantes, exames e dados de vacinação irrelevantes para o estudo foram removidos. Para realizar essa limpeza, foi feita uma análise manual e de correlação linear utilizando a correlação de Pearson para analisar a similaridade de cada parâmetro, identificando parâmetros redundantes. Dessa forma, foram removidos somente parâmetros com impacto limitado na investigação realizada.

Na Tabela 1, é possível observar os parâmetros com maior correlação entre si ao aplicar a correlação de Pearson na base de dados.

4.4 Análise da Correlação entre parâmetros de Geolocalização

A intuição de exemplo, podemos observar uma alta correlação entre parâmetros de geolocalização, como CO_REGIONA e CO_RG_RESI, ou CO_MUN_NOT e CO_MUN_RES. Suspeitou-se que os principais motivos para essas fortes correlações são:

- **Relacionamento Direto:** parâmetros como CO_REGIONA e CO_RG_RESI representam códigos para regionais de saúde e estão diretamente relacionados.
- **Preenchimento Automático:** A alta correlação resulta do preenchimento automático entre nomes e códigos, como observado em CO_MUN_NOT e CO_MUN_RES.

Feature 1	Feature 2	Correlation Value
SEM_NOT	NU_IDADE_N	0.9864
CO_REGIONA	CO_RG_RESI	0.9374
CO_REGIONA	CO_RG_INTE	0.9991
CO_MUN_NOT	CO_MUN_RES	0.9909
CO_MUN_NOT	CO_MU_INTE	0.9999
NU_IDADE_N	SEM_NOT	0.9864
CO_RG_RESI	CO_REGIONA	0.9374
CO_RG_RESI	CO_RG_INTE	0.9382
CO_MUN_RES	CO_MUN_NOT	0.9909
CO_MUN_RES	CO_MU_INTE	0.9905
HEMATOLOGI	HEPATICA	0.9210
HEPATICA	HEMATOLOGI	0.9210
M_AMAMENTA	CO_PS_VGM	0.9755
CO_RG_INTE	CO_REGIONA	0.9991
CO_RG_INTE	CO_RG_RESI	0.9382
CO_MU_INTE	CO_MUN_NOT	0.9999
CO_MU_INTE	CO_MUN_RES	0.9905
TP_FLU_PCR	TP_FLU_AN	0.9065
CO_PS_VGM	M_AMAMENTA	0.9755
PERD_OLFT	PERD_PALA	0.9482
PERD_PALA	PERD_OLFT	0.9482
TP_FLU_AN	TP_FLU_PCR	0.9065
RES_IGG	RES_IGM	0.9046
RES_IGM	RES_IGG	0.9046
IDADE	QUINQUENIO	0.9994
QUINQUENIO	IDADE	0.9994

Tabela 1 – Correlação entre os parâmetros na base de dados. (Autor)

- **Regras de Dados:** O sistema segue regras predefinidas para preencher os dados, contribuindo para a correlação elevada entre os parâmetros.
- **Dependência de Dados de Entrada:** Campos relacionados ao mesmo CEP ou município mostram alta correlação devido à dependência dos dados de entrada.

Devido a essas correlações, foi mantido apenas um código por localização geográfica, como um código para município e um código para região. Além disso, a eliminação de parâmetros com alta correlação foi realizada por meio de análises de relevância, o que ajudou a melhorar a qualidade dos parâmetros e reduzir a dimensionalidade da base de dados.

4.4.1 Análise de Valores Ausentes e Processamento de Datas

Uma análise inicial foi realizada para identificar valores ausentes em cada coluna, representando graficamente essas ausências por meio de um gráfico de barras, que pode ser observado na Figura 6:




Figura 6 – Valores ausentes em cada parâmetro (Autor).

Nesse gráfico, é possível observar que há uma quantidade considerável de valores nulos em grande parte dos parâmetros da base de dados. Isso ocorre porque muitos desses parâmetros só possuem valor caso o paciente se enquadre em alguma situação específica. No parâmetro **DIABETES** por exemplo, só há valores não nulos nas linhas correspondente a pacientes que tiveram essa informação preenchida durante o atendimento. No entanto, há ainda assim alguns parâmetros que de fato possuem valores nulos por problemas de preenchimento e fatores adversos durante o preenchimento das informações.

Também foi feito um processamento das datas presentes nessa base de dados. Isso ocorre porque o formato de data presente, não é o reconhecido por padrão pelo Python e, conseqüentemente, pelas funções presentes nas bibliotecas utilizadas. Dessa forma, o formato de data foi modificado para o padrão entendido pelo Python, garantindo uma representação que facilitou as análises posteriores.

4.4.2 Análise da Distribuição por Idade

Nesta seção, foi explorada a distribuição de casos de SRAG de acordo com faixas etárias, o que permitiu uma compreensão mais aprofundada do impacto dessa síndrome em diferentes grupos etários. A análise da distribuição por idade revelou padrões distintos sobre a vulnerabilidade de determinadas faixas etárias à SRAG.

O gráfico “Distribuição por faixa de idade” presente na Figura 7 foi elaborado para destacar a variação na incidência de casos de SRAG em diferentes grupos etários. Cada barra no gráfico representa uma faixa etária específica, contendo um intervalo de 5 anos, enquanto a altura da barra indica a quantidade de casos registrados. Essa representação visual proporcionou uma visão clara da distribuição da doença na população em diferentes faixas etárias.

A análise da distribuição por idade revelou que crianças com idades de 1 até antes de completar 5 anos apresentaram uma incidência significativamente mais alta de casos de SRAG, indicando uma possível vulnerabilidade nessa faixa etária. Em contraste, crianças com idade superior a 5 anos e adultos mais jovens (25 a 34 anos) demonstraram ser menos propensos a contrair a doença.




Figura 7 – Distribuição por faixa de idade (Autor).

4.4.3 Análise de subgrupos

Por meio da análise exploratória de dados, alguns subgrupos presentes na base de dados SRAG se demonstraram interessantes. Por esse motivo, tais subgrupos foram analisados separadamente, fornecendo informações interessantes.

4.4.3.0.1 Crianças de até 5 anos

Ao explorar mais detalhadamente a distribuição por idade, optou-se por focar especificamente no grupo de crianças de 0 a 5 anos devido ao número expressivo de casos nessa faixa etária. A análise da evolução dos casos nesse grupo revelou padrões intrigantes.

Apesar da incidência significativamente mais alta de contágios nessa faixa etária, surpreendentemente, a taxa de recuperação se demonstrou bastante elevada em comparação com a média geral da base de dados, podendo ser observado na Figura 8. Esse fenômeno sugere uma resistência alta para com essa síndrome, nesse grupo específico.




Figura 8 – Distribuição de evolução dos casos para crianças de até 5 anos (Autor)

A homogeneidade nos resultados de evolução dos casos entre as crianças de 0 a 5 anos indica que, embora tenham sido mais frequentemente afetadas, a capacidade de recuperação

foi bem mais elevada. Essa recuperação pode ser um indicativo de características específicas nessa faixa etária que devem ser estudadas com mais profundidade futuramente.

Contudo, diante desses resultados, concluiu-se que a análise mais abrangente da base de dados como um todo é mais interessante para esse estudo do que a análise focada apenas nesse subgrupo específico, devido a homogeneidade da evolução dos casos nesse subgrupo. A compreensão dos padrões de contágio e recuperação em diferentes faixas etárias ganha maior profundidade quando consideramos a interação desses grupos com a totalidade dos dados.

4.4.4 Análise temporal

Realizando a análise temporal sobre os casos de Síndrome Respiratória Aguda Grave (SRAG), evidenciou-se uma influência significativa do surto pandêmico da COVID-19 nos padrões de ocorrência ao longo do período estudado, de 2017 a 2023.




Figura 9 – Distribuição de casos por cada mês de cada ano da base de dados (Autor)

Na Figura 9, observa-se que o ano de 2020, marcado pelo início da pandemia, apresentou um pico expressivo no número de casos. O impacto mais significativo ocorreu a partir de março de 2020, quando a disseminação da COVID-19 no Brasil se intensificou, resultando em um aumento considerável de casos de SRAG.

Similarmente, os meses próximos ou pertencentes à estação de outono (março, abril, maio, junho e julho) foram os períodos de maior incidência de casos. Essa observação destaca a importância de considerar fatores sazonais na gestão da SRAG, especialmente durante esses meses.

Além disso, a análise do percentual de casos com evolução de cura ao longo dos anos evidenciou a dinâmica da recuperação dos pacientes, como pode ser observado na Figura 10. Antes da pandemia, mais de 80% dos casos apresentavam evolução de cura. No entanto, durante os anos de 2020 e 2021, esse percentual reduziu drasticamente, atingindo um mínimo de 62% em março de 2021. Esse declínio pode ser atribuído à sobrecarga do

sistema de saúde, ao aumento da gravidade dos casos devido à COVID-19 e às incertezas iniciais sobre o tratamento da doença.




Figura 10 – Porcentagem de Casos com evolução para cura em cada mês de cada ano estudado. (Autor)

A partir do momento em que medidas mais eficazes, incluindo vacinação em massa, foram implementadas, observou-se um aumento gradual na taxa de recuperação nos anos subsequentes. Essa tendência sugere que as estratégias de resposta à pandemia contribuíram para melhorar os desfechos dos casos de SRAG. Como mencionado na Seção 4.2, os dados coletados vão até agosto de 2023. Portanto, a Figura 9 não inclui informações referentes a partir do mês 10 para o ano de 2023. No gráfico da Figura 10, o percentual de cura para o mês 10 de 2023 aparece anormalmente alto. Isso se deve ao pequeno volume de dados coletados para esse mês, por decorrência de possíveis erros de anotação. Como o valor de cura foi normalizado, essas irregularidades resultaram em uma distorção para o mês em questão.

4.5 Aplicação da Árvore de Decisão de Classificação

A fim de analisar a importância dos parâmetros no resultado final da evolução dos casos, foi implementado um código que utiliza o algoritmo de Árvore de Decisão de Classificação, aplicado a base de dados estudada. A base de dados foi separada em duas partes, uma de treino contendo 80% dos dados e outra de teste contendo 20%. O algoritmo de Árvore de Decisão de Classificação foi então executado no *dataset* de teste e validado posteriormente no *dataset* de validação. Os resultados obtidos a respeito dos 20 parâmetros que demonstram maior importância estão descritos na Tabela 2.

Com base nos resultados obtidos da implementação da árvore de classificação, é possível observar a importância relativa dos diferentes parâmetros na predição da evolução dos casos, indicando quais características têm maior influência no modelo. As 20 primeiras

parâmetro	Importância na Predição
CLASSI_FIN	0.1195
SUPPORT_VEN	0.1064
IDADE	0.0774
CO_UNI_NOT	0.0604
SEM_NOT	0.0487
CO_MUN_RES	0.0291
NU_IDADE_N	0.0279
CO_MUN_NOT	0.0269
CO_MU_INTE	0.0251
CO_REGIONA	0.0185
UTI	0.0172
CO_RG_RESI	0.0164
CS_ESCOL_N	0.0147
RAIOX_RES	0.0145
TOMO_RES	0.0127
CS_RACA	0.0127
CO_RG_INTE	0.0126
RES_AN	0.0119
CRITERIO	0.01145

Tabela 2 – Importância dos parâmetros na predição da evolução dos casos.

linhas destacam a contribuição de cada parâmetro, conforme a importância atribuída pelo algoritmo. Algumas observações podem ser feitas a partir desses resultados:

- Parâmetros mais importantes: **CLASSI_FIN**, **SUPPORT_VEN** e **IDADE** são as três parâmetros mais importantes na predição da evolução do caso. Isso sugere que a natureza da classificação final, o suporte ventilatório e a idade do paciente desempenham papéis cruciais na determinação da evolução do paciente.
- Outros parâmetros relevantes: Outros parâmetros, como **CO_UNI_NOT**, **SEM_NOT**, e **CO_MUN_RES**, também apresentam importância significativa, indicando que informações sobre a unidade de notificação, semana de notificação e município de residência têm impacto na predição da evolução do caso.
- Possíveis *insights* clínicos: Alguns parâmetros relacionados a exames e sintomas, como **RAIOX_RES**, **TOMO_RES**, **TOSSE** e **FEBRE**, também são relevantes, o que sugere que esses fatores clínicos têm influência na evolução do quadro.
- Considerações práticas: A informação sobre a importância relativa dos parâmetros pode ser útil na otimização do modelo de predição ou na tomada de decisões clínicas. Para o contexto desse projeto, espera-se para os próximos passos utilizar essa avaliação de importância para fazer uma análise mais aprofundada na consideração dos parâmetros para possíveis análises de predição.

A Árvore de Decisão de Classificação se demonstrou uma ferramenta útil para compreender os fatores que mais influenciam a evolução dos casos e pode ser aprimorada ao longo do tempo com mais refinamentos e ajustes.

4.5.1 Heatmap

A correlação de Pearson foi utilizada novamente, para a criação de um *Heatmap* que evidencia parâmetros que possuem uma forte correlação entre si. A visualização foi disponibilizada na dashboard disponível no [link Dashboard 1](#). É possível observar alguns pontos de interesse importantes na Figura 11:




Figura 11 – *heatmap*, destaque dos fatores de risco. (Autor)

A partir dessa visualização, é possível observar quais parâmetros possuem forte correlação linear entre si. Quanto mais escuro o tom de azul, mais forte é a correlação direta entre os dois parâmetros, quanto mais avermelhada maior é a correlação inversa, e branco representa ausência de correlação. Esses *insights* ajudam a entender quais são os principais pontos de atenção para os pacientes no quadro de síndrome respiratória aguda grave. Fica evidente na Figura 11 que fatores de risco como asma, diabetes, uso de imunodepressivos, tem uma influência significativa na ocorrência de sintomas relacionados a síndrome respiratória. Isso pode indicar um ponto de atenção para pessoas com esses fatores de risco, devendo ser tratados de forma mais cuidadosa.

ATRIBUTOS	62_DOR_ABD	63_FADIGA	64_PERD_OLFT	65_PERD_PALA
62_DOR_ABD	1,00			
63_FADIGA	0,78	1,00		
64_PERD_OLFT	0,80	0,73	1,00	
65_PERD_PALA	0,79	0,73	0,95	1,00

Figura 12 – FP-Growth. (Autor)

Observando agora a Figura 12, como esperado, podemos perceber um indicativo de correlação entre os sintomas da síndrome, o que é evidente, visto que pessoas que desenvolvem um sintoma que afeta o sistema respiratório, tendem a ter sintomas correlatos,

no entanto, podemos ver com mais precisão quais sintomas possuem mais correlação entre si.

4.5.2 *Insights* obtidos a partir da aplicação do FP-Growth

Aplicando o FP-Growth, foram obtidos resultados importantes. As regras de associação geradas pelo FP-Growth demonstram uma relação significativa entre alguns parâmetros. Podemos analisar, por exemplo, na Figura 13, as regras mais relevantes associadas a evolução dos casos para óbito.

Antecedente	Consequente	Suporte	Confiança	Leverage	Lift	Métrica Zhangs
'CLASSI_FIN_5.0'	'EVOLUCAO_2.0'	0,18	0,31	0,05	1,35	0,61
'PUERPERA_2.0'	'EVOLUCAO_2.0'	0,10	0,28	0,02	1,24	0,30
'SIND_DOWN_2.0'	'EVOLUCAO_2.0'	0,10	0,28	0,02	1,23	0,29
'HEPATICA_2.0'	'EVOLUCAO_2.0'	0,10	0,28	0,02	1,22	0,27
'SATURACAO_1.0'	'EVOLUCAO_2.0'	0,16	0,27	0,03	1,20	0,40
'DESC_RESP_1.0'	'EVOLUCAO_2.0'	0,14	0,26	0,02	1,14	0,27
'CRIANCA_-1.0'	'EVOLUCAO_2.0'	0,23	0,26	0,03	1,12	0,93
'DISPNEIA_1.0'	'EVOLUCAO_2.0'	0,17	0,26	0,02	1,12	0,33
'CRITERIO_1.0'	'EVOLUCAO_2.0'	0,20	0,24	0,01	1,05	0,28
'CS_SEXO_1'	'EVOLUCAO_2.0'	0,13	0,24	0,00	1,03	0,06
'AMOSTRA_1.0'	'EVOLUCAO_2.0'	0,21	0,23	0,00	1,02	0,16
'CS_ZONA_1.0'	'EVOLUCAO_2.0'	0,19	0,23	0,00	1,01	0,05
'TP_AMOSTRA_1.0'	'EVOLUCAO_2.0'	0,18	0,23	0,00	1,00	0,02
'VOMITO_2.0'	'EVOLUCAO_2.0'	0,13	0,23	0,00	1,00	-0,01
'HOSPITAL_1.0'	'EVOLUCAO_2.0'	0,21	0,22	0,00	0,98	-0,26
'CS_GESTANT_6.0'	'EVOLUCAO_2.0'	0,15	0,22	0,00	0,97	-0,07
'NOSOCOMIAL_2.0'	'EVOLUCAO_2.0'	0,16	0,22	0,00	0,97	-0,09
'AVE_SUINO_2.0'	'EVOLUCAO_2.0'	0,14	0,22	0,00	0,97	-0,08
'CS_SEXO_0'	'EVOLUCAO_2.0'	0,10	0,22	0,00	0,96	-0,06
'ESTRANG_2.0'	'EVOLUCAO_2.0'	0,11	0,21	-0,01	0,91	-0,17
'TOSSE_1.0'	'EVOLUCAO_2.0'	0,14	0,20	-0,02	0,89	-0,29

Figura 13 – FP-Growth, regras associadas ao desfecho de não recuperação. (Autor)

Analisando detalhadamente as regras de associação mais relevantes, podemos observar *insights* que influenciam o resultado final, especificamente a evolução dos casos para óbito (EVOLUCAO_2.0).

Com base nas regras de associação obtidas, seguem algumas observações significativas:

- **Parâmetros com maior influência:** Alguns parâmetros exibem uma relação direta e significativa com a probabilidade de evolução para óbito. Por exemplo,

podemos observar na Figura 13 que o parâmetro `CLASSI_FIN_5.0`, que indica que a classificação final do caso foi relacionada à COVID-19, `PUERPERA_2.0`, que mostra que o paciente não é puérpera ou parturiente, e `SIND_DOWN_2.0`, que corresponde a pacientes sem síndrome de Down, apresentam uma influência considerável na predição de óbito. Esses fatores se destacam na determinação da gravidade do quadro clínico do paciente.

- **Impacto de condições clínicas específicas:** Condições como `HEPATICA_2.0`, `SATURACAO_1.0`, e `DESC_RESP_1.0` também estão fortemente associadas ao óbito, o que pode ser observado pelos valores de *lift* significativos. Isso sugere que problemas hepáticos, saturação reduzida e dificuldades respiratórias são indicadores importantes da gravidade do caso, refletindo a gravidade da condição clínica dos pacientes.

Esses *insights* podem ser utilizados para aprimorar a gestão de pacientes com SRAG, ajudando a identificar fatores de risco associados a desfechos graves e possibilitando intervenções mais direcionadas. No entanto, as regras associadas diretamente a evolução dos casos para óbito não obtiveram uma confiança significativa, o que impede conclusões mais firmes e próximas da realidade. Apesar disso, diversas regras importantes com maior relevância foram geradas relacionando outros parâmetros, e serão discutidas a seguir.

4.5.3 Tabela FP-Growth

Também foi gerada, uma Tabela tratada, com todas as regras geradas pelo FP-Growth. A Tabela da Figura 14 foi gerada com dados de todas as regras com confiança acima de 30% e suporte acima de 20%. Além disso, foram feitas tratativas para remover regras menos relevantes para o estudo:

- **Remoção de regras com mais de 3 parâmetros:** Foram removidas regras com mais de três parâmetros nos antecedentes ou nos consequentes, a fim de focar em regras mais diretas e simples de serem interpretadas. É importante ressaltar que a remoção dessas regras não gera uma perda significativa, visto que as regras com mais de três parâmetros possuem regras que representam informação similar no conjunto de regras com no máximo três parâmetros, só que de forma decomposta.
- **Remoção de regras com não ocorrência de parâmetros:** Regras que indicam a não ocorrência de um parâmetro, que ocorrem bastante em atributos como `FEBRE`, que possuem classes binárias (ocorreu ou não ocorreu), foram removidas, com exceção do caso de `EVOLUCAO`, e alguns outros casos estratégicos. Essa tratativa foi feita porque essas regras não geram informações relevantes, visto que o objetivo foi identificar a ocorrência entre parâmetros, e não a não ocorrência.

O intuito dessa Tabela é possibilitar a análise mais minuciosa de *insights* que podem auxiliar em melhorias de medidas para tratamento desse tipo de síndrome. Seguem alguns exemplos de regras relevantes obtidas:

- **Relação entre dispneia e tosse :** Os parâmetros DISPNEIA_1 e TOSSE_1 (Figura 16) representam a ocorrência desses sintomas para um dado paciente. Esses sintomas apresentam com um alto nível de suporte (0.49), o que indica que aproximadamente metade dos pacientes que apresentaram sintoma de tosse, também apresentaram dispneia¹.
- **Relação entre hospitalização e evolução do caso:** os parâmetros HOSPITAL_1 e EVOLUCAO_1 (Figura 15) indicam respectivamente, que o paciente foi hospitalizado e se recuperou da síndrome. O suporte de 0.63 para essa regra na Tabela, demonstra que 63% dos pacientes que foram hospitalizados se recuperaram. Já a confiança de 0.66 demonstra que a probabilidade de um paciente ser hospitalizado e se recuperar da síndrome é de 66%.
- **Relação entre dificuldade respiratória e outros sintomas:** O parâmetro DESC_RESP_1.0 (dificuldade respiratória) está relacionado a três consequentes importantes: CRITERIO_1.0 (critério de gravidade), DISPNEIA_1.0 (ocorrência de dispneia) e SATURACAO_1.0 (saturação de O₂ < 95%). O suporte para essas regras (Figura 17) varia entre 0.42 e 0.47, indicando que aproximadamente 42-47% dos pacientes com dificuldade respiratória apresentam esses sintomas ou condições associadas. A confiança das regras, entre 0.75 e 0.85, mostram alta probabilidade de coocorrência desses sintomas. O *lift* varia de 1.01 (relação neutra com o critério de gravidade) até 1.30 (correlação positiva com saturação baixa), reforçando a relevância dessas combinações.

¹ Sensação de dificuldade ou desconforto para respirar, frequentemente descrita como falta de ar.

Antecedentes	Consequentes	Sup. Antecedente	Sup. Consequente	Suporte	Confiança	lift	Leverage	C
	PCR_RESUL_1.0, POS_PCROUT_1.0							
SATURACAO_1.0, CRITERIO_1.0, POS_PCROUT_1.0	HOSPITAL_1.0, AMOSTRA_1.0	0,23	0,86	0,22	0,98	1,14	0,03	
EVOLUCAO_1.0, POS_PCROUT_1.0	AMOSTRA_1.0, CRITERIO_1.0	0,24	0,80	0,23	0,98	1,22	0,04	
SATURACAO_1.0, PCR_RESUL_1.0, POS_PCROUT_1.0	HOSPITAL_1.0	0,23	0,95	0,23	0,98	1,04	0,01	
AMOSTRA_1.0, POS_PCROUT_1.0, SATURACAO_1.0	HOSPITAL_1.0	0,23	0,95	0,23	0,98	1,04	0,01	
SATURACAO_1.0, POS_PCROUT_1.0	HOSPITAL_1.0	0,23	0,95	0,23	0,98	1,04	0,01	
HOSPITAL_1.0, EVOLUCAO_1.0, POS_PCROUT_1.0	PCR_RESUL_1.0, CRITERIO_1.0	0,23	0,40	0,23	0,98	2,48	0,14	
SATURACAO_1.0, PCR_RESUL_1.0, POS_PCROUT_1.0	HOSPITAL_1.0, AMOSTRA_1.0	0,23	0,86	0,23	0,98	1,14	0,03	
HOSPITAL_1.0, EVOLUCAO_1.0, POS_PCROUT_1.0	PCR_RESUL_1.0, AMOSTRA_1.0, CRITERIO_1.0	0,23	0,40	0,23	0,98	2,48	0,14	
EVOLUCAO_1.0, DISPNEIA_1.0, CRITERIO_1.0	HOSPITAL_1.0	0,38	0,95	0,37	0,98	1,04	0,01	

Figura 14 – Tabela de regras FP-Growth. (Autor)

Antecedentes	Consequentes	Antecedente SUP	Consequente Sup	Suporte	Confiança	lift	leverage	conviction	zhangs_metric
HOSPITAL_1.0	AMOSTRA_1.0, EVOLUCAO_1.0	0,95	0,59	0,57	0,60	1,03	0,01	1,04	0,49
HOSPITAL_1.0	EVOLUCAO_1.0	0,95	0,65	0,63	0,66	1,02	0,01	1,04	0,40

Figura 15 – Tabela FP-Growth, regra de HOSPITAL_1. (Autor)

Antecedentes	Consequentes	Antecedente SUP	Consequente Sup	Suporte	Confiança	lift	leverage	conviction	zhangs_metric
TOSSE_1.0	DISPNEIA_1.0	0,68	0,67	0,49	0,72	1,07	0,03	1,17	0,21
TOSSE_1.0	EVOLUCAO_1.0	0,68	0,65	0,46	0,68	1,05	0,02	1,10	0,15

Figura 16 – Tabela FP-Growth, regra de TOSSE_1. (Autor)

Antecedentes	Consequentes	Sup. Antecedente	Sup. Consequente	Suporte	Confiança	lift	Leverage	Convicção	Métrica zhangs
DESC_RESP_1.0	CRITERIO_1.0	0,55	0,84	0,47	0,85	1,01	0,00	1,05	0,02
DESC_RESP_1.0	DISPNEIA_1.0	0,55	0,67	0,46	0,83	1,23	0,08	1,87	0,41
DESC_RESP_1.0	SATURACAO_1.0	0,55	0,58	0,42	0,75	1,30	0,10	1,72	0,52
DESC_RESP_1.0	TOSSE_1.0	0,55	0,68	0,40	0,73	1,07	0,03	1,18	0,15

Figura 17 – Tabela FP-Growth, regra de DESC_RESP_1. (Autor)

4.6 Análises específicas

4.6.1 Análise da Faixa Etária

Nesta seção, são apresentadas visualizações e gráficos que analisam as características relacionadas à faixa etária dos pacientes na base de dados de SRAG (Síndrome Respiratória Aguda Grave). Essas visualizações foram criadas para destacar pontos relevantes sobre a distribuição etária e a evolução dos casos, fornecendo *insights* significativos para futuras pesquisas. Mais informações sobre a dashboard contendo as informações dessas visualizações podem ser encontradas no capítulo 5

A Figura 18 exibe um gráfico de pizza que divide a população entre crianças de 0 a 5 anos e pacientes de outras faixas etárias. Essa visualização foi criada com o objetivo de destacar o percentual significativo de crianças pequenas na base de dados, a fim de analisar a característica da evolução dos casos nesse grupo etário para a SRAG.




Figura 18 – Descrição populacional por idade. (Autor)

Em seguida, a Figura 19 apresenta a distribuição da evolução dos casos por idade para crianças e a Figura 20 mostra a distribuição dos casos por faixa etária geral. É importante notar que na Figura 20 a distribuição percentual é feita em relação ao total de casos do *dataset*, e não em relação ao total de casos de cada faixa etária, visto que o objetivo é justamente compreender o comportamento da distribuição percentual dos casos no escopo geral da base de dados. Essas visualizações permitem um comparativo entre as diferentes idades e evidenciam, especialmente para crianças até 5 anos, a discrepância da evolução dos casos entre essa faixa etária e as dos demais pacientes.

A análise também revela que, em todas as idades até 5 anos, a quantidade de casos de óbito é significativamente menor em comparação com outras faixas etárias. Por outro lado, observa-se que, a partir dos 30 anos, o percentual de óbitos aumenta progressivamente com a idade, sendo mais elevado entre pacientes com mais de 65 anos. Esses dados destacam a necessidade de atenção especial para idosos em estratégias de saúde pública voltadas ao combate da SRAG.




Figura 19 – Relação entre faixa etária infantil e evolução dos casos. (Autor)




Figura 20 – Distribuição percentual de casos por faixa etária e evolução. (Autor)

4.6.2 Análise de Correlação entre Sintomas

Os sintomas, comorbidades e informações hospitalares mostraram-se fatores determinantes na evolução dos casos de SRAG, conforme observado nas análises por Árvore de Decisão. Além disso, uma forte correlação entre esses fatores foi identificada por meio da correlação de Pearson e da aplicação do algoritmo FP-Growth. Com base nesses resultados, foram desenvolvidas visualizações dinâmicas que permitem a análise da correlação entre os fatores de risco dentro de cada um desses subgrupos: sintomas, comorbidades e informações hospitalares.

Essas visualizações oferecem a capacidade de investigar como a ocorrência de um fator de risco pode influenciar a presença de outros fatores. Por exemplo, na Figura 21, é apresentada a relação de ocorrência de diversos sintomas quando o sintoma de perda de olfato está presente. Essa abordagem pode ser estendida para analisar todos os parâmetros

de interesse dentro dos três subgrupos mencionados, proporcionando uma ferramenta útil para estudos posteriores e para a criação de estratégias preventivas mais eficazes.




Figura 21 – Ocorrências de sintomas em função de um sintoma específico. (Autor)

Na Figura 21, podemos observar que o sintoma mais frequentemente associado à perda de olfato é a tosse, seguido pela dispneia. Essa análise se demonstra útil para o planejamento de cuidados clínicos, pois ao identificar a presença de um sintoma, os profissionais de saúde podem prever a alta probabilidade de ocorrência de outros sintomas relacionados. Isso pode resultar em intervenções mais ágeis e eficazes, aumentando as chances de recuperação do paciente.

É importante ressaltar que este exemplo se refere ao caso do subgrupo de sintomas, todavia essa análise também abrange subgrupos de comorbidades e informações hospitalares. Embora não estejam apresentados aqui, devido à quantidade exaustiva de análises possíveis, essas correlações estão disponíveis na *dashboard* para análise dos interessados.

4.7 Análise de Regras de Associação entre parâmetros

Com o intuito de proporcionar uma análise aprofundada e intuitiva das regras de associação geradas pelo algoritmo FP-Growth, foram desenvolvidas visualizações que facilitam a compreensão das regras e das métricas associadas. Essas informações demonstraram suma importância para a análise da síndrome respiratória aguda grave (SRAG). Adotou-se a nomenclatura de fatores clínicos para os parâmetros da base de dados, nos gráficos mostrados nessa seção, a fim de facilitar o entendimento da informação transmitida nesses gráficos,

Na Figura 22, é apresentada a frequência de ocorrência de um determinado fator clínico, em relação ao total de pacientes da base de dados. Neste exemplo, estamos analisando o fator clínico `CLASSI_FIN_5.0`, que representa pacientes cuja classificação final da síndrome foi relacionada à COVID-19. Observa-se que o valor é de 0,57, o que indica que 57% dos pacientes na base de dados foram classificados como tendo a síndrome decorrente da COVID-19. A intuito de comparação das outras classificações finais em virtude dessa regra, foi gerado um gráfico comparativo da classificação final dos casos, que pode ser observado na Figura 23, a partir dos dados do *dataset*. Podemos observar que o resultado do algoritmo se aproxima bastante do resultado gerado a partir dos dados diretamente do *dataset*. Uma leve diferença percentual é esperada devido a tratativas diferentes entre os dados do *dataset* inseridos no *Power BI* e os dados utilizados na aplicação do FP-Growth. Ambos utilizam o mesmo *dataset*, porém com algumas tratativas diferentes, devido a características intrínsecas de cada ferramenta e do algoritmo.

Frequência de Ocorrência de cada Fator clínico analisado




Figura 22 – Frequência de ocorrência do fator clínico selecionado. (Autor)

Na Figura 24, é mostrado um gráfico que analisa a frequência de ocorrência de todos os fatores clínicos identificados nas regras de associação específicas para um determinado fator clínico. Neste caso, é possível observar quais fatores clínicos, ou combinações de fatores, ocorreram dado que a classificação final foi relacionada à COVID-19, bem como a probabilidade de ocorrência de cada um desses fatores ou combinações. Por exemplo, a regra `VACINA_COV_2.0` possui um valor de 0,13, o que indica que, entre os pacientes classificados com COVID-19, 13% não foram vacinados contra a doença.

Por fim, na Figura 25, é apresentada a probabilidade de ocorrência de um fator clínico ou de uma combinação de fatores clínicos, dado que o fator clínico em análise ocorreu. No exemplo apresentado, o fator clínico analisado é o `CLASSI_FIN_5.0`. Com base nas regras de associação geradas pelo FP-Growth, é possível estimar a probabilidade de ocorrência dos demais fatores clínicos listados no gráfico. Essa informação é valiosa para




Figura 23 – Frequência de classificação final dos casos. (Autor)




Figura 24 – Frequência de ocorrência de fatores clínicos dado que o fator clínico CLASSI_FIN_5.0 ocorreu. (Autor)

profissionais da saúde e outros interessados, pois aumenta a previsibilidade dos fatores clínicos que podem ocorrer em pacientes, permitindo uma preparação mais adequada e uma melhor gestão dos cuidados.




Figura 25 – Probabilidade de ocorrência de fatores clínicos dado que o fator clínico selecionado ocorreu. (Autor)

4.8 Aplicação de Redes Neurais na Previsão da Evolução dos Pacientes de SRAG

Após a aplicação do FP-Growth e das Árvores de Decisão, identificou-se uma oportunidade para aprimorar o desenvolvimento do projeto, introduzindo uma abordagem preditiva voltada para os casos de SRAG. O esperado é que a adição de um modelo de predição ao estudo, pudesse auxiliar a gestão de saúde pública na identificação precoce de pacientes com maior risco de evolução para óbito, permitindo intervenções mais eficazes e personalizadas. Além disso, essa abordagem amplia o conjunto de ferramentas disponíveis para a tomada de decisão no combate à síndrome, contribuindo para uma resposta mais estratégica e direcionada no tratamento dos pacientes. Para isso, optou-se por utilizar um modelo de rede neural profunda, que é capaz de capturar relações não lineares complexas e interações entre os múltiplos parâmetros presentes no conjunto de dados. A escolha por esse modelo se deu em função da quantidade significativa de parâmetros mesmo após o tratamento dos dados, com mais de 130 parâmetros, o que torna as redes neurais uma ferramenta robusta para modelar a evolução dos pacientes, considerando a complexidade intrínseca das interações entre os atributos da base de dados.

Para realizar a previsão da evolução dos pacientes com Síndrome Respiratória Aguda Grave (SRAG) em direção à cura ou óbito, optou-se por utilizar um modelo de rede neural, especificamente uma rede neural profunda com camadas densas (*fully connected layers*). Essa escolha foi motivada pela capacidade das redes neurais de capturar relações não lineares complexas e interações entre os múltiplos parâmetros presentes no conjunto de dados. Dada a quantidade significativa de parâmetros após o tratamento dos dados, com mais de 130 parâmetros, as redes neurais emergem como uma ferramenta robusta para modelar a evolução dos pacientes, considerando a complexidade intrínseca das interações entre os fatores clínicos.

4.8.1 Transformação dos Dados

Antes da aplicação da rede neural, a fim de adequar os dados a aplicação de redes neurais. Foram realizadas algumas etapas de pré-processamento:

- **Filtragem dos dados com base na evolução dos casos:** Foram removidos do *dataframe* todos os pacientes com evolução dos casos diferente de 1 ou 2, ou seja, pacientes que não evoluíram para óbito ou recuperação. Essa filtragem foi realizada pois o objetivo do modelo é prever a evolução dos pacientes para cura ou óbito, valores diferentes desses representam situações atípicas como ignorados ou não informados, que não são relevantes para análise e podem prejudicar o desempenho do modelo.
- **Seleção de classes:** As classes de interesse a serem previstas são pacientes que evoluíram para óbito (classe 1) e pacientes que se recuperaram (classe 2). A coluna *EVOLUCAO* foi modificada, de forma que a classe 2 (recuperados) foi mapeada para 0, facilitando a aplicação da classificação binária.
- **Remoção de colunas:** Foram removidas colunas com alto número de valores únicos (>10), exceto pela variável idade. Essa remoção se justifica pois as colunas com grande quantidade de valores únicos eram em sua maioria categóricas, e que possuem pouca importância para a evolução, o que foi analisado a partir do heatmap de correlação (Figura 11), Árvore de Decisão de Classificação (Figura 2) e análise manual. Essas colunas também possuem uma diversidade grande de categorias e que ocorrem com pouca frequência. Esse conjunto de motivos tornaram essas colunas prejudiciais para a performance e resultado do modelo e por isso foram removidas. Além disso, após tentativas com resultados com baixa qualidade do modelo, mesmo após tratativas como separação das datas em dias, meses e anos nas colunas de datas, essas colunas foram descartadas, pois a maioria delas contém uma quantidade muito grande de valores nulos, sendo muitas vezes maior do que a quantidade de valores preenchidos, fazendo mais sentido manter a idade e a semana de notificação, que são variáveis mais relevantes para a análise.
- **Conversão e tratamento de dados categóricos:** Todas as colunas foram ajustadas para formato numérico, e tiveram seus valores nulos tratados. Para isso, visto que as colunas eram majoritariamente categóricas, para essas colunas valores nulos foram preenchidos com inteiro "0", que foi selecionado por ser diferente de todas as possibilidades categoricas das colunas presentes no *dataset*. A coluna de idade já havia sido tratada previamente.
- **Transformação dos dados:** Os dados foram transformados utilizando a função *get_dummies* do pandas, que transforma variáveis categóricas em variáveis binárias.

Essa transformação foi necessária para que os dados pudessem ser utilizados no modelo de rede neural. Devido as melhorias no tratamento dos dados, a quantidade de colunas após a aplicação do *get_dummies*, a dimensionalidade da base foi reduzida de 5000 colunas para 89, sendo essas colunas removidas pobres em informações relevantes para aplicação do modelo.

- **Balanceamento de classes:** Dado o desbalanceamento do conjunto de dados (com mais pacientes recuperados do que pacientes que vieram a óbito), foi utilizada a técnica de *Random UnderSampling* para equilibrar as classes. Esse processo reduz a quantidade de transações da classe majoritária para se equiparar à classe minoritária, evitando que o modelo aprenda de forma enviesada. O *UnderSampling* foi utilizado ao invés do *OverSampling*, pois o *OverSampling* pode gerar dados sintéticos que não representam a realidade, enquanto o *UnderSampling* reduz a quantidade de dados, mas mantém a qualidade das transações existentes. Além disso, o custo do *UnderSampling*, que é reduzir a quantidade de dados para o estudo, não foi um problema, pois a quantidade de dados disponíveis era suficiente para a aplicação do modelo e o objetivo é prever a evolução dos pacientes. Ao fim da aplicação dessa técnica, o desbalanceio que era de 2.474.432 pacientes recuperados e 873.864 pacientes que vieram a óbito, foi ajustando, ficando 873.864 pacientes em cada classe. A aplicação desse balanceamento se justificou porque antes da aplicação o modelo estava tendencioso, prevendo com mais frequência a classe majoritária exatamente com a distribuição percentual de pacientes recuperados e pacientes que vieram a óbito, ou seja, ele estava tentando adivinhar com base na distribuição percentual de evolução dos casos no *dataset* de treino, e não aprendendo de fato a prever a evolução dos pacientes.

As tratativas de pré-processamento e transformação dos dados foram pensadas e melhoradas ao longo de uma série de tentativas com resultados insatisfatórios, identificando os problemas e ajustando as soluções para obter um modelo com melhor desempenho. Uma ferramenta fundamental para auxiliar nesse processo foi o uso da biblioteca *Optuna*, que permitiu a realização de experimentos automatizados para ajuste de hiperparâmetros, otimizando o desempenho do modelo. Além disso, ao identificar baixas performances do modelo, foi possível retornar ao pré-processamento e ajustar as etapas de transformação dos dados, como a remoção de colunas e o balanceamento das classes, para obter um modelo mais eficaz. Uma série de tentativas foram realizadas, as últimas podem ser observadas na Tabela 3. Antes de aplicar as configurações de hiperparâmetros no estudo do *Optuna*, foi feito um estudo teórico sobre os hiperparâmetros mais relevantes para a aplicação de redes neurais em problemas de classificação binária que mais se adequam as características da base estudada, e a partir disso, foram feitos ajustes nos conjuntos de hiperparâmetros possíveis a serem testados pelo *Optuna*. Dessa forma, o modelo foi construído usando a

Tent.	Acurácia	Duração	Função de ativação camadas ocultas	Taxa de aprendizado	Qtde de camadas ocultas	Otimizador	neurônios camada oculta 1	neurônios camada oculta 2	neurônios camada oculta 3	neurônios camada oculta 4	estado	função de ativação da camada de saída
0	0,75807	00:08	ReLu	0,000236414277728761	1	rmsprop	48	37			COMPLETE	sigmoid
1	0,49995	00:09	tanh	0,00213077862335246	3	sgd	55	53	50	57	COMPLETE	sigmoid
2		00:00	ReLu	0,0883256204713236	3	adam	46	38	47	54	FAIL	
0	0,74500	00:09	sigmoid	2,37243137075192E-05	2	adam	44	56	45		COMPLETE	sigmoid
1	0,62755	00:08	ReLu	0,000134127497382442	2	sgd	55	60	36		COMPLETE	sigmoid
2	0,75114	00:09	ReLu	4,16747429134276E-05	2	adam	47	52	62		COMPLETE	sigmoid
3	0,49995	00:06	sigmoid	0,00268403673052823	1	sgd	37	48			COMPLETE	sigmoid
4	0,50005	00:08	sigmoid	0,026861570285059	2	rmsprop	61	53	37		COMPLETE	sigmoid
5	0,49995	00:08	sigmoid	0,0127693757345478	2	rmsprop	64	39	32		COMPLETE	sigmoid
6	0,73876	00:08	ReLu	0,000249072330123219	2	rmsprop	51	46	61		COMPLETE	sigmoid
7		00:02	ReLu	3,31161923567634E-05	3	sgd	36	62	61	45	FAIL	
0	0,69652	00:08	ReLu	1,00235103873613E-06	1	adam	60	60			COMPLETE	sigmoid
1	0,67602	00:07	sigmoid	1,1590761205949E-06	1	rmsprop	55	38			COMPLETE	sigmoid
2	0,50005	00:08	ReLu	4,06507993452375E-09	3	rmsprop	44	52	34	63	COMPLETE	sigmoid
3		00:02	sigmoid	5,54828750058918E-07	1	adam	37	44			FAIL	sigmoid
0	0,75183	00:09	ReLu	7,15494393100353E-05	3	rmsprop	56	57	36	62	COMPLETE	sigmoid
1	0,75303	00:07	ReLu	4,50932521811239E-05	1	adam	42	33			COMPLETE	sigmoid
2	0,74894	00:10	sigmoid	7,46357965830016E-05	3	adam	62	44	43	59	COMPLETE	sigmoid
3	0,75170	00:08	sigmoid	0,000113461363975439	1	adam	51	57			COMPLETE	sigmoid
4	0,75767	00:07	ReLu	0,000188692722566316	1	rmsprop	55	39			COMPLETE	sigmoid
5	0,71983	00:07	sigmoid	0,000457761897217596	2	rmsprop	37	37	47		COMPLETE	sigmoid
6	0,74117	00:07	sigmoid	2,65983304873927E-05	1	adam	44	53			COMPLETE	sigmoid
7	0,71507	00:08	ReLu	3,5213184486604E-05	1	adam	56	43			COMPLETE	sigmoid
8	0,50006	00:10	sigmoid	2,72947176793139E-05	3	adam	49	40	33	64	COMPLETE	sigmoid
9	0,68895	00:07	ReLu	0,000435481452866312	2	rmsprop	36	43	64		COMPLETE	sigmoid

Tabela 3 – Experimentos realizados com o Optuna.

biblioteca *TensorFlow* e consistiu em uma rede neural densa (*feedforward*) com o objetivo de classificar corretamente os pacientes com base nos atributos disponíveis, prevendo se eles evoluíram para óbito ou recuperação. Os hiperparâmetros ajustados para teste usando o *Optuna* nas últimas tentativas foram:

- **Número de camadas ocultas:** Variou entre 1 e 4.
- **Número de neurônios por camada oculta:** Definido entre 32 e 64.
- **Número de neurônios da camada de saída:** Definido 1 por ser um problema de classificação binária.
- **Função de ativação:** ReLu, sigmoid ou SGD.
- **Taxa de aprendizado:** Valores sugeridos entre 1×10^{-5} e 1×10^{-3} , ajustando o ritmo de aprendizado do modelo.
- **Otimizador:** *adam* ou rmsprop, algoritmos populares para ajuste dos pesos da rede neural.

Após a otimização, um novo modelo foi treinado utilizando os melhores hiperparâmetros encontrados. Foi aplicada a técnica de Early Stopping, que interrompe o treinamento automaticamente se o desempenho do modelo não melhorar após um número específico de épocas (neste caso, 6 épocas), evitando *Overfitting*² e queda na performance do modelo. O modelo foi treinado com 80% dos dados e testado com os 20% restantes, e a acurácia final foi calculada com base nos dados de teste.

² efeito ocorre quando um modelo se ajusta excessivamente aos dados de treinamento, capturando até mesmo ruídos e padrões específicos desses dados, o que reduz sua capacidade de generalizar bem em novos dados.

4.8.2 Resultados Obtidos

4.8.3 Avaliação do Desempenho do Modelo

O desempenho do modelo foi avaliado utilizando várias métricas para uma análise completa:

- **Acurácia:** Mede a porcentagem de previsões corretas.
- **AUC-ROC:** Avalia a capacidade do modelo em distinguir entre as classes 0 e 1.
- **F1-Score:** Combina precisão e *recall*, sendo especialmente útil para conjuntos de dados desbalanceados.
- **Matriz de confusão:** Visualiza os erros do modelo, separando verdadeiros positivos, falsos positivos, verdadeiros negativos e falsos negativos.

4.8.3.1 Resultados Finais

Os resultados finais são mostrados na Tabela 4

Classe	Precisão	Recall (Sensibilidade)	F1-Score	Suporte
0	0,76	0,79	0,77	174.790
1	0,78	0,75	0,76	174.756
Acurácia		0,77 (349.546)		
Média Macro	0,77	0,77	0,77	349.546
Média Ponderada	0,77	0,77	0,77	349.546

Tabela 4 – Relatório de Classificação

A matriz de confusão é mostrada na Figura 26.

Esses resultados indicam que o modelo apresentou um bom desempenho na classificação, balanceando adequadamente a precisão e o *recall*, e demonstrando uma alta capacidade de discriminar entre as classes. A acurácia de 0,77 indica que o modelo foi capaz de prever corretamente a evolução dos pacientes em 77% dos casos, o que foi considerado um resultado satisfatório, dada a quantidade de valores nulos e a qualidade dos dados disponíveis que não eram ruins, mas estavam estão longe do ideal para uma predição mais acertada, já a matriz de confusão demonstra que o modelo teve um desempenho equilibrado na classificação das classes, com uma quantidade similar de falsos positivos e falsos negativos. Foi inferido que os hiperparâmetros que obtiveram o melhor resultado fazem sentido, isso porque:

- **Uma camada oculta:** Ter uma camada oculta permite que a rede aprenda representações mais complexas dos dados. Como a rede não é muito profunda, ajuda a evitar o risco de *overfitting* e reduz a complexidade computacional, o que é útil quando os




Figura 26 – Matriz de Confusão do modelo final de predição da evolução dos casos. (Autor)

dados não exigem muitos níveis de abstração. Acredita-se que isso foi possível devido ao pré-processamento eficiente que conseguiu reduzir a dimensionalidade dos dados e remover informações irrelevantes, deixando o *dataset* de treino da rede neural com 89 colunas, o que não é uma quantidade alta para modelagem de redes neurais.

- **Função de ativação das camadas ocultas:** A função de ativação *ReLU* é uma função de ativação redes neurais que apresenta eficiência para a maioria dos problemas de classificação, pois ajuda a evitar o problema do gradiente desvanescente, que é comum em funções de ativação mais antigas, como a função sigmóide. Foi escolhida para teste por sua popularidade e eficiência na maior parte dos casos.
- **Otimizador:** O otimizador *rmsprop* é ideal para problemas de classificação e ajusta a taxa de aprendizado de forma adaptativa. Foi escolhido para teste por sua eficiência em problemas de classificação e por ser um otimizador popular em redes neurais.
- **Função de ativação da camada de saída sigmoid:** A função de ativação sigmoid foi escolhida para teste por sua eficiência e por ser uma escolha padrão para a camada de saída em redes neurais com foco em classificação binária.
- **Taxa de aprendizado:** Uma taxa de aprendizado baixa ajuda o modelo a convergir de forma mais estável e a evitar saltos excessivos no espaço de busca, e também reduz o risco de overfitting. Essa taxa ocorreu no conjunto de melhores hiperparâmetros devido ao *range* de valores sugeridos para a taxa de aprendizado terem sido ajustados após uma série de tentativas, afunilando o intervalo para valores em que o modelo apresentou melhor desempenho.

- **Quantidade de neurônios por camada:** O chute inicial de variação foi entre 4 e 64, com base numa expectativa da complexidade das fronteiras de decisão do problema, e a quantidade de neurônios por camada foi ajustada para valores que apresentaram melhor desempenho, com base nos resultados dos experimentos. Assim, nas últimas tentativas os valores de neurônios por camada foram ajustados para 32 e 64, que foi o intervalo que apresentou melhor desempenho de acurácia.

4.8.4 Considerações Finais

A aplicação de redes neurais para a previsão da evolução de pacientes com SRAG demonstrou-se uma abordagem eficaz para lidar com a complexidade dos dados e a multiplicidade de fatores clínicos envolvidos. A simplificação das categorias dos parâmetros foi fundamental para melhorar a performance do modelo, destacando a importância do tratamento de dados no desenvolvimento de modelos preditivos. A acurácia alcançada sugere que o modelo é capaz de identificar padrões relevantes nos dados, que estão associados aos desfechos clínicos dos pacientes. No entanto, há espaço para refinamento do modelo, e futuras iterações poderiam explorar ajustes mais finos na arquitetura da rede, experimentação com diferentes otimizadores e técnicas de regularização, visando aumentar ainda mais a precisão das previsões.

5 Apresentação das *Dashboards*

Foram desenvolvidas duas *dashboards* interativas utilizando o Power BI, que podem ser acessadas a partir dos *links* [Dashboard 1](#) e [Dashboard 2](#), com o objetivo de apresentar os resultados obtidos nas análises realizadas, proporcionando visualizações dinâmicas que permitam aos interessados explorar os dados de maneira intuitiva e facilitada. Os dados da base de SRAG, disponibilizados em formato aberto, não apresentam uma estrutura amigável para o público leigo ou até mesmo para profissionais das áreas de dados e saúde. Diante disso, surgiu a necessidade de apresentar os resultados das análises de forma visual e interativa, visando facilitar uma análise mais aprofundada. Nesta seção, serão descritas as principais visualizações e funcionalidades presentes nas *dashboards* desenvolvidas.

5.1 *Dashboard* de Análise de Distribuição Populacional

A primeira *dashboard* foi desenvolvida com foco na análise da distribuição populacional dos casos de SRAG, destacando a evolução temporal dos casos e a distribuição por faixas etárias. O Apêndice [A](#) ilustra a tela inicial da *dashboard*, que resume os principais *insights* extraídos das análises.

5.2 *Dashboard* de *Heatmap* de Correlação

Como mencionado anteriormente, o *heatmap* de correlação permite uma visualização clara da força das correlações entre os parâmetros analisados, geradas pela aplicação da correlação de Pearson. Esta funcionalidade também está disponível na *dashboard*, possibilitando a exploração interativa dessas correlações.

5.3 *Dashboard* de Análise de Sintomas, Comorbidades e Informações Hospitalares

Esta *dashboard* contém dois tipos de gráficos principais:

- **Gráfico de pizza:** O gráfico de pizza, conforme apresentado no Apêndice [C](#), exibe a relação percentual de ocorrência de um conjunto de sintomas, concomitantemente a um sintoma específico. O sintoma a ser analisado, assim como os sintomas a serem observadas as relações percentuais, podem ser selecionados dinamicamente, atualizando automaticamente as proporções percentuais. É importante ressaltar que esta análise considera o percentual isolado de cada sintoma em relação ao

sintoma selecionado, de modo que, se um paciente apresentar mais de um sintoma, ele será contabilizado em cada uma das avaliações percentuais correspondentes. A mesma lógica foi aplicada para a análise de comorbidades e informações hospitalares, conforme demonstrado no Apêndice D.

- **Gráfico de barras:** O gráfico de barras, também presente no Apêndice C, apresenta a frequência de ocorrência de um sintoma específico em relação ao total de pacientes. Esta visualização tem como objetivo fornecer uma distribuição mais precisa da prevalência de cada sintoma na base de dados, algo que não é possível no gráfico de pizza devido à metodologia de contagem. Gráficos de barras similares foram gerados para a análise de comorbidades e informações hospitalares (Apêndice D).

5.4 *Dashboard* de Análise de Regras de Associação (FP-Growth)

A *dashboard* de regras de associação foi desenvolvida para apresentar, de forma clara e interativa, as regras geradas pelo algoritmo FP-Growth. A tabela inicial desta *dashboard*, ilustrada no Apêndice E, sintetiza os principais *insights* obtidos nas análises, permitindo a filtragem das regras por intervalos de confiança e suporte, além da seleção de parâmetros específicos nos antecedentes e consequentes das regras.

Além da tabela, a *dashboard* inclui um gráfico de dispersão que permite analisar a relação entre diferentes métricas associadas às regras. O gráfico é dinâmico, possibilitando a seleção das métricas de interesse e a filtragem das regras de acordo com critérios específicos, com atualização automática da visualização.

Por fim, também está disponível nessa *dashboard* uma visualização em formato de árvore, que mostra os antecedentes de cada consequente, de forma dinâmica conforme a seleção atual.

5.5 *Dashboard* de Gráficos das Métricas do FP-Growth

Uma página adicional foi criada na *dashboard*, conforme ilustrado no Apêndice F, apresentando gráficos baseados nas métricas obtidas pelo algoritmo FP-Growth. Esses gráficos visam fornecer uma análise visual e dinâmica das regras de associação geradas, com cada gráfico focando em um aspecto distinto das métricas calculadas. O objetivo dessa visualização é facilitar o entendimento das métricas, especialmente para aqueles que não estão familiarizados com o algoritmo, com explicações inseridas nos títulos de cada gráfico. Os gráficos também são dinâmicos, permitindo a filtragem das regras por intervalos de cada métrica e pela seleção de antecedentes e consequentes.

5.6 Visualização interativa do dicionário de dados

Uma funcionalidade interativa foi desenvolvida para exibir informações do dicionário de dados diretamente nas visualizações relevantes das *dashboards*. Com o uso de *tooltips*¹ dinâmicos, os usuários podem visualizar trechos do dicionário de dados correspondentes aos parâmetros observados no contexto atual. Essa implementação visa facilitar a compreensão dos parâmetros, uma vez que a base de dados utilizada contém uma grande quantidade de variáveis, muitas das quais possuem nomes pouco intuitivos. A exibição do dicionário se ajusta automaticamente conforme os parâmetros visualizados, como demonstrado na Figura 27.

Antecedentes	Consequentes	Sup. Antecedente	Sup. Consequente	Suporte	Confiança	lift
CS_ESC	Campo					
CS_ESC	AMOSTRA	1-Sim 2-Não				
CS_ESC		9-Ignorado				
CS_ESC	CS_ESCOL_N	0-Sem escolaridade/ Analfabeto				
CS_ESC		1-Fundamental 1º ciclo (1ª a 5ª série)				
CS_ESC		2-Fundamental 2º ciclo (6ª a 9ª série)				
CS_ESC		3- Médio (1º ao 3º ano) 4-Superior				
CS_ESC		5-Não se aplica 9-Ignorado				
CS_ESC	CS_ZONA	1-Urbana 2-Rural				
CS_ESC		3-Periurbana 9-Ignorado				
RAIOX_	HOSPITAL	1-Sim 2-Não				
HOSPIT		9-Ignorado				
RAIOX_	TP_AMOSTRA	1-Secreção de Naso- orofaringe				
EVOLUC		2-Lavado Broco-alveolar 3-Tecido post-mortem				
		4-Outra, qual? 5-LCR				
		9-Ignorado				
Desfec						

Figura 27 – Dica de dicionário de dados. (Autor)

¹ *Tooltips* no Power BI são janelas informativas que aparecem ao passar o cursor sobre elementos visuais, fornecendo detalhes adicionais sobre os dados, como valores e rótulos.

6 Conclusão

Este projeto de graduação aplicou com sucesso técnicas de mineração de dados para analisar a base de dados de SRAG do Ministério da Saúde do Brasil, obtendo *insights* importantes sobre os fatores que influenciam a evolução dos casos. As principais descobertas incluem:

- As árvores de decisão destacaram a classificação final, o uso de suporte ventilatório e a idade como os principais preditores da evolução clínica. Além disso, fatores como a unidade de notificação, município de residência e resultados de exames de imagem também se demonstraram importante para compreensão dos desfechos de evolução dos pacientes.
- O algoritmo FP-Growth revelou regras de associação significativas entre diferentes parâmetros, como fortes correlações entre certos sintomas e comorbidades, além de relações entre baixa saturação de oxigênio, dificuldades respiratórias e um maior risco de óbito.
- A análise de correlação identificou padrões na co-ocorrência de sintomas e relações entre fatores de risco e desfechos.
- O modelo de rede neural atingiu cerca de 77% de acurácia na previsão da evolução dos casos com base em parâmetros clínicos e demográficos.
- Foi disponibilizada uma plataforma de visualização de dados altamente interativa e abrangente, que oferece diversas visualizações personalizáveis para explorar relações específicas entre os parâmetros e os dados da base. Esta ferramenta proporciona uma visão mais transparente e intuitiva sobre os dados da Síndrome Respiratória Aguda Grave (SRAG) do OPENDATASUS, que pode ser uma poderosa aliada para profissionais de saúde e pesquisadores interessados em compreender melhor a dinâmica da síndrome no Brasil. A plataforma facilita a análise de padrões e tendências, permitindo uma exploração detalhada e acessível das informações relevantes para a tomada de decisões clínicas e de políticas públicas.

Os achados e modelos deste projeto têm implicações para informar políticas de saúde pública, alocação de recursos, tomada de decisões clínicas e estratégias de gerenciamento de doenças relacionadas ao SARS e doenças respiratórias. Ao identificar fatores críticos que influenciam os desfechos, profissionais de saúde e formuladores de políticas de saúde pública podem priorizar recursos, implementar intervenções direcionadas e desenvolver planos de tratamento personalizados para indivíduos ou populações de alto risco.

A respeito as limitações do projeto, uma delas é que esse se baseia em dados que podem conter erros ou inconsistências devido aos desafios de coleta e reporte de informações durante uma pandemia. A precisão dos *insights* derivados da análise depende da qualidade e completude dos dados subjacentes. Outra limitação é que a análise se concentra nos dados do Brasil, o que pode não ser representativo da situação global da SRAG ou generalizável para outras regiões ou países com características demográficas e de saúde diferentes. Além disso, o projeto utiliza principalmente dados até 2023, o que significa que ele pode não capturar os desenvolvimentos ou mudanças mais recentes na situação da SRAG, especialmente se novas variantes ou surtos surgirem após o período de coleta de dados.

De maneira geral, este projeto demonstrou o potencial das abordagens baseadas em dados para entender e gerenciar desafios de saúde pública, como a SRAG. Ao alinhar o conhecimento científico com um problema real, o projeto mostrou o impacto positivo da mineração de dados na abordagem de desafios complexos de saúde. Recomenda-se a exploração contínua de novos algoritmos, técnicas e o *feedback* de especialistas da área para garantir que o trabalho permaneça relevante e contribua para estratégias eficazes de gerenciamento de doenças e melhores resultados de saúde pública.

6.1 Trabalhos Futuros

O projeto de mineração de dados do banco de dados da SRAG abriu várias avenidas para pesquisas e desenvolvimentos futuros. Algumas direções potenciais incluem:

- Expandir a análise para incluir fontes de dados adicionais, como registros eletrônicos de saúde ou sistemas de vigilância de outras regiões/países, para obter uma compreensão global mais abrangente da SRAG.
- Explorar técnicas alternativas de aprendizado de máquina, como aprendizado profundo ou métodos de *ensemble*¹, para potencialmente melhorar a precisão e robustez dos modelos preditivos.
- Incorporar fatores socioeconômicos e ambientais para entender sua interação com a disseminação das doenças que causam a síndrome.
- Desenvolver novas funcionalidades, como capacidades de monitoramento em tempo real ou sistemas de alerta precoce, para facilitar intervenções oportunas e melhorar a preparação para emergências de saúde pública.

Outros trabalhos futuros potenciais incluem:

¹ refere-se a técnicas de aprendizado de máquina que combinam múltiplos modelos para melhorar a precisão preditiva.

- Realizar análises mais detalhadas, como estudos de caso ou análises de subgrupos, para obter *insights* mais profundos sobre populações de pacientes específicas ou regiões geográficas.
- Colaborar com organizações de saúde e agências de saúde pública para validar as descobertas em diferentes contextos e explorar aplicações práticas, como integrar modelos em sistemas de apoio à decisão ou desenvolver diretrizes baseadas em evidências.
- Integrar os modelos e análises com outras tecnologias, como GIS ou aplicativos móveis, para aumentar a acessibilidade e utilidade para diversos interessados.
- Explorar continuamente novos algoritmos e técnicas em aprendizado de máquina e análise de dados para melhorar ainda mais a eficácia e eficiência dos resultados.
- Coletar *feedback* de especialistas do domínio, como epidemiologistas e clínicos, para refinar e iterar os modelos e análises, garantindo relevância e alinhamento com as necessidades emergentes de saúde pública.

Referências

- ARZBERGER, P. et al. An international framework to promote access to data. *Science*, 2004. Citado na página 14.
- BARROS, G. F. de C.; SANTOS, N. L. dos; OULEE, W. T. Análise da síndrome respiratória aguda grave (srag) por meio da mineração de dados em um data warehouse. 2022. Citado na página 27.
- GURNEY, K. *An Introduction to Neural Networks*. First. London and New York: UCL Press Limited, 1997. This edition published in the Taylor & Francis e-Library, 2004. ISBN 1-85728-673-1. Citado 3 vezes nas páginas 5, 23 e 24.
- HAN, J.; KAMBER, M.; PEI, J. *Data Mining: Concepts and Techniques*. Third. AMSTERDAM • BOSTON • HEIDELBERG • LONDON • NEW YORK • OXFORD • PARIS • SAN DIEGO • SAN FRANCISCO • SINGAPORE • SYDNEY • TOKYO: Morgan Kaufmann, 2011. Morgan Kaufmann is an imprint of Elsevier. Citado 7 vezes nas páginas 5, 15, 16, 18, 19, 20 e 21.
- HUH, J. E.; HAN, S.; YOON, T. Data mining of coronavirus: Sars-cov-2, sars-cov and mers-cov. *BMC Res Notes*, v. 14, n. 1, p. 150, Apr 2021. Citado na página 26.
- JURAFSKY, D.; MARTIN, J. H. *Speech and Language Processing*. Draft of august 20, 2024. Stanford University, 2024. Redes Neurais. Disponível em: <<https://web.stanford.edu/~jurafsky/slp3/7.pdf>>. Citado 4 vezes nas páginas 5, 22, 23 e 24.
- LAZZARINI, N. et al. A machine learning model on real world data for predicting progression to acute respiratory distress syndrome (ARDS) among COVID-19 patients. *PLoS One*, v. 17, n. 7, p. e0271227, Jul 2022. Citado na página 26.
- MALIK, Y. S. et al. Coronavirus disease pandemic (COVID-19): Challenges and a global perspective. *Pathogens*, v. 9, n. 7, 2020. ISSN 2076-0817. Disponível em: <<https://www.mdpi.com/2076-0817/9/7/519>>. Citado na página 10.
- Ministério da Saúde. *SRAG 2021 a 2023 - Banco de Dados de Síndrome Respiratória Aguda Grave - incluindo dados da COVID-19*. 2023. Acesso em: 6 de outubro de 2024. Disponível em: <[URL_DO_SITE](#)>. Citado na página 15.
- Open Data Handbook. *What is Open Data?* 2023. Acesso em: 6 de outubro de 2024. Disponível em: <<https://opendatahandbook.org/guide/en/what-is-open-data/>>. Citado na página 14.
- RIBEIRO, M. L. F.; CORDEIRO, N. M.; ALVES, D. A. N. d. S. Aplicação da modelagem preditiva via Árvore de decisão nos casos de síndrome respiratória aguda grave (srag), com Ênfase na corona virus disease 2019 (COVID-19) no Brasil referente ao período de 2020 a 2022. *Research, Society and Development*, 2022. Disponível em: <<https://rsdjournal.org/index.php/rsd/article/view/36173>>. Citado na página 28.

SAUDE, M. da. *SRAG 2021 a 2024 - Banco de Dados de Síndrome Respiratória Aguda Grave - incluindo dados da COVID-19*. 2024. Acesso em 5 de setembro de 2024. Disponível em: <<https://opendatasus.saude.gov.br/dataset/srag-2021-a-2024>>. Citado 2 vezes nas páginas 5 e 32.

SILVA, A. O. d. Uso de machine learning para previsão da evolução de casos srag incluindo casos de covid-19 considerando variáveis clínicas e demográficas: Using machine learning to predict the evolution of sars cases including covid-19 cases considering clinical and demographic variables. Londrina, ago 2021. Trabalho de Conclusão de Curso (Bacharelado em Engenharia de Produção). Citado na página 28.



SILVA, B. B. d. *Uso de Mineração de Dados para Predição e Análise de Recuperação de Pacientes Infectados por Síndrome Respiratória Aguda Grave - SRAG*: Use of data mining for prediction and analysis of recovery of patients infected with severe acute respiratory syndrome - sars. 43 p. TCC (Graduação), Caicó, 05 2021. Curso de Sistemas de Informação, Departamento de Computação e Tecnologia. Disponível em: <<https://repositorio.ufrn.br/handle/123456789/42849>>. Citado na página 27.

STEWART, J. *Calculus : early transcendentals*. Belmont, Cal.: Brooks/Cole, Cengage Learning, 2012. ISBN 0538497904 9780538497909 0840058853 9780840058850 0538498714 9780538498715 0538498870 9780538498876 0840048254 9780840048257. Citado na página 25.


STRAUSBAUGH, L. J. et al. Merging infections. *Severe Acute Respiratory Syndrome*, 2004. Larry J. Strausbaugh, Section Editor. Citado na página 10.

UNIVERSITY, C. *RMSPProp*. 2024. <<https://optimization.cbe.cornell.edu/index.php?title=RMSPProp>>. Accessed: 2024-09-18. Citado na página 25.

APÊNDICE A – Dash de análise de distribuição populacional. (Autor)



APÊNDICE C – Dash de análise de sintomas. (Autor)



Comorbidade em análise

Comorbidade analisada	nº pacientes afetados
RENAL	125,87K



Attribute	Proportion
CARDIOMY	1.000
DIABETES	0.771
PNEUMONY	0.171
NEUROLOGIC	0.164
ASMA	0.144
RENAL	0.134
IMMUNOPR	0.104
HEPATICA	0.034
HEMATOLOG	0.024
INFECTIOUS	0.014

Informação hospitalar em análise

Trat. Hosp. Analizado UTI	nº pacientes afectados 1.10M
------------------------------	---------------------------------




Category	Sum of Soma (M)
UT	1.037M
SUPER_VEN	0.37M
FADOLRES	0.15M

APÊNDICE E – Dash Tabela FP-Growth. (Autor)

Tabela de resultados da análise de padrões frequentes (FP-Growth)

Antecedentes	Consecuentes	Sup. Antecedente	Sup. Consecuente	Signific.	Hit	Leverage
CS, ESQOL, N.90, T1, AMOSTRAL, T10, HOSPITAL, T10	CS, ZDM, T10	0.23	0.81	0.21	0.90	1.11
CS, ESQOL, N.90, T1, AMOSTRAL, T10	CS, ZDM, T10	0.24	0.81	0.22	0.90	1.11
CS, ESQOL, N.90, T1, AMOSTRAL, T10, AMOSTRAL, T10	CS, ZDM, T10	0.24	0.81	0.22	0.90	1.11
CS, ESQOL, N.90, T1, AMOSTRAL, T10, CRITERIO, T10	CS, ZDM, T10	0.24	0.81	0.22	0.90	1.11
CS, ESQOL, N.90, T1, AMOSTRAL, T10, AMOSTRAL, T10	CS, ZDM, T10	0.26	0.81	0.24	0.90	1.11
CS, ESQOL, N.90, T1, AMOSTRAL, T10	CS, ZDM, T10	0.27	0.81	0.24	0.90	1.11
CS, ESQOL, N.90, T1, AMOSTRAL, T10, CRITERIO, T10	CS, ZDM, T10	0.25	0.81	0.22	0.89	1.10
CS, ESQOL, N.90, T1, AMOSTRAL, T10	CS, ZDM, T10	0.25	0.81	0.22	0.89	1.09
CS, ESQOL, N.90, T1, AMOSTRAL, T10	CS, ZDM, T10	0.28	0.81	0.25	0.88	1.09
CS, ESQOL, N.90	CS, ZDM, T10	0.29	0.81	0.26	0.88	1.08
RAOK, RES, 6.0, AMOSTRAL, T10	CS, ZDM, T10	0.23	0.81	0.20	0.88	1.08
HOSPITAL, T10, RAOK, RES, 6.0	CS, ZDM, T10	0.23	0.81	0.21	0.87	1.07
RAOK, RES, 6.0	CS, ZDM, T10	0.24	0.81	0.21	0.87	1.07
PROBUCION, T10, AMOSTRAL, T10, CS, PRAO, T10	CS, ZDM, T10	0.25	0.81	0.22	0.87	1.07



APÊNDICE F – Dash Graficos FP-Growth. (Autor)

Gráficos de resultados da análise de padrões frequentes (FP-Growth)

