

UNIVERSIDADE TECNOLÓGICA FEDERAL DO PARANÁ

AMARI ORNELAS DA SILVA

**USO DE MACHINE LEARNING PARA PREVISÃO DA EVOLUÇÃO DE CASOS DE
SRAG INCLUINDO CASOS DE COVID-19 CONSIDERANDO VARIÁVEIS
CLÍNICAS E DEMOGRÁFICAS**

LONDRINA

2021

AMAURI ORNELLAS DA SILVA

**USO DE MACHINE LEARNING PARA PREVISÃO DA EVOLUÇÃO DE CASOS DE
SRAG INCLUINDO CASOS DE COVID-19 CONSIDERANDO VARIÁVEIS
CLÍNICAS E DEMOGRÁFICAS**

Trabalho de Conclusão de Curso
apresentado como requisito parcial à
obtenção do título de Bacharel em
Engenharia de Produção, do
Departamento de Engenharia de
Produção, da Universidade Tecnológica
Federal do Paraná.

Orientador: Prof. Dr. Bruno Samways dos
Santos

LONDRINA

2021

AMAURI ORNELLAS DA SILVA

**USO DE MACHINE LEARNING PARA PREVISÃO DA EVOLUÇÃO DE CASOS DE
SRAG INCLUINDO CASOS DE COVID-19 CONSIDERANDO VARIÁVEIS
CLÍNICAS E DEMOGRÁFICAS**

Trabalho de Conclusão de Curso de Graduação apresentado como requisito para obtenção do título de Bacharel em Engenharia de Produção da Universidade Tecnológica Federal do Paraná (UTFPR).

Data de aprovação: 20/agosto/2021

Bruno Samways dos Santos
Doutor
Universidade Tecnológica Federal do Paraná

Rogério Tondato
Doutor
Universidade Tecnológica Federal do Paraná

Rafael Henrique Palma Lima
Doutor
Universidade Tecnológica Federal do Paraná

**LONDRINA
2021**

Dedico este trabalho às minhas famílias,
a que me fez e a que eu me fiz.

AGRADECIMENTOS

Agradeço à minha família que acreditou em mim, me incentivou e quando eu achei que não seria mais capaz, insistiram em mim.

Aos meus amigos que estiveram comigo durante as diversas fases dessa trajetória.

Ao meu orientador pela paciência, dedicação e inspiração desde o começo e que me ajudou a chegar até aqui.

Aos professores que me ajudaram sempre que eu precisei.

Agradeço a todos aqueles que direta ou indiretamente contribuíram para a conclusão desse trabalho.

E aos meus irmãos e irmãs: *Ubuntu*.

*Tudo que é familiar desapareceu!
O mundo parece novo em folha.*

*É um mundo mágico, Haroldo,
velho amigo. Vamos explorar!*

Bill Waterson

RESUMO

Este trabalho faz uma análise exploratória da base de dados se Síndrome Respiratória Aguda Grave (SRAG) disponibilizada pelo Sistema Único de Saúde (SUS) e utilização métodos de aprendizagem supervisionada para a previsão da evolução dos casos dos pacientes para óbito ou cura. Duas bases foram criadas para comparação dos resultados e seleção de variáveis relevantes pelos modelos de classificação, uma contendo as variáveis clínicas e outra contendo variáveis clínicas e demográficas. Os classificadores utilizados foram o k-vizinhos mais próximos (*k-nearest neighbors* – KNN), Árvores de Decisão, Regressão Logística, Florestas Aleatórias, Redes Neurais e o XGBoost. O XGBoost obteve o melhor resultado de área sob a curva (*area under de curve* – AUC): 0,86 e os principais atributos para classificação foram o uso de suporte ventilatório invasivo, idade acima de 70 anos e internação na UTI, os principais atributos demográficos foram morar na região nordeste e norte. A base com variáveis demográficas apresentou resultados levemente superiores aos resultados obtidos somente com as variáveis clínicas e permitiu compreender quais características sociodemográficas são mais relevantes no desfecho de casos de SRAG.

Palavras-chave: Covid. Coronavirus. *Machine learning*. Classificação.

ABSTRACT

This work presents an exploratory analysis of the public database about Severe Acute Respiratory Syndrome (SARS) and the use of supervised learning methods to predict the evolution of patients' cases to death or cure. Two databases were created to compare the results and select relevant variables by the classification models, one containing the clinical variables and the other containing clinical and demographic variables. The classifiers used were k-nearest neighbors (KNN), Decision Trees, Logistic Regression, Random Forests, Neural Networks and XGBoost. XGBoost had the best area under the curve (AUC) result: 0.86 and the main attributes for classification were the use of invasive ventilation support, age over 70 years and admission to the ICU, the main demographic attributes were living in the northeast and north regions. The database with demographic variables presented results slightly superior to the results obtained with the clinical variables alone and allowed us to understand which sociodemographic characteristics are more relevant in the outcome of SARS cases.

Keywords: Covid. Coronavirus. Machine learning. Classification.

SUMÁRIO

1. INTRODUÇÃO.....	1
1.1 OBJETIVO GERAL	2
1.2 OBJETIVOS ESPECÍFICOS	2
1.3 JUSTIFICATIVA.....	3
1.4 ESTRUTURA DO TRABALHO	3
2. TÉCNICAS APLICADAS.....	4
2.1 APRENDIZADO DE MÁQUINA	4
2.2 TAREFAS DE CLASSIFICAÇÃO	4
2.3 TÉCNICAS DE CLASSIFICAÇÃO	5
2.3.1. K-Nearest Neighbors	5
2.3.2. Árvores de Decisão	6
2.3.3. Florestas Aleatórias	7
2.3.4. Regressão Logística	8
2.3.5. Redes Neurais	8
2.3.6. XGBoost	9
3. MÉTRICAS	11
4. TRABALHOS CORRELATOS	14
5. MATERIAIS E MÉTODOS.....	20
6. RESULTADOS E DISCUSSÕES	22
6.1 RESULTADO DA ANÁLISE DESCRITIVA.....	22
6.2 RESULTADOS DOS MODELOS DE MACHINE LEARNING	25
7. CONCLUSÃO.....	29
REFERÊNCIAS.....	30

1. INTRODUÇÃO

O ano de 2020 foi marcado pela pandemia da doença do novo coronavírus (COVID-19), uma doença respiratória causada pelo vírus SARS-Cov19 que, desde seu início no final de 2019 na província de Wuhan, China, praticamente todos os países do mundo reportaram casos da doença e as autoridades têm tomado diferentes medidas para diminuir o seu contágio. Ao mesmo tempo, pesquisadores trabalham em como combater a doença, seja na pesquisa em relação às vacinas ou entendendo como ela se comporta.

No Brasil, desde a epidemia de H1N1 causada pelo vírus Influenza A em 2009, seguindo orientações da OMS, é mantido um repositório com as informações de todos os casos reportados de Síndrome Respiratória Aguda Grave (SRAG), sejam elas causadas pelo vírus Influenza, outros agentes etiológicos ou, a partir de 2020, também novo Corona Vírus.

A SRAG é uma síndrome respiratória infecciosa causada por um vírus e que infecta o trato respiratório superior, onde os pacientes apresentam um quadro gripal acompanhado de frequência respiratória igual ou superior a 20 incursões por minuto ou saturação de oxigênio menor que 95% em ar ambiente (ARAÚJO, Kamilla. *et al.*, 2020).

O Sistema Único de Saúde (SUS), vinculado ao Ministério da Saúde do Brasil disponibiliza publicamente os dados sobre os casos de SRAG, incluindo informações sobre fatores de risco para doenças respiratórias, sintomas apresentados e evolução do caso, além de informações demográficas, como raça, idade, região de habitação, entre outras. Essas informações permitem fazer uma análise que contempla não somente os fatores clínicos, mas também dimensões demográficas do paciente e, sendo o Brasil um dos países mais desiguais socialmente (WORLD INEQUALITY REPORT, 2018), características socioeconômicas podem estar entre os fatores que influenciam na evolução de cada caso.

Ao final de julho de 2021 o Brasil já tinha ultrapassado a marca de 550 mil mortos por COVID-19 e apesar dos esforços internacionais para minimizar os efeitos da pandemia, os números de óbitos no Brasil continuam crescendo, sendo o segundo em números absolutos de mortes e também em quantidade de mortes por milhão de habitantes. Para entender como esses fatores podem aumentar o risco de óbito é possível voltar os olhos para a mineração de dados e *machine learning*, a área da

saúde é uma das que mais cresce em número de pesquisas utilizando essas ferramentas.

Comparados aos atuais métodos bioestatísticos, *machine learning* é uma alternativa mais flexível e escalável, além de permitir que dados de diversos tipos sejam incluídos em sua análise (NGIAM; KHOR, 2019). Esse é um dos motivos pelo qual esse tipo de inteligência artificial tem sido cada vez mais implementado na área da saúde que, historicamente, gera um grande volume de dados, seja por motivos de pesquisa, armazenamento de registros, regulamentos ou outros (SOLEIMANI-ROOZBAHANI; GHATARI; RADFAR, 2019).

Com o crescimento acelerado desse volume de dados se torna cada vez mais comum que fontes de dados diferentes sejam integradas e combinadas, com esta integração podendo melhorar o resultado para os pacientes de forma significativa (HERLAND; KHOSHGOFTAAR; WALD, 2014), mas devido à complexidade dos dados também há limitações e fatores chaves que devem ser observados. Segundo Ngiam e Khor (2019) a acurácia e a aplicabilidade das ferramentas de *machine learning* devem ser próximas daquelas de ferramentas médicas regulamentadas.

Existe um grande volume de dados disponibilizados publicamente pelo SUS (Sistema Único de Saúde) referente aos casos reportados de Síndrome Respiratória Aguda Grave incluindo casos de COVID-19 e que possuem uma variedade de tipos de informação que podem trazer à luz novas percepções em saúde pública e o comportamento da pandemia no Brasil.

1.1 OBJETIVO GERAL

Comparar diferentes técnicas de *machine learning* na previsão da evolução de casos de Síndrome Respiratória Aguda Grave utilizando um conjunto de variáveis preditoras clínicas e um conjunto de variáveis preditoras clínicas e demográficas.

1.2 OBJETIVOS ESPECÍFICOS

- Avaliar a importância das variáveis nos modelos.
- Avaliar as métricas de classificação nas diferentes técnicas aplicadas.
- Explorar a base de dados de SRAG do SUS.
- Selecionar o melhor conjunto de variáveis preditoras.

1.3 JUSTIFICATIVA

Segundo Chiavegatto Filho (2015) existe uma grande oportunidade na associação de epidemiologistas com profissionais com experiência em análise de dados, principalmente no que diz respeito a políticas públicas de saúde, dado o crescimento no volume de dados nessa área e a pressão por transparência nos gastos públicos. Essa combinação de expertises pode potencializar o auxílio no controle de infecções, diagnósticos e tratamentos de várias doenças, e ajudar na gestão de recursos da saúde e gestão hospitalar (MACIEL *et al.*, 2015).

Dada a severidade da pandemia da Covid-19 determinar características preditivas de mortalidade e uso de recursos médicos é uma atividade crítica e o uso de variáveis sociodemográficas não-clínicas pode revelar disparidades nos sistemas de saúde de acordo com Wollenstein-Betech (2020).

Apesar do grande número de cientistas com trabalhos sobre o coronavírus e a Covid-19 a falta de pesquisas utilizando informações da América do Sul e do Brasil evidencia a necessidade da realização de pesquisas e iniciativas que explorem esses dados (SAIRE, 2020).

1.4 ESTRUTURA DO TRABALHO

Após esta introdução o trabalho está dividido em mais seis capítulos: As Técnicas aplicadas são apresentadas no capítulo 2 e as métricas de avaliação no capítulo 3, Trabalhos correlatos serão discutidos no capítulo 4 enquanto os detalhes de como o trabalho foi feito estão em Materiais e Métodos no capítulo 5. Os resultados obtidos e discussões acontecem no capítulo 6 e, por fim, o trabalho é concluído no capítulo 7.

2. TÉCNICAS APLICADAS

2.1 APRENDIZADO DE MÁQUINA

No aprendizado de máquina as especificações de relações matemáticas e/ou probabilísticas entre as diferentes variáveis do problema são aprendidas de forma automática a partir dos próprios dados. Essas relações, chamadas modelos, são criadas e então utilizadas para diferentes fins (GRUS, 2016).

Esses modelos podem ser aprendidos de maneira supervisionada ou não-supervisionada. No primeiro caso deve existir um conjunto de dados rotulados com a resposta correta para a aprendizagem, esses são chamados problemas de classificação. Já no segundo caso esses rótulos não existem, são chamados problemas de clusterização e o objetivo é encontrar grupos (clusters) dentro dos dados, porém, como não há rótulos o modelo não é capaz de dizer qual o significado semântico dos clusters encontrados (HAN *et al.*, 2012).

2.2 TAREFAS DE CLASSIFICAÇÃO

O problema do qual trata a Classificação é o de aprendizagem da estrutura dos dados em um conjunto que já está particionado em categorias ou classes, o modelo criado é utilizado para estimar o rótulo de categoria (ou classe) de dados não vistos anteriormente e cuja categoria é desconhecida. Esse modelo se assemelha ao de clusterização, no sentido de que também irá criar conjuntos de regras para separação em grupos, porém a principal diferença é que levará em consideração o número e estrutura dos grupos disponíveis na etapa de aprendizagem e tentará replicar essas características. Além disso um modelo de classificação captura a noção de agrupamento do usuário, fazendo com que os grupos resultantes tenham um significado semântico muito bem definido e uma aplicação direta a uma grande variedade de problemas (AGGARWAL, 2015). Algumas aplicações da tarefa de classificação são:

- **Marketing direcionado:** Neste caso os grupos correspondem ao interesse do consumidor em determinado produto, os dados do perfil de comportamento de consumo anterior do cliente costumam estar disponíveis para a criação do modelo.

- **Tratamento de Doenças:** Tem havido um aumento nos últimos anos no uso de *machine learning* na pesquisa médica, nesses problemas geralmente características dos pacientes são variáveis do modelo e a classe que está sendo usada como resultado pode ser um diagnóstico, um tratamento ou um resultado por exemplo.
- **Análise de Dados Multimídia:** Usado geralmente na classificação de grandes volumes de informações multimídia como fotos, vídeos, áudios ou outros dados mais complexos. O objetivo pode ser classificar se aquele conteúdo possui alguma característica específica ou descreve uma situação particular (AGGARWAL, 2015).

2.3 TÉCNICAS DE CLASSIFICAÇÃO

Neste trabalho foram utilizadas seis técnicas de classificação: *K-Nearest Neighbors* (KNN), Árvores de Decisão, Florestas Aleatórias, Regressão Logística e Redes Neurais, com o objetivo de classificar os casos quanto à sua evolução (Cura ou Óbito) utilizando as informações clínicas e demográficas dos pacientes.

2.3.1. *K-Nearest Neighbors*


Descrito pela primeira vez no início dos anos 1950 este método tem sido vastamente utilizado na área de reconhecimento de padrões e é baseado no aprendizado por analogia, isto é, comparando a instância que está sendo testada com aquelas que são semelhantes. O conjunto de instâncias de treino possui n atributos e cada instância é representada por um ponto em um espaço de n dimensões. Quando uma instância que não possui rótulo é dada, o KNN então procura nesse espaço pelas k instâncias de treino armazenadas ali que estejam mais próximas da instância que deve ser classificada, essas instâncias são os “vizinhos mais próximos”, o rótulo dessa nova instância será aquele que tiver a maioria dentre os k vizinhos mais próximos (HAN *et al.*, 2012).

Para calcular a distância entre os pontos pode se utilizar alguns métodos de cálculo, o mais comum é a distância euclidiana, que é calculada como:

$$Dist(X_1, X_2) = \sqrt{\sum_{i=1}^n (X_{1i} - X_{2i})^2}$$

Onde X_1 e X_2 são instâncias que possuem os pontos $(X_{11}, X_{12}, \dots, X_{1n})$ e $(X_{21}, X_{22}, \dots, X_{2n})$ respectivamente como coordenadas no espaço de n dimensões.

A Figura 1 é exemplo de um caso onde o objetivo é classificar a estrela vermelha como sendo da Classe A ou da Classe B e diferença entre o resultado para k igual a 3 ou k igual a 6.



Fonte: (DEWILDE, 2021)


Na Figura é possível concluir que quando $k=3$ a nova instância é classificada como pertencente a Classe B (lilás), já quando $k=6$ a mesma instância é agora classificada como Classe A (amarela). Isso mostra que o valor de k é um valor sensível e que deve ser otimizado para obter o melhor resultado possível. Também deve-se notar que para o KNN ser o classificador eficiente é preciso assumir a premissa de que os pontos que estão próximos um do outro são similares. Além disso, este classificador não é capaz de explicar os fatores determinantes para que as classes estejam divididas como estão (GRUS, 2016).

2.3.2. Árvores de Decisão

Árvores de decisão são uma estrutura como um fluxograma, onde cada nó interno representa um teste em algum atributo, cada ramo representa as saídas desse teste e cada folha (ou nó terminal) uma classe, o nó mais alto em uma árvore é o nó raiz. Dado uma instância para o qual não se sabe a classificação, os atributos dessa instância são testados na árvore de decisão e um caminho é traçado desde a raiz até uma folha, que determina qual a categoria para aquela instância (HAN *et al.*, 2012).

A Figura 2 é um exemplo de uma estrutura de Árvore de Decisão.

Figura 2 – Estrutura de Árvore de Decisão



A Figura 2 é uma árvore de decisão simples que faz no máximo 3 testes antes de classificar uma instância, porém essas árvores podem ser muito maiores dependendo da quantidade de atributos e da complexidade da relação entre eles. As Árvores de Decisão são fáceis de serem entendidas e interpretadas e seu processo é completamente transparente, além de poderem lidar tanto com atributos numéricos quanto categóricos. Agora, para construir a árvore de decisão é preciso escolher quais testes serão feitos e em qual ordem. O ideal é que os testes escolhidos sejam capazes de dar muitas informações sobre o que a árvore deveria prever, já que a cada teste há uma separação entre as possibilidades de resultado a intenção é fazer como que essa separação seja a mais útil possível. A quantidade de informação que cada teste pode trazer é calculada utilizando um índice que pode ser *entropia*, ou *gini*, por exemplo, esses valores vão indicar o nível de incerteza associado aos dados (GRUS, 2016).

2.3.3. Florestas Aleatórias


Florestas Aleatórias são um tipo de método *ensemble*, isto é, formado por um conjunto de classificadores onde cada classificador vota em uma classe e o resultado do método composto é baseado no conjunto desses resultados. No caso das Florestas Aleatórias esse método é formado por um conjunto de árvores de decisão. Essas árvores individuais são geradas utilizando uma seleção aleatória de atributos para os nós de decisão, durante a classificação, cada árvore vota e a classe mais votada é retornada como resposta (HAN *et al.*, 2012).

Métodos compostos costumam ser mais acurados que os classificadores que os compõem, já que como a classificação é feita pela votação da maioria dos

classificadores individuais, tendo somente duas classes o método composto só irá errar se mais da metade dos classificadores individuais estiverem errados.

2.3.4. Regressão Logística

A Regressão Logística tem como objetivo calcular a probabilidade de uma instância ser classificada como pertencente a uma classe ou não. Por ser uma probabilidade, o valor resultante deve estar entre 0 e 1, como base pode-se utilizar a regressão linear (ou outro estimador) para estimar a probabilidade de classificar a instância como pertencente àquela classe. Porém, a regressão linear gera uma saída entre $-\infty$ e $+\infty$, então a maneira pela qual isso é resolvido é por meio de uma função de ligação, que liga esses dois intervalos $[0, 1]$ e $(-\infty, +\infty)$. A $\text{logit}(x)$ é uma função que recebe um valor entre 0 e 1 e retorna um número real. Utiliza-se a sua inversa, que deve receber um valor real e retornar uma probabilidade, essa é a função sigmoide ou logística e é representada na Figura 3.



Fonte: (Z_AI, 2020)

Para fazer a classificação o modelo calcula a soma ponderada dos atributos e então aplica a função logística, valores próximos a 1 representam uma probabilidade alta de pertencer a classe em questão, enquanto valores próximos a 0 representam uma grande probabilidade de não pertencer a classe (GERÓN, 2019)

2.3.5. Redes Neurais


Uma rede neural é um modelo inspirado na forma como funciona o cérebro, consiste em neurônios artificiais que desenvolvem cálculos a partir do resultado que recebe de um outro neurônio e dispara uma resposta. São muito utilizadas em *deep*

learning e reconhecimento de caligrafia e detecção facial, porém a maioria dos modelos de rede neural são difíceis de interpretar (GRUS, 2016).

As vantagens desse modelo é que são muito tolerantes a dados com ruído e também são capazes de classificar padrões nos quais não foram treinados e são naturalmente paralelizáveis, o que pode acelerar o processo computacional (HAN *et al.*, 2012).

A rede neural mais simples é a *perceptron*, que se comporta como um único neurônio com n entradas binárias. Essa rede executa uma soma ponderada de suas e retorna se essa soma for maior ou igual a zero. Essa ponderação ocorre através de pesos que são propriamente escolhidos. Esses “neurônios”, assim como neurônios orgânicos podem ser conectados e criar redes mais complexas e com diversas camadas, tendo uma camada de entrada, uma ou mais camadas ocultas e uma camada de saída como ilustrado na Figura 4.

Figura 4 - Estrutura de uma Rede Neural Multicamada



Fonte: (MOHANTY, 2019)

Cada camada é composta de unidades, as entradas são passadas para as unidades criando a Camada de Entrada, esses dados são então ponderados e passados para uma segunda camada, esse processo se repete até que os dados tenham passado por toda a rede, que tem uma quantidade arbitrária de camadas, até chegarem à Camada de Saída que emite a classe predita pela rede (HAN *et al.*, 2012).

2.3.6. XGBoost

O XGBoost é um algoritmo baseado em árvore de decisão que utiliza uma estrutura de *gradient boosting*, isto é, é um modelo formado por um conjunto de modelos preditores mais fracos. A diferença da estrutura de *boosting* para a estrutura

de *bagging* (que é o caso das árvores de decisão) é que, na primeira, a seleção dos parâmetros não é totalmente aleatória e utiliza-se da resposta do preditor anterior para escolher quais parâmetros são melhores para seguir. A vantagem do XGBoost é que ele combina técnicas de otimização de *software* e de *hardware* para obter resultados melhores em um tempo menor (GOMES, 2019).

Esse classificador tem feito muito sucesso devido à sua escalabilidade, sendo considerado rápido tanto em uma única máquina quanto em sistemas distribuídos. Essa escalabilidade se deve às melhorias trazidas pelo XGBoost em relação aos outros métodos de *boosting*, tais como melhoria do trato com dados esparsos, procedimentos de ponderação na aproximação de aprendizado por árvore, computação paralela e distribuída (CHEN; GUESTRIN, 2016).

3. MÉTRICAS

Após o modelo classificar as instâncias é preciso avaliar o quão bem ele executou a tarefa, para isso são utilizadas métricas de desempenho. Essa avaliação é feita utilizando um conjunto de dados que não foi consultado durante a preparação do modelo, conhecido como conjunto de teste. Isso impede que o classificador seja bem avaliado quando, na verdade, ele está superespecializado em classificar as instâncias que já conhece (o chamado *overfitting*). As métricas utilizadas neste trabalho e fórmulas estão exibidas na Tabela 1.

Tabela 1 - Métricas de Avaliação	
Métrica	Fórmula
Acurácia	$\frac{VP + VN}{VP + FP + VN + FN}$
Precisão	$\frac{VP}{VP + FP}$
Sensibilidade (Recall)	$\frac{VP}{VP + FN}$
F1 Score	$\frac{2(precisão)(sensibilidade)}{precisão + sensibilidade}$

As fórmulas da Tabela 1 fazem referência aos valores:


- *VP*: Número de Verdadeiros Positivos, estas são instâncias positivas e que foram corretamente categorizadas pelo classificador.
- *FP*: Número de Falsos Positivos, estas são instâncias negativas e que foram categorizadas erroneamente pelo classificador como sendo positivas.
- *FN*: Número de Falsos Negativos, estas são instâncias positivas e que foram categorizadas erroneamente pelo classificador como sendo negativas. E há também:
- *VN*: Número de Verdadeiros Negativos, instâncias negativas e que foram categorizadas corretamente pelo classificador como sendo negativas. Esses termos estão sumarizados na Tabela 2, chamada Matriz de Confusão.

Tabela 2 – Matriz de Confusão			
		Classe Predita	
		Sim	Não
		Sim	<i>VP</i>
Classe Real	Não	<i>FP</i>	<i>VN</i>

Essa matriz considera um problema com duas classes, mas pode haver matrizes maiores de tamanho $m \times m$, onde m é o número de classes (HAN *et al.*, 2012).

Além dessas métricas há ainda a curva ROC (*Receiver operating characteristics*) que é uma forma de visualizar a qualidade do classificador em relação ao custo associado em se classificar falsos negativos ou falsos positivos. Em casos de pacientes com câncer, por exemplo, o custo de classificar como não-canceroso um paciente canceroso é muito maior do que o de classificar um paciente saudável como canceroso. A curva ROC é plotada utilizando os valores da taxa de verdadeiros positivos (TVP) no eixo vertical, essa taxa é calculada como sendo o número de verdadeiros positivos dividido pelo total de positivos no conjunto de dados, que é a sensibilidade. No eixo horizontal é utilizada a taxa de falsos positivos (TFP), que é calculada como o número de falsos positivos dividido pelo total de negativos no conjunto. O resultado é mostrado na Figura 5.

Figura 5 – Exemplo de curva ROC



Fonte: (NCSS, 2021)

Na Figura 5 a linha vermelha representa a curva ROC e a linha preta é a linha de referência onde para cada verdadeiro positivo há um falso positivo, ou seja, um classificador que tem 50% de chance de acertar e é, portanto, tão ruim quanto um palpite aleatório. Para medir o desempenho desse modelo é possível calcular a área abaixo da curva ROC, quanto mais próximo a 0,5 pior é o classificador, um classificador perfeito terá a área abaixo da curva igual a 1,0.

4. TRABALHOS CORRELATOS

Existem vários trabalhos publicados que também tratam da intersecção entre *machine learning* e a medicina, incluindo problemas de classificação e SRAG, com algumas destas pesquisas descritas na sequência.

Gosh *et al.* (2020) usaram modelos *Quantitative Structure-Activity Relationship* (QSAR) baseados em otimização de Monte Carlo para a classificação de diversos inibidores das proteases principais (*main proteases* – Mpro) para a SARS-CoV com o objetivo de acelerar a busca de inibidores Mpro para a SARS-CoV-2. Também foram identificadas as principais características moleculares para a regulação dos inibidores. Como parte da tarefa da classificação, aplicaram-se as técnicas *Gradient Boosting Machines* (GBM), *Random Forest* (RF), *Support Vector Machines* (SVM) e *k-nearest neighbors* (KNN) com validação cruzada 5-fold, todos aplicados em um *dataset* disponibilizado na literatura. Houve também a análise estrutural e interpretação físico-química dos possíveis inibidores.

Dey *et al.* (2020) aplicaram os classificadores RF, KNN, *Naïve Bayes* (NB), XGBoost, AdaBoost, *Deep multi-layered perceptron* (DMLP) e SVM com funções de base radial, linear e polinomial para a predição das interações entre proteínas (*Protein-protein interactions* – PPIs). Os atributos foram selecionados por *Kohonen's Learning Vector Quantization* (LVQ). Três *datasets* foram utilizados e os modelos foram validados com experimentos biológicos por meio de 1.326 proteínas em potencial. Os modelos foram avaliados por acurácia, kappa, precisão, especificidade, recall e f1-score a partir da validação cruzada 10-fold com 10 repetições. Os classificadores SVM de base radial e polinomial, assim como RF, obtiveram melhores resultados em praticamente todas as métricas.

Banerjee *et al.* (2020) utilizaram *machine learning* e testes estatísticos para identificar pacientes que testaram positivo para a SARS-CoV-2 a partir de análise sanguínea, sem nenhum conhecimento prévio sobre sintomas e históricos individuais. Os dados foram obtidos no Hospital Israelita Albert Einstein, em São Paulo (Brasil), padronizando-os (normalização com média 0 e desvio-padrão 1). O conjunto total foi de 598 registros, contendo atributos como idade, resultado do teste rt-PCR SARS-CoV-2 e exames de sangue. Com os classificadores RF, *Generalized Linear Models* (GLM) com regularização Lasso, *Logistic Regression* (LR) e Redes Neurais Artificiais (ANN), a validação cruzada 10-fold mostrou que a acurácia e especificidade dos

modelos RF, GLM-Lasso e ANN foram melhores no geral. Também foram avaliados a sensibilidade e *area under the curve* (AUC).

Para a estimativa de número de casos, Singh *et al.* (2020) aplicaram *autoregressive integrated moving average* (ARIMA) e *least square-SVM* (LS-SVM) em números sobre os casos diários confirmados de SARS-CoV-2 nos cinco países mais afetados durante o desenvolvimento do trabalho (Itália, Espanha, França, Reino Unido e Estados Unidos América). Os parâmetros do ARIMA foram estimados por *plots* da função de autocorrelação (*autocorrelation function* - ACF e ACF parcial PACF), incluindo *Maximum Likelihood*. A adequação geral do modelo foi feita pelo teste de *Ljung Box*. Analisando as métricas *Mean Absolute Error* (MAE), *Mean Squared Error* (MSE) e *Root Mean Squared Error* (RMSE), o LS-SVM se mostrou uma técnica melhor no geral.

Tuli *et al.* (2020) aplicaram um modelo matemático para a previsão do crescimento da pandemia da COVID-19, incluindo um modelo de ajuste (*fitting*) baseado em *machine learning* o qual foi capaz de atualizar pesos iterativos, caracterizando um modelo *Robust Weibull* e chegando-se a um framework de predição em *cloud computing*. Os dados utilizados foram retirados do site *Our World in Data* (<https://ourworldindata.org/coronavirus-source-data>) e o modelo de predição baseado na modificação da distribuição de Weibull, quando comparado ao modelo baseado em distribuição Gaussiana, mostrou melhores resultados para diversos países analisados.

Modelos de séries temporais foram utilizados para a previsão de infectados pelo novo coronavírus no trabalho de Alzahrani *et al.* (2020). Os autores aplicaram média móvel, Modelo Autoregressivo, Modelo Autoregressivo baseado em média móvel (ARMA) e *Integrated ARMA* (ARIMA). Os dados foram extraídos do *Saudi Ministry of Health* e os modelos foram aplicados para uma previsão de até quatro semanas para 31 cidades sauditas. O modelo ARIMA foi o que obteve o melhor resultado em métricas como o RMSE, MAE, MAPE, *Root Mean Squared Relative Error* (RMSRE) e coeficiente de determinação R^2 .

Ahamad *et al.* (2020) desenvolveram uma metodologia para a identificação dos principais sintomas para as pessoas que testaram positivo para a COVID-19, validando a mesma com dados de pacientes de sete províncias chinesas (totalizando 6.512 pacientes) com atributos referentes às características pessoais e de presença de sintomas. As técnicas utilizadas foram SVM, DT, RF e XGBoost LightGBM e GBM,

implementadas em Python 3 após as estatísticas iniciais implementadas em software SPSS *version 25.0*. Após a análise com as métricas como acurácia, precisão, *recall*, *f1 Score*, AUC e *Log Loss*, destacou-se que os atributos mais importantes foram: infecção pulmonar, tosse e pneumonia, sendo que o atributo que menos teve importância para os modelos foi a idade. Quanto às métricas, XGBoost obteve a melhor acurácia com uma boa seleção de atributos, mas os outros modelos também tiveram um bom desempenho.

Já Gatti *et al.* (2020) analisaram o impacto da poluição do ar nos quadros de mortalidade e de testes positivos para o surto de SARS-CoV-2 na Itália. Os dados foram retirados de múltiplas fontes, incluindo o repositório de qualidade do ar (*Air Quality Index - AQI*) dos anos de 2015 a 2019. Com o auxílio da linguagem R, versão 3.6.1, foram elaborados testes de regressão com RF, avaliando o RMSE e R^2 . Testes estatísticos paralelos para a análise de correlação e regressão foram regressão linear, correlação de Pearson e *Canonical Correlation Analysis* (CCA). A partir de atributos relacionados às doenças crônicas, número de camas, salários, AQI, testes, casos positivos, e mortalidade, o nível de material particulado (PM2.5) é o fator mais importante para prever os efeitos do SARS-CoV-2, mostrando que a piora da qualidade do ar em virtude da produtividade não é a decisão mais acertada.

Doornick *et al.* (2020) elaboraram um modelo de previsão de número de casos de SARS-CoV-2 utilizando os dados disponíveis da Johns Hopkins, atualizado diariamente no *link* github.com/CSSEGISandData/COVID-19, do *New York Times*. Para a previsão, foi utilizada uma versão aprimorada do *calibrated average of rho and delta methods* (Card), adicionando um terceiro método na média, mostrando o novo método identificado como Cardt. Comparou-se os resultados em termos de MAE, *Mean Percentage Error* (MPE), MAPE e MAPE ponderado. As previsões para sete dias foram satisfatórias quando comparadas a outros modelos implementados na literatura.

Nemati *et al.* (2020) pesquisaram sobre o tempo de internação em hospitais com uma amostra de 1,182 pacientes hospitalizados. Todos os dados brutos foram obtidos pela base epidemiológica da COVID-19 ([https://www.thelancet.com/journals/laninf/article/PIIS1473-3099\(20\)30119-5/fulltext](https://www.thelancet.com/journals/laninf/article/PIIS1473-3099(20)30119-5/fulltext)), incluindo no estudo os atributos sobre idade, sexo, datas disponíveis e a classe (*death or discharge*), transformando este último em uma classe binária. Métodos estatísticos como *Kaplan-Meyer estimator* (KM), *Cox Proportional Hazard*, CoxNet e *Accelerated*

Failure Time (IPCRidge) e de *machine learning*, neste caso, SVM e variações do GBM (Stagewise GBM e Componentwise GBM) foram aplicados, mostrando que a técnica GBM *Stagewise* é o método com maior acurácia para a classificação do tempo de alta (*discharge*), quanto que KM e regressão de Cox sugeriram que o sexo e a idade têm influência direta no tempo de recuperação do paciente.

Já Sun *et al.* (2020) aplicaram os modelos de *machine learning* em enfermarias para analisar o índice de risco de infecção da COVID-19 (ou seja, ao menos um residente infectado) a partir de uma amostra de 1.146 casas em Massachussetts, Georgia, New Jersey e validados com dados de 1.021 casas do estado da Califórnia (2020). A técnica utilizada foi GBM, com métricas AUC, Sensibilidade e Especificidade por meio da validação 10-*fold*. Os resultados, quando comparados aos modelos ANN e LR mostraram que GBM obteve os melhores resultados médios nas três métricas no conjunto de treinamento, porém no conjunto de validação teve um resultado inferior quanto à sensibilidade.

Kavadi *et al.* (2020) desenvolveram uma regressão chamada de *Progressive Partial Derivative Linear Regression* (PPDLR) para a identificação dos atributos normalizados da amostra e *Partial Derivative Regression and Nonlinear Machine Learning* (PDR-NML) para prever tendências da pandemia da COVID-19 com dados obtidos do site *Kaggle* com relação ao estado de Tamilnadu, India. A partir de 5.000 amostras, a acurácia alcançada foi de aproximadamente 99% para 5.000 instâncias, enquanto que para 50.000, esta acurácia caiu para algo em torno de 97%, melhor do que modelos baseado em AI e Regressão Linear Múltipla.

Loey *et al.* (2021) utilizaram *deep learning* (Resnet-50 *Convolutional neural networks*) para a extração de atributos de imagem de reconhecimento de máscaras, enquanto que a classificação sobre o uso de máscaras foi realizada por DT, SVM e ensemble. Três datasets foram explorados: *Real-World Masked Face Dataset* (RMFD); *Simulated Masked Face Dataset* (SMFD) e *Labeled Faces in the Wild* (LFW). O SVM obteve a melhor acurácia para as três bases de dados, alcançando na última uma acurácia de 100%. Também foi, em geral, o melhor método quanto ao recall, precisão e F1 Score.

Na pesquisa de Wang *et al.* (2020), os autores aplicaram um modelo de regressão logística para alimentar um modelo de machine learning para séries temporais chamado de *FbProphet* com o objetivo de prever o número de casos e o pico da pandemia. Os dados foram retirados da base oficial da Johns Hopkins, focando

especialmente no Brasil, Rússia, Índia, Peru e Indonésia, além do cenário global. O modelo de estimação mostrou que o pico da pandemia seria ao final de outubro, com um acumulado de infecções na faixa de 14,12 milhões de pessoas no mundo todo.

A partir do uso de ANN, Magazzino *et al.* (2020) exploraram a concentração de materiais particulados (PM2.5 e PM10.0) e a sua relação com as mortes por COVID-19 nas cidades francesas de Paris, Lyon e Marseille. Desta forma, foi possível para os autores estimarem um valor de *threshold* de PM2.5 e PM10.0 no qual seria evidenciado que acima deste valor, o número de mortes pela COVID-19 cresceria. Também foi aplicado o *Causal Direction from Dependency* (D2C) para checar a consistência dos resultados.

Nour *et al.* (2020) utilizaram *deep learning* (especificamente, Rede Neural Convolucional) para identificar atributos significativos de imagens de raio-X de tórax com três classes (COVID-19, normal e pneumonia viral) para alimentar algoritmos de *machine learning*: KNN; SVN e DT. Um algoritmo bayesiano foi aplicado para a otimização dos hiperparâmetros e a validação foi a partir do *holdout* (70% para treino e 30% para teste). Os resultados mostraram que para todas as métricas analisadas, ou seja, acurácia, sensibilidade, especificidade e *F-score*, o modelo de SVM foi superior em três delas.

Já no trabalho de Yadaw *et al.* (2020), a pesquisa se baseou na predição da mortalidade pela COVID-19 e identificação dos atributos clínicos mais importantes de pacientes do hospital de Mount Sinai (*Mount Sinai Health System*, New York City, NY, USA). O estudo utilizou um conjunto de dados com mais de 4000 instâncias iniciais, contou a aplicação técnicas aplicadas foram a LR, RF, SVM e XGBoost e também de análise de atributos baseado em teste t, chi-quadrado e *Odds Ratio*. Os resultados mostraram que a oxigenação mínima é o atributo mais importante dentre aqueles analisados, enquanto que o XGBoost foi a técnica que mostrou o melhor desempenho para a métrica avaliada (AUC).

Yesilkanat (2020) utilizaram seis meses de dados para prever o número de casos em 190 países a partir da RF. Os dados foram retirados da Universidade Johns Hopkins (*Johns Hopkins University Center for Systems Science and Engineering*) e todo o estudo foi desenvolvido na linguagem de programação R. Foram avaliadas métricas como o R^2 , *Mean Error* (ME) e RMSE para a previsão de até 17 dias futuros, com treinamento na validação 10-fold. Foram encontrados resultados considerados

promissores para a previsão de curto período da pandemia da COVID-19 no cenário mundial.

Já Khan *et al.* (2020) analisaram a taxa de mortalidade pela COVID-19 em cinco países distintos (Turquia, Espanha, Paquistão, França e Suécia) a partir de técnicas de regressão: Modelo de regressão polinomial (PRM) e *Gaussian process regression* (GPR) com hiperparâmetros otimizados. Todos os dados foram coletados do European Center for Disease Prevention and Control (ECGC) por meio do site <https://ourworldindata.org/coronavirus>. O modelo foi validado em um conjunto de teste para as métricas de *Regression Loss* e RMSE, com GPR tendo se sobressaído na maior parte dos testes realizados.

Por fim, Ardakani *et al.* (2020) desenvolveram uma pesquisa a partir de tomografia computadorizada (CT) do tórax para classificar pacientes com a COVID-19. Foram utilizadas 1.020 imagens CT de 108 pacientes com COVID-19 e 86 pacientes com pneumonia adquirida de outras doenças, todas obtidas a partir na Iran University of Medical Science (IUMS). Análises estatísticas iniciais foram aplicadas para testar a normalidade dos dados (Kolmogorov-Smirnov), comparação de grupos (teste t e chi-quadrado), com nível de significância de 0,05. Técnicas baseadas em *deep learning* foram aplicadas com 10 topologias diferentes CNN para a classificação, baseando-se nas métricas de sensibilidade, especificidade, acurácia, *Positive Predictive Value* (PPV), *Negative Predictive Value* (NPV) e AUC. Nesta pesquisa, as redes ResNet-101 e *Xception* tiveram desempenhos superiores, com a ResNet-101 sendo considerada a mais recomendada pela sua alta sensibilidade, podendo ser uma ferramenta auxiliar em departamentos de radiologia.

5. MATERIAIS E MÉTODOS

Este trabalho é uma pesquisa de Modelagem e Simulação, de objetivo explicativo e abordagem quantitativa. Utilizou-se a base de dados disponibilizada pelo DataSUS com os casos reportados de SRAG no período de 01 de janeiro de 2020 até o dia 31 de dezembro de 2020. Para tratar os dados e criar os modelos de *machine learning* foi utilizada a linguagem *Python 3* na ferramenta *Jupyter Notebook*, e ainda as bibliotecas *Scikit-learn*, *Imblearn*, *Pandas* e *Numpy* para manipulação dos dados, e *Matplotlib* e *Seaborn* para visualização.


Os dados foram baixados em formato CSV e importados brutos para o Python, consistindo em 154 colunas e 1.187.048 linhas, então foi iniciado o pré-processamento dos dados. Como a variável resposta é a EVOLUCAO que, de acordo com o dicionário de dados que acompanha a base de dados pode ter resposta “1” para o paciente que se recuperou e “2” para o paciente que foi a óbito, qualquer registro com informações ausentes ou ignoradas (essas marcadas com o valor “9” no banco de dados) foi removido.

O próximo passo foi excluir todas as colunas que tinham mais de 50% de dados faltantes ou ignorados, e selecionar as variáveis de interesse para o modelo, nesse momento foram retiradas de forma manual da base informações como nome e código da cidade, identificador da unidade de saúde, código do país, entre outros. Após esta etapa restaram 956.491 linhas e 45 colunas, sendo 669.658 instancias na classe Cura e 286.833 na classe Óbito.

Em seguida as variáveis foram tratadas, categorizadas e dicotomizadas para que ao final os modelos trabalhassem exclusivamente com variáveis binárias, a partir desse conjunto que foi realizada a análise descritiva, nesta etapa ficaram 954.491 instâncias e 64 atributos que foram divididos entre clínicos e demográficos, o primeiro com 49 e o segundo com 15 atributos.

Os dados foram então divididos em treino (70%) e teste (30%). Esses grupos foram utilizados para a modelagem e classificação. Após essa etapa o resultado dos modelos foi mensurado, avaliados e discutidos, todas essas etapas podem ser vistas na Figura 6.

Figura 6 – Fluxograma das atividades realizadas neste trabalho




6. RESULTADOS E DISCUSSÕES

6.1 RESULTADO DA ANÁLISE DESCRITIVA

A distribuição de óbitos e curas por mês no ano de 2020 é mostrada na Figura 7.


Figura 7 – Distribuição do Volume de Casos de SRAG em 2020 por mês e por evolução.



É possível notar que após as primeiras notificações em março de 2020 os números sobem até o mês de julho que bate o recorde de notificações no ano e então baixam nos três meses para retomarem o aumento no último bimestre.

Na figura 8 é apresentado os principais agentes causadores de SRAG em 2020, onde é possível notar o quanto a COVID-19 foi significativa no volume de notificações.

Figura 8 - Agentes causadores de SRAG




De todos os casos presentes na base, 61,9% correspondem a COVID-19 e 36,7% não-especificados, foi possível observar no Brasil que juntamente com o aumento dos casos de Covid um aumento das notificações não-especificadas, parte

disso se justifica pela dificuldade de realizar as testagens para COVID-19 e o atraso no começo dos testes em relação ao restante do mundo.

A figura 9 mostra a taxa de mortalidade média por notificação por SRAG no ano de 2020 em cada estado do Brasil.

Figura 9 – Taxa de Mortalidade por caso notificado



Vale destacar os estados de Sergipe e Espírito Santo com 59,4% e 51,6% de taxa de fatalidade por SRAG respectivamente, sendo os estados com os maiores índices, seguidos por Roraima (48,6%), Rio de Janeiro (43,7%) e Maranhão (43,0%).

A taxa com que uma característica é apresentada no conjunto de dados e a taxa com que as pessoas que apresentaram essa característica foram a óbito estão na figura 10.

Figura 10 - Proporção de pacientes que apresentaram a característica e a taxa como que esses pacientes foram a óbito

SEXO_F	0.46	0.29
SEXO_I	0	0.18
SEXO_M	0.54	0.31
RACA_ASIATICA	0.01	0.32
RACA_BRANCA	0.39	0.29
RACA_INDIGENA	0	0.33
RACA_NAO_DECLARADA	0.16	0.26
RACA_NEGRA	0.38	0.32
ZONA_NAO_INFORMADA	0.01	0.28
ZONA_PERIURBANA	0	0.3
ZONA_RURAL	0.04	0.34
ZONA_URBANA	0.85	0.3
SUPPORT_VEN_INVASIVO	0.15	0.74
SUPPORT_VEN_NAO	0.26	0.12
SUPPORT_VEN_NAO_INFORMADO	0.04	0.36
SUPPORT_VEN_NAO_INVASIVO	0.42	0.23
RAIOX_RES_CONSOLIDACAO	0.02	0.33
RAIOX_RES_INFILTRADO_INTERSTICIAL	0.15	0.3
RAIOX_RES_MISTO	0.03	0.35
RAIOX_RES_NAO_INFORMADO	0.42	0.33
RAIOX_RES_NAO_REALIZADO	0.24	0.27
RAIOX_RES_NORMAL	0.04	0.15
RAIOX_RES_OUTRO	0.1	0.29
PCR_RESUL_AGUARDANDO	0.05	0.3
PCR_RESUL_DETECTAVEL	0.48	0.34
PCR_RESUL_INCONCLUSIVO	0	0.29
PCR_RESUL_NAO_DETECTAVEL	0.35	0.23
PCR_RESUL_NAO_INFORMADO	0.06	0.35
PCR_RESUL_NAO_REALIZADO	0.05	0.32
DIAGNOSTICO_COVID_19	0.62	0.35
DIAGNOSTICO_INFLUENZA	0	0.13
DIAGNOSTICO_NAO_ESPECIFICADO	0.37	0.22
DIAGNOSTICO_NAO_INFORMADO	0	0.36
DIAGNOSTICO_OUTRO_AGENTE	0	0.26
DIAGNOSTICO_OUTRO_VIRUS	0	0.07
	Apresentou	Óbito

É possível notar que a maioria dos casos notificados se dão por pessoas que vivem na zona urbana, porém a taxa de letalidade é semelhante entre os grupos da

zona urbana, rural, periurbana e não-informada. Quanto ao diagnóstico, COVID-19 é o que mais apareceu na base e com uma taxa de letalidade de 35% no grupo. Agora dentre as variáveis clínicas a que mais se destaca é o Suporte Ventilatório Invasivo que ocorreu em 15% dos casos deste estudo e que 75% desses casos evoluíram para óbito.

Na Figura 11 estão as taxas para idade, quantos estão presentes no grupo e quantos foram a óbito dentro de cada faixa etária.

Figura 11 – Taxa de pacientes em cada faixa etária e a taxa de pacientes que foram a óbito

IDADE_0-10	0.06	0.04
IDADE_11-20	0.02	0.08
IDADE_21-30	0.05	0.09
IDADE_31-40	0.09	0.12
IDADE_41-50	0.12	0.17
IDADE_51-60	0.16	0.25
IDADE_61-70	0.19	0.36
IDADE_MAIS_71	0.31	0.49
	Apresentou	Óbito

A partir desta figura é possível perceber que o volume de notificações aumenta com o aumento da idade assim como aumenta as taxas de óbito, sendo as maiores nos grupos acima de 51 anos.

6.2 RESULTADOS DOS MODELOS DE MACHINE LEARNING

A partir dos dados mostrados extraiu-se uma base de treino contendo 70% do volume dos dados e uma base de teste com o restante (ou seja, validação *holdout*). Além dessa divisão, foi feita uma separação entre variáveis clínicas e variáveis demográficas e cada modelo foi treinado e testado uma vez com a base somente com as variáveis clínicas e uma outra vez com todas as variáveis, clínicas e demográficas.

A seleção dos parâmetros dos modelos foi feita de forma manual, testando algumas combinações e escolhendo aquela com melhor resultado.

Os resultados dos modelos de aprendizado de máquina estão descritos na Tabela 1 com colunas distintas para cada conjunto de variáveis, somente clínicas e clínicas acrescidas das demográficas (chamada somente de “demográficas”).


Tabela 3 - Resultados dos modelos

Métricas	KNN		Árvore de Decisão		Regressão Logística	
	Clínicas	Demográficas	Clínicas	Demográficas	Clínicas	Demográficas
Precisão	0,77	0,77	0,78	0,79	0,78	0,78
Acurácia	0,77	0,78	0,79	0,80	0,79	0,79
F1 Score	0,77	0,77	0,79	0,79	0,78	0,78
AUC	0,79	0,79	0,83	0,84	0,83	0,84

Métricas	Florestas Aleatórias		XGBoost		Redes Neurais	
	Clínicas	Demográficas	Clínicas	Demográficas	Clínicas	Demográficas
Precisão	0,79	0,80	0,80	0,80	0,79	0,80
Acurácia	0,80	0,80	0,80	0,81	0,80	0,81
F1 Score	0,79	0,79	0,79	0,80	0,79	0,80
AUC	0,85	0,85	0,85	0,86	0,72	0,74

É possível notar da Tabela 3 que a diferença entre os modelos com os diferentes grupos de variáveis foi insignificante, sendo que o modelo de Redes Neurais foi o único que apresentou uma melhora em todas as métricas quando as variáveis demográficas foram adicionadas, mas em contrapartida, teve o pior desempenho em AUC. A Figura 12 apresenta o comparativo entre as curvas ROC do XGBoost e Redes Neurais.

Figura 12 – Curvas ROC para os classificadores XGBoost e Redes Neurais




O Modelo de XGBoost foi o que apresentou os melhores resultados em todas as métricas, acompanhado dos modelos de árvore, esses modelos são conhecidos

por lidarem bem com dados faltantes já que durante a fase de treino o algoritmo aprende a incluí-los nos nós de decisão, como muitas perguntas puderam ter suas respostas ignoradas durante o preenchimento dos dados nos hospitais, essa característica colocou os modelos de árvore em vantagem. O XGBost também foi um modelo que treinou e classificou mais rápido.

Os resultados obtidos foram melhores que àqueles obtidos por outras pesquisas. Wollenstein-Betech, *et al.* (2020) realizou uma pesquisa semelhante e foi obtido uma AUC de 0,79 no melhor classificador, que também foi o XGBoost, quanto à acurácia seu melhor classificador foi o SVM (*Support Vector Machines*) com resultado de 0,72 enquanto a acurácia tanto do XGBoost quanto das Redes Neurais neste trabalho foi de 0,81. O volume de instâncias utilizado nesta pesquisa foi 8 vezes maior do que o utilizado na pesquisa citada.

Os resultados obtidos pelos modelos de árvore também podem ser úteis pela facilidade de interpretação dos modelos, o que permite que seja possível conhecer quais atributos foram mais relevantes durante a classificação. A partir do modelo de Árvore de Decisão foi extraída a importância das variáveis, as 20 variáveis mais importantes estão apresentadas na Figura 13.

Figura 13 - Importância de Variáveis



A variável mais relevante para o modelo foi a variável que indica o uso ou não de suporte ventilatório invasivo, e utilizando os dados das Figura 10, nota-se que 74% de todos os pacientes da base que utilizaram esse tratamento foram a óbito. O uso de

suporte ventilatório invasivo é um recurso utilizado quando o paciente apresenta um quadro agravado de SRAG, sendo um dos últimos recursos, portanto, é esperado que esse atributo seja importante para descrever casos que podem ir a óbito.

Alguns outros atributos clínicos apareceram como importantes também como idade maior que 60 anos e paciente hospitalizado ou internado na UTI, além do diagnóstico do paciente com Covid-19. No conjunto das variáveis menos relevantes, destacam-se a Região não-informada, idade entre 11 e 40 anos, outros agentes etiológicos que não o Coronavírus, além de algumas outras variáveis que representaram um menor volume na base.

A primeira variável demográfica a aparecer em ordem de importância é a Região Nordeste em 15º lugar e Região Norte em 17º. Essas são as regiões mais escuras no mapa mostrado na Figura 9. Ou seja, onde houve a maior taxa de óbitos por casos notificados. Essas duas regiões também são as regiões mais pobres do Brasil, a região Norte foi a mais afetada pela primeira onda da pandemia e ao final de dezembro de 2020 a cepa P1, com maior transmissibilidade, era responsável por 31% das amostras examinadas.

7. CONCLUSÃO

O estudo sobre propagação de epidemias principalmente em países com uma grande desigualdade social é extremamente relevante e traz resultados que podem ser úteis na prevenção, controle e tratamento dessas doenças, por isso um estudo que considera variáveis demográficas assim como variáveis clínicas pode expor algumas características latentes no que diz respeito à saúde pública.

Neste trabalho foi possível identificar fatores que contribuem para a evolução dos casos de SRAG, principalmente casos de Covid-19, como uso de suporte ventilatório, internação, idade e região de habitação. Este estudo não tem por objetivo promover uma análise completa de causa e efeito, já que para tanto uma análise muito mais profunda deve ser feita e em colaboração com pesquisadores da área da saúde e saúde coletiva.

Os modelos de classificação se mostraram eficientes e, portanto, úteis no direcionamento de ações e pesquisas para entender como a pandemia de Covid-19 está se comportando no Brasil. Futuros estudos podem levar essa pesquisa adiante com novos dados de 2021 assim como diferentes classificadores que podem retornar novas análises e entendimentos sobre o tema. É possível utilizar a base de dados de 2020 para treinar o modelo e avaliar sua performance na base de casos de 2021, observando assim mudanças nas características da pandemia e quais variáveis melhor podem indicar essa transformação. Na área clínica é possível separar variáveis de tratamento daquelas de sintomas e comorbidades para avaliar qual dos grupos de variável consegue melhor descrever a evolução do caso.

REFERÊNCIAS

AGGARWAL, Charu C. **Data mining**: The textobook. New York, EUA: Springer. 2015

AHAMAD, Md. Martuza; AKTAR, Sakifa; RASHED-AL-MAHFUZ, Md.; UDDIN, Shahadat; LIÒ, Pietro; XU, Haoming; SUMMERS, Matthew A.; QUINN, Julian M.W.; MONI, Mohammad Ali. A machine learning model to identify early stage symptoms of SARS-Cov-2 infected patients. **Expert Systems With Applications**, v. 160, p. 113661, dez. 2020. Elsevier.

ALZHRANI, Saleh I.; ALJAMAAN, Ibrahim A.; AL-FAKIJ, Ebrahim I. Forecasting the spread of the COVID-19 pandemic in Saudi Arabia using ARIMA prediction model under current public health interventions. **Journal of Infection and Public Health**, v. 13, n. 7, p. 914-919, jul. 2020.

ARAUJO, Kamilla Lelis Rodrigues de; AQUINO, Érika Carvalho de; SILVA, Lara Livia Santos da; TERNES, Yves Mauro Fernandes. Fatores associados à Síndrome Respiratória Aguda Grave em uma Região Central do Brasil. **Ciência & Saúde Coletiva**, v. 25, n. 2, p. 4121-4130, out. 2020.

ARDAKANI, Ali Abbasian; KANAFI, Alireza Rajabzadeh; ACHARYA, U. Rajendra; KHADEM, Nazanin; MOHAMMADI, Afshin. Application of deep learning technique to manage COVID-19 in routine clinical practice using CT images: results of 10 convolutional neural networks. **Computers In Biology And Medicine**, v. 121, p. 103795, jun. 2020.

BANERJEE, Abhirup; RAY, Surajit; VORSELAARS, Bart; KITSON, Joanne; MAMALAKIS, Michail; WEEKS, Simonne; BAKER, Mark; MACKENZIE, Louise S.. Use of Machine Learning and Artificial Intelligence to predict SARS-CoV-2 infection from Full Blood Counts in a population. **International Immunopharmacology**, v. 86, p. 106705, set. 2020.

CASCARDI, Alessio; MICELLI, Francesco; AIELLO, Maria Antonietta. An Artificial Neural Networks model for the prediction of the compressive strength of FRP-confined concrete circular columns. **Engineering Structures**, v. 140, p. 199-208, jun. 2017.

CHEN, Tianqi; GUESTRIN, Carlos. XGBoost. **Proceedings Of The 22Nd Acm Sigkdd International Conference On Knowledge Discovery And Data Mining**, p. 785-794, 13 ago. 2016. ACM. Disponível em: <<https://dl.acm.org/doi/abs/10.1145/2939672.2939785>>. Acesso em: 11 ago. 2021.

CHIAVEGATTO FILHO, Alexandre Dias Porto. Uso de big data em saúde no Brasil: perspectivas para um futuro próximo. **Epidemiologia e Serviços de Saúde**, v. 24, n. 2, p. 325-332, jun. 2015.

DEWILDE, Burton. **Classification of hand-written digits (3)**. 2012. Disponível em: <<https://bdewilde.github.io/blog/blogger/2012/10/26/classification-of-hand-written-digits-3/>>. Acesso em 24 ago. 2021.

DEY, Lopamudra; CHAKRABORTY, Sanjay; MUKHOPADHYAY, Anirban. Machine learning techniques for sequence-based prediction of viral–host interactions between SARS-CoV-2 and human proteins. **Biomedical Journal**, v. 43, n. 5, p. 438-450, out. 2020.

FRIEDMAN, Jerome H. Stochastic gradient boosting. **Computational Statistics & Data Analysis**, Elsevier, v. 38, n. 4, p. 367–378, 2002

GATTI, Roberto Cazzolla; VELICHEVSKAYA, Alena; TATEO, Andrea; AMOROSO, Nicola; MONACO, Alfonso. Machine learning reveals that prolonged exposure to air pollution is associated with SARS-CoV-2 mortality and infectivity in Italy. **Environmental Pollution**, v. 267, p. 115471, dez. 2020.

GERÓN, Aurélien. **Hands-on machine learning with Scikit-Learn, Keras & TensorFlow**: Concept, tools, and techniques to build inteligente systems. 2. ed. Sebastopol, CA, EUA: O'Reilly Media, 2019.

GHOSH, Kalyan; AMIN, Sk. Abdul; GAYEN, Shovanlal; JHA, Tarun. Chemical-informatics approach to COVID-19 drug discovery: exploration of important fragments and data mining based prediction of some hits from natural origins as main protease (mpro) inhibitors. **Journal Of Molecular Structure**, v. 1224, p. 129026, jan. 2021.

GOMES, Pedro, César Tebaldi. Conheça o algoritmo XGBoost. **Datageeks**. 2019. Disponível em: <<https://www.datageeks.com.br/xgboost/>>. Acesso em 11 ago. 2021.

GRUS, Joel. **Data science do zero**: primeiras regras com Python. Rio de Janeiro: Altabooks, 2016.

HAN, Jiawei; KAMBER, Micheline; PEI, Jian. **Data Mining**: concepts and techniques. 3 ed. Waltham, MA, EUA: Morgan Kaufmann, 2012.

JAMES, Gareth *et al.* **An Introduction to Statistical Learning**: with applications in R. Stanford: Springer, 2013.

KAVADI, Durga Prasad; PATAN, Rizwan; RAMACHANDRAN, Manikandan; GANDOMI, Amir H. Partial derivative Nonlinear Global Pandemic Machine Learning prediction of COVID 19. **Chaos, Solitons & Fractals**, v. 139, p. 110056, out. 2020.

KHAN, Y.A.; ABBAS, S. Z.; TRUONG, Buu-Chau. Machine learning-based mortality rate prediction using optimized hyper-parameter. **Computer Methods And Programs In Biomedicine**, v. 197, p. 105704, dez. 2020.

LOEY, Mohamed; MANOGARAN, Gunasekaran; TAHA, Mohamed Hamed N.; KHALIFA, Nour Eldeen M.. A hybrid deep transfer learning model with machine learning methods for face mask detection in the era of the COVID-19 pandemic. *Measurement*, v. 167, p. 108288, jan. 2021.

MACIEL, Thales Vaz; SEUS, Vinicius da Rosa; MACHADO, Karina dos Santos; BORGES, Eduardo Nunes. Mineração de dados em triagem de risco de saúde. **Revista Brasileira de Computação Aplicada**, v. 7, n. 2, p. 26-40, 13 maio 2015. UPF Editora.

MAGAZZINO, Cosimo; MELE, Marco; SCHNEIDER, Nicolas. The relationship between air pollution and COVID-19-related deaths: an application to three french cities. **Applied Energy**, v. 279, p. 115835, dez. 2020.

NOUR, Majid; CÖMERT, Zafer; POLAT, Kemal. A Novel Medical Diagnosis model for COVID-19 infection detection based on Deep Features and Bayesian Optimization. **Applied Soft Computing**, v. 97, p. 106580, dez. 2020.

MOHANTY, Awhan. Multi layer perceptron (MLP) models on real world banking data. **Becoming Human**. Disponível em: < <https://becominghuman.ai/multi-layer-perceptron-mlp-models-on-real-world-banking-data-f6dd3d7e998f>>. Acesso em 11 ago. 2021.

NCSS. **Roc curves in NCSS**. 2021. Disponível em: <<https://www.ncss.com/software/ncss/roc-curves-ncss/>>. Acesso em 24 ago. 2021.

NEMATİ, Mohammadreza; ANSARY, Jamal; NEMATİ, Nazafarin. Machine-Learning Approaches in COVID-19 Survival Analysis and Discharge-Time Likelihood Prediction Using Clinical Data. **Patterns**, v. 1, n. 5, p. 100074, ago. 2020.

NGIAM, Kee Yuan; KHOR, Ing Wei. Big data and machine learning algorithms for health-care delivery. **The Lancet Oncology**, v. 20, n. 5, p. 262-273, maio 2019.

CHIRE, Josimar. Data Mining Approach to Analyze Covid19 Dataset of Brazilian Patients. **Medrxiv**, p. 1-15, 15 ago. 2020. Cold Spring Harbor Laboratory.

SINGH, Sarbjit; PARMAR, Kulwinder Singh; MAKKHAN, Sidhu Jitendra Singh; KAUR, Jatinder; PESHORIA, Shruti; KUMAR, Jatinder. Study of ARIMA and least square support vector machine (LS-SVM) models for the prediction of SARS-CoV-2 confirmed cases in the most affected countries. **Chaos, Solitons & Fractals**, v. 139, p. 110086, out. 2020.

SOLEIMANI-ROOZBAHANI, Fatemeh; GHATARI, Ali Rajabzadeh; RADFAR, Reza. Knowledge discovery from a more than a decade studies on healthcare Big Data systems: a scientometrics study. **Journal Of Big Data**, v. 6, n. 1, p. 2-15, 31 jan. 2019. Springer Science and Business Media LLC

TREXLER, Joel C.; TRAVIS, Joseph. Nontraditional Regression Analyses. **Ecology**, v. 74, n. 6, p. 1629-1637, set. 1993. Wiley.

TULI, Shreshth; TULI, Shikhar; TULI, Rakesh; GILL, Sukhpal Singh. Predicting the growth and trend of COVID-19 pandemic using machine learning and cloud computing. **Internet Of Things**, v. 11, p. 100222, set. 2020.

WANG, Peipei; ZHENG, Xinqi; LI, Jiayang; ZHU, Bangren. Prediction of epidemic trends in COVID-19 with logistic model and machine learning technics. **Chaos, Solitons & Fractals**, v. 139, p. 110058, out. 2020.

WOLLENSTEIN-BETECH, Salomón; SILVA, Amanda A. B.; FLECK, Julia L.; CASSANDRAS, Christos G.; PASCHALIDIS, Ioannis Ch.. Physiological and socioeconomic characteristics predict COVID-19 mortality and resource utilization in Brazil. **Plos One**, v. 15, n. 10, p. 1-15, 14 out. 2020. Public Library of Science (PLoS)

YADAW, Arjun s; LI, Yan-Chak; BOSE, Sonali; IYENGAR, Ravi; BUNYAVANICH, Supinda; PANDEY, Gaurav. Clinical features of COVID-19 mortality: development and validation of a clinical prediction model. **The Lancet Digital Health**, v. 2, n. 10, p. 516-525, out. 2020.

YEŞILKANAT, Cafer Mert. Spatio-temporal estimation of the daily cases of COVID-19 in worldwide using random forest machine learning algorithm. **Chaos, Solitons & Fractals**, v. 140, p. 110210, nov. 2020.

Z_AI. Logistic regression explained. **Towards Data Science**. 2020. Disponível em: <<https://towardsdatascience.com/logistic-regression-explained-9ee73cede081>>. Acesso em 24 ago. 2021.