

UNIVERSIDADE FEDERAL DO ESPÍRITO SANTO - UFES
CENTRO UNIVERSITÁRIO DO NORTE DO ESPÍRITO SANTO - CEUNES
DEPARTAMENTO DE COMPUTAÇÃO E ELETRÔNICA - DCE
BACHARELADO EM CIÊNCIA DA COMPUTAÇÃO

IASMIN MARQUES PEREIRA

Análise de Dados – DataSUS sobre a Síndrome Respiratória Aguda Grave

SÃO MATEUS, ES

2025

IASMIN MARQUES PEREIRA

Análise de Dados – DataSUS sobre a Síndrome Respiratória Aguda Grave

Proposta de monografia apresentada ao curso de Ciência da Computação do Centro Universitário do Norte do Espírito Santo, como requisito parcial para cumprimento da disciplina de Trabalho de Conclusão de Curso.

Orientadora: Prof.^a Silvia das Dores Rissino (UFES).

SÃO MATEUS, ES

2025

SUMÁRIO

1	INTRODUÇÃO.....	1
2	PROBLEMA E HIPÓTESE	4
2.1	PROBLEMA DE PESQUISA	4
2.2	HIPÓTESE.....	4
3	REFERENCIAL TEÓRICO.....	5
3.1	SRAG (SÍNDROME RESPIRATÓRIA AGUDA GRAVE)	5
3.2	DADOS.....	5
3.2.1	KDD	5
3.2.2	DADOS ABERTOS	7
3.2.3	BASE DE DADOS SRAG (DataSUS).....	7
3.3	PRÉ-PROCESSAMENTO DE DADOS	7
3.4	ANÁLISE DE DADOS	9
3.5	TÉCNICAS DE ANÁLISE	9
3.6	ALGORITMOS	9
3.6.1	ANÁLISE ESTATÍSTICA.....	10
3.6.2	MINERAÇÃO DE DADOS.....	11
3.6.3	APRENDIZADO DE MÁQUINA	11
3.6.4	REDES NEURAIS E DEEP LEARNING	12
3.6.5	ÁRVORES DE DECISÃO.....	13
3.7	APRENDIZADO DE MÁQUINA	13
4	OBJETIVOS.....	15
4.1	OBEJETIVO GERAL.....	15
4.2	OBJETIVOS ESPECÍFICOS	15
5	METODOLOGIA.....	16
6	RESULTADOS INICIAIS	19
7	CRONOGRAMA	21
8	REFERÊNCIAS BIBLIOGRÁFICAS	23

1 INTRODUÇÃO

A saúde pública no Brasil enfrenta desafios consideráveis em virtude da vasta extensão territorial e das diferenças socioeconômicas presentes no país atualmente. O Sistema Único de Saúde (SUS) é reconhecido como uma das mais amplas iniciativas de saúde pública em escala global, buscando sempre garantir o acesso universal aos serviços de saúde para milhões de cidadãos brasileiros, no entanto alguns desafios como a sobrecarga do sistema de saúde e a desigualdade no acesso aos serviços reforçam a necessidade de estratégias inovadoras para aprimorar a gestão de equipamentos, pessoas e da eficiência hospitalar (Paim, 2020). Além disso, com a pandemia de COVID-19 ficou evidente a importância da modernização dos sistemas de monitoramento e previsão de surtos, tornando essencial o uso de técnicas avançadas de análise de dados para auxiliar na tomada de decisões (Silva e Silva Neto, 2022).

Além da importância que temos da modernização de sistemas de monitoramento, pode-se verificar, através de estudos que a inteligência artificial tem desempenhado um papel fundamental na análise de dados de saúde, permitindo a identificação precoce de fatores de risco, a previsão de desfechos clínicos e a otimização da alocação de recursos hospitalares (Sena, 2021).

A saúde é um direito fundamental do ser humano e um pilar essencial para o desenvolvimento social e econômico de uma sociedade. Para auxiliar a garantir esse direito básico à população existe o monitoramento epidemiológico, que desempenha um papel central na prevenção e no controle de doenças, através dele temos a possibilidade de alocação eficiente de recursos e até mesmo a antecipação de surtos. Pode-se verificar que tecnologias como a inteligência artificial (*Artificial Intelligence* - AI) e o aprendizado de máquina (*Machine Learning* - ML) vem sendo muito utilizadas para detectar padrões em pequeno e grandes volumes de dados, auxiliando no desenvolvimento de estratégias preventivas e na tomada de decisões clínicas (Sena, 2021).

A utilização de tecnologias como o Aprendizado de Máquina e Inteligência Artificial tornam-se cada vez mais relevantes diante de doenças, como por exemplo a Síndrome Respiratória Aguda Grave (SRAG), que apresentam altos índices de hospitalização e mortalidade (Belini, Ataíde e Lochter, 2024).

A Síndrome Respiratória Aguda Grave (SRAG) é uma condição respiratória severa causada por diferentes agentes infecciosos, incluindo SARS-CoV-2¹, Influenza² e Vírus Sincicial Respiratório. O SRAG possui um impacto que tem sido crítico sobre o sistema de saúde, reforçando a necessidade de abordagens de prevenção e previsão para otimizar o atendimento e reduzir a mortalidade da população.

Estudos apontam que a SRAG afeta predominantemente grupos vulneráveis, como por exemplo em idosos e indivíduos com comorbidades, como por exemplo doenças cardiovasculares, diabetes, doenças renais crônicas, doenças pulmonares crônicas, obesidade; e que pode levar a complicações graves que demandam suporte maior, como internação em UTI³ e ventilação mecânica (Silva, 2021). Uma ferramenta que auxilia na previsão de casos de risco da Síndrome (SRAG) é a análise preditiva, é através dela que temos a possibilidade de uma resposta mais rápida e eficaz do sistema de saúde (Júnior, 2024).

A capacidade de prever casos graves de SRAG pode contribuir para uma resposta mais eficiente e rápida, permitindo um melhor direcionamento de recursos hospitalares, como por exemplo os leitos de UTI e ventiladores mecânicos. Modelos preditivos baseados em aprendizado de máquina vêm sendo utilizados para identificar fatores de risco e prever desfechos clínicos, possibilitando intervenções precoces (Sena, 2021). Abordagens como esta são fundamentais para otimizar a gestão hospitalar e aprimorar as políticas de saúde pública. A aplicação desses modelos tem mostrado resultados positivos na alocação eficiente de recursos, melhoria da gestão hospitalar e consequentemente reduzir a mortalidade em pacientes críticos (Silva e Silva Neto, 2022).

O processo de análise de dados para predição de doenças segue a abordagem do *Knowledge Discovery in Databases* (KDD), em português a Descoberta de Conhecimento em Bases de Dados, que possui diversas etapas interdependentes para a extração de conhecimento útil a partir de grandes volumes de dados (Fayyad, Piatetsky-Shapiro e Smyth, 1996). As etapas que serão utilizadas, a partir da abordagem do KDD, são a seleção de dados, pré-processamento, a transformação de dados, mineração de dados, interpretação e avaliação dos resultados.

¹ SARS-COV-2: pertence à família Coronaviridae, subgênero Sarbecovírus, e é o sétimo coronavírus conhecido a infectar humanos.

² Influenza: A influenza, também conhecida como gripe, é uma doença viral que afeta o sistema respiratório.

³ UTI: Unidade hospitalar de pacientes gravemente doente

Embora o processo de KDD siga uma sequência estruturada de etapas, ele não é estritamente linear. Durante a análise pode ser necessário retornar a etapas anteriores para fazer ajustes, como por exemplo: refinar o pré-processamento, modificar a seleção de algumas variáveis ou testar novos modelos de aprendizagem. Essas iterações ocorrem para garantir que os insights extraídos dos dados sejam mais precisos e úteis para a tomada de decisão (Fayyad, Piatetsky-Shapiro e Smyth, 1996).

Este estudo tem como objetivo investigar metodologias para análise de desfechos clínicos em pacientes diagnosticados com SRAG, utilizando dados do DataSUS de 2024. Para isso, serão revisadas técnicas de aprendizado de máquina, como Regressão Logística, *Random Forest* e *XGBoost* e além disso, busca-se identificar quais variáveis são mais relevantes na predição do desfecho clínico dos pacientes, contribuindo para futuras aplicações no TCC 2.

2 PROBLEMA E HIPÓTESE

2.1 PROBLEMA DE PESQUISA

O aumento constante dos casos de Síndrome Respiratória Aguda Grave (SRAG) reforça a necessidade de aprimorar as estratégias de monitoramento e previsão de desfechos clínicos, visando otimizar a assistência aos pacientes e a tomada de decisão na saúde pública. Diante disso, como as técnicas de análise preditiva podem ser aplicadas aos dados do DataSUS para prever desfechos clínicos de pacientes com SRAG? E quais as variáveis disponíveis no conjunto de dados do DataSUS (SRAG 2021 a 2024) estão mais associadas ao desfecho clínico de óbito?

2.2 HIPÓTESE

Através da utilização de técnicas de mineração de dados para análise de desfechos clínicos de pacientes com SRAG em dados clínicos processados, comparados e exibidos de modo a gerar previsões mais precisas e completas que podem facilitar a tomada de decisões clínicas mais assertivas e aprimorando as estratégias de monitoramento e intervenção em saúde pública.

3 REFERENCIAL TEÓRICO

3.1 SRAG (SÍNDROME RESPIRATÓRIA AGUDA GRAVE)

A Síndrome Respiratória Aguda Grave (SRAG) é uma infecção respiratória severa caracterizada por sintomas como tosse, febre, desconforto respiratório, pressão ou dor persistente no tórax, dispneia e baixa saturação de oxigênio (menor que 95% em ar ambiente). Sua etiologia⁴ está relacionada a diversos agentes infecciosos, como por exemplo: vírus, Influenza, SARS-CoV-2 e Vírus Sincicial Respiratório (Belini, Ataíde e Lochter, 2024).

A SRAG pode abranger casos de Síndrome Gripal (SG) que quando evoluídos podem levar a pessoa a hospitalização, na maioria dos casos, comprometendo o sistema respiratório. Quando um paciente apresenta sinais da SG junto com sinais mais graves como dispneia, desconforto respiratório, saturação de oxigênio inferior a 95% é notificada no SIVEP-Gripe⁵ (Belini, Ataíde e Lochter, 2024).

Pode-se diferenciar a SRAG da SG através da gravidade dos sintomas que a pessoa apresenta, em caso leve é considerado SG com suspeita de COVID-19 já em casos mais graves a pessoa apresenta SRAG. Durante a pandemia provocada pela COVID-19, a SRAG ganhou maior relevância, evidenciando a necessidade de estratégias preventivas para identificação precoce de casos graves e otimização de recursos hospitalares (Júnior, 2024).

3.2 DADOS

3.2.1 KDD

A descoberta de conhecimento em banco de dados, mas também conhecido como KDD, *Knowledge Discovery in Databases*, é um processo que permite a identificação de padrões, informações e conhecimentos através de etapas que são interdependentes. As etapas que serão utilizadas para auxiliar na interpretação do conjunto de dados são: seleção de dados, pré-

⁴ Etiologia: é o estudo ou ciência das causas.

⁵ SIVEP-Gripe: Sistema de Informação da Vigilância Epidemiológica da Gripe.


processamento, a transformação de dados, mineração de dados, interpretação e avaliação dos resultados.

Esse processo inicia-se com na etapa de seleção dos dados, onde informações relevantes são extraídas de bases públicas, como a que será utilizada será a do DataSUS. Na segunda etapa é realizado o pré-processamento de dados garantindo sempre a qualidade do conjunto de dados, nela ocorre a normalização, limpeza e tratamento de valores nulos, duplicados, ausentes e irrelevantes (Júnior, 2024).

A próxima fase envolve a transformação dos dados, onde são aplicadas técnicas como, por exemplo, engenharia de atributos para destacar variáveis importantes para a modelagem. Em seguida, ocorre a mineração de dados, etapa onde algoritmos de aprendizado de máquina são utilizados para prever desfechos clínicos e identificar padrões. Modelos como Regressão Logística, *Decision Tree* e *Random Forest* são amplamente utilizados nesse contexto, apresentando um alto desempenho na predição de mortalidade em pacientes com SRAG (Silva e Silva Neto, 2022).

Na última etapa ocorre a interpretação e avaliação dos resultados através da utilização de métricas, como por exemplo acurácia, precisão, *recall* e AUC-ROC para validar a eficácia dos modelos. A análise desses resultados possibilita a extração de *insights* clínicos valiosos, contribuindo para a tomada de decisão na gestão hospitalar e saúde pública (Belini, Ataide e Lochter, 2024).

Figura 1 – As etapas do processo de KDD



Fonte: ZOUZA (2025, online).

3.2.2 DADOS ABERTOS

Dados abertos referem-se a conjuntos de informações disponibilizados sem restrições e com transparência para o público, possibilitando sua reutilização para pesquisas científicas e desenvolvimento de políticas públicas. Essas bases de dados possuem quatro principais características: disponibilidade de acesso, reutilização, redistribuição e participação universal (Júnior, 2024).

Bases de dados abertas podem representar informações importantes em diversas áreas, como por exemplo, saúde, educação, desenvolvimento, economia, negócios, entre outras áreas. No contexto da saúde, os dados abertos viabilizam estudos epidemiológicos e a construção de modelos preditivos (Silva, 2021).

3.2.3 BASE DE DADOS SRAG (DataSUS)

Através da Secretaria de Vigilância em Saúde (SVS), o Ministério da Saúde (MS) faz a vigilância da SRAG no Brasil desde a pandemia de Influenza A(H1N1)pdm09. A partir disso, a vigilância de SRAG foi incorporada à rede de vigilância de Influenza e outros vírus respiratórios, que anteriormente atuava exclusivamente com a vigilância sentinela de Síndrome Gripal (SG) (MINISTÉRIO DA SAÚDE, 2025).

Atualmente o DataSUS é a principal plataforma de dados abertos em saúde no Brasil, disponibilizando informações epidemiológicas, hospitalares e ambulatoriais que podem servir para análises objetivas que podem facilitar na tomada de decisões. O acesso a esses dados permite análises aprofundadas sobre a incidência de doenças e os impactos no sistema de saúde (Júnior, 2024).

3.3 PRÉ-PROCESSAMENTO DE DADOS

O pré-processamento é uma etapa essencial pois é com ela que garantimos a qualidade dos dados fazendo a remoção de ruídos e a adequação dos dados às necessidades analíticas. Técnicas como, por exemplo, transformação de variáveis, normalização e redução de dimensionalidade são aplicadas para melhorar a representatividade dos dados e minimizar o

impacto de *outliers*, garantindo que os modelos consigam aprender padrões significativos (Júnior, 2024).

Na etapa de pré-processamento é onde ocorre o tratamento de valores ausentes, normalização de variáveis e balanceamento de classes. É comum em bases de dados alguns valores ausentes, como por exemplo campos com preenchimento não obrigatórios em formulários, isso pode comprometer a precisão dos modelos.

No tratamento de valores ausentes ocorre a manipulação desses dados, não necessariamente a eliminação deles, pois isso pode afetar o nosso resultado final. Métodos como imputação por média, mediana e algoritmos de preenchimento baseado em aprendizado de máquina são utilizados para excluir informações duplicadas, nulas e também para minimizar esse problema (Sena, 2021).

Na etapa de normalização de variáveis é onde ocorre a padronização para que fiquem dentro de uma mesma escala, evitando que atributos com valores numéricos altos influenciem desproporcionalmente os modelos preditivos (Belini, Ataíde e Lochter, 2024). Como por exemplo a normalização *min-max*, que transforma os valores de uma variável para uma escala específica, geralmente entre 0 e 1), o que facilita a comparação entre as variáveis de diferentes magnitudes; pode ser utilizada na idade dos pacientes, exemplo na equação (1), sendo calculado para um paciente de 50 anos.

$$X_{normalizado} = \frac{X - X_{mínimo}}{X_{máximo} - X_{mínimo}} = \frac{50 - 20}{80 - 20} = \frac{30}{60} = 0.5 \quad (1)$$

Dessa forma, a idade é convertida para uma escala entre 0 e 1, facilitando a comparação entre variáveis de diferentes magnitudes em algoritmos de aprendizado de máquina.

O desbalanceamento de classes ocorre quando há uma disparidade significativa entre as categorias de um conjunto de dados, com a utilização de técnicas como *Random UnderSampling* e SMOTE (*Synthetic Minority Over-sampling Technique*) pode-se corrigir esse problema. O *UnderSampling* reduz a quantidade de dados, mas ainda mantém a qualidade, enquanto o SMOTE pode gerar dados sintéticos que não representam a realidade, proporcionando um melhor equilíbrio na aprendizagem do modelo (Júnior, 2024).

3.4 ANÁLISE DE DADOS

A análise de dados é um processo que possui como principal objetivo transformar informações e números em insights que auxiliam na otimização e descoberta de conhecimento para tomada de decisões mais assertivas. Métodos como o aprendizado de máquina e mineração de dados são amplamente utilizados para identificar padrões ocultos e gerar *insights* estratégicos a partir de grandes volumes de informação.

Na área da saúde, a análise de dados tem se tornado um campo fundamental para o monitoramento e tomada de decisões clínicas e epidemiológicas. O uso de dados estruturados permite a criação de modelos, como por exemplo modelos preditivos capazes de identificar padrões em grandes volumes de informações, auxiliando na prevenção e controle de doenças (Belini, Ataide e Lochter, 2024).

3.5 TÉCNICAS DE ANÁLISE

A análise de dados envolve muitas abordagens que permitem extrair informações relevantes de grandes volumes de dados. Técnicas estatísticas e de aprendizado de máquina desempenham um papel fundamental nesse processo, pois possibilitam a construção de modelos e identificação de padrões diferentes aplicações, desde classificação e previsão até agrupamento e detecção de anomalias (Sena, 2021).

3.6 ALGORITMOS

Existem diversas técnicas de Análise de Dados que utilizam diferentes algoritmos, como por exemplo a análise estatística, mineração de dados, Aprendizado de Máquina, redes neurais e *Deep Learning*.

3.6.1 ANÁLISE ESTATÍSTICA

3.6.1.1 Regressão Linear

A Regressão Linear é uma técnica estatística muito utilizada para previsão de valores numéricos com base em variáveis independentes. O algoritmo busca modelar a relação entre uma variável independente (ou mais variáveis) através de uma equação linear. Como por exemplo, na equação (2) da regressão linear simples, que demonstra a previsão do preço de uma casa com base em sua área.

$$y = \beta_0 + \beta_1 x + \epsilon \quad (2)$$

Onde,

- y representa uma variável dependente
- x representa a variável independente
- β_0 é o intercepto
- β_1 é o coeficiente angular
- ϵ é o erro.

3.6.1.2 Regressão Logística

A Regressão Logística é um método estatístico amplamente utilizado para modelagem de variáveis categóricas cujo o principal objetivo é estimar a probabilidade de um evento ocorrer com base em variáveis independentes, sendo muito utilizada em problemas de classificação binária (Silva e Silva Neto, 2022). Como por exemplo, na equação (3), temos que a regressão logística usa a função sigmoide (logística)⁶ para transformar uma combinação linear de variáveis independentes em uma probabilidade; nesse caso utilizada para modelar a probabilidade de um evento binário ocorrer: prever se um paciente tem ou não uma determinada doença.

$$P(y = 1 | x) = \frac{1}{1 + e^{-(\beta_0 + \beta_1 x)}} \quad (3)$$

⁶ Função sigmoide é uma função matemática que gera uma curva em forma de "S"

Onde,

- $P(y = 1 | x)$: é a probabilidade de o evento ocorrer (por exemplo, ter ou não a doença);
- β_0 : intercepto (termo constante).
- β_1 : coeficiente que representa o impacto da variável X .
- e : base do logaritmo natural (aproximadamente 2,718).

3.6.2 MINERAÇÃO DE DADOS

A mineração de dados é o processo de explorar grandes conjuntos de dados para descobrir padrões, correlações e informações úteis.

3.6.2.1 Apriori

Apriori é um algoritmo utilizado para encontrar padrões frequentes em bases de dados transacionais, alguns casos de uso comuns são sistemas de previsão e recomendação de doenças, como análise de cestas de mercado para plataformas de comércio eletrônico (IBM, 2024).

3.6.2.2 K-Means

O *K-Means* é um algoritmo de agrupamento que divide dados, não rotulados, em “*K*” *clusters* com base em características semelhantes, é muito utilizado em ciência de dados para segmentação de mercado, segmentação de imagens, agrupamento de documentos e compactação de imagens (IBM, 2024).

3.6.3 APRENDIZADO DE MÁQUINA

3.6.3.1 Random Forest

O algoritmo *Random Forest* (traduzido para Floresta Aleatória) é uma técnica baseada em um conjunto de árvores de decisão, sendo eficaz para problemas de classificação, previsão e regressão. Estudos indicam que esse método tem alto desempenho na predição de desfechos clínicos (Belini, Ataíde e Lochter, 2024). Através dele é possível melhorar a precisão e reduzir o *overfitting*⁷, como por exemplo na previsão de uma espécie de uma flor com base em suas características.

⁷ Overfitting: ocorre quando um algoritmo se ajusta muito de perto aos seus dados de treinamento;

3.6.3.2 XGBoost

O *XGBoost* (*Extreme Gradient Boosting* - traduzido para aumento de gradiente extremo) é um algoritmo baseado em árvores de decisão (que será explicado mais à frente) que utiliza *boosting* para aumentar a precisão preditiva. Ele é altamente otimizado e frequentemente utilizado em disciplinas do curso de ciência de dados, como por exemplo computação paralela e distribuída, devido ao seu alto desempenho e eficiência computacional (Silva, 2021). Um exemplo de utilização desse algoritmo pode ser para previsão de preço de ações com base em indicadores financeiros.

3.6.3.3 K -Nearest Neighbors (KNN)

O algoritmo *k-Nearest Neighbors* (kNN - traduzido para *k*-vizinhos mais próximos) classifica novas amostras com base na proximidade em relação aos vizinhos mais próximos, muito utilizado para tarefas de reconhecimento de padrões. Ele classifica um novo dado considerando os "*k*" vizinhos mais próximos no espaço multidimensional, concedendo a ele o rótulo mais frequente entre os vizinhos. Como por exemplo, recomendar filmes a um usuário com base nas preferências de usuários semelhantes.

O método é simples e eficaz para reconhecimento de padrões, sendo utilizado em diversas aplicações, incluindo análises na área da saúde. Para calcular a proximidade entre instâncias, o *KNN* faz a utilização de métricas como a distância euclidiana, o que pode impactar diretamente na acurácia do modelo (Silva, 2021).

3.6.3.4 Support Vector Machine (SVM)

Support Vector Machine (SVM - traduzido para máquina de vetores de suporte) é um algoritmo que encontra um hiperplano que faz a separação de classes de dados amplamente utilizados para tarefas de classificação e regressão. O principal objetivo do algoritmo é encontrar um hiperplano ótimo que maximize a margem entre diferentes classes, permitindo uma separação eficiente dos dados. Esse método é frequentemente empregado em problemas médicos e de detecção de padrões devido à sua capacidade de generalização, boa seleção de atributos e alta acurácia (Silva, 2021).

3.6.4 REDES NEURAIIS E DEEP LEARNING

3.6.4.1 Artificial Neural Networks (ANNs)

As *Artificial Neural Networks* (RNAs - Redes Neurais Artificiais) são modelos inspirados no funcionamento do cérebro humano e têm sido aplicadas com sucesso na predição de doenças, especialmente em problemas complexos como diagnóstico por imagem (Júnior, 2024). Um exemplo de utilização é o reconhecimento de escrita manual.

3.6.4.2 Redes Neurais Convolucionais (CNNs)

As Redes Neurais Convolucionais (CNNs - *Convolutional Neural Network*) é um subconjunto do aprendizado de máquina muito utilizado para tarefas de classificação e visão computacional, como por exemplo identificação de objetos em uma imagem (IBM, 2024).

3.6.4.3 Redes Neurais Recorrentes (RNNs)

A Rede Neural Recorrente (RNN - *Convolutional Neural Network*) é uma rede neural profunda treinada com a utilização de dados sequenciais ou com séries temporais, com o objetivo de criar um modelo de Aprendizado de Máquina (ML) sendo capaz de fazer previsões com base em *inputs* sequenciais. Podem ser utilizadas, como por exemplo, para prever níveis diários de inundação com base em dados anteriores de enchentes, marés e informações meteorológicas (IBM, 2024).

3.6.5 ÁRVORES DE DECISÃO

Como Árvore de Decisão (em inglês *Decision Tree*) é um algoritmo de aprendizado de máquina e ao mesmo tempo uma técnica de mineração de dados, utilizada para prever, classificar e extrair conhecimento a partir de dados foi criada esta seção para detalhar sua aplicação e importância. Pode-se dizer que as Árvores de Decisão são modelos hierárquicos que segmentam os dados com base em condições lógicas sucessivas. Elas são eficientes e interpretáveis para tarefas de classificação e regressão, sendo frequentemente utilizadas em conjunto com outros métodos para aumentar a robustez dos modelos (Silva e Silva Neto, 2022).

3.7 APRENDIZADO DE MÁQUINA

A Inteligência Artificial (IA) ou *Machine Learning* é um campo da ciência da computação que imita o pensamento humano na capacidade de aprender e tomar decisões. Atualmente, a medicina tem utilizado *ML* para aprimorar diagnósticos, prognósticos e no auxílio aos médicos para tratamentos em diversas especialidades como cardiologia, neurologia, oncologia e dermatologia (Vitoria, 2022).

Esses modelos podem ser aprendidos de maneira supervisionada ou não supervisionada.

O aprendizado supervisionado envolve o treinamento de modelos com dados rotulados, sendo amplamente utilizado na predição de doenças e no apoio à decisão médica. De acordo com Vitoria (2022) o objetivo central do aprendizado supervisionado é verificar qual é o modelo

que, a partir de dados rotulados anteriormente em treinamentos, permita fazer previsões sobre os dados futuros. Modelos como Regressão Logística, *Random Forest* e Redes Neurais são frequentemente aplicados para classificação e predição de desfechos clínicos, proporcionando insights valiosos para profissionais de saúde (Belini, Ataíde e Lochter, 2024).

Já o aprendizado não supervisionado é aplicado para identificar padrões ocultos nos dados sem a necessidade de rótulos predefinidos. De acordo com Vitoria (2022), ao contrário do aprendizado supervisionado, os dados não têm rótulos identificadores, apenas os preditores estão disponíveis no conjunto de dados e não as saídas especificadas.

4 OBJETIVOS

4.1 OBEJETIVO GERAL

Investigar e definir uma abordagem metodológica para a análise preditiva de desfechos clínicos em pacientes com Síndrome Respiratória Aguda Grave (SRAG), por meio de técnicas de Ciência de Dados e aprendizado de máquina, utilizando dados do DataSUS.

4.2 OBJETIVOS ESPECÍFICOS

- Realizar um levantamento bibliográfico sobre a aplicação da análise de dados na área da saúde, com ênfase na predição de doenças respiratórias.
- Estudar as etapas da descoberta de conhecimento em banco de dados.
- Analisar material bibliográfico que utilizam aprendizado de máquina para a predição de desfechos clínicos, identificando metodologias, técnicas e modelos utilizados.
- Investigar o banco de dados do *DataSUS*, compreendendo sua estrutura, variáveis disponíveis e possíveis desafios na manipulação dos dados.
- Definir as técnicas de pré-processamento a serem utilizadas, considerando tratamento de valores ausentes, normalização de variáveis e balanceamento de classes.
- Identificar os algoritmos de aprendizado de máquina mais adequados para a análise preditiva dos desfechos clínicos da Síndrome Respiratória Aguda Grave.

5 METODOLOGIA

Inicialmente, foi realizada revisão bibliográfica de artigos publicados entre 2020 e 2025 em periódicos disponíveis nas bases de dados da Coordenação de Aperfeiçoamento de Pessoal de Nível Superior (CAPES) e do Google Acadêmico, de modo a construir uma fundamentação teórica sólida e construtiva.

Para encontrar periódicos, os seguintes descritores foram utilizados, tanto em português brasileiro quanto em inglês: SRAG; análise de dados; análise de dados na área da saúde; Modelos de aprendizagem; Modelos de predição; Ciência de dados. Os artigos selecionados foram estudados, fichados e organizados de modo que possam ser facilmente consultados posteriormente.

Através da revisão bibliográfica, foram estudadas técnicas de Ciência e Análise de Dados, das quais serão escolhidas as que ofereçam aplicabilidade geral ou específica ao contexto da Síndrome respiratória aguda grave. A revisão bibliográfica prosseguirá nas fases subsequentes do projeto conforme a necessidade.

Este estudo se caracteriza como uma pesquisa aplicada com uma abordagem exploratória e quantitativa. A pesquisa exploratória é justificada pela necessidade de investigação de padrões e informações nos dados de SRAG, podendo-se avaliar a eficiência e eficácia de diferentes modelos. Já a pesquisa aplicada possui o intuito de gerar conhecimento para praticabilidade na área da saúde, enquanto a abordagem quantitativa permite a análise estatística dos dados disponíveis.

O objetivo deste estudo é analisar a base história SRAG 2021 a 2024 (disponíveis no *DataSUS*) e desenvolver um modelo preditivo para análise de desfechos clínicos em pacientes diagnosticados com SRAG através da identificação e comparação de variáveis (relevantes, ou seja, que influenciam os desfechos clínicos) presentes no *Dataset*, utilizando técnicas de aprendizado de máquina. E fazer a comparação e análise de diferentes algoritmos para determinar qual apresenta melhor desempenho na predição.

Os dados utilizados neste estudo serão extraídos do banco de dados do *DataSUS*, com o foco principal na base histórica SRAG 2021 a 2024, que disponibiliza informações de saúde pública no Brasil. O conjunto de dados contém registros de pacientes diagnosticados com SRAG incluindo variáveis clínicas, epidemiológicas e demográficas. Serão levadas consideração variáveis como presença de comorbidades, idade, sexo, uso de ventilação mecânica, internação em UTI e status vacinal contra COVID-19, Influenza, entre outras informações importantes.

A amostra será composta por registros de pacientes diagnosticados com SRAG no ano de 2024, totalizando aproximadamente 26.000 registros. Inicialmente os critérios de inclusão consideram apenas pacientes com diagnóstico confirmado, enquanto registros incompletos ou inconsistentes serão excluídos ou tratados durante a fase de pré-processamento.

O pré-processamento dos dados será realizado em etapas para garantir a qualidade e a usabilidade do conjunto de dados, incluindo o tratamento de valores ausentes, normalização de variáveis e balanceamento de classes.

Para a implementação do modelo preditivo, serão utilizadas diversas ferramentas computacionais que auxiliam na visualização, manipulação e análise dos dados.

O *Google Colaboratory* será utilizado como ambiente principal de desenvolvimento, permitindo a execução de código *Python* na nuvem, sem necessidade de configuração local e com suporte a bibliotecas de aprendizado de máquina. A linguagem de programação principal que será adotada é o *Python*, devido à sua ampla utilização na análise de dados e aprendizado de máquina, sua sintaxe acessível e vasta comunidade garantem suporte contínuo e atualizações frequentes. Com a possível utilização dos pacotes *Numpy*, *Math* e *SciPy* que disponibilizam diversas funções e operações matemáticas envolvendo vetores, matrizes, cálculos de dispersão, medidas de posição e centralidade, entre outras funcionalidades.

A biblioteca *Pandas* será utilizada para manipulação e análise dos dados, permitindo a leitura, filtragem e transformação do conjunto de dados de forma eficiente. O *DataFrame*, estrutura de dados fornecida pelo *Pandas*, será utilizado para armazenar e processar os registros extraídos da base histórica SRAG 2021 a 2024 do *DataSUS*. Caso haja necessidade de análise geoespacial, o *GeoDataFrame* poderá ser empregado para lidar com informações geográficas

e distribuição espacial dos casos de SRAG. A biblioteca *Matplotlib* será utilizada para visualização gráfica dos dados, possibilitando a criação de histogramas, gráficos de dispersão e outras representações visuais que auxiliem na interpretação dos resultados.


6 RESULTADOS INICIAIS

A análise exploratória dos dados da Síndrome Respiratória Aguda Grave (SRAG) foi realizada com o objetivo de identificar padrões e tendências relevantes para modelagem preditiva. Os dados foram obtidos do Open *DataSUS* e passaram por um processo de limpeza e tratamento para remoção de valores inconsistentes e preenchimento de dados ausentes. Principais achados:

- Distribuição geográfica: A visualização inicial indicou que a incidência de casos varia significativamente entre os estados brasileiros, com algumas regiões apresentando um número expressivamente maior de notificações.
- Fatores associados aos desfechos clínicos: Foram analisadas variáveis como idade, comorbidades e necessidade de internação, sendo observada uma forte correlação entre idade avançada e maior taxa de óbitos.
- Modelagem preditiva: Um modelo de *Random Forest* foi treinado para prever os desfechos dos pacientes (cura, óbito ou indefinido). O desempenho inicial do modelo apresentou uma acurácia satisfatória, mas melhorias podem ser feitas através do ajuste de hiperparâmetros e seleção de variáveis mais relevantes.
- Visualizações exploratórias: Foram gerados gráficos para representar a distribuição dos casos, permitindo uma melhor compreensão dos padrões existentes nos dados.

Os próximos passos incluem o refinamento da modelagem preditiva, a validação cruzada dos modelos e a aplicação de métricas adicionais para avaliar a qualidade das previsões.

Figura 2 - Código e Gráfico que mostra a idade dos pacientes




Fonte: O Autor

Figura 3 – Código e Gráfico que mostra a distribuição de desfechos da SRAG

✓ Visualizar algumas distribuições


```
[ ] plt.figure(figsize=(12,6))

# Exemplo: Distribuição de óbitos (caso tenha essa coluna no dataset)
if 'EVOLUCAO' in df.columns:
    sns.countplot(x=df['EVOLUCAO'])
    plt.title("Distribuição de Desfechos da SRAG")
    plt.xlabel("1 = Cura | 2 = Óbito | 3 = Não Definido")
    plt.show()
```



Fonte: O Autor

Figura 4 - Mapa que mostra a relação de cores entre o número de casos por estado



Fonte: O Autor

7 CRONOGRAMA

Tabela 1 – Planejamento das atividades executadas no semestre 2024/2.

ATIVIDADE - 2024/2	Out.	Nov.	Dez.	Jan.	Fev.	Mar.
Reuniões com a orientadora	X	X	X	X	X	X
Levantamento bibliográfico	X	X	X	X	X	
Estudo de técnicas de Aprendizado de Máquina e Análise de Dados		X	X	X	X	
Coleta e preparação dos dados			X	X	X	
Estudo da Síndrome Respiratória Aguda Grave (SRAG)			X	X	X	
Definição da metodologia			X	X	X	
Estudo da descoberta de Conhecimento em Bases de Dados			X	X	X	
Análise Superficial/ Inicial dos Dados				X	X	X
Estruturação do projeto final do TCC1				X	X	X
Apresentação do TCC 1						X

Fonte: O Autor.

O cronograma de atividades deste projeto previsto para o semestre 2025/1 pode ser observado na Tabela 2.

Tabela 2 – Planejamento das atividades previstas para o semestre 2025/1.

ATIVIDADE - 2025/1	Abr.	Mai	Jun.	Jul.	Ago.
Reuniões com a orientadora	X	X	X	X	X
Aprofundamento do estudo do KDD	X	X	X	X	
Aprofundamento do estudo das técnicas de Análise de dados	X	X	X		
Processamento adequado dos Dados	X	X	X	X	
Fazer a análise de dados (Preditiva)	X	X	X	X	X
Escrita da monografia	X	X	X	X	X
Apresentação do TCC 2					X

Fonte: O Autor.

8 REFERÊNCIAS BIBLIOGRÁFICAS

ALTINO, Rita de Cássia et al. **A importância da notificação compulsória frente à Síndrome Respiratória Aguda Grave (SRAG) e Covid-19.** Rev. Salusvita (Online), p. 627-649, 2020.

AMAZON WEB SERVICES. **O que é mineração de dados?** Disponível em: <https://aws.amazon.com/pt/what-is/data-mining/>. Acesso em: 08 mar. 2025.

AMAZON WEB SERVICES. **O que é regressão logística?** Disponível em: <https://aws.amazon.com/pt/what-is/logistic-regression/>. Acesso em: 08 mar. 2025.

BAHIA. Secretaria da Saúde. **Guia rápido SIVEP-Gripe.** Atualizado em maio de 2021. Disponível em: https://www.saude.ba.gov.br/wp-content/uploads/2021/05/GUIA-RAPIDO-SIVEP-GRIPE-atualizado-em-maio_2021.pdf. Acesso em: 04 mar. 2025.

BARRETO, Evandro Fernandes. **Ciência de dados aplicada à pandemia do coronavírus no Brasil, uma análise socioeconômica.** 2021. Trabalho de Conclusão de Curso (Bacharelado em Ciência da Computação) – Universidade Estadual Paulista “Júlio de Mesquita Filho”, Faculdade de Ciências, Bauru, 2021.

BELINI, Gustavo Torres; ATAIDE, Danilo da Silva; LOCHTER, Johannes Von. **Modelo de Machine Learning para Predição de Problemas Respiratórios.** Facens Centro Universitário, Sorocaba, 2024.

BRASIL. Ministério da Saúde. **COVID-19.** Disponível em: <https://www.gov.br/saude/pt-br/assuntos/saude-de-a-a-z/c/covid-19>. Acesso em: 20 jan. 2025.

BRASIL. Ministério da Saúde. **Gripe (Influenza).** Disponível em: <https://www.gov.br/saude/pt-br/assuntos/saude-de-a-a-z/g/gripe-influenza>. Acesso em: 20 fev. 2025.

FAYYAD, U.; PIATETSKY-SHAPIO, G.; SMYTH, P. **From data mining to knowledge discovery in databases.** AI Magazine, v. 17, n. 3, p. 37-54, 1996.

FIOCRUZ – Fundação Oswaldo Cruz. **Casos de síndrome respiratória continuam crescendo em todo o país.** Agência Brasil, 2024. Disponível em: <https://agenciabrasil.ebc.com.br/saude/noticia/2024-03/casos-de-sindrome-respiratoria-continuum-crescendo-em-todo-o-pais>. Acesso em: 16 jan. 2025.

IBM. **Algoritmo Apriori.** Disponível em: <https://www.ibm.com/br-pt/think/topics/apriori-algorithm>. Acesso em: 08 mar. 2025.

IBM. **K-means clustering.** Disponível em: <https://www.ibm.com/br-pt/topics/k-means-clustering>. Acesso em: 08 mar. 2025.

IBM. **Redes neurais convolucionais.** Disponível em: <https://www.ibm.com/br-pt/think/topics/convolutional-neural-networks>. Acesso em: 08 mar. 2025.

IBM. **Redes neurais recorrentes.** Disponível em: <https://www.ibm.com/br-pt/think/topics/recurrent-neural-networks>. Acesso em: 08 mar. 2025.

IBM. **Regressão linear.** Disponível em: <https://www.ibm.com/br-pt/topics/linear-regression>. Acesso em: 08 mar. 2025.

INSTITUTO FEDERAL DE SANTA CATARINA (IFSC). **Como funciona uma Unidade de Terapia Intensiva.** Disponível em: https://www.ifsc.edu.br/post-ifsc-verifica/-/asset_publisher/uII70Nv266Xk/content/id/1983737/como-funciona-uma-unidade-de-terapia-intensiva. Acesso em: 20 fev. 2025.

JÚNIOR, Uálaci dos Anjos. **Mineração de dados na base de dados de SRAG.** 2024. Trabalho de Conclusão de Curso (Bacharelado em Engenharia da Computação) – Universidade Federal do Espírito Santo, São Mateus, 2024.

MARQUES, Iasmin. **Análise de Dados - Preditiva.** Disponível em: https://colab.research.google.com/drive/1tg1hKxFYfgRVxRXTjPlIKwhKSm_goi8P. Acesso em: 08 mar. 2025.

MINISTÉRIO DA SAÚDE (Brasil). **OpenDataSUS – Sobre**. Disponível em: <https://opendatasus.saude.gov.br/about>. Acesso em: 04 mar. 2025.

MINISTÉRIO DA SAÚDE (Brasil). **Síndrome Respiratória Aguda Grave – SRAG 2021 a 2024**. Disponível em: <https://opendatasus.saude.gov.br/dataset/srag-2021-a-2024/resource/8cb52f73-0184-41d5-8a8f-87d8f415652c>. Acesso em: 10 fev. 2025.

PAIM, J. S. **O Sistema Único de Saúde (SUS) aos 30 anos**. Ciência & Saúde Coletiva, v. 25, n. 3, p. 357-364, 2020. Disponível em: <https://www.scielo.br/j/csc/a/Qg7SJFjWPjvdQjvnRzxS6Mg/?lang=pt>. Acesso em: 16 jan. 2025.

SEBRAE. **O que é e como funciona a análise preditiva na saúde? Entenda**. Disponível em: <https://sebrae.com.br/sites/PortalSebrae/ufs/pe/artigos/o-que-e-e-como-funciona-a-analise-preditiva-na-saude-entenda>. Acesso em: 16 jan. 2025.

SENA, Gabrielle Ribeiro. **Modelos preditivos de óbito para pacientes com COVID-19**. 2021. Tese (Doutorado em Saúde Integral) – Instituto de Medicina Integral Prof. Fernando Figueira (IMIP), Recife, 2021.

SILVA, Amauri Ornellas da. **Uso de Machine Learning para previsão da evolução de casos de SRAG incluindo casos de COVID-19 considerando variáveis clínicas e demográficas**. 2021. Trabalho de Conclusão de Curso (Bacharelado em Engenharia de Produção) – Universidade Tecnológica Federal do Paraná, Londrina, 2021. Disponível em: <https://repositorio.utfpr.edu.br/jspui/handle/1/26211>. Acesso em: 16 jan. 2025.

SILVA, Risomario; SILVA NETO, Darcy Ramos da. **Inteligência artificial e previsão de óbito por Covid-19 no Brasil: uma análise comparativa entre os algoritmos Logistic Regression, Decision Tree e Random Forest**. Saúde em Debate, v. 46, n. especial 8, p. 118-129, dez. 2022.

VITORIA, Sergio Ricardo Pacheco da. **Machine Learning e Análise Preditiva em Saúde: um estudo de caso sobre detecção de anomalias em contas médicas do Exército**. 2022. Dissertação (Mestrado em Governança, Tecnologia e Inovação) – Pontifícia Universidade Católica de Minas Gerais, Brasília, 2022.

ZOUZA. **Knowledge Discovery in Databases (KDD)**. Medium, 2025. Disponível em: <https://medium.com/blog-do-zouza/knowledge-discovery-in-databases-kdd-462ea2775715>. Acesso em: 08 mar. 2025.