

A large blue graphic on the left side of the slide. It features a magnifying glass over a pie chart, with a bar chart below it. There are also several small blue squares of different sizes scattered around the graphic.

Comparação de modelos de aprendizado de máquina para previsão de desfechos clínicos em pacientes hospitalizados com Síndrome Respiratória Aguda Grave (SRAG)

Aluna: Iasmin Marques Pereira

Orientador: Prof.^a Dra. Silvia das Dores Rissino (CEUNES-UFES)

São Mateus - ES
2025



Sumário

1. **Introdução**
2. **Motivação**
3. **Problema de Pesquisa**
4. **Objetivos**
5. **Fundamentação Teórica**
6. **Metodologia**
7. **Resultados e Discussões**
9. **Conclusão e Trabalhos Futuros**
10. **Referências**

-

Introdução

Contextualização & Problema



Saúde pública

Papel essencial na promoção do bem-estar e prevenção de doenças.



Monitoramento epidemiológico

Identificação e análise de padrões de saúde e doenças.



Intervenções e recursos

Direcionamento eficiente para melhorar a assistência à saúde.



Aumento de casos de SRAG

Necessidade de estratégias para previsão de desfechos clínicos.



Gestão hospitalar e políticas públicas

Aprimoramento por meio de intervenções rápidas e direcionadas.



Aprendizado de máquina

Ferramenta para prever desfechos clínicos (óbito, cura ou indefinido) auxiliando na tomada de decisões

Motivação

- **Impacto da SRAG na saúde pública**

- Aumento na incidência de casos
- Ameaça a saúde pública
- Aumento da mortalidade (casos graves)
- Esgotamento de recursos hospitalares

- **Importância da predição para otimização de recursos hospitalares**
 - Prever a gravidade dos casos
 - Alocar recursos de maneira mais eficaz
 - Leitos em UTIs e ventiladores mecânicos
- **Melhora da eficiência hospitalar**
- **Salvar vidas**



Problema de Pesquisa

O crescimento dos casos de SRAG exige melhores estratégias de monitoramento e previsão de desfechos clínicos para otimizar a assistência e apoiar decisões na saúde pública.

- Como as técnicas de análise preditiva podem ser aplicadas aos dados do DataSUS para prever desfechos clínicos de pacientes com SRAG??
- Quais variáveis do DataSUS (2021–2024) estão mais associadas ao óbito?



Objetivos

Objetivo principal

Avaliar o desempenho preditivo e computacional dos modelos Random Forest e CART na previsão de desfechos clínicos de pacientes com SRAG utilizando dados do DataSUS.

Objetivos específicos

- Levantamento bibliográfico sobre análise de dados em saúde e predição de doenças respiratórias.
- Explorar o processo KDD e aplicar pré-processamento (valores ausentes, normalização, balanceamento).

Fonte: Canva



Objetivos

Objetivos específicos

- Analisar bibliografia sobre aprendizado de máquina e metodologias utilizadas.
- Investigar e compreender o banco de dados DataSUS.
- Implementar e comparar os modelos Random Forest e CART.
- Avaliar desempenho preditivo e computacional em diferentes ambientes.
- Discutir efetividade e viabilidade dos modelos.



Fundamentação Teórica

SRAG

KDD

Aprendizado de Máquina

Técnicas & Algoritmos

Random Forest


Árvore de decisão

CART

Métricas de Avaliação do Modelo

SRAG - Síndrome Respiratória Aguda Grave


- Condição - sistema respiratório
- Resulta de infecções por diversos vírus (SARS-CoV-2, Influenza, e outros Vírus - respiratório).
- Grande impacto no sistema de saúde
- Sintomas graves - internação hospitalar
- Grupos vulneráveis (como idosos e pacientes com comorbidades).
- Sintomas: desconforto respiratório, pressão ou dor persistente no tórax, coloração azulada dos lábios ou rosto.



Fonte: ESBrasil


KDD - Knowledge Discovery in Databases

- Descoberta de conhecimento em banco de dados
- Várias etapas interdependentes
- Seleção de dados, pré-processamento, transformação, mineração e avaliação.
- Extrair conhecimento útil de grandes volumes de dados
- Essencial para análises preditivas.



Aprendizado de Máquina

- Machine Learning
- Subárea da inteligência artificial
- Utiliza algoritmos para permitir que computadores aprendam com os dados e façam previsões;
- **Aprendizado Supervisionado**
 - Modelos são treinados com dados rotulados e são usados para previsões ou classificações
- **Aprendizado Não Supervisionado**
 - Identificar padrões em dados não rotulados. Exemplos incluem clustering.



Fundamentação Teórica

Técnicas & Algoritmos

Técnicas

- Fundamentais para transformar dados brutos em insights;
- Principais técnicas incluem:
 - **Análise Estatística:** descrever e inferir características dos dados
 - **Mineração de Dados:** descoberta de padrões e extração de informações relevantes (BigData)

Algoritmos

- Cada um possui suas particularidades e aplicabilidade, possibilitando a modelagem de diferentes tipos de dados e problemas;
- A seleção do algoritmo apropriado é crítica
- Influencia a eficácia e a precisão das previsões
- Permitindo adaptar a modelagem às características específicas dos dados disponíveis;


Fundamentação Teórica

Random Forest

- Conjunto de múltiplas árvores de decisão.
- Amostras aleatórias para cada árvore → voto majoritário ou média.
- Alta precisão e redução de overfitting.
- Bom desempenho em classificação e previsão (óbito por COVID-19).
- Estudos: acurácia média de 77%, boa generalização.



Árvore de Decisão



- Modelo hierárquico → regras sucessivas “Se... então...”.
- Usado para classificação e regressão.
- Simples, interpretável e eficiente.
- Critérios de divisão:
 - Índice de Gini → mede impureza.
 - Entropia → mede desordem, busca maior ganho de informação.
- Visual e fácil de explicar para tomada de decisão.



CART

- **Critérios de parada:** divisão continua até atingir um limite de profundidade ou nós homogêneos.
- **Velocidade de treinamento:** rápido para treinar e interpretar mesmo em grandes datasets.
- **Baixa complexidade computacional:** ideal para ambientes com recursos limitados.
- **Flexibilidade:** pode lidar com variáveis contínuas e categóricas.
- **Explicabilidade:** possibilita impressão ou visualização direta da árvore para suporte a decisões clínicas.
- **Aplicabilidade em saúde:** útil quando é necessário transparência e agilidade na tomada de decisão.

Fundamentação Teórica

Métricas de Avaliação do Modelo

- **Matriz de Confusão:** acertos e erros por classe.
- **Revocação (Recall ou Sensibilidade):** taxa de acertos nos positivos.
- **F1-Score:** equilíbrio entre precisão e recall.
- **Acurácia:** proporção de predições corretas.
- **AUC-ROC:** capacidade de distinguir classes.
- **Precisão (Precision):** acertos entre os previstos como positivos.

Métricas de Avaliação do Modelo

Matriz Confusão

- Organiza acertos e erros do modelo em forma de tabela.
- Identifica VP, VN, FP e FN. Permite visualizar onde o modelo mais erra.
- Base para métricas como Acurácia, Precisão, Recall, F1 e AUC-ROC.

Acurácia

Proporção de predições corretas no total de observações.
Limitação: pode ser enganosa em bases desbalanceadas.

$$Acurácia = \frac{VP - VN}{VP + VN + FP + FN}$$

Precisão (Precision)

Proporção de acertos entre os previstos como positivos.
Fórmula: $VP / (VP + FP)$.
Importante para minimizar falsos positivos.

$$Precisão = \frac{VP}{VP + FP}$$

Fundamentação Teórica

Métricas de Avaliação do Modelo

Revocação (Recall ou Sensibilidade)

Mede a capacidade de identificar os casos positivos corretamente. Alta revocação é crucial em predição de óbitos.

$$\text{Recall} = \frac{VP}{VP + FN}$$

F1-Score

Média harmônica entre Precisão e Recall. Equilíbrio entre falsos positivos e falsos negativos. Útil em bases desbalanceadas.

$$F1 = 2 \times \frac{\text{Precisão} \times \text{Recall}}{\text{Precisão} + \text{Recall}}$$

AUC-ROC (Área sob a Curva ROC)

Curva ROC: relação entre TPR (sensibilidade) e FPR (1 - especificidade).

AUC: mede a área sob a curva ROC.

Interpretação:

- AUC = 1 → Modelo perfeito.
- AUC = 0,5 → Aleatório.
- AUC > 0,9 → Excelente desempenho.

Metodologias

1

Revisão
bibliográfica

2

Fonte de dados

3

Dicionário de
dados

4

KDD

5

Materiais
(Ferramentas)

6

Ambientes de
Execução

Metodologia

Revisão Bibliografica

- Artigos publicados entre 2020 e 2025
- Fichados e organizados para facilitar a consulta.

Número Artigo	Título do Trabalho	Tipo de trabalho	Autor(es)	Ano	Palavras-chave	Link
1	Aplicação da modelagem preditiva via árvore de decisão nos casos de Síndrome Respiratória Aguda Grave (SRAG), com ênfase na Corona Virus Disease 2019 (COVID-19) no Brasil referente ao período de 2020 a 2022	Artigo	Miriam Lecília Farias Ribeiro, Natália Moraes Cordeiro, Dâmocles Aurélio Nascimento da Silva Alves.	12/11/2022	árvore de decisão, covid-19, estatística, predição, SRAs;	https://rsdjournal.org/index.php/rsd/article/view/36173
2	MODELOS PREDITIVOS DE ÓBITO PARA PACIENTES COM COVID-19	Tese Doutorado	GABRIELLE RIBEIRO SENA	01/09/2021	Coronavírus; Infecção por SARS-CoV-2; Criança; Idoso; Câncer	http://higia.imip.org.br/bitstream/123456789/641/1/Depósito%20Tese%20Gabrielle%20Sena.pdf
3	CIÊNCIA DE DADOS APLICADA À PANDEMIA DO CORONAVÍRUS NO BRASIL, UMA ANÁLISE SOCIOECONÔMICA	TCC	EVANDRO FERNANDES BARRETO	26/07/2021	Pandemia, COVID-19, Ciência de Dados, Análise de Dados, Dados Geográficos, Dados Socioeconômicos, Visualização de Dados.	https://repositorio.unesp.br/entities/publication/4f46fa86-57f0-45d5-aa0c-d3540da95bbf
4	MODELO DE MACHINE LEARNING PARA PREDIÇÃO DE PROBLEMAS RESPIRATÓRIOS	Artigo	Gustavo Torres Belini, Danilo da Silva Ataíde e Johannes Von Lochter		Machine Learning, Síndrome Respiratória Aguda Grave, Modelos Preditivos, Gradient Boosting, Saúde Pública	https://www.ciaca-conf.org/wp-content/uploads/2024/12/CIACA2024_PT_F_021_Belini.pdf
5	Painéis de monitoramento de dados epidemiológicos como estratégia de gestão da vigilância e da atenção à saúde	Artigo	Vanessa Coelho de Aquino Benjoi Ferraz Victor Vohryzek Ferezin Margarete Knoch Betina Durovni Valéria Saraceni Veruska Lahdo Mara Lisiane de Moraes dos Santos Alessandro Diogo De-Carli	06/05/2024	Vigilância em Saúde Pública; Sistemas de Informação em Saúde; Tomada de Decisões; Análise de Dados	https://doi.org/10.1590/1413-812320242911.04142024
6	Machine Learning e Análise Preditiva em saúde: um estudo de caso sobre detecção de anomalias em contas médicas do Exército	Dissertação	Sergio Ricardo Pacheco da Vitoria	04/03/2022	DBSCAN; ISOLATION FOREST; contas médicas; SAMMED; auditoria; Machine Learning	https://bdt.d.ucb.br:8443/jspui/handle/tede/3198#preview-link0

Fonte: Autor

Número Artigo	Título do Trabalho	Tipo de trabalho	Autor(es)	Ano	Palavras-chave	
1	Aplicação da modelagem preditiva via árvore de decisão nos casos de Síndrome Respiratória Aguda Grave (SRAG), com ênfase na Corona Virus Disease 2019 (COVID-19) no Brasil referente ao período de 2020 a 2022	Artigo	Miriam Lecília Farias Ribeiro, Natália Moraes Cordeiro, Dâmocles Aurélio Nascimento da Silva Alves.	12/11/2022	árvore de decisão, covid-19, estatística, predição, SRAs;	https://rsdjournal.org/index.php/rsd/article
2	MODELOS PREDITIVOS DE ÓBITO PARA PACIENTES COM COVID-19	Tese Doutorado	GABRIELLE RIBEIRO SENA	01/09/2021	Coronavírus; Infecção por SARS-CoV-2; Criança; Idoso; Câncer	http://higia.imip.org.br/bitstream/123456789/123456789/1
3	CIÊNCIA DE DADOS APLICADA À PANDEMIA DO CORONAVÍRUS NO BRASIL, UMA ANÁLISE SOCIOECONÔMICA	TCC	EVANDRO FERNANDES BARRETO	26/07/2021	Pandemia, COVID-19, Ciência de Dados, Análise de Dados, Dados Geográficos, Dados Socioeconômicos, Visualização de Dados.	https://repositorio.unesp.br/entities/publication
4	MODELO DE MACHINE LEARNING PARA PREDIÇÃO DE PROBLEMAS RESPIRATÓRIOS	Artigo	Gustavo Torres Belini, Danilo da Silva Ataíde e Johannes Von Lochter		Machine Learning, Síndrome Respiratória Aguda Grave, Modelos Preditivos, Gradient Boosting, Saúde Pública	https://www.ciaca-conf.org/wp-content/uploads/2023/08/10-1590-1413-812320242911.0.pdf
5	Painéis de monitoramento de dados epidemiológicos como estratégia de gestão da vigilância e da atenção à saúde	Artigo	Vanessa Coelho de Aquino Benjaino Ferraz Victor Vohryzek Ferezin Margarete Knoch Betina Durovni Valéria Saraceni Veruska Lahdo Mara Lisiane de Moraes dos Santos Alessandro Diogo De-Carli	06/05/2024	Vigilância em Saúde Pública; Sistemas de Informação em Saúde; Tomada de Decisões; Análise de Dados	https://doi.org/10.1590/1413-812320242911.0
6	Machine Learning e Análise Preditiva em saúde: um estudo de caso sobre detecção de anomalias em contas médicas do Exército	Dissertação	Sergio Ricardo Pacheco da Vitoria	04/03/2022	DBSCAN; ISOLATION FOREST; contas médicas; SAMMED; auditoria; Machine Learning	https://bdtd.ucb.br:8443/jspui/handle/tede


Metodologia

Base de Dados

- **Fonte: DataSUS - SRAG 2021 a 2024**
- **Dados Abertos**
- **Características dos Dados**
 - Variáveis clínicas, epidemiológicas e demográficas
 - Variáveis analisadas: Idade, sexo, comorbidades, ventilação mecânica, internação em UTI, vacinação;
- **Tamanho da amostra: +26.000 registros**
- **Dicionário de Dados**

openDataSUS

Fonte: OpenDataSUS



Metodologia

Base de Dados

Informações Adicionais

Campo	Valor
Autor	Datasus
Última Atualização	4 de agosto de 2025, 02:30 (UTC-03:00)
Criado	11 de janeiro de 2022, 15:30 (UTC-03:00)
Cobertura Geográfica	Nacional
Cobertura Temporal	A partir da Semana Epidemiológica 01 de cada ano.
Contato	dadosabertos@saude.gov.br
Granularidade Geográfica	Município
Granularidade temporal	Dia
Periodicidade de atualização	semanal
Referências	Classificação Brasileira de Ocupações (MTE), Tabela de Código de Municípios (IBGE), Cadastro Nacional de Estabelecimentos de Saúde (CNES).
Área Responsável	CGIAE/DAENT/SVSA

Informações sobre o Dataset

Metodologia

Dicionário de Dados



MINISTÉRIO DA SAÚDE
SECRETARIA DE VIGILÂNCIA EM SAÚDE

SIVEP-Gripe
SISTEMA DE INFORMAÇÃO DA VIGILÂNCIA EPIDEMIOLÓGICA DA GRIPE
19/09/2022.

Dicionário de Dados

FICHA DE REGISTRO INDIVIDUAL – CASOS DE SÍNDROME RESPIRATÓRIA AGUDA GRAVE HOSPITALIZADOS

Este documento tem como finalidade descrever as variáveis exportadas para o banco de dados em DBF.

CAMPO OBRIGATÓRIO é aquele cuja ausência de dado impossibilita a inclusão do registro no sistema.

CAMPO ESSENCIAL é aquele que, apesar de não ser obrigatório, registra dado necessário à investigação do caso ou ao cálculo de indicador epidemiológico ou operacional.

CAMPO INTERNO é aquele que apesar de não constar na ficha e não aparecer no display da tela, é preenchido automaticamente pelo sistema.

CAMPO OPCIONAL é aquele que só deve ser preenchido caso seja necessário, aparece no display da tela e consta no banco de dados.

Nome do campo	Tipo	Categoria	Descrição	Características	DBF
Nº	Varchar2(12)		Número do registro	Campo Interno Número sequencial gerado automaticamente pelo sistema. Utilizar o padrão: 320120000123 Dígito 1: caracteriza o tipo da ficha (1=SG, 2=SRAG-UTI e 3-SRAG Hospitalizado). Dígitos 2 a 12: número sequencial gerado automaticamente pelo sistema.	NU_NOTIFIC
1-Data do preenchimento da ficha de notificação	Date DD/MM/AAAA		Data de preenchimento da ficha de notificação	Campo Obrigatório Data deve ser <= a data da digitação.	DT_NOTIFIC

O que facilitou o entendimento e o fluxo de informações dentro do dataset;

Dicionário de Dados

FICHA DE REGISTRO INDIVIDUAL – CASOS DE SÍNDROME RESPIRATÓRIA AGUDA GRAVE HOSPITALIZADOS

Este documento tem como finalidade descrever as variáveis exportadas para o banco de dados em DBF.

CAMPO OBRIGATÓRIO é aquele cuja ausência de dado impossibilita a inclusão do registro no sistema.
CAMPO ESSENCIAL é aquele que, apesar de não ser obrigatório, registra dado necessário à investigação do caso ou ao cálculo de indicador epidemiológico ou operacional.
CAMPO INTERNO é aquele que apesar de não constar na ficha e não aparecer no display da tela, é preenchido automaticamente pelo sistema.
CAMPO OPCIONAL é aquele que só deve ser preenchido caso seja necessário, aparece no display da tela e consta no banco de dados.

Nome do campo	Tipo	Categoria	Descrição	Características	DBF
Nº	Varchar2(12)		Número do registro	Campo Interno Número sequencial gerado automaticamente pelo sistema. Utilizar o padrão: 320120000123 Dígito 1: caracteriza o tipo da ficha (1=SG, 2=SRAG-UTI e 3-SRAG Hospitalizado). Dígitos 2 a 12: número sequencial gerado automaticamente pelo sistema.	NU_NOTIFIC
1-Data do preenchimento da ficha de notificação	Date DD/MM/AAAA		Data de preenchimento da ficha de notificação.	Campo Obrigatório Data deve ser <= a data da digitação.	DT_NOTIFIC
Semana Epidemiológica do preenchimento da ficha de notificação	Varchar2(6)		Semana Epidemiológica do preenchimento da ficha de	Campo Interno Calculado a partir da data dos Primeiros Sintomas. (SS)	SEM_NOT

FICHA DE REGISTRO INDIVIDUAL – CASOS DE SÍNDROME RESPIRATÓRIA AGUDA GRAVE HOSPITALIZADOS

Este documento tem como finalidade descrever as variáveis exportadas para o banco de dados em DBF.

CAMPO OBRIGATÓRIO é aquele cuja ausência de dado impossibilita a inclusão do registro no sistema.

CAMPO ESSENCIAL é aquele que, apesar de não ser obrigatório, registra dado necessário à investigação do caso ou ao cálculo de indicador epidemiológico ou operacional.

CAMPO INTERNO é aquele que apesar de não constar na ficha e não aparecer no display da tela, é preenchido automaticamente pelo sistema.

CAMPO OPCIONAL é aquele que só deve ser preenchido caso seja necessário, aparece no display da tela e consta no banco de dados.

Nome do campo	Tipo	Categoria	Descrição	Características	DBF
Nº	Varchar2(12)		Número do registro	Campo Interno Número sequencial gerado automaticamente pelo sistema. Utilizar o padrão: 320120000123 Dígito 1: caracteriza o tipo da ficha (1=SG, 2=SRAG-UTI e 3=SRAG Hospitalizado). Dígitos 2 a 12: número sequencial gerado automaticamente pelo sistema.	NU_NOTIFIC
1-Data do preenchimento da ficha de notificação	Date DD/MM/AAAA		Data de preenchimento da ficha de notificação.	Campo Obrigatório Data deve ser <= a data da digitação.	DT_NOTIFIC
Semana Epidemiológica do preenchimento da ficha de notificação	Varchar2(6)		Semana Epidemiológica do preenchimento da ficha de	Campo Interno Calculado a partir da data dos Primeiros Sintomas. (SS)	SEM_NOT Fonte: OpenDataSus

Metodologia

Ficha de Notificação

		Nº				
		SIVEP-Gripe - SISTEMA DE INFORMAÇÃO DA VIGILÂNCIA EPIDEMIOLÓGICA DA GRIPE FICHA DE REGISTRO INDIVIDUAL - CASOS DE SÍNDROME RESPIRATÓRIA AGUDA GRAVE HOSPITALIZADO - 10/02/2023.				
MINISTÉRIO DA SAÚDE SECRETARIA DE VIGILÂNCIA EM SAÚDE						
CASO DE SÍNDROME RESPIRATÓRIA AGUDA GRAVE (SRAG-HOSPITALIZADO): Indivíduo com SG que apresente: dispneia/desconforto respiratório OU pressão persistente no tórax OU saturação de O2 menor que 95% em ar ambiente OU coloração azulada dos lábios ou rosto. Para efeito de notificação no SIVEP-Gripe, devem ser considerados os casos de SRAG hospitalizados ou os óbitos por SRAG independente de hospitalização.						
1	Data do preenchimento da ficha de notificação: ____/____/____		2	Data de 1ºs sintomas ____/____/____		
3	UF: ____		4	Município: _____		
				Código (IBGE): ____/____/____		
5	Unidade de Saúde: _____		Código (CNES): ____/____/____			
Dados do Paciente	6	Tem CPF? __ 1-Sim 2-Não		7	CPF: ____/____/____-____	
	8	Estrangeiro __ 1-Sim 2-Não				
	9	Cartão Nacional de Saúde (CNS): ____/____/____/____/____/____				
	10	Nome: _____		11	Sexo: __ 1- Masc. 2- Fem. 9- Ign	
	12	Data de nascimento: ____/____/____		13	(Ou) Idade: ____/____/____	
			1-Dia 2-Mês 3-Ano __			
	14	Gestante: __				
			1-1º Trimestre 2-2º Trimestre 3-3º Trimestre 4-Idade Gestacional Ignorada 5-Não 6-Não se aplica 9-Ignorado			
	15	Raça/Cor: __ 1-Branca 2-Preta 3-Amarela 4-Parda 5-Indígena 9-Ignorado				
	16	Se indígena, qual etnia? _____				
17	É membro de povo ou comunidade tradicional? __ 1-Sim 2-Não		18	Se sim, qual? _____		
19	Escolaridade: __ 0-Sem escolaridade/Analfabeto 1-Fundamental 1º ciclo (1ª a 5ª série) 2-Fundamental 2º ciclo (6ª a 9ª série) 3-Médio (1º ao 3º ano) 4-Superior 5-Não se aplica 9-Ignorado					
20	Ocupação: _____		21	Nome da mãe: _____		
e residência	22	CEP: ____/____/____-____				
	23	UF: ____		24	Município: _____	
					Código (IBGE): ____/____/____	
	25	Bairro: _____		26	Logradouro (Rua, Avenida, etc.): _____	
				27	Nº: _____	

Exemplo de Ficha de notificação
do ano de 2023

Fonte: DataSUS



MINISTÉRIO DA SAÚDE
SECRETARIA DE VIGILÂNCIA EM SAÚDE

SIVEP-Gripe - SISTEMA DE INFORMAÇÃO DA VIGILÂNCIA EPIDEMIOLÓGICA DA GRIPE
FICHA DE REGISTRO INDIVIDUAL - CASOS DE SÍNDROME RESPIRATÓRIA AGUDA GRAVE HOSPITALIZADO - 10/02/2023

No

CASO DE SÍNDROME RESPIRATÓRIA AGUDA GRAVE (SRAG-HOSPITALIZADO): Indivíduo com SG que apresente: dispneia/desconforto respiratório OU pressão persistente no tórax OU saturação de O2 menor que 95% em ar ambiente OU coloração azulada dos lábios ou rosto.

Para efeito de notificação no SIVEP-Gripe, devem ser considerados os casos de SRAG hospitalizados ou os óbitos por SRAG independente de hospitalização.

1	Data do preenchimento da ficha de notificação:	____ ____ _____	2	Date de 1 ^{as} sintomas	____ ____ _____	
3	UF:	__ __	4	Município:	_____ Código (IBGE): ____ ____ ____ ____ ____ ___	
5	Unidade de Saúde:	Código (CNES): __ __ __ __ __ __ __ ___				
Dados do Paciente	6	Tem CPF? __ 1-Sim 2-Não	7	CPF: ____ ____ ____ ____ ____ ____ ____ ____ ____ ____ ____ ____ ____ ____ ____ ____ _		
	8	Estrangeiro __ 1-Sim 2-Não				
	9	Cartão Nacional de Saúde (CNS): ____ ____ ____ ____ ____ ____ ____ ____ ____ ____ ____ ____ ____ ____ ____ ____ _				
	10	Nome: _____			11	Sexo: __ 1- Masc. 2- Fem. 9- Ign
	12	Data de nascimento: _____ _____ _____	13	(Ou) Idade: ____ ____ _____ 1-Dia 2-Mês 3-Ano __	14	Gestante: __ 1-1º Trimestre 2-2º Trimestre 3-3º Trimestre 4-Idade Gestacional ignorada 5-Não 6-Não se aplica 9-Ignorado
	15	Raça/Cor: __ 1-Branca 2-Preta 3-Amarela 4-Parda 5-Indígena 9-Ignorado				
	16	Se indígena, qual etnia? _____				
	17	É membro de povo ou comunidade tradicional? __ 1-Sim 2-Não			18	Se sim, qual? _____
	19	Escolaridade: __ 0-Sem escolaridade/Analfabeto 1-Fundamental 1º ciclo (1ª a 5ª série) 2- Fundamental 2º ciclo (6ª a 9ª série) 3-Médio (1º ao 3º ano) 4-Superior 5-Não se aplica 9-Ignorado				
20	Ocupação: _____	21	Nome da mãe: _____			
e residência	22	CEP: ____ ____ ____ ____ - ____ ____ ____				
	23	UF: ____ ____	24	Município:	Código (IBGE): ____ ____ ____ ____ ____ ___	
	25	Bairro:	26	Logradouro (Rua, Avenida, etc.):	27	Nº: _____

CASO DE SÍNDROME RESPIRATÓRIA AGUDA GRAVE (SRAG-HOSPITALIZADO): Indivíduo com SG que apresente: dispneia/desconforto respiratório OU pressão persistente no tórax OU saturação de O2 menor que 95% em ar ambiente OU coloração azulada dos lábios ou rosto.


Para efeito de notificação no SIVEP-Gripe, devem ser considerados os casos de SRAG hospitalizados ou os óbitos por SRAG independente de hospitalização.

1	Data do preenchimento da ficha de notificação: ____ ____ _____						2	Data de 1ºs sintomas ____ ____ _____										
3	UF: ____ ____		4	Município: _____						Código (IBGE): ____ ____ ____ ____ ____ ____								
5	Unidade de Saúde: _____								Código (CNES): ____ ____ ____ ____ ____ ____ ____ ____									
Dados do Paciente	6	Tem CPF? __ 1-Sim 2-Não							7	CPF: ____ ____ ____ ____ ____ ____ ____ ____ ____ ____ ____ ____ ____ ____ ____ ____								
	8	Estrangeiro __ 1-Sim 2-Não																
	9	Cartão Nacional de Saúde (CNS): ____ ____ ____ ____ ____ ____ ____ ____ ____ ____ ____ ____ ____ ____ ____ ____																
	10	Nome: _____								11	Sexo: __ 1- Masc. 2- Fem. 9- Ign							
	12	Data de nascimento: ____ ____ ____ ____ ____ ____					13	(Ou) Idade: ____ ____ ____ 1-Dia 2-Mês 3-Ano __					14	Gestante: __ 1-1º Trimestre 2-2º Trimestre 3-3º Trimestre 4-Idade Gestacional Ignorada 5-Não 6-Não se aplica 9-Ignorado				
	15	Raça/Cor: __ 1-Branca 2-Preta 3-Amarela 4-Parda 5-Indígena 9-Ignorado																
	16	Se indígena, qual etnia? _____																
	17	É membro de povo ou comunidade tradicional? __ 1-Sim 2-Não								18	Se sim, qual? _____							
	19	Escolaridade: __ 0-Sem escolaridade/Analfabeto 1-Fundamental 1º ciclo (1ª a 5ª série) 2- Fundamental 2º ciclo (6ª a 9ª série) 3-Médio (1º ao 3º ano) 4-Superior 5-Não se aplica 9-Ignorado																
20	Ocupação: _____							21	Nome da mãe: _____									
Endereço e residência	22	CEP: ____ ____ ____ ____ ____ - ____ ____ ____																
	23	UF: ____ ____		24	Município: _____						Código (IBGE): ____ ____ ____ ____ ____ ____							
	25	Bairro: _____					26	Logradouro (Rua, Avenida, etc.): _____						27	Nº: _____			

Fonte: DataSUS

Metodologia **Fluxo de Registro**

Fluxo de registro e atendimento de
pacientes com SRAG no SIVEP-Gripe




Etapas do Processo de KDD

- **Seleção dos dados:** identificação e extração das variáveis relevantes para a análise.
- **Pré-processamento e limpeza:** tratamento de valores ausentes e padronização das categorias presentes no dataset.
- **Transformação:** reestruturação e codificação das variáveis, tornando-as adequadas para a aplicação dos algoritmos de aprendizado de máquina.
- **Mineração de dados:** aplicação dos algoritmos Random Forest e CART para a predição do desfecho clínico, tendo a variável EVOLUCAO como alvo.
- **Interpretação e avaliação dos resultados:** análise do desempenho dos modelos, considerando métricas (acurácia, precisão, recall, F1-score, AUC-ROC) apropriadas para problemas de classificação.

Materiais (Ferramentas)

- **Google Colab:** execução em nuvem, sem necessidade de configuração local.
- **Jupyter Notebook:** usado em PC Gamer e Cluster para organização e comparação de tempos de processamento.
- **Linguagem:** Python, pela ampla utilização em análise de dados e ML.
- **Bibliotecas:**
 - Scikit-learn, Imbalanced-learn: modelagem e pré-processamento.
 - Pandas, Pandas Profiling (ydata-profiling): manipulação e análise de dados.
 - Matplotlib, Seaborn: visualização de dados.
 - GeoPandas: análise geoespacial dos casos SRAG.
- **Repositório GitHub:** código público para reprodutibilidade e transparência (https://github.com/iasminimp/srag_tcc)



Ambientes de Execução

- Testes realizados em três ambientes: PC pessoal (Iasmin), PC Gamer, Cluster acadêmico (UFES).
- Tempo de execução medido do carregamento dos dados à predição final.
- Comparação permitiu identificar vantagens e limitações de cada ambiente.

Ambiente	Processador	Memória RAM	Armazenamento	Sistema Operacional	Observações
PC Gamer	AMD Ryzen 5 1600X	8 GB	SSD 512 GB	Fedora 42	Computador gamer
Iasmin	Intel Core i5-1235U (12ª geração) @ 1.30 GHz	16 GB	SSD 477 GB	Windows 11	Computador doméstico
UFES (cluster)	Intel Xeon E5620 @ 2.40 GHz	35 GB	N/D	openSUSE Leap (kernel 5.14)	Servidor acadêmico

Resultados e Discussões

Resultados e Discussões

Análise Exploratória do Dataset

- Realizada antes da aplicação dos modelos preditivos.
- Dataset: casos de SRAG do DataSUS.
- Objetivos:
 - Compreender a estrutura dos dados.
 - Avaliar a distribuição das variáveis.
 - Identificar padrões relacionados aos desfechos clínicos.
- Dados incluíram informações demográficas, clínicas, laboratoriais e de evolução do caso.



Quadro 3 – Variáveis selecionadas para análise preditiva


Variável	Tipo	Descrição	Categoria
PUERPERA	Varchar2(1)	Paciente é puérpera (até 45 dias do parto).	Essencial
CARDIOPATI	Varchar2(1)	Paciente possui doença cardiovascular crônica.	Essencial
HEMATOLOGI	Varchar2(1)	Paciente possui doença hematológica crônica.	Essencial
SIND_DOWN	Varchar2(1)	Paciente possui Síndrome de Down.	Essencial
HEPATICA	Varchar2(1)	Paciente possui doença hepática crônica.	Essencial
ASMA	Varchar2(1)	Paciente possui asma.	Essencial
DIABETES	Varchar2(1)	Paciente possui diabetes mellitus.	Essencial
NEUROLOGIC	Varchar2(1)	Paciente possui doença neurológica crônica.	Essencial
PNEUMOPATI	Varchar2(1)	Paciente possui outra pneumopatia crônica.	Essencial
IMUNODEPRE	Varchar2(1)	Paciente possui imunodeficiência ou imunodepressão.	Essencial
RENAL	Varchar2(1)	Paciente possui doença renal crônica.	Essencial
OBESIDADE	Varchar2(1)	Paciente possui obesidade.	Essencial
OUT_MORBI	Varchar2(1)	Paciente possui outros fatores de risco não listados.	Essencial
FATOR_RISC	Varchar2(1)	Indica se o paciente possui algum fator de risco (1=Sim, 2=Não, 9=Ignorado).	Essencial
NU_IDADE_N	Varchar2(3)	Idade informada quando não há data de nascimento.	Obrigatório
SUPPORT_VEN	Varchar2(1)	Tipo de ventilação utilizada (1=Invasivo, 2=Não invasivo, 3=Não, 9=Ignorado).	Essencial
UTI	Varchar2(1)	Paciente foi internado em UTI? (1=Sim, 2=Não, 9=Ignorado).	Essencial
TOSSE	Varchar2(1)	Paciente apresentou tosse? (1=Sim, 2=Não, 9=Ignorado).	Essencial
EVOLUCAO	Varchar2(1)	Desfecho do caso (1=Cura, 2=Óbito, 3=Óbito por outras causas, 9=Ignorado).	Essencial

Fonte: O Autor


Resultados e Discussões

Análise das Variáveis Relevantes para o Desfecho Clínico (Variáveis importantes)

Variável	Tipo	Descrição	Categoria
PUERPERA	Varchar2(1)	Paciente é puérpera (até 45 dias do parto).	Essencial
CARDIOPATI	Varchar2(1)	Paciente possui doença cardiovascular crônica.	Essencial
HEMATOLOGI	Varchar2(1)	Paciente possui doença hematológica crônica.	Essencial
SIND_DOWN	Varchar2(1)	Paciente possui Síndrome de Down.	Essencial
HEPATICA	Varchar2(1)	Paciente possui doença hepática crônica.	Essencial
ASMA	Varchar2(1)	Paciente possui asma.	Essencial
DIABETES	Varchar2(1)	Paciente possui diabetes mellitus.	Essencial
NEUROLOGIC	Varchar2(1)	Paciente possui doença neurológica crônica.	Essencial
PNEUMOPATI	Varchar2(1)	Paciente possui outra pneumopatia crônica.	Essencial
IMUNODEPRE	Varchar2(1)	Paciente possui imunodeficiência ou imunodepressão.	Essencial
RENAL	Varchar2(1)	Paciente possui doença renal crônica.	Essencial
OBESIDADE	Varchar2(1)	Paciente possui obesidade.	Essencial
OUT_MORBI	Varchar2(1)	Paciente possui outros fatores de risco não listados.	Essencial
FATOR_RISC	Varchar2(1)	Indica se o paciente possui algum fator de risco (1=Sim, 2=Não, 9=Ignorado).	Essencial
NU_IDADE_N	Varchar2(3)	Idade informada quando não há data de nascimento.	Obrigatório
SUPPORT_VEN	Varchar2(1)	Tipo de ventilação utilizada (1=Invasivo, 2=Não invasivo, 3=Não, 9=Ignorado).	Essencial
UTI	Varchar2(1)	Paciente foi internado em UTI? (1=Sim, 2=Não, 9=Ignorado).	Essencial
TOSSE	Varchar2(1)	Paciente apresentou tosse? (1=Sim, 2=Não, 9=Ignorado).	Essencial
EVOLUCAO	Varchar2(1)	Desfecho do caso (1=Cura, 2=Óbito, 3=Óbito por outras causas, 9=Ignorado).	Essencial




Top 20 Variáveis mais Importantes - Árvore de Decisão



180

Árvore de Decisão - CART



Modelos Preditivos

Random Forest

- **Hiperparâmetros ótimos:**

- n_estimators = 100
- max_depth = 7
- min_samples_leaf = 2
- min_samples_split = 5

- **Métricas principais (conjunto de teste):**


- F1-score: 0,522
- AUC-ROC: 0,838
- Recall (óbito): 0,64
- Acurácia geral: 0,82

Classe	Precisão	Recall	F1-score	Suporte
Cura (0)	0,93	0,85	0,89	8.727
Óbito (1)	0,44	0,64	0,52	1.625
Acurácia	-	-	0,82	10.352
Macro Avg	0,68	0,74	0,70	10.352
Weighted Avg	0,85	0,82	0,83	10.352

Fonte: O Autor

Modelos Preditivos

- **Matriz de confusão:**
- TN = 7.417
- FP = 1.310
- FN = 589
- TP = 1.036
- **Execução:** tempo de treinamento $\approx 33,5s$
- **Análise:**
- Alta detecção de óbitos $\rightarrow$ prioridade em aplicações clínicas.
- Falsos positivos $>$ falsos negativos $\rightarrow$ comportamento aceitável em cenários críticos.



Modelos Preditivos

CART

- **Hiperparâmetros ajustados:**

- max_depth = 5
- min_samples_leaf = 1
- min_samples_split = 2

- **Métricas principais (conjunto de teste):**


- F1-score: 0,496
- AUC-ROC: 0,819
- Recall (óbito): 0,62
- Acurácia geral: 0,80

Classe	Precisão	Recall	F1-score	Suporte
Cura (0)	0,92	0,84	0,88	8.727
Óbito (1)	0,41	0,62	0,50	1.625
Acurácia	-	-	0,80	10.352
Macro Avg	0,67	0,73	0,69	10.352
Weighted Avg	0,84	0,80	0,82	10.352

Fonte: O Autor

Modelos Preditivos

- **Matriz de confusão:**
- $TN = 7.288$
- $FP = 1.439$
- $FN = 615$
- $TP = 1.010$
- **Execução:** tempo de treinamento $\approx 10,4s$
- **Análise:**
- Desempenho inferior ao Random Forest.
- Mais falsos negativos $\rightarrow$ maior risco clínico.
- Mais falsos positivos $\rightarrow$ menor precisão para diferenciar casos críticos



Modelos Preditivos

Comparação – Random Forest vs CART

- Desempenho preditivo:
 - Random Forest → F1-score, AUC-ROC, acurácia e recall superiores.
 - Melhor separação entre classes na Curva ROC.
- Matrizes de confusão:
 - Random Forest → maior TP (1.036) e menor FN (589).
 - CART → TP = 1.010, FN = 615.
- Variáveis mais importantes (CART):
 - SUPORT_VEN e NU_IDADE_N → 94% da importância.
 - UTI, TOSSE, OUT_MORBI → impacto menor.


Modelos Preditivos

Comparação – Random Forest vs CART

- Aspectos práticos:
 - CART → maior interpretabilidade, útil para decisões clínicas rápidas.
 - Random Forest → menor overfitting, maior robustez, mas custo computacional maior.
- Conclusão:
 - Random Forest → melhor desempenho geral.
 - CART → alternativa viável quando a explicabilidade é prioridade.


Resultados e Discussões

Modelos Preditivos




Resultados e Discussões

Modelos Preditivos




Resultados e Discussões

Modelos Preditivos



Top 20 Features - Importância (%) - CART




Modelos Preditivos

Métrica	<u>Random Forest</u>	CART
F1-score (Classe Óbito)	0,522	0,496
Recall (Classe Óbito)	0,64	0,62
Precisão (Classe Óbito)	0,44	0,41
AUC-ROC	0,838	0,819
Acurácia	0,82	0,80
Tempo de Execução (s)	33,5	10,4
Verdadeiros Positivos (TP)	1.036	1.010
Falsos Negativos (FN)	589	615
Falsos Positivos (FP)	1.310	1.439
Verdadeiros Negativos (TN)	7.417	7.288


Fonte: O Autor

Resultados e Discussões

Modelos Preditivos




Curva ROC - CART vs Random Forest




Comparação de tempo de execução (Tempo computacional)

- **Máquinas avaliadas:** PC Gamer (Fedora), PC Iasmin (Windows) e Cluster UFES (Xeon)
- **Objetivo:** analisar impacto do hardware e sistema operacional no tempo de execução.
- **Resultados principais:**
 - **PC Gamer → mais rápido (30 s) mesmo com hardware modesto.**
 - Cluster UFES → desempenho intermediário (82 s).
 - PC Iasmin → mais lento (130 s) apesar de hardware moderno.
- Fatores influentes: SO, gerenciamento térmico, paralelismo e processos ativos.



Comparação de Tempo de Execução por Máquina



Fonte: O Autor

Comparação de tempo de execução (Tempo computacional)

- **Random Forest:** tempo maior devido a múltiplas árvores → maior custo computacional.
- **CART:** mais leve e rápido em todos os ambientes.
- Tempo total (Notebook):
 - PC Gamer → 30,07 s
 - PC Iasmin → 129,82 s
 - Cluster UFES → 82,32 s
- Implicação: modelos viáveis mesmo em ambientes limitados (< 2 min).

Máquina	Tempo Total	CART	RF
PC Gamer	30.07 s	3.58 s	18.74 s
PC Iasmin	129.82 s	26.44 s	91.67 s
Cluster UFES	82.32 s	11.30 s	56.76 s

Fonte: O Autor

Comparação Geral – RF vs CART

- **Random Forest:**

- Melhor desempenho preditivo ($F1 = 0,522$; $\text{Recall} = 0,64$; $\text{AUC-ROC} = 0,838$).
- Maior custo computacional (55,7 s em média).
- Menor interpretabilidade.

- **CART:**

- Execução mais rápida (13,7 s em média).
- Regras claras → maior interpretabilidade.
- Leve desempenho inferior ($F1 = 0,496$; $\text{Recall} = 0,62$; $\text{AUC-ROC} = 0,819$).
- Trade-off: performance x interpretabilidade.

Variáveis Mais Relevantes

- **Principais fatores de risco:**
 - Idade (NU_IDADE_N)
 - Suporte ventilatório (SUPPORT_VEN)
 - Internação em UTI
- **Menor impacto:**
 - Tosse
 - Histórico vacinal (COVID-19)
- **Conclusão: alinhamento com evidências clínicas existentes.**

Resultados e Discussões

Limitações do Estudo

- Qualidade dos dados: registros incompletos, sintomas e vacinação com inconsistências.
- Falta de variáveis clínicas detalhadas → reduz poder preditivo.
- Generalização limitada → dados exclusivamente brasileiros.
- Cluster sem paralelismo → hardware subutilizado.
- Dificuldades iniciais para compilar os códigos no computador pessoal → motivou testes em diferentes ambientes para verificar impacto do hardware na eficiência do modelo

Conclusão e Trabalhos futuros

Conclusão

- **Modelos desenvolvidos:** CART e Random Forest aplicados à predição de desfechos clínicos em SRAG.
- **Principais resultados**
 - Random Forest: melhores métricas (F1-score, AUC-ROC, recall para óbito) → maior robustez preditiva.
 - CART: menor custo computacional e maior interpretabilidade → útil para cenários que exigem explicabilidade.
- **Variáveis mais relevantes:** idade, suporte ventilatório invasivo e internação em UTI.
- **Ambiente computacional**
 - PC Gamer → menor tempo de execução.
 - Cluster UFES → tempo intermediário.
 - PC pessoal → maior tempo, possivelmente devido ao SO e limitações de hardware.
- **Contribuição:** Apoio à tomada de decisão clínica e otimização de recursos hospitalares.

Trabalhos futuros

- Incluir variáveis de sintomas e investigar impacto no desempenho.
- Avaliar técnicas alternativas de balanceamento e métricas adicionais (MCC, Índice de Youden).
- Usar One-Hot Encoding para variáveis categóricas.
- Atualizar e expandir a base de dados para maior generalização.
- Otimizar execução em clusters com paralelismo e bibliotecas como joblib e Dask.

Referências

SOMITI. Conheça os principais aspectos sobre a Síndrome Respiratória Aguda Grave. Blog Somiti, 2024. Disponível em: <https://blog.somiti.org.br/conheca-os-principais-aspectos-sobre-a-sindrome-respiratoria-aguda-grave/>. Acesso em: 10 mar. 2025.

COREN-RO. Aumento de casos de SRAG e quatro óbitos por COVID-19 colocam Rondônia em alerta. Conselho Regional de Enfermagem de Rondônia, 2024. Disponível em: <https://www.coren-ro.org.br/aumento-de-casos-de-srag-e-quatro-obitos-por-covid-19-colocam-rondonia-em-alerta/>. Acesso em: 20 mar. 2025.

GLOBO. Aumentam casos graves de SRAG em crianças e adolescentes. Revista Crescer, 2024. Disponível em: <https://revistacrescer.globo.com/criancas/saude/noticia/2024/11/aumentam-casos-graves-de-srag-em-criancas-e-adolescentes.ghtml>. Acesso em: 21 mar. 2025.

ES BRASIL. Casos de Síndrome Respiratória Grave aumentam em 2021. ES Brasil, 2021. Disponível em: <https://esbrasil.com.br/casos-de-sindrome-respiratoria-grave-aumentam-em-2021/>. Acesso em: 10 mar. 2025.

ZOUZA, Blog do. Knowledge Discovery in Databases (KDD). Medium, 2024. Disponível em: <https://medium.com/blog-do-zouza/knowledge-discovery-in-databases-kdd-462775715>. Acesso em: 14 mar. 2025.

MERCADO BINÁRIO. Aprendizado de Máquina. Mercado Binário, 2024. Disponível em: <https://mercadobinario.com.br/blog/aprendizado-de-maquina/>. Acesso em: 10 mar. 2025.

Referências

SITES INSTITUCIONAIS E GOVERNAMENTAIS:

MINISTÉRIO DA SAÚDE. Meus SUS Digital – Sobre o SUS. 2024. Disponível em: <https://meususdigital.saude.gov.br/perfil/sobre-sus>. Acesso em: 15 mar. 2025.

MINISTÉRIO DA SAÚDE. Open DataSUS – SRAG 2021 a 2024. 2024. Disponível em: <https://opendatasus.saude.gov.br/dataset/srag-2021-a-2024>. Acesso em: 24 mar. 2025.



IASMIN MARQUES PEREIRA

Obrigada ;)

iasminimp7@gmail.com

www.iasminmarques.com.br

A large blue graphic on the left side of the slide. It features a magnifying glass over a pie chart, with a bar chart below it. There are also several small blue squares of different sizes scattered around the graphic.

Comparação de modelos de aprendizado de máquina para previsão de desfechos clínicos em pacientes hospitalizados com Síndrome Respiratória Aguda Grave (SRAG)

Aluna: Iasmin Marques Pereira

Orientador: Prof.^a Dra. Silvia das Dores Rissino (CEUNES-UFES)

São Mateus - ES
2025