

UNIVERSIDADE FEDERAL DO ESPÍRITO SANTO - UFES
CENTRO UNIVERSITÁRIO DO NORTE DO ESPÍRITO SANTO - CEUNES
DEPARTAMENTO DE COMPUTAÇÃO E ELETRÔNICA - DCE
BACHARELADO EM CIÊNCIA DA COMPUTAÇÃO

IASMIN MARQUES PEREIRA

Análise de Dados – DataSUS sobre a Síndrome Respiratória Aguda Grave

SÃO MATEUS, ES

2025

IASMIN MARQUES PEREIRA

Análise de Dados – DataSUS sobre a Síndrome Respiratória Aguda Grave

Trabalho de Conclusão de Curso ou
Dissertação ou Tese apresentado à Faculdade...
ou Instituto... da Universidade Federal de
Uberlândia como requisito parcial para
obtenção do título de bacharel, especialista,
mestre ou doutor em

Área de concentração:

Orientadora: Prof.^a Silvia das Dores Rissino
(UFES).

SÃO MATEUS, ES

2025

A ficha catalográfica contém as informações bibliográficas (autor, título, local de publicação, assuntos e outras) necessárias para identificação da obra.

A confecção da ficha catalográfica para teses e dissertações é feita de forma automatizada dentro do Portal do Aluno.

Acesse: [Tutorial para confecção da Ficha Catalográfica Online](#)

Acesse: www.portalestudante.ufu.br

Modelo:

Ficha Catalográfica Online do Sistema de Bibliotecas da UFU
com dados informados pelo(a) próprio(a) autor(a).

C376 2019	Cavalcanti, Ricardo Francisco, 1991- Computação nas nuvens [recurso eletrônico] : uma nova abordagem de armazenamento / Ricardo Francisco Cavalcanti. - 2019. Orientador: José Machado de Oliveira. Coorientadora: Maria da Silva Souza. Dissertação (Mestrado) - Universidade Federal de Uberlândia, Pós-graduação em Ciência da Computação. Modo de acesso: Internet. Disponível em: http://dx.doi.org/10.14393/ufu.di.2019.1 Inclui bibliografia. Inclui ilustrações. 1. Computação. I. Oliveira, José Machado de, 1971- (Orient.). II. Souza, Maria da Silva, 1970-, (Coorient.). III. Universidade Federal de Uberlândia. Pós-graduação em Ciência da Computação. IV. Título. CDU: 681.3
--------------	--

Bibliotecários responsáveis pela estrutura de acordo com o AACR2:
Gizele Cristine Nunes do Couto - CRB6/2091
Nelson Marcos Ferreira - CRB6/3074

NOME COMPLETO DO AUTOR

**Folha de aprovação -
elemento pré-textual
obrigatório**

Título do trabalho:
subtítulo (se houver)

Trabalho de Conclusão de Curso ou
Dissertação ou Tese apresentado à Faculdade...
ou Instituto... da Universidade Federal de
Uberlândia como requisito parcial para
obtenção do título de bacharel, especialista,
mestre ou doutor em

Área de concentração:

Cidade, data

Banca Examinadora:

Nome – Titulação (sigla da instituição)

Nome – Titulação (sigla da instituição)

Nome – Titulação (sigla da instituição)

Nome – Titulação (sigla da instituição)

Dedico este trabalho aos meus pais, pelo estímulo,
carinho e compreensão.

AGRADECIMENTOS

Agradeço ao professor e amigo... o incentivo, motivação e orientação nesta caminhada acadêmica.

Aos colegas... e...,

Agradeço ao Conselho Nacional de Desenvolvimento Científico e Tecnológico (CNPq) pela bolsa concedida durante os anos do curso.

Agradeço também, ao coordenador do setor..., da Universidade..., por permitir o meu afastamento....

**Epígrafe - elemento
pré-textual opcional**

“Ninguém ignora tudo. Ninguém sabe tudo.
Todos nós sabemos alguma coisa. Todos nós
ignoramos alguma coisa.”
(FREIRE, 2002, p. 69)

RESUMO

Elemento obrigatório elaborado conforme NBR6028 da Associação Brasileira de Normas Técnicas (2003), apresentado em um só bloco de texto sem recuo de parágrafo consistindo na apresentação concisa das ideias do texto completo. Deve descrever de forma clara e sintética a natureza do trabalho, o objetivo, o método, os resultados e as conclusões, visando fornecer elementos para o leitor decidir sobre a consulta ao texto completo. Deve ser redigido em linguagem clara e objetiva, ser inteligível por si mesmo, empregar verbos na voz ativa e na terceira pessoa do singular e conter de 150 a 500 palavras. Deve-se evitar o uso de símbolos abreviaturas, fórmulas, quadros, equações. Após o texto do resumo, seguem as palavras-chave representativas do conteúdo do trabalho, que devem aparecer após um espaço em branco de 1,5, à margem esquerda, separadas entre si por ponto final.

Palavras-chave: Trabalhos acadêmicos. Formatação de documentos. Normalização bibliográfica

ABSTRACT

Elemento obrigatório para trabalhos de conclusão de curso (graduação ou especialização), mestrado e doutorado. É a versão do resumo em português para outro idioma, neste exemplo em inglês. Deve aparecer em página distinta e seguindo a mesma formatação do resumo em português. A versão das palavras-chave em outro idioma deve seguir a mesma formatação utilizada no resumo em português.

Keywords: Academic Works. Abstracts. Documents formatting.

LISTA DE ILUSTRAÇÕES

Gráfico 1 -	XXXXXXXXXXXXXXXXX.....	x
Fotografia 1 -	XXXXXXXXXXXXXXXXX.....	xx
Quadro 1 -	XXXXXXXXXXXXXXXXX	xx
Gráfico 2 -	XXXXXXXXXXXXXXXXX	xx

LISTA DE TABELAS

[illegible]

LISTA DE ABREVIATURAS E SIGLAS

ABNT	Associação Brasileira de Normas Técnicas
CNPq	Conselho Nacional de Desenvolvimento Científico e Tecnológico
IBGE	Instituto Brasileiro de Geografia e Estatística
UFU	Universidade Federal de Uberlândia

SUMÁRIO

1	INTRODUÇÃO.....	1
1.1	Problema	3
1.2	Objetivos.....	3
1.2.1	Objetivo Geral	3
1.2.2	Objetivos Específicos	3
1.3	Organização do Trabalho	4
2	REVISÃO BIBLIOGRÁFICA	5
2.1	SRAG (Síndrome Respiratória Aguda Grave).....	5
2.2	Dados	5
2.2.1	KDD	5
2.2.2	Dados Abertos	6
2.2.3	Base de dados aberta de Síndrome Respiratória Aguda Grave (DataSUS).....	7
2.3	Pré processamento de dados	7
2.4	Análise de Dados	9
2.5	Técnicas de Análise	9
2.6	Algoritmos	9
2.6.1	Análise Estatística	9
2.6.2	Mineração de Dados	10
2.6.3	Aprendizado de Máquina.....	11
2.6.4	Redes Neurais e Deep Learning	13
2.7	Árvore de Decisão	13
2.7.1	Conceito de Árvore de Decisão	13
2.7.2	Algoritmo CART (Classification and Regression Trees).....	14
2.8	Métricas de Avaliação Preditiva/ Modelo	15
2.9	Trabalhos Relacionados	15
3	METODOLOGIA.....	16
3.1	Dados	16
3.2	Pré-processamento	16
3.3	Ferramentas e Tecnologias	16
3.4	Implementação dos modelos.....	16
3.5	Ambientes de Execução	16

3.6	Algoritmos Avaliados	16
4	RESULTADOS	17
4.1	Comparação dos Modelos Preditivos	17
4.2	Comparação de Tempo de Execução	17
5	DISCUSSÃO	18
6	CONCLUSÃO	19
6.1	Trabalhos Futuros	19
7	REFERÊNCIAS BIBLIOGRÁFICAS	20

1 INTRODUÇÃO

A saúde pública no Brasil enfrenta desafios consideráveis em virtude da vasta extensão territorial e das diferenças socioeconômicas presentes no país atualmente. O Sistema Único de Saúde (SUS) é reconhecido como uma das mais amplas iniciativas de saúde pública em escala global, buscando sempre garantir o acesso universal aos serviços de saúde para milhões de cidadãos brasileiros, no entanto alguns desafios como a sobrecarga do sistema de saúde e a desigualdade no acesso aos serviços reforçam a necessidade de estratégias inovadoras para aprimorar a gestão de equipamentos, pessoas e da eficiência hospitalar (Paim, 2020). Além disso, com a pandemia de COVID-19 ficou evidente a importância da modernização dos sistemas de monitoramento e previsão de surtos, tornando essencial o uso de técnicas avançadas de análise de dados para auxiliar na tomada de decisões (Silva e Silva Neto, 2022).

Além da importância que temos da modernização de sistemas de monitoramento, pode-se verificar, através de estudos que a inteligência artificial tem desempenhado um papel fundamental na análise de dados de saúde, permitindo a identificação precoce de fatores de risco, a previsão de desfechos clínicos e a otimização da alocação de recursos hospitalares (Sena, 2021).

A saúde é um direito fundamental do ser humano e um pilar essencial para o desenvolvimento social e econômico de uma sociedade. Para auxiliar a garantir esse direito básico à população existe o monitoramento epidemiológico, que desempenha um papel central na prevenção e no controle de doenças, através dele temos a possibilidade de alocação eficiente de recursos e até mesmo a antecipação de surtos. Pode-se verificar que tecnologias como a inteligência artificial (*Artificial Intelligence* - AI) e o aprendizado de máquina (*Machine Learning* - ML) vem sendo muito utilizadas para detectar padrões em pequeno e grandes volumes de dados, auxiliando no desenvolvimento de estratégias preventivas e na tomada de decisões clínicas (Sena, 2021).

A utilização de tecnologias como o Aprendizado de Máquina e Inteligência Artificial tornam-se cada vez mais relevantes diante de doenças, como por exemplo a Síndrome Respiratória Aguda Grave (SRAG), que apresentam altos índices de hospitalização e mortalidade (Belini, Ataíde e Lochter, 2024).

A Síndrome Respiratória Aguda Grave (SRAG) é uma condição respiratória severa causada por diferentes agentes infecciosos, incluindo SARS-CoV-2¹, Influenza² e Vírus Sincicial Respiratório. O SRAG possui um impacto que tem sido crítico sobre o sistema de saúde, reforçando a necessidade de abordagens de prevenção e previsão para otimizar o atendimento e reduzir a mortalidade da população.

Estudos apontam que a SRAG afeta predominantemente grupos vulneráveis, como por exemplo em idosos e indivíduos com comorbidades, como por exemplo doenças cardiovasculares, diabetes, doenças renais crônicas, doenças pulmonares crônicas, obesidade; e que pode levar a complicações graves que demandam suporte maior, como internação em UTI³ e ventilação mecânica (Silva, 2021). Uma ferramenta que auxilia na previsão de casos de risco da Síndrome (SRAG) é a análise preditiva, é através dela que temos a possibilidade de uma resposta mais rápida e eficaz do sistema de saúde (Júnior, 2024).

A capacidade de prever casos graves de SRAG pode contribuir para uma resposta mais eficiente e rápida, permitindo um melhor direcionamento de recursos hospitalares, como por exemplo os leitos de UTI e ventiladores mecânicos. Modelos preditivos baseados em aprendizado de máquina vêm sendo utilizados para identificar fatores de risco e prever desfechos clínicos, possibilitando intervenções precoces (Sena, 2021). Abordagens como esta são fundamentais para otimizar a gestão hospitalar e aprimorar as políticas de saúde pública. A aplicação desses modelos tem mostrado resultados positivos na alocação eficiente de recursos, melhoria da gestão hospitalar e consequentemente reduzir a mortalidade em pacientes críticos (Silva e Silva Neto, 2022).

O processo de análise de dados para predição de doenças segue a abordagem do *Knowledge Discovery in Databases* (KDD), em português a Descoberta de Conhecimento em Bases de Dados, que possui diversas etapas interdependentes para a extração de conhecimento útil a partir de grandes volumes de dados (Fayyad, Piatetsky-Shapiro e Smyth, 1996). As etapas que serão utilizadas, a partir da abordagem do KDD, são a seleção de dados, pré-processamento, a transformação de dados, mineração de dados, interpretação e avaliação dos resultados.

¹ SARS-COV-2: pertence à família Coronaviridae, subgênero Sarbecovírus, e é o sétimo coronavírus conhecido a infectar humanos.

² Influenza: A influenza, também conhecida como gripe, é uma doença viral que afeta o sistema respiratório.

³ UTI: Unidade hospitalar de pacientes gravemente doente

Embora o processo de KDD siga uma sequência estruturada de etapas, ele não é estritamente linear. Durante a análise pode ser necessário retornar a etapas anteriores para fazer ajustes, como por exemplo: refinar o pré-processamento, modificar a seleção de algumas variáveis ou testar novos modelos de aprendizagem. Essas iterações ocorrem para garantir que os insights extraídos dos dados sejam mais precisos e úteis para a tomada de decisão (Fayyad, Piatetsky-Shapiro e Smyth, 1996).

1.1 Problema

O aumento constante dos casos de Síndrome Respiratória Aguda Grave (SRAG) reforça a necessidade de aprimorar as estratégias de monitoramento e previsão de desfechos clínicos, visando otimizar a assistência aos pacientes e a tomada de decisão na saúde pública. Diante disso, como as técnicas de análise preditiva podem ser aplicadas aos dados do DataSUS para prever desfechos clínicos de pacientes com SRAG? E quais as variáveis disponíveis no conjunto de dados do DataSUS (SRAG 2021 a 2024) estão mais associadas ao desfecho clínico de óbito?

1.2 Objetivos

1.2.1 Objetivo Geral

Investigar e definir uma abordagem metodológica para a análise preditiva de desfechos clínicos em pacientes com Síndrome Respiratória Aguda Grave (SRAG), por meio de técnicas de Ciência de Dados e aprendizado de máquina, utilizando dados do DataSUS.

1.2.2 Objetivos Específicos

- Realizar um levantamento bibliográfico sobre a aplicação da análise de dados na área da saúde, com ênfase na predição de doenças respiratórias.
- Estudar as etapas da descoberta de conhecimento em banco de dados.
- Analisar material bibliográfico que utilizam aprendizado de máquina para a predição de desfechos clínicos, identificando metodologias, técnicas e modelos utilizados.
- Investigar o banco de dados do *DataSUS*, compreendendo sua estrutura, variáveis disponíveis e possíveis desafios na manipulação dos dados.
- Definir as técnicas de pré-processamento a serem utilizadas, considerando tratamento de valores ausentes, normalização de variáveis e balanceamento de classes.

- Identificar os algoritmos de aprendizado de máquina mais adequados para a análise preditiva dos desfechos clínicos da Síndrome Respiratória Aguda Grave.
- Comparar a eficácia dos modelos de Predição Random Forest e CART, tendo como principal foco o desfecho clínico (EVOLUCAO).
- Avaliar a performance computacional do algoritmo, Modelo de Predição – CART e Random Forest, em diferentes ambientes de execução.

1.3 Organização do Trabalho

2 REVISÃO BIBLIOGRÁFICA

2.1 SRAG (Síndrome Respiratória Aguda Grave)

A Síndrome Respiratória Aguda Grave (SRAG) é uma infecção respiratória severa caracterizada por sintomas como tosse, febre, desconforto respiratório, pressão ou dor persistente no tórax, dispneia e baixa saturação de oxigênio (menor que 95% em ar ambiente). Sua etiologia⁴ está relacionada a diversos agentes infecciosos, como por exemplo: vírus, Influenza, SARS-CoV-2 e Vírus Sincicial Respiratório (Belini, Ataíde e Lochter, 2024).

A SRAG pode abranger casos de Síndrome Gripal (SG) que quando evoluídos podem levar a pessoa a hospitalização, na maioria dos casos, comprometendo o sistema respiratório. Quando um paciente apresenta sinais da SG junto com sinais mais graves como dispneia, desconforto respiratório, saturação de oxigênio inferior a 95% é notificada no SIVEP-Gripe⁵ (Belini, Ataíde e Lochter, 2024).

Pode-se diferenciar a SRAG da SG através da gravidade dos sintomas que a pessoa apresenta, em caso leve é considerado SG com suspeita de COVID-19 já em casos mais graves a pessoa apresenta SRAG. Durante a pandemia provocada pela COVID-19, a SRAG ganhou maior relevância, evidenciando a necessidade de estratégias preventivas para identificação precoce de casos graves e otimização de recursos hospitalares (Júnior, 2024).

2.2 Dados

2.2.1 KDD

A descoberta de conhecimento em banco de dados, mas também conhecido como KDD, *Knowledge Discovery in Databases*, é um processo que permite a identificação de padrões, informações e conhecimentos através de etapas que são interdependentes. As etapas que serão utilizadas para auxiliar na interpretação do conjunto de dados são: seleção de dados, pré-processamento, a transformação de dados, mineração de dados, interpretação e avaliação dos resultados.

Esse processo inicia-se com na etapa de seleção dos dados, onde informações relevantes são extraídas de bases públicas, como a que será utilizada será a do DataSUS. Na segunda etapa é

⁴ Etiologia: é o estudo ou ciência das causas.


⁵ SIVEP-Gripe: Sistema de Informação da Vigilância Epidemiológica da Gripe.

realizado o pré-processamento de dados garantindo sempre a qualidade do conjunto de dados, nela ocorre a normalização, limpeza e tratamento de valores nulos, duplicados, ausentes e irrelevantes (Júnior, 2024).

A próxima fase envolve a transformação dos dados, onde são aplicadas técnicas como, por exemplo, engenharia de atributos para destacar variáveis importantes para a modelagem. Em seguida, ocorre a mineração de dados, etapa onde algoritmos de aprendizado de máquina são utilizados para prever desfechos clínicos e identificar padrões. Modelos como Regressão Logística, *Decision Tree* e *Random Forest* são amplamente utilizados nesse contexto, apresentando um alto desempenho na predição de mortalidade em pacientes com SRAG (Silva e Silva Neto, 2022).

Na última etapa ocorre a interpretação e avaliação dos resultados através da utilização de métricas, como por exemplo acurácia, precisão, *recall* e AUC-ROC para validar a eficácia dos modelos. A análise desses resultados possibilita a extração de *insights* clínicos valiosos, contribuindo para a tomada de decisão na gestão hospitalar e saúde pública (Belini, Ataíde e Lochter, 2024).

Figura 1 – As etapas do processo de KDD



Fonte: ZOUZA (2025, online)

2.2.2 Dados Abertos

Dados abertos referem-se a conjuntos de informações disponibilizados sem restrições e com transparência para o público, possibilitando sua reutilização para pesquisas científicas e

desenvolvimento de políticas públicas. Essas bases de dados possuem quatro principais características: disponibilidade de acesso, reutilização, redistribuição e participação universal (Júnior, 2024).

Bases de dados abertas podem representar informações importantes em diversas áreas, como por exemplo, saúde, educação, desenvolvimento, economia, negócios, entre outras áreas. No contexto da saúde, os dados abertos viabilizam estudos epidemiológicos e a construção de modelos preditivos (Silva, 2021).

2.2.3 Base de dados aberta de Síndrome Respiratória Aguda Grave (DataSUS)

Através da Secretaria de Vigilância em Saúde (SVS), o Ministério da Saúde (MS) faz a vigilância da SRAG no Brasil desde a pandemia de Influenza A(H1N1)pdm09. A partir disso, a vigilância de SRAG foi incorporada à rede de vigilância de Influenza e outros vírus respiratórios, que anteriormente atuava exclusivamente com a vigilância sentinela de Síndrome Gripal (SG) (MINISTÉRIO DA SAÚDE, 2025).

Atualmente o DataSUS é a principal plataforma de dados abertos em saúde no Brasil, disponibilizando informações epidemiológicas, hospitalares e ambulatoriais que podem servir para análises objetivas que podem facilitar na tomada de decisões. O acesso a esses dados permite análises aprofundadas sobre a incidência de doenças e os impactos no sistema de saúde (Júnior, 2024).

2.3 Pré processamento de dados

O pré-processamento é uma etapa essencial pois é com ela que garantimos a qualidade dos dados fazendo a remoção de ruídos e a adequação dos dados às necessidades analíticas. Técnicas como, por exemplo, transformação de variáveis, normalização e redução de dimensionalidade são aplicadas para melhorar a representatividade dos dados e minimizar o impacto de *outliers*, garantindo que os modelos consigam aprender padrões significativos (Júnior, 2024).

Na etapa de pré-processamento é onde ocorre o tratamento de valores ausentes, normalização de variáveis e balanceamento de classes. É comum em bases de dados alguns valores ausentes,

como por exemplo campos com preenchimento não obrigatórios em formulários, isso pode comprometer a precisão dos modelos.

No tratamento de valores ausentes ocorre a manipulação desses dados, não necessariamente a eliminação deles, pois isso pode afetar o nosso resultado final. Métodos como imputação por média, mediana e algoritmos de preenchimento baseado em aprendizado de máquina são utilizados para excluir informações duplicadas, nulas e também para minimizar esse problema (Sena, 2021).

Na etapa de normalização de variáveis é onde ocorre a padronização para que fiquem dentro de uma mesma escala, evitando que atributos com valores numéricos altos influenciem desproporcionalmente os modelos preditivos (Belini, Ataide e Lochter, 2024). Como por exemplo a normalização *min-max*, que transforma os valores de uma variável para uma escala específica, geralmente entre 0 e 1), o que facilita a comparação entre as variáveis de diferentes magnitudes; pode ser utilizada na idade dos pacientes, exemplo na equação (1), sendo calculado para um paciente de 50 anos.

$$X_{normalizado} = \frac{X - X_{mínimo}}{X_{máximo} - X_{mínimo}} = \frac{50 - 20}{80 - 20} = \frac{30}{60} = 0.5 \quad (1)$$

Dessa forma, a idade é convertida para uma escala entre 0 e 1, facilitando a comparação entre variáveis de diferentes magnitudes em algoritmos de aprendizado de máquina.

O desbalanceamento de classes ocorre quando há uma disparidade significativa entre as categorias de um conjunto de dados, com a utilização de técnicas como *Random UnderSampling* e SMOTE (*Synthetic Minority Over-sampling Technique*) pode-se corrigir esse problema. O *UnderSampling* reduz a quantidade de dados, mas ainda mantém a qualidade, enquanto o SMOTE pode gerar dados sintéticos que não representam a realidade, proporcionando um melhor equilíbrio na aprendizagem do modelo (Júnior, 2024).

2.4 Análise de Dados

A análise de dados é um processo que possui como principal objetivo transformar informações e números em insights que auxiliam na otimização e descoberta de conhecimento para tomada de decisões mais assertivas. Métodos como o aprendizado de máquina e mineração de dados são amplamente utilizados para identificar padrões ocultos e gerar *insights* estratégicos a partir de grandes volumes de informação.

Na área da saúde, a análise de dados tem se tornado um campo fundamental para o monitoramento e tomada de decisões clínicas e epidemiológicas. O uso de dados estruturados permite a criação de modelos, como por exemplo modelos preditivos capazes de identificar padrões em grandes volumes de informações, auxiliando na prevenção e controle de doenças (Belini, Ataíde e Lochter, 2024).

2.5 Técnicas de Análise

A análise de dados envolve muitas abordagens que permitem extrair informações relevantes de grandes volumes de dados. Técnicas estatísticas e de aprendizado de máquina desempenham um papel fundamental nesse processo, pois possibilitam a construção de modelos e identificação de padrões diferentes aplicações, desde classificação e previsão até agrupamento e detecção de anomalias (Sena, 2021).

2.6 Algoritmos

Existem diversas técnicas de Análise de Dados que utilizam diferentes algoritmos, como por exemplo a análise estatística, mineração de dados, Aprendizado de Máquina, redes neurais e *Deep Learning*.

2.6.1 Análise Estatística

2.6.1.1 Regressão Linear

A Regressão Linear é uma técnica estatística muito utilizada para previsão de valores numéricos com base em variáveis independentes. O algoritmo busca modelar a relação entre uma variável independente (ou mais variáveis) através de uma equação linear. Como por exemplo, na equação (2) da regressão linear simples, que demonstra a previsão do preço de uma casa com base em sua área.

$$y = \beta_0 + \beta_1 x + \epsilon \quad (2)$$

Onde,

- y representa uma variável dependente
- x representa a variável independente
- β_0 é o intercepto
- β_1 é o coeficiente angular
- ϵ é o erro.

2.6.1.2 Regressão Logística

A Regressão Logística é um método estatístico amplamente utilizado para modelagem de variáveis categóricas cujo o principal objetivo é estimar a probabilidade de um evento ocorrer com base em variáveis independentes, sendo muito utilizada em problemas de classificação binária (Silva e Silva Neto, 2022). Como por exemplo, na equação (3), temos que a regressão logística usa a função sigmoide (logística)⁶ para transformar uma combinação linear de variáveis independentes em uma probabilidade; nesse caso utilizada para modelar a probabilidade de um evento binário ocorrer: prever se um paciente tem ou não uma determinada doença.

$$P(y = 1 | x) = \frac{1}{1 + e^{-(\beta_0 + \beta_1 x)}} \quad (3)$$

Onde,

- $P(y = 1 | x)$:é a probabilidade de o evento ocorrer (por exemplo, ter ou não a doença);
- β_0 : intercepto (termo constante).
- β_1 : coeficiente que representa o impacto da variável X .
- e : base do logaritmo natural (aproximadamente 2,718).

2.6.2 Mineração de Dados

A mineração de dados é o processo de explorar grandes conjuntos de dados para descobrir padrões, correlações e informações úteis.

⁶ Função sigmoide é uma função matemática que gera uma curva em forma de "S"

2.6.2.1 Apriori

Apriori é um algoritmo utilizado para encontrar padrões frequentes em bases de dados transacionais, alguns casos de uso comuns são sistemas de previsão e recomendação de doenças, como análise de cestas de mercado para plataformas de comércio eletrônico (IBM, 2024).

2.6.2.2 K-Means

O *K-Means* é um algoritmo de agrupamento que divide dados, não rotulados, em “*K*” *clusters* com base em características semelhantes, é muito utilizado em ciência de dados para segmentação de mercado, segmentação de imagens, agrupamento de documentos e compactação de imagens (IBM, 2024).

2.6.3 Aprendizado de Máquina

A Inteligência Artificial (IA) ou *Machine Learning* é um campo da ciência da computação que imita o pensamento humano na capacidade de aprender e tomar decisões. Atualmente, a medicina tem utilizado *ML* para aprimorar diagnósticos, prognósticos e no auxílio aos médicos para tratamentos em diversas especialidades como cardiologia, neurologia, oncologia e dermatologia (Vitoria, 2022).

Esses modelos podem ser aprendidos de maneira supervisionada ou não supervisionada.

O aprendizado supervisionado envolve o treinamento de modelos com dados rotulados, sendo amplamente utilizado na predição de doenças e no apoio à decisão médica. De acordo com Vitoria (2022) o objetivo central do aprendizado supervisionado é verificar qual é o modelo que, a partir de dados rotulados anteriormente em treinamentos, permita fazer previsões sobre os dados futuros. Modelos como Regressão Logística, *Random Forest* e Redes Neurais são frequentemente aplicados para classificação e predição de desfechos clínicos, proporcionando insights valiosos para profissionais de saúde (Belini, Ataide e Lochter, 2024).

Já o aprendizado não supervisionado é aplicado para identificar padrões ocultos nos dados sem a necessidade de rótulos predefinidos. De acordo com Vitoria (2022), ao contrário do aprendizado supervisionado, os dados não têm rótulos identificadores, apenas os preditores estão disponíveis no conjunto de dados e não as saídas especificadas.

2.6.3.1 Random Forest

O algoritmo *Random Forest* (traduzido para Floresta Aleatória) é uma técnica baseada em um conjunto de árvores de decisão, sendo eficaz para problemas de classificação, previsão e regressão. Estudos indicam que esse método tem alto desempenho na predição de desfechos clínicos (Belini, Ataíde e Lochter, 2024). Através dele é possível melhorar a precisão e reduzir o *overfitting*⁷, como por exemplo na previsão de uma espécie de uma flor com base em suas características.

2.6.3.2 XGBoost

O *XGBoost* (*Extreme Gradient Boosting* - traduzido para aumento de gradiente extremo) é um algoritmo baseado em árvores de decisão (que será explicado mais à frente) que utiliza *boosting* para aumentar a precisão preditiva. Ele é altamente otimizado e frequentemente utilizado em disciplinas do curso de ciência de dados, como por exemplo computação paralela e distribuída, devido ao seu alto desempenho e eficiência computacional (Silva, 2021). Um exemplo de utilização desse algoritmo pode ser para previsão de preço de ações com base em indicadores financeiros.

2.6.3.3 K -Nearest Neighbors (KNN)

O algoritmo *k-Nearest Neighbors* (kNN - traduzido para *k*-vizinhos mais próximos) classifica novas amostras com base na proximidade em relação aos vizinhos mais próximos, muito utilizado para tarefas de reconhecimento de padrões. Ele classifica um novo dado considerando os "*k*" vizinhos mais próximos no espaço multidimensional, concedendo a ele o rótulo mais frequente entre os vizinhos. Como por exemplo, recomendar filmes a um usuário com base nas preferências de usuários semelhantes.

O método é simples e eficaz para reconhecimento de padrões, sendo utilizado em diversas aplicações, incluindo análises na área da saúde. Para calcular a proximidade entre instâncias, o *KNN* faz a utilização de métricas como a distância euclidiana, o que pode impactar diretamente na acurácia do modelo (Silva, 2021).

2.6.3.4 Support Vector Machine (SVM)

Support Vector Machine (SVM - traduzido para máquina de vetores de suporte) é um algoritmo que encontra um hiperplano que faz a separação de classes de dados amplamente utilizados para tarefas de classificação e regressão. O principal objetivo do algoritmo é encontrar um hiperplano ótimo que maximize a margem entre diferentes classes, permitindo uma separação eficiente dos dados. Esse método é frequentemente empregado em problemas médicos e de

⁷ Overfitting: ocorre quando um algoritmo se ajusta muito de perto aos seus dados de treinamento;

detecção de padrões devido à sua capacidade de generalização, boa seleção de atributos e alta acurácia (Silva, 2021).

2.6.4 Redes Neurais e Deep Learning

2.6.4.1 Artificial Neural Networks (ANNs)

As *Artificial Neural Networks* (RNs - Redes Neurais Artificiais) são modelos inspirados no funcionamento do cérebro humano e têm sido aplicadas com sucesso na predição de doenças, especialmente em problemas complexos como diagnóstico por imagem (Júnior, 2024). Um exemplo de utilização é o reconhecimento de escrita manual.

2.6.4.2 Redes Neurais Convolucionais (CNNs)

As Redes Neurais Convolucionais (CNNs - *Convolutional Neural Network*) é um subconjunto do aprendizado de máquina muito utilizado para tarefas de classificação e visão computacional, como por exemplo identificação de objetos em uma imagem (IBM, 2024).

2.6.4.3 Redes Neurais Recorrentes (RNNs)

A Rede Neural Recorrente (RNN - *Convolutional Neural Network*) é uma rede neural profunda treinada com a utilização de dados sequenciais ou com séries temporais, com o objetivo de criar um modelo de Aprendizado de Máquina (ML) sendo capaz de fazer previsões com base em *inputs* sequenciais. Podem ser utilizadas, como por exemplo, para prever níveis diários de inundação com base em dados anteriores de enchentes, marés e informações meteorológicas (IBM, 2024).

2.7 Árvore de Decisão

2.7.1 Conceito de Árvore de Decisão

Como Árvore de Decisão (em inglês *Decision Tree*) é um algoritmo de aprendizado de máquina e ao mesmo tempo uma técnica de mineração de dados, utilizada para prever, classificar e extrair conhecimento a partir de dados foi criada esta seção para detalhar sua aplicação e importância. Pode-se dizer que as Árvores de Decisão são modelos hierárquicos que segmentam os dados com base em condições lógicas sucessivas. Elas são eficientes e interpretáveis para tarefas de classificação e regressão, sendo frequentemente utilizadas em conjunto com outros métodos para aumentar a robustez dos modelos (Silva e Silva Neto, 2022).

- Como a árvore divide os dados (por Gini ou entropia, por exemplo).
- A ideia de "nós", "ramos", "folhas", e decisões hierárquicas.

- Vantagens (interpretabilidade, rapidez) e desvantagens (overfitting).

2.7.2 Algoritmo CART (Classification and Regression Trees)

Detalhar o funcionamento do CART: critérios de divisão (Gini ou Entropia), profundidade, podas, vantagens e desvantagens.

Exemplos de uso em saúde e previsão.

- Histórico e proposta do algoritmo.
- Como ele realiza divisões com base no índice de Gini.
- Processo de criação da árvore, critérios de parada, e poda.
- Aplicações no contexto de saúde ou esportes.
- Vantagens e limitações.

2.8 Métricas de Avaliação Preditiva/ Modelo

- Definições formais de Acurácia, Precisão, Recall, F1-Score, AUC-ROC, Matriz de Confusão.
- Gráficos ilustrativos se possível (para facilitar a compreensão de AUC, por exemplo).
- Justificativa das métricas escolhidas para o problema (ex: F1-score por causa de desbalanceamento).

2.9 Trabalhos Relacionados

<https://bmcpublikealth.biomedcentral.com/articles/10.1186/s12889-024-18815-0>

Rodrigues et al. (2024) propuseram um estudo com foco na predição de abandono do tratamento da tuberculose utilizando algoritmos de aprendizado de máquina aplicados a dados de registros nacionais do Brasil. O trabalho utilizou um conjunto abrangente de variáveis demográficas, clínicas e sociais disponíveis no Sistema de Informação de Agravos de Notificação (SINAN) para treinar e avaliar modelos supervisionados. Foram testados diferentes algoritmos, incluindo Random Forest, XGBoost, LightGBM, entre outros, com o objetivo de identificar pacientes com maior probabilidade de evasão do tratamento. Os modelos apresentaram desempenho promissor, com destaque para o XGBoost, que alcançou AUC-ROC superior a 0,75. Os autores destacam a importância do uso de inteligência artificial como ferramenta auxiliar na vigilância em saúde pública, sugerindo que modelos preditivos podem orientar estratégias direcionadas de intervenção, reduzindo perdas no tratamento e melhorando o controle da doença.

<https://www.sciencedirect.com/science/article/abs/pii/S1047279725001127?via%3Dihub>

3 METODOLOGIA

Objetivo: Descrever como a pesquisa foi conduzida, passo a passo.

Deve conter:

- Descrição da base de dados (ex: SIVEP-Gripe, SINAN, ou dados esportivos, com número de registros e atributos).
- Pré-processamento dos dados:
 - Limpeza, tratamento de valores ausentes
 - Balanceamento de classes (SMOTE, ADASYN, etc.)
 - Codificação de variáveis
- Construção dos modelos:
 - Algoritmos utilizados
 - Estratégias de divisão dos dados (train/test, k-fold)
 - Ajuste de hiperparâmetros (GridSearch, RandomSearch, etc.)
- Ferramentas utilizadas:
 - Python, bibliotecas, Google Colab, etc.
- Métricas utilizadas para comparação dos modelos

3.1 Dados

3.2 Pré-processamento

3.3 Ferramentas e Tecnologias

3.4 Implementação dos modelos

3.5 Ambientes de Execução

contar sobre as maquinas (propriedades)

3.6 Algoritmos Avaliados

4 RESULTADOS

Objetivo: Apresentar os resultados obtidos a partir dos experimentos realizados.

Deve conter:

- Desempenho dos modelos (em tabelas e gráficos):
 - Accuracy, Precision, Recall, F1-Score, AUC
 - Matriz de confusão
 - Curvas ROC
- Comparações entre os modelos (ex: CART vs Random Forest)
- Tabelas de feature importance
- Tempo de execução (se for foco da análise)
- Gráficos gerados (posicione e comente)

4.1 Comparação dos Modelos Preditivos

4.2 Comparação de Tempo de Execução

5 DISCUSSÃO

Objetivo: Interpretar os resultados, compará-los com a literatura e refletir sobre implicações e limitações.

Deve conter:

- Análise crítica dos resultados
- Comparação com trabalhos da revisão bibliográfica
- Interpretação das variáveis mais relevantes (feature importance)
- Discussão sobre limitações (ex: qualidade dos dados, falta de variáveis clínicas detalhadas, etc.)
- Potenciais melhorias e sugestões para trabalhos futuros

6 CONCLUSÃO

Objetivo: Retomar os objetivos e apresentar os principais achados do trabalho.

Deve conter:

- Retomada dos objetivos e se foram alcançados
- Principais conclusões do estudo
- Contribuições do trabalho (teóricas, práticas, metodológicas)
- Sugestões de continuidade (ex: aplicar SHAP, testar deep learning, expandir base de dados)

6.1 Trabalhos Futuros

7 REFERÊNCIAS BIBLIOGRÁFICAS

ALTINO, Rita de Cássia et al. **A importância da notificação compulsória frente à Síndrome Respiratória Aguda Grave (SRAG) e Covid-19.** Rev. Salusvita (Online), p. 627-649, 2020.

AMAZON WEB SERVICES. **O que é mineração de dados?** Disponível em: <https://aws.amazon.com/pt/what-is/data-mining/>. Acesso em: 08 mar. 2025.

AMAZON WEB SERVICES. **O que é regressão logística?** Disponível em: <https://aws.amazon.com/pt/what-is/logistic-regression/>. Acesso em: 08 mar. 2025.

BAHIA. Secretaria da Saúde. **Guia rápido SIVEP-Gripe.** Atualizado em maio de 2021. Disponível em: https://www.saude.ba.gov.br/wp-content/uploads/2021/05/GUIA-RAPIDO-SIVEP-GRIPE-atualizado-em-maio_2021.pdf. Acesso em: 04 mar. 2025.

BARRETO, Evandro Fernandes. **Ciência de dados aplicada à pandemia do coronavírus no Brasil, uma análise socioeconômica.** 2021. Trabalho de Conclusão de Curso (Bacharelado em Ciência da Computação) – Universidade Estadual Paulista “Júlio de Mesquita Filho”, Faculdade de Ciências, Bauru, 2021.

BELINI, Gustavo Torres; ATAIDE, Danilo da Silva; LOCHTER, Johannes Von. **Modelo de Machine Learning para Predição de Problemas Respiratórios.** Facens Centro Universitário, Sorocaba, 2024.

BRASIL. Ministério da Saúde. **COVID-19.** Disponível em: <https://www.gov.br/saude/pt-br/assuntos/saude-de-a-a-z/c/covid-19>. Acesso em: 20 jan. 2025.

BRASIL. Ministério da Saúde. **Gripe (Influenza).** Disponível em: <https://www.gov.br/saude/pt-br/assuntos/saude-de-a-a-z/g/gripe-influenza>. Acesso em: 20 fev. 2025.

FAYYAD, U.; PIATETSKY-SHAPIO, G.; SMYTH, P. **From data mining to knowledge discovery in databases.** AI Magazine, v. 17, n. 3, p. 37-54, 1996.

FIOCRUZ – Fundação Oswaldo Cruz. **Casos de síndrome respiratória continuam crescendo em todo o país.** Agência Brasil, 2024. Disponível em: <https://agenciabrasil.ebc.com.br/saude/noticia/2024-03/casos-de-sindrome-respiratoria-continuum-crescendo-em-todo-o-pais>. Acesso em: 16 jan. 2025.

IBM. **Algoritmo Apriori.** Disponível em: <https://www.ibm.com/br-pt/think/topics/apriori-algorithm>. Acesso em: 08 mar. 2025.

IBM. **K-means clustering.** Disponível em: <https://www.ibm.com/br-pt/topics/k-means-clustering>. Acesso em: 08 mar. 2025.

IBM. **Redes neurais convolucionais.** Disponível em: <https://www.ibm.com/br-pt/think/topics/convolutional-neural-networks>. Acesso em: 08 mar. 2025.

IBM. **Redes neurais recorrentes.** Disponível em: <https://www.ibm.com/br-pt/think/topics/recurrent-neural-networks>. Acesso em: 08 mar. 2025.

IBM. **Regressão linear.** Disponível em: <https://www.ibm.com/br-pt/topics/linear-regression>. Acesso em: 08 mar. 2025.

INSTITUTO FEDERAL DE SANTA CATARINA (IFSC). **Como funciona uma Unidade de Terapia Intensiva.** Disponível em: https://www.ifsc.edu.br/post-ifsc-verifica/-/asset_publisher/uII70Nv266Xk/content/id/1983737/como-funciona-uma-unidade-de-terapia-intensiva. Acesso em: 20 fev. 2025.

JÚNIOR, Uálaci dos Anjos. **Mineração de dados na base de dados de SRAG.** 2024. Trabalho de Conclusão de Curso (Bacharelado em Engenharia da Computação) – Universidade Federal do Espírito Santo, São Mateus, 2024.

MARQUES, Iasmin. **Análise de Dados - Preditiva.** Disponível em: https://colab.research.google.com/drive/1tg1hKxFYfgRVxRXTjPlIKwhKSm_goi8P. Acesso em: 08 mar. 2025.

MINISTÉRIO DA SAÚDE (Brasil). **OpenDataSUS – Sobre**. Disponível em: <https://opendatasus.saude.gov.br/about>. Acesso em: 04 mar. 2025.

MINISTÉRIO DA SAÚDE (Brasil). **Síndrome Respiratória Aguda Grave – SRAG 2021 a 2024**. Disponível em: <https://opendatasus.saude.gov.br/dataset/srag-2021-a-2024/resource/8cb52f73-0184-41d5-8a8f-87d8f415652c>. Acesso em: 10 fev. 2025.

PAIM, J. S. **O Sistema Único de Saúde (SUS) aos 30 anos**. Ciência & Saúde Coletiva, v. 25, n. 3, p. 357-364, 2020. Disponível em: <https://www.scielo.br/j/csc/a/Qg7SJFjWPjvdQjvnRzxS6Mg/?lang=pt>. Acesso em: 16 jan. 2025.

SEBRAE. **O que é e como funciona a análise preditiva na saúde? Entenda**. Disponível em: <https://sebrae.com.br/sites/PortalSebrae/ufs/pe/artigos/o-que-e-e-como-funciona-a-analise-preditiva-na-saude-entenda>. Acesso em: 16 jan. 2025.

SENA, Gabrielle Ribeiro. **Modelos preditivos de óbito para pacientes com COVID-19**. 2021. Tese (Doutorado em Saúde Integral) – Instituto de Medicina Integral Prof. Fernando Figueira (IMIP), Recife, 2021.

SILVA, Amauri Ornellas da. **Uso de Machine Learning para previsão da evolução de casos de SRAG incluindo casos de COVID-19 considerando variáveis clínicas e demográficas**. 2021. Trabalho de Conclusão de Curso (Bacharelado em Engenharia de Produção) – Universidade Tecnológica Federal do Paraná, Londrina, 2021. Disponível em: <https://repositorio.utfpr.edu.br/jspui/handle/1/26211>. Acesso em: 16 jan. 2025.

SILVA, Risomario; SILVA NETO, Darcy Ramos da. **Inteligência artificial e previsão de óbito por Covid-19 no Brasil: uma análise comparativa entre os algoritmos Logistic Regression, Decision Tree e Random Forest**. Saúde em Debate, v. 46, n. especial 8, p. 118-129, dez. 2022.

VITORIA, Sergio Ricardo Pacheco da. **Machine Learning e Análise Preditiva em Saúde: um estudo de caso sobre detecção de anomalias em contas médicas do Exército**. 2022. Dissertação (Mestrado em Governança, Tecnologia e Inovação) – Pontifícia Universidade Católica de Minas Gerais, Brasília, 2022.

ZOUZA. **Knowledge Discovery in Databases (KDD)**. Medium, 2025. Disponível em: <https://medium.com/blog-do-zouza/knowledge-discovery-in-databases-kdd-462ea2775715>. Acesso em: 08 mar. 2025.

RODRIGUES, M. M. S. et al. Machine learning algorithms using national registry data to predict loss to follow-up during tuberculosis treatment. *BMC Public Health*, v. 24, art. 1385, 23 maio 2024. DOI:10.1186/s12889-024-18815-0.

Overview

Brought to you by YData

OverviewAlerts345Reproduction

Dataset statistics

Number of variables	191	DateTime	28
Number of observations	10000	Numeric	20
Missing cells	1090740	Categorical	108
Missing cells (%)	57.1%	Text	25
Duplicate rows	0	Unsupported	10
Duplicate rows (%)	0.0%		
Total size in memory	14.6 MiB		
Average record size in memory	1.5 KiB		

Variable types

DateTime	28
Numeric	20
Categorical	108
Text	25
Unsupported	10

Variables

Select Columns ▾

DT_NOTIFICDate

Distinct	389	Minimum	2023-12-31 00:00:00
----------	-----	---------	---------------------

APÊNDICE B – Código: Análise Preditiva (Comparação Algoritmos) (Autor)

```

# Instalar dependências
!pip install imbalanced-learn --quiet

# Início de tempo total
import time
inicio_total = time.time()

# Imports
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns

from sklearn.model_selection import train_test_split, GridSearchCV
from sklearn.tree import DecisionTreeClassifier
from sklearn.ensemble import RandomForestClassifier
from sklearn.metrics import classification_report, roc_auc_score, roc_curve, confusion_matrix

from imblearn.pipeline import Pipeline as ImbPipeline
from imblearn.over_sampling import SMOTE

# Carregar o dataset
df = pd.read_csv("../INFLUD24-03-02-2025.csv", sep=";", encoding="latin1", low_memory=False)

# Pré-processamento
df = df[df['EVOLUCAO'].isin([1, 2])].copy()
df['EVOLUCAO'] = df['EVOLUCAO'].map({1: 0, 2: 1})

fatores_risco = ['PUERPERA', 'CARDIOPATI', 'HEMATOLOGE', 'SINO_DOWN', 'HEPATICA',
                'ASMA', 'DIABETES', 'NEUROLOGIC', 'PNEUMOPATI', 'IMMUNODEPRE',
                'RENAL', 'OBESIDADE', 'OUT_MORBI']
variaveis = fatores_risco + ['FATOR_RISCO', 'NU_IDADE_N', 'SUPORT_VEN', 'UTI', 'TOSSE']
df_model = df[variaveis + ['EVOLUCAO']].copy()

for col in variaveis:
    df_model[col] = pd.to_numeric(df_model[col], errors='coerce')
df_model.replace(9, np.nan, inplace=True)
df_model.dropna(inplace=True)

df_model['N_COMORB'] = df_model[fatores_risco].eq(1).sum(axis=1)
X = df_model.drop(columns=['EVOLUCAO'])
y = df_model['EVOLUCAO']

X_train, X_test, y_train, y_test = train_test_split(X, y, stratify=y, test_size=0.2, random_state=42)

# Pipelines
pipe_cart = ImbPipeline([['smote', SMOTE(random_state=42)],
                        ['cart', DecisionTreeClassifier(class_weight='balanced', random_state=42)]])

pipe_rf = ImbPipeline([['smote', SMOTE(random_state=42)],
                       ['rf', RandomForestClassifier(class_weight='balanced', random_state=42)]])

# Parâmetros
param_cart = {'cart__max_depth': [3, 5, 7],
              'cart__min_samples_leaf': [1, 2],
              'cart__min_samples_split': [2, 5]}

param_rf = {'rf__n_estimators': [100],
            'rf__max_depth': [5, 7],
            'rf__min_samples_leaf': [1, 2],
            'rf__min_samples_split': [2, 5]}

# Treinar CART
start = time.time()
grid_cart = GridSearchCV(pipe_cart, param_grid=param_cart, scoring='f1', cv=5, n_jobs=-1)
grid_cart.fit(X_train, y_train)
end = time.time()
minutos, segundos = divmod(end - start, 60)
print(f"• CART Best Params: ", grid_cart.best_params_)
print("Train F1: ", grid_cart.score(X_train, y_train))
print("Test F1: ", grid_cart.score(X_test, y_test))
print(f"• Tempo CART: {int(minutos)} min {round(segundos, 2)} s")
y_pred_cart = grid_cart.predict(X_test)
print("AUC CART: ", roc_auc_score(y_test, grid_cart.predict_proba(X_test)[:, 1]))
print(classification_report(y_test, y_pred_cart))

# Treinar Random Forest
start = time.time()
grid_rf = GridSearchCV(pipe_rf, param_grid=param_rf, scoring='f1', cv=5, n_jobs=-1)
grid_rf.fit(X_train, y_train)
end = time.time()
minutos, segundos = divmod(end - start, 60)
print(f"• RF Best Params: ", grid_rf.best_params_)
print("Train F1: ", grid_rf.score(X_train, y_train))
print("Test F1: ", grid_rf.score(X_test, y_test))
print(f"• Tempo RF: {int(minutos)} min {round(segundos, 2)} s")
y_pred_rf = grid_rf.predict(X_test)
print("AUC RF: ", roc_auc_score(y_test, grid_rf.predict_proba(X_test)[:, 1]))
print(classification_report(y_test, y_pred_rf))

# Curva ROC
fpr_cart, tpr_cart, _ = roc_curve(y_test, grid_cart.predict_proba(X_test)[:, 1])
fpr_rf, tpr_rf, _ = roc_curve(y_test, grid_rf.predict_proba(X_test)[:, 1])

plt.figure(figsize=(10, 6))
plt.plot(fpr_cart, tpr_cart, label='CART')
plt.plot(fpr_rf, tpr_rf, label='Random Forest')
plt.plot([0, 1], [0, 1], 'k--')
plt.xlabel('False Positive Rate')
plt.ylabel('True Positive Rate')
plt.title('Curva ROC - CART vs Random Forest')
plt.legend()
plt.grid()
plt.show()

# Matriz de Confusão
fig, axs = plt.subplots(1, 2, figsize=(12, 5))
sns.heatmap(confusion_matrix(y_test, y_pred_cart), annot=True, fmt='d', cmap='Blues', ax=axs[0])
axs[0].set_title('Matriz de Confusão - CART')
axs[0].set_xlabel('Previsto')
axs[0].set_ylabel('Real')

sns.heatmap(confusion_matrix(y_test, y_pred_rf), annot=True, fmt='d', cmap='Greens', ax=axs[1])
axs[1].set_title('Matriz de Confusão - Random Forest')
axs[1].set_xlabel('Previsto')
axs[1].set_ylabel('Real')

plt.tight_layout()
plt.show()

# Tempo total de execução
fim_total = time.time()
min_total, seg_total = divmod(fim_total - inicio_total, 60)
print(f"• Tempo total de execução do código: {int(min_total)} min {round(seg_total, 2)} s")

```

APÊNDICE C – Código: Análise de Variáveis (Cart sem variáveis de Apoio)

```

# Bibliotecas
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns
import time

from sklearn.model_selection import train_test_split
from sklearn.tree import DecisionTreeClassifier, plot_tree
from sklearn.metrics import classification_report, confusion_matrix
from sklearn.preprocessing import LabelEncoder

from imblearn.over_sampling import SMOTE

# Cronômetro
start_time = time.time()

# 1. Carregar os dados
df = pd.read_csv("../content/drive/MyDrive/TCC I/Análise de Dados/INFLUD24-03-02-2025.csv", sep=";",
encoding="latin1", low_memory=False)

# 2. Selecionar variável alvo e filtrar
df = df[df['EVOLUCAO'].isin([1, 2]).copy()]
df['EVOLUCAO'] = df['EVOLUCAO'].map({1: 0, 2: 1}) # 0 = Cura, 1 = Óbito

# 3. Selecionar colunas preditoras
# Remove 'EVOLUCAO' e colunas que não fazem sentido (ID's, datas, etc.)
colunas_remover = ['EVOLUCAO', 'DT_NOTIFIC', 'DT_INTERNA', 'DT_SIN_PRI', 'DT_EVOLUCA']
variaveis = [col for col in df.columns if col not in colunas_remover]

X = df[variaveis].copy()
y = df['EVOLUCAO']

# 4. Converter variáveis categóricas em numéricas
for col in X.columns:
    if X[col].dtype == 'object':
        X[col] = X[col].fillna('Desconhecido')
        le = LabelEncoder()
        X[col] = le.fit_transform(X[col].astype(str))
    else:
        X[col] = pd.to_numeric(X[col], errors='coerce')

# 5. Tratar valores ausentes
X = X.fillna(-999) # ou outra estratégia

# 6. Balanceamento
sm = SMOTE(random_state=42)
X_res, y_res = sm.fit_resample(X, y)

# 7. Treinamento do modelo
X_train, X_test, y_train, y_test = train_test_split(
    X_res, y_res, test_size=0.3, random_state=42, stratify=y_res
)

clf = DecisionTreeClassifier(random_state=42, criterion='gini', max_depth=5)
clf.fit(X_train, y_train)

# 8. Avaliação
y_pred = clf.predict(X_test)
print("\n📊 Classification Report:\n", classification_report(y_test, y_pred))

# 9. Matriz de Confusão
cm = confusion_matrix(y_test, y_pred)
plt.figure(figsize=(6,5))
sns.heatmap(cm, annot=True, fmt='d', cmap='Blues',
            xticklabels=['Cura (0)', 'Óbito (1)'],
            yticklabels=['Cura (0)', 'Óbito (1)'])
plt.xlabel('Predito')
plt.ylabel('Real')
plt.title('Matriz de Confusão - Árvore de Decisão')
plt.show()

# 10. Importância das variáveis
importancias = pd.DataFrame({
    'Variável': X.columns,
    'Importância': clf.feature_importances_
}).sort_values(by='Importância', ascending=False)

plt.figure(figsize=(10,6))
sns.barplot(x='Importância', y='Variável', data=importancias, palette='viridis')
plt.title('Importância das Variáveis - Árvore de Decisão')
plt.show()

print("\nImportância das variáveis:")
print(importancias)

# 11. Árvore de Decisão
plt.figure(figsize=(20,10))
plot_tree(clf, feature_names=X.columns, class_names=['Cura', 'Óbito'],
          filled=True, rounded=True, fontsize=10)
plt.title('Árvore de Decisão - CART')
plt.show()

# Tempo total
end_time = time.time()
elapsed_time = end_time - start_time
print(f"\n⌚ Tempo total de execução: {elapsed_time:.2f} segundos")

```


Dicionário de Dados


FICHA DE REGISTRO INDIVIDUAL – CASOS DE SÍNDROME RESPIRATÓRIA AGUDA GRAVE HOSPITALIZADOS

Este documento tem como finalidade descrever as variáveis exportadas para o banco de dados em DBF.

CAMPO OBRIGATÓRIO é aquele cuja ausência de dado impossibilita a inclusão do registro no sistema.
CAMPO ESSENCIAL é aquele que, apesar de não ser obrigatório, registra dado necessário à investigação do caso ou ao cálculo de indicador epidemiológico ou operacional.
CAMPO INTERNO é aquele que apesar de não constar na ficha e não aparecer no display da tela, é preenchido automaticamente pelo sistema.
CAMPO OPCIONAL é aquele que só deve ser preenchido caso seja necessário, aparece no display da tela e consta no banco de dados.

Nome do campo	Tipo	Categoria	Descrição	Características	DBF
Nº	Varchar2(12)		Número do registro	Campo Interno Número sequencial gerado automaticamente pelo sistema. Utilizar o padrão: 320120000123 Dígito 1: caracteriza o tipo da ficha (1=SG, 2=SRAG-UTI e 3-SRAG Hospitalizado). Dígitos 2 a 12: número sequencial gerado automaticamente pelo sistema.	NU_NOTIFIC
1-Data do preenchimento da ficha de notificação	Date DD/MM/AAAA		Data de preenchimento da ficha de notificação.	Campo Obrigatório Data deve ser <= a data da digitação.	DT_NOTIFIC
Semana Epidemiológica do preenchimento da ficha de notificação	Varchar2(6)		Semana Epidemiológica do preenchimento da ficha de	Campo Interno Calculado a partir da data dos Primeiros Sintomas. (SS)	SEM_NOT

APÊNDICE E – Árvore de Decisão (autor)



APÊNDICE F – Analise Exploratória dos Dados ??

a) **ANEXO A – TÍTULO DO ANEXO**

O anexo constitui material não elaborado pelo autor, que serve de fundamentação, comprovação e ilustração do seu trabalho.

Elemento opcional. Deve ser precedido da palavra ANEXO, identificado com letras maiúsculas do alfabeto, travessão e respectivo título (como exemplificado acima). O título “**ANEXO**” deve estar centralizado e com a mesma tipologia utilizada para as seções primárias, sugestão: maiúsculo e negrito.

**Anexo – elemento pós-textual
opcional**