



Escrita

Estrutura do TCC II - Iasmin

▼ 1. Resumo

▼ 2. Abstract

▼ 3. Lista de Figuras

▼ 4. Lista de Quadros

▼ 5. Lista de Tabelas

▼ 6. SUMÁRIO

1. Introdução
 - 1.1 Problema e Hipótese
 - 1.1.1 Problema de Pesquisa
 - 1.1.2 Hipótese
 - 1.2 Objetivos
 - 1.2.1 Objetivo Geral
 - 1.2.2 Objetivos Específicos
 - 1.3 Organização do Trabalho/ Estrutura do trabalho
2. Revisão Bibliográfica
 - 2.1 SRAG (Síndrome Respiratória Aguda Grave)
 - 2.2 Dados
 - 2.2.1 Dados Abertos
 - 2.2.2 Base de dados aberta de Síndrome Respiratória Aguda Grave (SRAG)
 - 2.2.3 Mineração de Dados e KDD
 - 2.2.3.1 Pré processamento de dados
 - 2.3 Análise de Dados
 - 2.4 Técnicas de Análise/ Aprendizado
 - 2.5 Algoritmos
 - 2.5.1 Cart
 - 2.5.2 Random Forest
 - 2.6 Árvore de Decisão
 - 2.6.1 Conceito e Funcionamento
 - 2.7 Aprendizado de Máquina
 - 2.8 Métricas de Avaliação Preditiva
 - F1-Score, AUC, Accuracy, Precision, Recall
 - Matriz de confusão
 - 2.9 Eficiência Computacional
 - Tempo de execução como métrica
 - Discussão sobre ambiente, hardware e limitações práticas
 - 2.10 Trabalhos Relacionados

- 3. Metodologia
 - 3.1 DADOS
 - 3.1.1 Análise Exploratória Inicial
 - 3.2 Pré-processamento
 - 3.3 Ferramentas e Tecnologias
 - Google Colab, Python, bibliotecas (Pandas, Scikit-learn, Matplotlib)
 - Ambientes computacionais distintos: cluster UFES, PC Geraldo, PC lasmin
 - 3.4 Implementação dos modelos
 - 3.5 Ambientes de Execução
 - 3.6 Algoritmos Avaliados
 - 3.7 Avaliação de Desempenho Computacional
- 4. Resultados
 - 4.1 Comparação dos Modelos Preditivos
 - 4.1.1 Random Forest
 - 4.1.2 CART
 - 4.1.3 Síntese Comparativa: Random Forest vs CART [nao tenho certeza se vou deixar]
 - 4.2 Comparação de Tempo de Execução
- 5. Discussão
- 6. Conclusão
 - 6.1 Trabalhos Futuros
- 7. Referências

▼ 1. Introdução

▼ 1.1 Problema e Hipótese

1.1.1 Problema de Pesquisa

1.1.2 Hipótese

▼ 1.2 Objetivos

1.2.1 Objetivo Geral

1.2.2 Objetivos Específicos

- ☐ Avaliar a **performance computacional** do algoritmo (real_collab) em diferentes ambientes de execução.
- ☐ Comparar a **eficácia preditiva** dos modelos **Random Forest** e **CART** aplicados ao desfecho clínico (EVOLUCAO).

▼ 1.3 Organização do Trabalho/ Estrutura do trabalho

- Explicar como foi dividido o trabalho em tópicos

Verificar

- ☐ Contextualização da SRAG e importância da análise preditiva.
- ☐ Relevância de algoritmos eficientes em tempo de execução e desempenho preditivo.

▼ 2. Revisão Bibliográfica

▼ 2.1 SRAG (Síndrome Respiratoria Aguda Grave)

- ☐ Conceito de análise preditiva na saúde.

▼ 2.2 Dados

2.2.1 Dados Abertos

2.2.2 Base de dados aberta de Síndrome Respiratória Aguda Grave

2.2.3 Mineração de Dados e KDD

2.2.3.1 Pré processamento de dados

Verificar

☐ colocar a parte de pre processamento, limpeza de dados, de acordo com o KDD?

☐ ja explica aqui mesmo O KDD ?

☐ Analise Exploratória dos dados ??? Para verificar o que tinha no dataset

▼ 2.3 Analise de Dados

▼ 2.4 Técnicas de Analise/ Aprendizado

▼ 2.5 Algoritmos

2.5.1 Cart

2.5.2 Random Forest

- Verificar:

☐ Técnicas de aprendizado supervisionado (Random Forest e CART).

▼ 2.6 Árvore de Decisão

2.6.1 Conceito e Funcionamento

▼ 2.7 Aprendizado de Maquina

▼ 2.8 Métricas de Avaliação Preditiva

- F1-Score, AUC, Accuracy, Precision, Recall
- Matriz de confusão

▼ 2.9 Eficiência Computacional

- Tempo de execução como métrica
- Discussão sobre ambiente, hardware e limitações práticas

Informações dos Computadores

- **Computador Geraldo**

Ryzen 1600x

8gb de ram

512 de SSD

SO: fedora 42

- **Cluster UFES**

Memória : 35 g

Processador : Intel(R) Xenon(R) CPU e5620 @ 2.40ghz

SO : opensuse-leap

Kernel : 5.14

- **Computador lasmin**

Processador : 12th Gen Intel(R) Core(TM) i5-1235U (1.30 GHz)

RAM instalada: 16,0 GB (utilizável: 15,7 GB)

Armazenamento: 477GB

Placa de video: 128MB

▼ 2.10 Trabalhos Relacionados

☐ Trabalhos que comparam modelos sob diferentes recursos computacionais.

▼ 3. Metodologia

▼ 3.1 DADOS

3.1.1 Análise Exploratória Inicial

☐ descrever o que continua no dataset e o que pudemos retirar disso;

Verificar:

- **Descrição da base de dados**
- Fonte: DataSUS (SRAG 2024), com ênfase na variável `EVOLUCAO`.
- Variável-alvo: **EVOLUCAO** (1 = Cura, 2 = Óbito).
- Features: fatores de risco (PUERPERA, CARDIOPATI, etc.).

▼ 3.2 Pré-processamento

- Limpeza, balanceamento, encoding e seleção de variáveis com base no dicionário de dados.
- Exclusão de valores ausentes.
- Mapeamento binário (`EVOLUCAO` → 0,1).
- Balanceamento com SMOTE.
- Divisão treino/teste (sem balanceamento no teste).

▼ 3.3 Ferramentas e Tecnologias

- Google Colab, Python, bibliotecas (Pandas, Scikit-learn, Matplotlib)
- Ambientes computacionais distintos: cluster UFES, PC Geraldo, PC lasmin
- Ambiente principal: Google Colab (execução em nuvem com suporte a GPU/TPU).
- Implementação em Python.
- Principais bibliotecas:
 - `Pandas` (manipulação de dados),
 - `Scikit-learn` (modelagem e avaliação),
 - `Matplotlib/Seaborn` (visualização),
 - `Imbalanced-learn` (SMOTE).
- Execução também realizada em:
 - PC Geraldo (Fedora, Ryzen 1600x, 8GB RAM),
 - PC lasmin (Windows, CPU moderna, 16GB RAM),
 - Cluster UFES (ambiente de alto desempenho).

Informações dos Computadores

• Computador Geraldo

Ryzen 1600x

8gb de ram

512 de SSD

SO: fedora 42

• Cluster UFES

Memória : 35 g

Processador : Intel(R) Xenon(R) CPU e5620 @ 2.40ghz

SO : opensuse-leap

Kernel : 5.14

• Computador lasmin

Processador : 12th Gen Intel(R) Core(TM) i5-1235U (1.30 GHz)

RAM instalada: 16,0 GB (utilizável: 15,7 GB)

Armazenamento: 477GB

Placa de video: 128MB

▼ 3.4 Implementação dos modelos

- `modelo_real_collab` como base para os dois modelos.
- Uso de pipeline com GridSearchCV.

- Execução em 3 máquinas com diferentes configurações.

▼ 3.5 Ambientes de Execução

- Descrever as diferentes máquinas utilizadas para rodar o `real_collab`, com specs:
 - Processador, memória RAM, tipo de armazenamento, sistema operacional.
 - Ex: Colab (cloud), PC pessoal (Windows/Linux), laboratório da universidade.

Informações dos Computadores

- **Computador Geraldo**

Ryzen 1600x

8gb de ram

512 de SSD

SO: fedora 42

- **Cluster UFES**

Memória : 35 g

Processador : Intel(R) Xenon(R) CPU e5620 @ 2.40ghz

SO : opensuse-leap

Kernel : 5.14

- **Computador lasmin**

Processador : 12th Gen Intel(R) Core(TM) i5-1235U (1.30 GHz)

RAM instalada: 16,0 GB (utilizável: 15,7 GB)

Armazenamento: 477GB

Placa de video: 128MB

▼ 3.6 Algoritmos Avaliados

- Explicação técnica dos modelos Random Forest e CART.
- Parâmetros utilizados em ambos.
- Métricas para avaliação: acurácia, precisão, recall, F1-score, AUC.

▼ 3.7 Avaliação de Desempenho Computacional

- Tempo de execução (treinamento e predição).
- Consumo de memória (se possível).
- Análise de gargalos e eficiência.

▼ 4. Resultados

▼ 4.1 Comparação dos Modelos Preditivos

4.1.1 Random Forest:

- F1-score teste: **0.522**
- AUC: **0.838**
- Melhor para recall da classe minoritária (óbito)

4.1.2 CART:

- F1-score teste: **0.496**
- AUC: **0.819**
- Mais simples e interpretável, mas menos eficaz na predição.

Modelo	F1-Score (Test)	AUC	Accuracy	Precision	Recall
CART	0.496	0.819	0.80	0.41	0.62
Random Forest	0.522	0.838	0.82	0.44	0.64

4.1.3 Síntese Comparativa: Random Forest vs CART [nao tenho certeza se vou deixar]

☐ Verificar

- Tabela com métricas (Random Forest vs CART).
- Matriz de confusão e AUC para ambos.
- Gráficos de importância das features.

▼ 4.2 Comparação de Tempo de Execução

- Tabela comparativa dos tempos (por máquina e modelo).
- Gráficos de barras/linha para visualização clara.



Máquina	Tempo Total	CART	RF
PC Geraldo	30.07 s	3.58 s	18.74 s
PC lasmin	129.82 s	26.44 s	91.67 s
Cluster UFES	82.32 s	11.30 s	56.76 s

Discussão:

- PC Geraldo, mesmo com hardware inferior, teve melhor desempenho geral.
- PC lasmin, com hardware moderno, foi mais lento (possivelmente devido ao SO e multitarefa).
- Cluster teve desempenho intermediário, mostrando que paralelismo nem sempre é vantajoso.

▼ Insights Resultados do Modelo

Arvore de Decisão



Análise Comparativa dos Modelos CART e Random Forest

Neste estudo, dois modelos de aprendizado supervisionado foram treinados para prever o desfecho clínico (**EVOLUCAO**) de pacientes com Síndrome Respiratória Aguda Grave (SRAG): **Decision Tree (CART)** e **Random Forest**. Ambos os modelos foram ajustados utilizando **validação cruzada** e **balanceamento de classes com SMOTE**, considerando a natureza desbalanceada dos dados (maior número de curados em relação aos óbitos).

◆ Modelo CART

O modelo CART foi ajustado com os melhores hiperparâmetros encontrados: `max_depth=5` , `min_samples_leaf=1` e `min_samples_split=2` . Seu desempenho nos dados de teste foi:

- **F1-Score (teste):** 0.50
- **Acurácia:** 80%
- **AUC ROC:** 0.82
- **Tempo de execução:** 10,38 segundos

A matriz de confusão (Figura 1) demonstra que o modelo foi capaz de prever corretamente **1010 casos de óbito** (classe minoritária), com um **recall de 62%** para essa classe, o que indica boa sensibilidade mesmo com simplicidade estrutural.

A árvore gerada (Figura 2) evidencia a lógica hierárquica das decisões. A primeira divisão ocorre pela variável `SUPPORT_VEN` , seguida por `NU_IDADE_N` (idade), `UTI` , `TOSSE` e comorbidades como `NEUROLOGIC` e `OUT_MORBI` . Isso confirma que pacientes que utilizaram ventilação invasiva, tinham idade avançada e comorbidades relevantes apresentaram maior probabilidade de óbito.

A análise de importância das variáveis (Figura 3) reforça esses achados, com `SUPPORT_VEN` e `NU_IDADE_N` representando juntos **94% da importância total do modelo**, seguidos por `TOSSE` , `UTI` e `OUT_MORBI` .

◆ Modelo Random Forest

O modelo Random Forest foi ajustado com `n_estimators=100` , `max_depth=7` , `min_samples_leaf=2` e `min_samples_split=5` . Seu desempenho superou levemente o CART:

- **F1-Score (teste):** 0.52
- **Acurácia:** 82%
- **AUC ROC:** 0.84
- **Tempo de execução:** 33,52 segundos

A matriz de confusão (Figura 1) mostra uma leve melhora na previsão da classe 1 (óbito), com **1036 acertos** e menos falsos negativos (589 vs. 615 do CART). Além disso, a **curva ROC** (Figura 4) evidencia superioridade da Random Forest em praticamente todas as faixas da taxa de falsos positivos, mantendo maior área sob a curva.

Interpretação Clínica e Técnica

A partir das análises gráficas e quantitativas:


- **SUPPORT_VEN** (uso de ventilação) e **NU_IDADE_N** (idade) são os principais fatores de risco associados à mortalidade por SRAG.
- Pacientes jovens, sem suporte ventilatório invasivo e que não passaram por UTI possuem altíssima probabilidade de cura.
- Já pacientes idosos, com comorbidades neurológicas, múltiplas morbidades (`OUT_MORBI`), internados em UTI e ventilados invasivamente compõem os grupos mais vulneráveis.

Conclusão Parcial

Embora o modelo Random Forest tenha apresentado desempenho levemente superior ao CART, o modelo de árvore de decisão tem a vantagem de **interpretabilidade direta**, útil para aplicações clínicas e explicações em contexto médico. Ambos os modelos se mostraram viáveis para uso preditivo, com potencial de auxiliar a triagem de pacientes com maior risco de óbito e otimizar recursos hospitalares em unidades do SUS.

Legendas para inserção no TCC:


- **Figura 1** – Matrizes de confusão comparando CART e Random Forest.
- **Figura 2** – Árvore de decisão gerada pelo modelo CART.
- **Figura 3** – Top 20 variáveis mais importantes para o modelo CART (%).
- **Figura 4** – Curva ROC comparativa entre CART e Random Forest.



▼ Interpretação dos Resultados - Computador

Interpretação Técnica

- **PC Geraldo** teve o melhor desempenho, mesmo com apenas 8GB de RAM e um Ryzen 1600x (CPU com boa performance por núcleo). Isso pode ser devido ao Fedora ser um SO leve e o código estar mais otimizado para uso local, com menor overhead de virtualização.
- **Cluster UFES**, apesar do hardware mais robusto em termos de memória, utilizou um **Xeon E5620**, que tem clock mais baixo e menor eficiência por núcleo. O tempo ainda foi bom, mas não foi o mais rápido.
- **PC Iasmin**, com um i5 de 12ª geração e 16GB RAM, teve o **pior tempo**, possivelmente por estar executando em um ambiente com mais processos paralelos em segundo plano (SO Windows ou virtualização via Jupyter/Colab local), além de throttling térmico ou economia de energia.



Aqui está o gráfico comparativo de tempo de execução do modelo `modelo_real_collab` em cada máquina. Ele mostra claramente que:

- O **PC Geraldo** teve a melhor performance geral.
- O **PC lasmin** teve o maior tempo total, especialmente no Random Forest.
- O **Cluster UFES** ficou com desempenho intermediário em todas as etapas.

Conclusão para o TCC

Os experimentos foram executados em três máquinas com configurações distintas, a fim de avaliar o impacto do ambiente computacional na eficiência de compilação do modelo. Curiosamente, o tempo total de execução mais rápido foi registrado no PC Geraldo, com 30 segundos, apesar de possuir apenas 8GB de RAM, demonstrando que fatores como sistema operacional e uso de recursos locais podem influenciar significativamente a performance computacional. O Cluster da UFES apresentou desempenho intermediário, enquanto o PC lasmin, embora com melhor especificação de memória e CPU, foi o mais lento, possivelmente devido a limitações de gerenciamento térmico, energia ou overhead do ambiente. Esse resultado reforça a importância de considerar o contexto computacional ao avaliar a viabilidade de aplicação de modelos preditivos em cenários clínicos reais.

Seção que podemos utilizar

Resultados, Discussão ou até Conclusão

1. Interpretação Técnica dos Resultados

- **Variação significativa nos tempos de execução:** O tempo total variou de **30 segundos a 2 minutos**, o que é considerável mesmo sendo o mesmo código e os mesmos dados.
- **PC Geraldo teve o melhor tempo**, apesar de ter especificações mais modestas. Isso pode ser explicado pelo uso do Fedora (SO leve e eficiente), ausência de virtualização e foco computacional exclusivo.
- **PC lasmin teve o pior desempenho**, mesmo com mais RAM e CPU moderna. A possível causa: throttling térmico, múltiplos processos simultâneos, modo de energia e overhead do sistema (provavelmente Windows).
- **O Cluster UFES ficou em segundo**, mas não superou o PC Geraldo, mostrando que nem sempre maior hardware implica melhor desempenho, principalmente com códigos que não paralelizam fortemente.

2. Impacto na Pesquisa / Relevância no TCC

- A eficiência de execução do modelo é importante se ele for aplicado em **ambientes clínicos reais**, como hospitais com diferentes níveis de infraestrutura computacional.
- O modelo se mostrou **viável para execução mesmo em máquinas com recursos limitados**, o que reforça sua aplicabilidade em cenários do SUS, por exemplo.
- A comparação mostra que **otimização do ambiente de execução é tão importante quanto o hardware**, o que pode abrir espaço para futuras investigações sobre deployment.

3. Sugestão de Trecho para o TCC II

Para avaliar a viabilidade computacional da aplicação do modelo preditivo desenvolvido, o notebook modelo_real_collab foi executado em três ambientes distintos: um computador pessoal com Fedora (PC Geraldo), o cluster institucional da UFES e um notebook pessoal com Windows (PC Iasmin). Curiosamente, o menor tempo de execução foi observado no PC Geraldo (30.07s), mesmo sendo a máquina com menor quantidade de RAM (8GB) e um processador mais antigo (Ryzen 1600x). O Cluster UFES apresentou tempo intermediário (82.32s), enquanto o PC Iasmin, com hardware mais recente, foi o mais lento (129.82s).

Esses resultados evidenciam que fatores como sistema operacional, overhead de processos paralelos e gerenciamento de energia/térmico influenciam diretamente a performance computacional. Isso reforça que, além do algoritmo, a **infraestrutura computacional e o ambiente de execução** devem ser considerados para garantir a aplicabilidade do modelo em contextos hospitalares reais.

A análise também sugere que **o modelo preditivo desenvolvido é leve e portátil**, com tempo de execução compatível com operações clínicas mesmo em dispositivos de médio porte, ampliando seu potencial de uso em sistemas de saúde pública com recursos computacionais limitados.

☐ mas talvez utilizar de uma forma mais visual e que um usuário leigo/ comum possa aproveitar da ferramenta;

☐ adicionar a essa seção a importância da máquina para análise de grandes dados faz a diferença no tempo de processamento e como isso afeta diretamente o resultado da compilação, o tempo, e o acesso *igualitário a informação/ acesso à informação no Brasil (precária) .

▼ 5. Discussão

- Qual máquina foi mais eficiente na execução do notebook?
- O desempenho dos modelos foi afetado pela máquina?
- Qual modelo preditivo teve melhor desempenho e por quê?
- Há trade-offs entre acurácia e interpretabilidade?
- Limitações no ambiente de execução e sugestões para análises futuras.
 - O RF teve melhor desempenho preditivo, especialmente no recall da classe minoritária (óbito), o que é crucial em saúde pública.
 - O CART oferece maior interpretabilidade e é computacionalmente mais leve.

- Em ambientes clínicos com restrição de hardware, ambos os modelos mostraram-se viáveis, com tempo de execução inferior a 2 minutos.
- A escolha entre CART e RF pode ser guiada pela necessidade de interpretação versus performance.

▼ 6. Conclusão

- Retomada dos objetivos.
- Real_collab se mostrou (mais/menos) eficiente em máquina X.
- Random Forest se destacou em métricas preditivas, enquanto CART apresentou melhor interpretabilidade.
- **eficiência computacional**
- Possibilidades de uso prático e recomendações futuras.
 - Ambos os modelos são eficazes na predição de desfechos clínicos em SRAG.
 - Random Forest é mais robusto em desempenho, mas o CART pode ser preferido onde simplicidade e agilidade são exigidas.
 - O estudo evidencia que a configuração do ambiente computacional impacta significativamente o desempenho, sendo um fator relevante para futuras implementações práticas no SUS ou em unidades hospitalares de baixa infraestrutura.

▼ 6.1 Trabalhos Futuros

▼ 7. Referências

Tips

<https://www.instagram.com/reel/DK3EdjoREaa/?igsh=cW43bmJyemc0OWNu>

Tabela x Quadro

Finalidade

TABELA
Caráter Quantitativo.

QUADRO
Caráter Qualitativo.

Design

TABELA

Número de documentos	Total
Artigos	20
Livros	7
Trabalhos em eventos	15
Total	42

QUADRO

Cores	Classificação
Amarelo	Cor primária.
Verde	Cor secundária.
Amarelo-esverdeado	Cor terciária.

Características principais

TABELA

Representar dados numéricos;
Não apresenta bordas laterais.

QUADRO

Representar dados textuais;
Apresenta bordas laterais.


Importante:

Nas tabelas e quadros é necessário referenciar a fonte utilizada, de outros documentos ou resultados da própria pesquisa.

PORTAL

UFPR

SiBi



Links

Algoritmo CART

<https://www.minitab.com/pt-br/solutions/analytics/statistical-analysis-predictive-analytics/cart/>

Trabalhos referências

- Bases

✓ Jadsmita

✓ Wesley

✓ Vinicius

[JADSMILA__PG2.pdf](#)

[TCC.ViniciusChavesNascimento_Corrigido_Final.pdf](#)

[dissertacao_wallace.pdf](#)

Informações sobre os PCs

- **Computador Geraldo**

Ryzen 1600x

8gb de ram

512 de SSD

SO: fedora 42

- **Cluster UFES**

Memória : 35 g

Processador : Intel(R) Xenon(R) CPU e5620 @ 2.40ghz

SO : opensuse-leap

Kernel : 5.14

- **Computador lasmin**

Processador : 12th Gen Intel(R) Core(TM) i5-1235U (1.30 GHz)

RAM instalada: 16,0 GB (utilizável: 15,7 GB)

Armazenamento: 477GB

Placa de video: 128MB

Arquivos Para analisar

[modelo_analise_variaveis.ipynb](#)

[modelo_real_cart.ipynb](#)

[modelo_real_collab.ipynb](#)

[modelo_real_random.ipynb](#)

[notas_cart.txt](#)

[notas_real_collab.txt](#)

[notas_real_random.txt](#)

[notas_variaveis.txt](#)

Motivos de escolher o modelo_real_collab

- ☐ Resultados semelhantes e o código centralizado em um so lugar
- ☐ apenas a AUC foi melhor no modelo separado, mas em comparação estatística foi insignificante a mudança;

Colab	Algoritmos	Test F1	AUC	Teste samples
modelo_real_cart	CART	0.4912	0.8251	11.107
modelo_real_random	Random Forest	0.5211	0.8448	11.107
modelo_real_collab	CART + RF	0.4958 (CART) / 0.5218 (RF)	0.8185 / 0.8383	10.352

Você pode mencionar na seção de "Resultados" ou "Discussão" algo como:

"Embora o modelo Random Forest isolado tenha obtido ligeiramente maior AUC (0.8448 vs 0.8383), optou-se pelo uso do modelo implementado no notebook unificado, pois apresenta organização superior e facilidade para comparação entre algoritmos no mesmo pipeline, sem comprometer significativamente a performance."

- Código atualizado

[modelo_real_collab.ipynb](#)