



Inteligência artificial em processos de extração de conhecimento KDD e KDT

Thoughts on artificial intelligence in KDD and KDT knowledge extraction processes

Inteligencia artificial en procesos de extracción de conocimiento KDD y KDT

Luís Roberto Albano Bueno da Silva – Uniso | Sorocaba | SP | Brasil | E-mail: luiz.silva@prof.uniso.br | Orcid: <https://orcid.org/0000-0002-9021-5720>

Resumo: Este artigo apresenta processos de extração de conhecimento em banco de dados e textos (KDD e KDT) e a técnica de sua aplicação que utiliza inteligência artificial e redes neurais. Destaca também possíveis impactos em concepções sobre inteligência artificial fraca (existente) e forte (ainda não existente) nos processos de extração de conhecimento e apresenta reflexões acerca dos mesmos e dos impactos científico e social de pesquisas de transição de um modelo para o outro. Entre os resultados, destaca-se que as tecnologias de inteligência artificial forte precisam ser protagonizadas para uma melhor utilização das ferramentas de extração de conhecimento, bem como a educação sobre inteligência artificial deve ser promovida entre pesquisadores a fim de mitigar problemas atualmente percebidos.

Palavras-chave: Inteligência artificial. Extração de conhecimento. Dados. Informação.

Abstract: This paper aims to present the processes related to extraction of knowledge in databases and in texts (KDD and KDT) and the technique applied involving artificial intelligence and neural networks. It also highlights possible impacts involving concepts from weak artificial intelligence (real) and strong A.I. (not yet real) in the processes of knowledge extraction and presents reflections about these same processes and the scientific and social impacts of research about transitioning from one model to the other. Among its results, we highlight that technologies of artificial intelligence need to become protagonists for a better use of knowledge extraction tools, as well as education about artificial intelligence must be promoted among researchers in order to mitigate currently perceived problems.

Keywords: Artificial intelligence. Knowledge extraction. Data. Information.

Resumen: Este artículo presenta los procesos de extracción de conocimiento en bases de datos y textos (*KDD* y *KDT*) y la técnica de aplicación que utiliza inteligencia artificial y redes neuronales. También destaca los posibles impactos en las concepciones sobre inteligencia artificial débil (existente) y fuerte (aún no existente) en los procesos de extracción de conocimiento y presenta reflexiones sobre ellos y los impactos científicos y sociales de las transiciones de investigación de un modelo a otro. Entre los resultados, cabe destacar que las tecnologías de inteligencia artificial fuertes deben ser protagonistas para un mejor uso de las herramientas de extracción de conocimiento, así como la educación sobre inteligencia artificial debe promoverse entre los investigadores para mitigar los problemas actualmente percibidos.

Palabras clave: Inteligencia artificial. Extracción de conocimiento. Datos. Información.

• Recebido em 17 de out. de 2019 • Aprovado em 08 de nov. 2019 • e-issn: 2177-5788
DOI: <https://doi.org/10.22484/2177-5788.2020v46n1p161-180>

Copyright © 2020. Conteúdo de acesso aberto, distribuído sob os termos da Licença Internaonal da CreativeCommons – CC BY-NC-SA – Atribuição Não Comercial – Permite distribuição e reprodução, desde que atribuam os devidos créditos à publicação, ao(s) autor(es) e que licenciem as novas criações sob termos idênticos.



1 Introdução e metodologia

A extração de conhecimento de banco de dados e textos, *Knowledge Discovery in Databases* – KDD (Extração de Conhecimento de Base de Dados) e *Knowledge Discovery in Texts* – KDT (Extração de Conhecimento em Textos), respectivamente, é uma das formas de revisão bibliográfica e documental mais utilizadas quando da análise de grande volume de dados e informações dentro das humanidades digitais. O conhecimento do seu processo de trabalho, bem como das ferramentas utilizadas para este fim – e seu potencial – dão liberdade para o usuário/pesquisador produzir conhecimento de forma a não se agarrar a metodologias equivocadas ou banhadas em senso comum. Assim, o presente trabalho visa apresentar duas ferramentas de análise informacional de extração de conhecimento amplamente utilizadas em humanidades digitais: extração de conhecimento em banco de dados e extração de conhecimento em textos. A apresentação destas ferramentas busca identificar suas características funcionais e introduzir alguns conceitos técnicos básicos para fins de esclarecimento. Além disso, apresentação desses conceitos básicos, explicita-se o conceito de redes neurais artificiais, método de aprendizagem de máquina/inteligência artificial utilizadas em softwares de extração de conhecimento, importantes para o entendimento do dimensionamento potencial das ferramentas de processamento de dados e informações. Em paralelo a essa explanação, são introduzidos as concepções de inteligência artificial fraca e forte, a fim de posteriormente promover uma reflexão acerca do impacto de ambas dentro do âmbito da extração de conhecimento nas humanidades digitais.

Para tanto, elaborou-se uma revisão bibliográfica sobre extração de conhecimento com base em Ambrósio e Moraes (2007); sobre inteligência artificial com Coppin (2012), Artero (2009) e Russell e Norvig (2004) e, para redes neurais usamos Braga, Ludermir e Carvalho (2000). Em seguida, apresentamos as reflexões sobre as Inteligências Artificiais (IAs).



2 O que é extração de conhecimento e sua metodologia (KDD e KDT)?

Extração de conhecimento é a forma pela qual – através de um algoritmo que utiliza algum padrão de inteligência – dados extraídos de bancos de dados, textos ou outras mídias são tratados e apresentados como informação a fim de gerar conhecimento e promover solução de problemas.

Segundo Ambrósio e Moraes (2007, p. 2):

Descobrir conhecimento significa identificar, receber informações relevantes, e poder processá-las e agregá-las ao conhecimento prévio de seu usuário, mudando o estado de seu conhecimento atual, a fim de que determinada situação ou problema possa ser resolvido. Neste sentido, observa-se que a o processo de descoberta de conhecimento está fortemente relacionado à forma pela qual a informação é processada.

Os dados para descoberta podem ou não estar estruturados de modo a ser processados em software como esta finalidade. Cada caso impacta no método escolhido e no processo aplicado, possibilitando mais ou menos intervenção durante o processo. Independentemente do método escolhido, os dados trabalhados passam por uma série de processos que visam apresentar ao final informações relativas ao contexto do que se pesquisa. Importante frisar que o processo de extração de conhecimento apresenta as informações de forma estrutural, demandando de outras aplicações caso necessite de uma apresentação gráfica. Também, importante ressaltar, que o processamento de dados em informações não é algo completamente consolidado e apresenta algumas falhas potenciais – futuramente apresentadas no âmbito das humanidades digitais.

Pode-se, em teoria, aplicar ferramentas de software para a extração de conhecimento em qualquer tipo de documento (desde que o documento seja adaptado para esse fim). Dada a incapacidade de esgotar todas as possibilidades de extração de conhecimento documental



existentes, este trabalho foca apenas nas extrações de bancos de dados estruturados e textos.

Normalmente a descoberta de conhecimento em dados estruturados é chamada *KDD* (*Knowledge Discovery in Databases*) e a descoberta em dados não estruturados - normalmente em textos -, é chamada de *KDT* (*Knowledge Discovery from Text*). Ambas têm processos específicos de trabalho, dependentes do modo como os dados estão organizados.

No *KDD* os dados estão organizados em um banco de dados, armazenados de modo a possibilitar a identificação de relacionamentos entre palavras ou conjunto de palavras. Nesse sentido, como se trata de busca em banco de dados, os dados não necessariamente estão armazenados em forma de texto, por vezes organizados em tabulações, listas ou tuplas. As relações existentes são normalmente comparativas, onde pode ser identificado o aparecimento de determinados dados em determinados conjuntos em um determinado número de vezes. Normalmente os processos *KDD* utilizam ferramentas de mineração de dados para a extração, específicas para bancos de dados organizados de forma estruturada. Extração de conhecimento em banco de dados utiliza ferramentas estatísticas e matemáticas, necessitando que os dados crus sejam limpos e organizados para um melhor processamento.

Processos *KDD* possuem, geralmente, quatro fases: identificação do problema, preparação dos dados, mineração de dados e pós-processamento. O quadro que segue – Quadro 1 - explicita cada fase e as ações tomadas em cada uma.



Quadro 1 – Processo KDD

Identificação do Problema	Preparação dos Dados	Mineração de Dados	Pós Processamento
Nesta fase, são identificados os objetivos e metas do processo de extração de conhecimento do banco de dados, bem como os termos, palavras ou atributos de entrada no processo de mineração; São elencados os melhores conjuntos de dados possíveis para extração, quais modelos de processamento dos dados serão utilizados para atingir o objetivo, os critérios de entrada de dados para o algoritmo de mineração e qual o possível impacto qualitativo e quantitativo na fase de pós processamento; Esta fase é crucial pois ela define os dados de entrada do método de mineração. Dados de entrada não tão bem selecionados podem gerar informações não tão interessantes de saída.	Após a identificação do conjunto de dados a ser utilizado, estes são coletados e armazenados em um conjunto de dados único; Estes dados extraídos são adequados (convertidos e transformados) para o tipo de software de mineração. Uma boa adequação aos padrões de marcação, quando aplicados, podem facilitar essa fase (XML); Os dados são limpos, excluindo-se termos com erros de digitação, valores de atributos inválidos e termos fora do padrão (CamelCase, XML etc.); Após sua limpeza, os dados são reduzidos por meio de amostragem estatística estabelecendo o modelo de dados a ser utilizado no processo de mineração.	A mineração de dados utiliza ferramentas da estatística, redes neurais, inteligência artificial, visualização de dados, entre outras áreas de forma a compilar a partir dos objetivos traçados e elencados os dados buscados e organizá-los de forma a transformá-los em informação passível de compreensão, uso e crescimento do conhecimento; Uma vez que o algoritmo de mineração deve ser desenvolvido de forma específica para o tipo de apresentação de informação, é essencial que na fase da identificação do problema ele seja escolhido de forma correta. Uma saída é a analogia de dados similares, ou ainda, desenvolvimento de software de mineração específico para o trabalho.	Nessa fase os dados estruturados são apresentados e é verificada a qualidade dos mesmos no que tange sua qualidade como informação e amplificador de conhecimento para o que foi buscado; Neste processo é escolhido o melhor modo de apresentação do minerado, bem como a análise posterior do apresentado; Caso os dados processados não sejam interessantes, é possível realizar novo processo alterando as bases de preparação e mineração, a fim de atingir de forma mais interessante o objetivo inicial.

Fonte: Elaborado pelo autor (2019)



Já a extração de conhecimento de textos é o processo de construir a informação e utilizá-la a partir de dados não estruturados em textos, considerando não somente o levantamento quantitativo de palavras, mas também associação de palavras, semântica, contexto dentro de uma base de linguagem natural.

As principais contribuições desta área estão relacionadas à busca de informações específicas em documentos, à análise qualitativa e quantitativa de grandes volumes de textos, e à melhor compreensão de textos disponíveis em documentos. Textos estes que podem estar representados das mais diversas formas, dentre elas: e-mails; arquivos em diferentes formatos (pdf, doc, txt, por exemplo); páginas Web; campos textuais em bancos de dados; textos eletrônicos digitalizados a partir de papéis. (AMBRÓSIO; MORAIS, 2007, p. 6).

A extração de da informação e conhecimento de um texto, considerando a tentativa de lidar com a linguagem natural (mais próxima da humana), faz uso de uma grande quantidade de tecnologias, além de depender de processos de organização dos dados coletados e seu preparo. Para tanto, utiliza de ferramentas de inteligência artificial e *machine learning*, como redes neurais artificiais. Processos *KDT* possuem normalmente sete fases: seleção dos textos, análise, preparação dos dados, indexação e normalização, cálculo de relevância, seleção dos termos e análise. No processo *KDT*, a preparação dos dados pode ser feita de forma manual ou automática. Normalmente nos primeiros usos do software - ou primeiras iterações -, esta fase que envolve a seleção dos tipos de dados a ser pesquisados é feita por anotação no texto ou seleção manual. Após treino da rede neural, espera-se que o software já seja capaz de identificar automaticamente alguns padrões interessantes, baseados no anteriormente pesquisado. Apesar de parecer um processo de automação prático, pode apresentar algumas falhas como posteriormente será apresentado. O quadro que segue - Quadro 2 - explicita cada fase e as ações tomadas em cada fase de um processo *KDT*.



Quadro 2 – Processo KDT

Seleção dos Textos	Análise Estatística	Análise Semântica	Preparação dos Dados
Nesta etapa são escolhidos os textos base nos quais será feita a prospecção a partir de palavras ou conjuntos de palavras-chave; A seleção dos textos é feita através de levantamento de corpus que constitua um grupo significativo de objetos para o objetivo de busca, independentemente da temática dos textos; Textos em PDF, Word ou outros processadores de texto devem ser considerados no desenvolvimento do software de extração, bem como API (Application Programming Interface) de sites que se intenta realizar as buscas;	A análise estatística utiliza métodos da matemática e da estatística para definir não frequência de palavras e termos em um texto, bem como sua posição e momento em cada recorte de texto selecionado; Um meio comum de trabalhar com o método estatístico é tratar os textos como um bag of words, considerando que as palavras e termos apresentados desenharão um mapa de frequências textuais razoáveis que representem o texto.	A análise semântica baseia-se na funcionalidade dos termos encontrados nos textos, analisando-os com base em técnicas de linguagem natural; A análise semântica leva em conta a importância das palavras no texto de acordo com sua morfologia, sintaxe, semântica, bem como sua relação com a cultura e história do texto escrito, a análise do discurso em nível de posição do termo no texto e o contexto em que este foi escrito. Nesse sentido, o algoritmo analisará o texto comparando-o com outros textos similares para identificar termos e palavras potenciais para serem analisadas.	"A preparação dos dados é a primeira etapa do processo de descoberta de conhecimento em textos. Envolve a seleção dos dados que constituem a base de textos de interesse e o trabalho inicial para tentar selecionar o núcleo que melhor expressa o conteúdo destes textos. Além de prover uma redução dimensional, o objetivo desta etapa é tentar identificar similaridades em função da morfologia ou do significado dos termos nos textos" (MORAIS; AMBRÓSIO, 2005, p. 9); A partir de um modelo desenvolvido para tal, os textos são analisados comparando-se a necessidade das informações do usuário e as análises feitas a partir do modelo de abordagem selecionado (estatístico ou semântico). A inserção das necessidades pode ser feita através de anotações textuais ou ainda seleção de TAGS geradas nas análises anteriores.
Indexação e Normalização	Cálculo de relevância	Seleção dos Termos	Análise dos Resultados
Os dados são limpos, excluindo-se termos com erros de digitação, valores de atributos inválidos	A partir de índice criado, são verificadas repetições de padrões de	Nessa etapa são selecionados os termos obtidos e(ou) pesquisados de forma a prover condições para	Nesta fase o algoritmo KDT utiliza ferramentas de análise estatística e semântica para identificar as relações possíveis entre textos e termos



e termos fora do padrão (CamelCase, XML etc.); Após sua limpeza, os dados são reduzidos por meio de amostragem estatística estabelecendo o modelo de dados a ser utilizado no cálculo de relevância; Este modelo gera um índice que é utilizado no cálculo de relevância. Estes processos se dão utilizando redes neurais artificiais (IA fraca).	ordenamento e uso, bem como repetições de estilo e uso; Os termos assim são classificados dos mais importantes (com maior frequência) para os menos importantes (com menor frequência). Estes processos se dão utilizando redes neurais artificiais (IA fraca).	uma análise textual de forma relevante; Esta análise pode ser feita de forma estatística ou semântica, considerando novamente a abordagem selecionada; Seleções por peso dos termos mais relevantes é o método mais utilizado por ser mais simples. Algoritmos que consideram a linguagem natural são mais complexos, pois, mesmo atrelado a fases anteriores, demanda de aprendizagem de máquina e codificação mais complexa, considerando que seu peso não reside apenas na ocorrência da palavra, mas sim na sua importância para os textos em contexto analisados.	e apresentar as relações entre os pontos treinados ou observados com mais destaque; Dependendo o algoritmo e do software utilizado, abordagens gráficas de visualização de informação se fazem necessários, dado do grande volume de informações produzido. Estes processos se dão utilizando redes neurais artificiais (IA fraca).
---	--	--	--

Fonte: Elaborado pelo autor (2019)

3 IA forte, IA fraca e redes neurais

A definição de inteligência artificial é algo bastante complexo, tendo em vista que esta depende da definição do que é inteligência. Inteligência, em linhas gerais, pode ser definida como a capacidade de um sistema, orgânico ou sintético, agir de modo “aparentemente” inteligente, sendo capaz de tomar decisões, armazenar informações, aprender, entre outras funções. Este “aparentar inteligência” normalmente é oriundo de



comparação com outros sistemas que entendemos como inteligentes, como animais ou o próprio ser humano, que exercem o livre-arbítrio em tomada de decisões, a partir da análise de determinadas situações em que se encontram. A capacidade de inteligência de sistemas orgânicos e naturais se dá pelo processo evolutivo, onde a seleção natural descarta os sistemas fisiologicamente não preparados e seleciona aqueles capazes de responder a certas condições ambientais, privilegiando sistemas capazes de responder a intempéries da natureza. Obviamente, a seleção natural não se fixa apenas nos processos cognitivos; em especial no *homo sapiens sapiens* – que é normalmente a base de comparação para o desenvolvimento de inteligências artificiais – seu polegar opositor e configuração do encéfalo garantiram uma posição de privilégio frente a outras espécies.

Coppin (2012, p. 4) esclarece que a “Inteligência Artificial envolve utilizar métodos baseados no comportamento inteligente de humanos e outros animais para solucionar problemas complexos”. Ampliando essa definição, Artero (2009, p. 19) explica que:

De imediato se observa que as definições de IA seguem na mesma linha que as definições para a IN, simplesmente, adaptando-se para o computador e, em resumo, sugerem que a IA é o estudo de como fazer os computadores realizarem tarefas que, no momento, as pessoas fazem melhor, o que inclui a capacidade de adquirir e aplicar conhecimentos aprendidos.

Russell e Norvig (2004) apresentam definições além daquelas comparativas com as funções animais ou humanas. Isso se dá, pois, o estudo da inteligência artificial é muito amplo, envolvendo múltiplas ciências. Dada sua complexidade, por vezes, estes modelos não encontram um ponto de interseção teórico, devido suas bases epistemológicas.



Como se poderia esperar, existe uma tensão entre abordagens centradas em torno de seres humanos e abordagens centradas em torno da racionalidade. Uma abordagem centrada nos seres humanos deve ser uma ciência empírica, envolvendo hipóteses e confirmação experimental. Uma abordagem racionalista envolve uma combinação de matemática e engenharia. (RUSSELL; NORVIG, 2004, p. 4).

Desse modo, Russell e Norvig (2004) dividem a definição de inteligência artificial em quatro campos: (I) sistemas que pensam como seres humanos, (II) sistemas que pensam racionalmente, (III) sistemas que atuam como seres humanos, (IV) sistemas que atuam racionalmente. O quadro a seguir - Quadro 3 - explicita algumas definições de inteligência artificial nesse sentido, que podem nos ajudar a compor uma definição mais abrangente.

Quadro 3 – Algumas definições de inteligência artificial, organizadas em quatro categorias

Sistemas que pensam como seres humanos	Sistemas que pensam racionalmente
O novo e interessante esforço para fazer os computadores pensarem... máquinas com mentes, no sentido total e literal.	O estudo das faculdades mentais pelo uso de modelos computacionais.
[Automatização de] atividades que associamos ao pensamento humano, atividades como a tomada de decisões, a resolução de problemas, o aprendizado...	O estudo das computações que tornam possível perceber, raciocinar e agir.
Sistemas que atuam como seres humanos	Sistemas que atuam racionalmente
A arte de criar máquinas que executam funções que exigem inteligência quando executadas por pessoas.	A Inteligência Computacional é o estudo do projeto de agentes inteligentes.

Fonte: Russell e Norvig (2004, p. 5)



Assim, podemos definir inteligência artificial como a capacidade de um sistema sintético – projetado utilizando-se de conhecimentos das ciências da computação e cognitivas –, de agir de forma inteligente, resolvendo problemas, quando comparado com sistemas inteligentes naturais orgânicos, moldados por meio da seleção natural. Essa definição abrange parte significativa das possibilidades da inteligência artificial, dando conta de uma série de aplicações, atendendo uma série de problemas em que automações são necessárias. É importante, no entanto, indicar que as inteligências artificiais hoje existentes são sistemas especialistas, ou seja, sistemas projetados para uma determinada finalidade. A capacidade de um sistema inteligente agir de forma *stricto sensu* como um ser orgânico é hipotética, dividindo inclusive a inteligência artificial em dois campos de estudo: a inteligência artificial fraca e a inteligência artificial forte. A inteligência artificial fraca desenvolve sistemas especialistas, utilizando das teorias cognitivas e da ciência da computação para prover automações mais bem definidas, em que um algoritmo tradicional programado seria muito complexo ou inviável de execução por métodos normais. Por outro lado, a inteligência artificial forte é uma inteligência artificial hipotética, capaz de realizar todas as operações passíveis que um humano ou animal fosse capaz de operacionalizar. Artero (2009) nos indica que outra distinção entre IA forte e a IA fraca está no fato da capacidade de uma delas ter consciência de seus atos e ações.

No primeiro caso, acredita-se que as máquinas serão realmente capazes de pensar como uma pessoa, apresentando todas as características de consciência que os humanos possuem, enquanto o segundo grupo acredita apenas na possibilidade das máquinas simularem o comportamento humano, porém, sem a real consciência de suas ações. (ARTERO, 2009, p. 16).

Uma saída para identificar se uma IA é fraca ou forte foi definida por Alan Turing (1912-1954), considerado o pai da ciência da computação. Turing foi responsável por grande expansão teórica dos alicerces da ciência da computação, em especial na modelagem computacional de



dados, provendo grande arcabouço teórico para o desenvolvimento computacional moderno. Turing sugeriu um teste, que posteriormente ficaria conhecido como “teste de Turing” onde, através de um sistema fechado, seria impossível distinguir entre um sistema automático e um ser humano.

O teste de Turing, proposto por Alan Turing (1950), foi projetado para fornecer uma definição operacional satisfatória de inteligência. Em vez de propor uma lista longa e talvez controversa de qualificações exigidas para inteligência, ele sugeriu um teste baseado na impossibilidade de distinguir entre entidades inegavelmente inteligentes - os seres humanos. O computador passará no teste se um interrogador humano, depois de propor algumas perguntas por escrito, não conseguir descobrir se as respostas escritas vêm de uma pessoa ou não. (RUSSEL; NORVIG, 2004, p. 4).

O objetivo do teste era fazer com que uma pessoa conversasse com um computador e com um ser humano ao mesmo tempo, todos isolados entre si. A pessoa julgadora deveria então, após a conversa – que pode ser apenas casual ou troca de perguntas e respostas –, definir quem é o computador com inteligência e quem é a pessoa. Se isso não fosse possível, diz-se que o computador ou máquina passou no teste. Pelo fato de que inteligências artificiais fortes são apenas hipotéticas, nenhum dispositivo até hoje passou no teste.

O teste de Turing é importante, pois além de ser uma ferramenta para identificação de IAs fortes, nos dá parâmetros para o desenvolvimento de sistemas potencialmente mais fortes. Muitos autores consideram a IA forte uma impossibilidade, tendo em vista que ainda não somos capazes de definir de forma acertada o processamento mental, humano ou animal, base para o desenvolvimento das IA. No entanto, a compreensão de como obter inteligências artificiais mais fortes, especialmente no que tange sua interface com o ser humano em sistemas interativos e de controle, nos ajuda a criar sistemas especialistas melhores e com melhor entendimento das nuances humanas. Nesse sentido, a busca por inteligências artificiais mais fortes redimensiona as



possibilidades de uso de sistemas inteligentes, que tem se tornado *players* de destaque em dispositivos digitais, virtuais e físicos.

Aplicações comuns de inteligências artificiais variam desde um simples algoritmo de busca de um provedor de pesquisa até o sistema de movimentação e navegação de um veículo autônomo. Normalmente, utiliza-se inteligência artificial em sistemas que um algoritmo programável se torna inviável ou oneroso, dada a complexidade do algoritmo inteligente. Além disso, sistemas inteligentes utilizam métodos matemáticos e estatísticos para tomada de decisões e controle, sendo capazes de aprender e melhorar seu desempenho, dada sua arquitetura construtiva. No entanto, importante ressaltar, que esse processo de aprendizado reside mais em um processo de adaptação do que aprendizado per si. Aprender, de forma mais estrita, seria algo característico de uma IA forte, mais do que de uma IA fraca. No entanto, por se assemelhar ao entendimento do aprendizado tradicional, diz-se que IA fracas também podem “aprender”.

Nesse contexto, um dos sistemas mais utilizados em ferramentas de extração de conhecimento para aprendizado e adaptação de bancos de dados e textos em processo de filtro, organização e limpeza são as redes neurais, em especial redes neurais de aprendizagem por reforço.

Redes neurais artificiais baseiam-se no modelo biológico neuronal, desenvolvido por McCulloch e Pitts, na década de 1940. Trata-se de um modelo de neurônio matemático baseado no sistema orgânico, que gerou outros modelos de neurônios utilizados em redes neurais atualmente. Sua configuração é de grande importância para os sistemas de inteligência artificial com aprendizado, pois a analogia aos sistemas orgânicos possibilitou não somente um rápido desenvolvimento de tecnologias de tomada de decisão, como também redimensionou as bases teóricas matemáticas para o desenvolvimento de redes neurais artificiais supervisionadas, de fácil treinamento e utilizadas em sistemas de extração de conhecimento.



Redes supervisionadas são um tipo particular de rede neural que é treinada através de um agente externo, chamado professor. A função do professor é adequar os pesos de uma rede neural, bem como o peso do *bias* – uma entrada específica do neurônio que recebe valor 1, para não ocorrer problemas no cálculo de funcionamento do neurônio – a fim de que esta, após treino, seja capaz de apresentar um conjunto de valores de saída esperado em um determinado tipo de aplicação, normalmente reconhecimento de padrões ou ainda classificação de elementos, passíveis de aplicação em automações ou outros sistemas inteligentes.

O objetivo é ajustar os parâmetros da rede, de forma a encontrar uma ligação entre os pares de entrada e saída fornecidos. [...] O professor indica explicitamente um comportamento bom ou ruim para a rede, visando a direcionar o processo de treinamento. A rede tem sua saída corrente (calculada) comparada com a saída desejada, recebendo informações do supervisor sobre o erro da resposta atual. A cada padrão de entrada submetido à rede compara-se a resposta desejada (que representa uma ação ótima para ser realizada pela rede) com a resposta calculada, ajustando-se os pesos das conexões para minimizar o erro. A minimização da diferença é incremental, já que pequenos ajustes são feitos nos pesos a cada etapa de treinamento, de tal forma que estes caminhem – se houver solução possível – para uma solução. (BRAGA; LUDERMIR; CARVALHO, 2000, p. 16).

Em especial, redes neurais artificiais de aprendizado por reforço possuem um processo de treinamento análogo ao da aprendizagem em seres humanos, via repetição e reforço, pois a medida de desempenho do sistema é baseada não no que se espera numericamente da saída da rede, mas sim, se as saídas estão corretas ou não: ou seja, o parâmetro para verificar se uma rede neural com aprendizado por reforço é a tentativa e erro. Isto equivale a ideia de que se uma determinada ação repetida for satisfatória, ela deverá ser reforçada para ser aprendida.

Minsky (1961) esclarece que este sistema de aprendizagem, conforme visto anteriormente, requer um agente crítico, capaz de avaliar se os padrões de entrada e saída estão, dentro da aplicação, atendendo ao que foi solicitado, indicando uma resposta positiva ou negativa para a composição de pesos do sistema.



Para que a aprendizagem ocorra, o agente crítico observa o ambiente em que o sistema de aprendizagem por reforço está e recebe dele um valor, para cada ação esperada da rede neural. Se um valor for maior, entende-se que este possui um grau de satisfação maior na relação rede/espaco, fazendo com que o algoritmo de ajuste dos pesos não atue tanto nos terminais dos nodos, criando uma condição em que aquela situação possa ser repetida. A determinação da resposta do crítico se dá pelo sinal de reforço, que é um valor que indica que se a rede está atuando de maneira correta ou não. O sinal de reforço em uma rede neural de aprendizagem por reforço pode ser um mapeamento das combinações de entrada e saída verificados e calculados, ou ainda, apenas a saída da rede neural. Conforme a rede neural passa por treinamento, em cada interação (ciclo de aprendizagem) o crítico verifica o sinal de reforço, recebe um valor de satisfação e indica, via algoritmo de treinamento, um reajuste dos pesos dos terminais dos nodos, a fim de criar uma condição na rede que, para cada situação apresentada, esta possa ser generalizada para todas as possibilidades aplicáveis, ou seja, que seu sistema de configuração de pesos internos atenda, para todas as variações possíveis de entrada, todas as condições desejadas. Isso não necessariamente ocorre quando nuances muito específicas se apresentam, demandando do pesquisador/usuário atenção com os dados/informação produzidos.

4 Possíveis contribuições da IA forte na extração de conhecimento para as humanidades digitais

Até o momento percebe-se que as informações produzidas pelas metodologias previamente explicitadas se estruturam a partir de dados coletados e organizados, oriundos de algoritmo previamente estabelecido. Isto impacta em duas questões interessantes para reflexão: (1) as informações produzidas estão limitadas pelo algoritmo de processamento de dados e, (2) considerando o paradigma da inteligência artificial fraca, as informações produzidas não são efetivamente apresentadas como



conhecimento, ficando a cabo do usuário estabelecer relações entre as mesmas para a finalização e completude de sua análise. Cabe salientar que os impactos das arquiteturas de software não se limitam a essas questões, porém para as humanidades digitais estas se tornam explicitamente mais interessantes.

No que tange as limitações relativas à arquitetura do software de processamento dos dados em informação, reside o peso de sua estrutura encapsular e aplicar problemas oriundos das próprias linguagens de programação ou entendimento de como cada processo deve ser executado. Na busca de filtrar e reduzir o grande volume de dados normalmente observado e tratado quando das humanidades digitais, o desenvolvedor do software pode não perceber determinadas idiosincrasias de grupos específicos de dados e involuntariamente excluí-los do processo de análise. A percepção de determinados padrões de filtragem e limpeza segue regras pré-estabelecidas como boas práticas de processamento de dados, porém pode não levar em conta nuances muito específicas de grupos muito ímpares, seja no que se refere ao processo de linguagem natural ou ainda à padrões sociais e organizacionais que, dependendo da amplitude e frequência, podem ser considerados ruídos e não dados interessantes para a composição das informações. Além disso, o relacionamento de determinados bancos de dados ou documentações inicialmente e aparentemente não relacionados, mas com potencial informacional em combinação podem ser tratados como itens não elegíveis de integração, diminuindo o *range* de possíveis paridades comuns nas ciências humanas entre pacotes de sinais heterogêneos.

Sistemas de extração de conhecimento em texto, em especial, são muito dependentes das primeiras iterações de análises de dados para a determinação de seu comportamento geral em processamento. Sistemas de extração de conhecimento em texto podem utilizar como ferramenta de seleção de termos, normalização ou cálculo de relevância redes neurais simples de aprendizagem por reforço, onde o cálculo dos pesos de cada nodo acaba se ajustando ao tipo de documento ou texto utilizado, em



especial no que tange a forma e não necessariamente ao conteúdo, fazendo com que este se torne – de forma involuntária – especialista em determinado tipo de linguagem.

Nesse sentido, a incapacidade de sistemas de inteligência artificial fraca de processar linguagem natural de forma genuína faz com que certas nuances ou conotações textuais possam passar despercebidas. Como observado anteriormente, sistemas de inteligência artificial são utilizados quando o desenvolvimento de um software para análise de dados se torna muito complexo devido ao modelo de processamento que se demanda; nesse sentido, redes neurais ou qualquer outro sistema de inteligência artificial aplicado à textos acaba se tornando especialista ou disfuncional, pois as denotações estatísticas possíveis fogem das possibilidades não apenas de escrita, mas das nuances flexíveis das mesmas. É importante que isso seja frisado pois a inteligência artificial – mesmo dentro de meio acadêmico ou profissional –, sofre de grande distorção de possibilidades de aplicação oriunda do entretenimento ou ainda do senso comum do ferramental.

Essa visão distorcida, por assim dizer, pode nublar muitas vezes as reais saídas explicitadas em uma análise de conhecimento, fazendo com que o pesquisador ou usuário acredite estar observando conhecimento, quando de fato observa dados organizados ou por vezes informações em níveis iniciais. A apresentação de dados de sistemas que utilizam inteligência artificial forte não faz juízo de valor, conforme visto anteriormente. São apenas organização de dados limpos e arranjados conforme um padrão pré-estabelecido que se refinam a cada iteração de utilização do software. Assim, possíveis relações de dados ou informações podem levar a falácias de falsa-simetria ou falsa-relação caso os dados não sejam observados e analisados de forma correta.

Além disso, pode-se dizer que *Big Data* gera *Big Information*. Uma grande quantidade de informações precisa novamente ser estruturada a fim de ser tratada como conhecimento e ser utilizada de forma adequada na manutenção de pesquisa ou sociedade.



Nesse contexto, a inteligência artificial forte, dentro das demandas das humanidades digitais, poderia auxiliar nestes processos pois (1) não residiria em uma arquitetura de software fixa, sendo capaz de não apenas se adaptar aos textos e bancos utilizados mas compreender de fato os pesos dos materiais analisados e (2) poderia prover informações inicialmente organizadas em conhecimento contextualizado, sendo capaz de verificar dentro das nuances textuais e de necessidade de pesquisa o que poder-se-ia extrair de forma mais acurada, dado o grande volume de informação gerado no contexto da extração.

De fato, algo que contribui para o aprimoramento de pesquisas que utilizam grandes volumes de informação são as ferramentas de visualização da informação. A apresentação da informação em gráficos (dinâmicos ou estáticos) facilita muito a observação de relações explícitas ou implícitas de informações quando extraídas, porém, dado o contexto do pesquisador/usuários, parte significativa de relações pode ser involuntariamente ignorada, algo que pode de fato ser apontado por uma inteligência artificial forte, ampliadora da capacidade de visão e compreensão de cenários. Além disso, o fato de não depender de uma arquitetura única de aprendizagem mitiga as chances de recursividade ou ainda limitação de visualização do contexto dos dados, potencializando o uso deste tipo de ferramental para uma grande amplitude de fatos, bem como a observação de relações entre dados e informações aparentemente sem ligação.

O conhecimento gerado por uma IA forte em um sistema de extração de conhecimento faria com que, *de facto*, este tipo de sistema promovesse o debate em torno de conhecimento produzido e não apenas sobre informações geradas. O potencial deste tipo de aplicação ingressa inclusive na possibilidade da geração do novo, ou seja, da pesquisa científica em si. Pesquisas que relacionam grande volume de informações oriundas de extensas revisões bibliográficas poderiam ser desenvolvidas de forma não apenas mais rápida, mas observando ligações entre conjuntos de informações que poderiam ser consideradas alicerçantes



para pesquisas futuras, promovendo o desenvolvimento científico de forma mais exponencial.

5 Considerações finais

O desenvolvimento das tecnologias de inteligência artificial deveria caminhar para o desenvolvimento de sistemas mais fortes no que tange o processamento de sinais e informações a fim de produzir conhecimento de forma mais integrada e aplicada às necessidades técnicas e sociais. Não se espera, contudo, em curto espaço de tempo, o desenvolvimento de uma inteligência artificial forte *stricto sensu*. Sabe-se muito pouco do modo como o processamento mental humano ocorre, referencial para o desenvolvimento de uma cognição artificial paralela à humana. Nesse sentido, considerando os benefícios possíveis da aplicação de IAs fortes no processo de extração de conhecimento, esforços no sentido de revisar os métodos técnicos que são utilizados atualmente se fazem necessários, visando tecnologias o mais próximo das IAs fortes quanto o possível. Viu-se que os sistemas atualmente utilizados podem causar condições desfavoráveis para resultados de pesquisa, desvalidando produtos científicos/técnicos/sociais com impacto de mudança efetiva. Nunca anteriormente na história da ciência presenciou-se um arcabouço possível tão grande de dados e informações disponíveis e melhorar o modo como os mesmos são tratados se torna essencial. Pode-se considerar que o tratamento de grande conjunto de dados gera um grande conjunto de informações com potencial para uma grande produção de conhecimento; no entanto, para tal, a leitura e tratamento correto desse grande volume é essencial para não incorrer em entendimentos disfuncionais ou falaciosos de dados e informações. Para o atual momento, a fim de evitar esse tipo de “efeito colateral”, cabe ao pesquisador ou profissional se atualizar quanto ao potencial dos ferramentais utilizados para não ficar à serviço de um entendimento baseado em senso comum e não em técnica; em outras palavras, compreender as limitações dos aplicativos e softwares que parecem realizar ações inteligentes que, além de ter limitações, podem



incorrer em erros que devem ser estudados e compreendidos, a fim de melhorar seu potencial uso, facilitar a escolha de sua aplicabilidade e produzir ferramentas melhores e mais fortes para o futuro.

Referências

AMBRÓSIO, Ana Paula; MORAIS, Edison. **Mineração de textos**. Goiás: Instituto de informática Universidade Federal de Goiás, 2007.

ARTERO, Almir Olivette. **Inteligência artificial**: teórica e prática. São Paulo: Livraria da Física, 2009.

BRAGA, Antônio; LUDERMIR, Teresa; CARVALHO, André. **Redes neurais artificiais**: teorias e aplicações. Rio de Janeiro: LTC, 2000.

COPPIN, Ben. **Inteligência artificial**. Rio de Janeiro: LTC, 2012.

MINSKY, Marvin. Steps towards artificial intelligence. **Proc. of the Institute of Radio Engineers**, n. 49, p. 8-32, 1961. Disponível em:

<https://courses.csail.mit.edu/> HYPERLINK

["https://courses.csail.mit.edu/6.803/pdf/steps.pdf"](https://courses.csail.mit.edu/6.803/pdf/steps.pdf) HYPERLINK

["https://courses.csail.mit.edu/6.803/pdf/steps.pdf"](https://courses.csail.mit.edu/6.803/pdf/steps.pdf) HYPERLINK

["https://courses.csail.mit.edu/6.803/pdf/steps.pdf"](https://courses.csail.mit.edu/6.803/pdf/steps.pdf)6.803 HYPERLINK

["https://courses.csail.mit.edu/6.803/pdf/steps.pdf"](https://courses.csail.mit.edu/6.803/pdf/steps.pdf) HYPERLINK

["https://courses.csail.mit.edu/6.803/pdf/steps.pdf"](https://courses.csail.mit.edu/6.803/pdf/steps.pdf)HYPERLINK

["https://courses.csail.mit.edu/6.803/pdf/steps.pdf"](https://courses.csail.mit.edu/6.803/pdf/steps.pdf) HYPERLINK

["https://courses.csail.mit.edu/6.803/pdf/steps.pdf"/pdf/steps.pdf](https://courses.csail.mit.edu/6.803/pdf/steps.pdf/pdf/steps.pdf). Acesso em: 16 dez. 2019.

RUSSELL, Stuart; NORVIG, Peter. **Inteligência artificial**. Rio de Janeiro: Campus, 2004.