

UNIVERSIDADE FEDERAL DO ESPÍRITO SANTO (UFES)
CENTRO UNIVERSITÁRIO NORTE DO ESPÍRITO SANTO (CEUNES)
DEPARTAMENTO DE COMPUTAÇÃO E ELETRÔNICA (DCEL)
BACHARELADO EM CIÊNCIA DA COMPUTAÇÃO

VINÍCIUS CHAVES NASCIMENTO

ANÁLISE DE DESEMPENHO DE FUTEBOLISTAS DA *ENGLISH PREMIER LEAGUE*
2020/2021

SÃO MATEUS, ES
2022

VINÍCIUS CHAVES NASCIMENTO

ANÁLISE DE DESEMPENHO DE FUTEBOLISTAS DA *ENGLISH PREMIER LEAGUE*
2020/2021

Trabalho apresentado à disciplina de Trabalho de Conclusão de Curso II como requisito parcial à obtenção do grau de Bacharel em Ciência da Computação.

Orientadora: Prof.^a Dra. Silvia das Dores Rissino.

SÃO MATEUS, ES
2022

VINÍCIUS CHAVES NASCIMENTO

ANÁLISE DE DESEMPENHO DE FUTEBOLISTAS DA *ENGLISH PREMIER LEAGUE*
2020/2021

Trabalho apresentado à disciplina de Trabalho de Conclusão de Curso II como requisito parcial à obtenção do grau de Bacharel em Ciência da Computação.

BANCA EXAMINADORA

Prof.^a Dra. Silvia das Dores Rissino
Dpto. de Computação e Eletrônica / UFES

Prof.^a Dra. Luciana Lee
Dpto. de Computação e Eletrônica / UFES

Prof. Dr. Oberlan Christo Romão
Dpto. de Computação e Eletrônica / UFES

SÃO MATEUS, ES
2022

Dedico este trabalho ao meu avô Heráclito Nascimento, que motivou todos ao seu redor com uma vida inspiradora de trabalho, fé e humanidade.

AGRADECIMENTOS

Agradeço a Deus por não me deixar desistir diante das dificuldades encontradas e por me proporcionar saúde para concluir esta jornada tão importante em minha vida. Agradeço aos meus professores e professoras que compartilharam seu valioso conhecimento comigo e transformaram a minha percepção do mundo com seus exemplos inspiradores. Agradeço à minha família que me deu sustentação para sonhar e lutar pelos meus sonhos. Agradeço à minha noiva que esteve comigo em todos os momentos desta caminhada vivendo os bons e maus momentos e seguindo em frente. Agradeço à minha orientadora, a Prof.^a Dra. Silvia das Dores Rissino, que me orientou, me incentivou e me ensinou, sendo uma pessoa fundamental para que este trabalho pudesse existir.

*"The best way to predict the future is to
invent it."*

(Alan Kay)

RESUMO

O aumento considerável da quantidade de dados gerada diariamente nos últimos anos tem motivado clubes de futebol a investirem em análise estatística para obter vantagem competitiva e otimizar processos através da utilização de técnicas de Análise de Dados conhecidas e no desenvolvimento de novas técnicas no âmbito da Ciência de Dados. Este projeto visa analisar o desempenho de meio-campistas que atuaram na *English Premier League* 2020/21. Para realizar a análise, dados de fundamentos técnicos dos meio-campistas que atuaram em pelo menos 16 partidas do campeonato, foram selecionados e pré-processados. Finalmente, são aplicadas técnicas para comparar, agrupar e classificar o nível de proficiência de futebolistas em determinadas características de acordo com o seu comportamento em campo refletido nos dados analisados. A análise e a classificação de futebolistas possibilita construir uma base sólida, que pode ser específica, mas é possível ser aplicada em diferentes situações que envolvam a seleção e a contratação de atletas por clubes de futebol, de modo a otimizar tais processos.

Palavras-chave: Futebol, Ciência de Dados, Pré-processamento, Análise Descritiva, Correlação, Classificação, Agrupamento, Discretização, Análise de Desempenho.

ABSTRACT

The considerable increase in the amount of data generated daily in recent years has motivated football clubs to invest in statistical analysis to obtain competitive advantage and optimize processes through the use of known Data Analysis techniques and the development of new techniques in the field of Data Science. This project aims to analyze the performance of midfielders who played in the English Premier League 2020/21. To carry out the analysis, technical fundamentals data from midfielders who played in at least 16 league matches were selected and pre-processed. Finally, techniques are applied to compare, cluster and classify the proficiency level of soccer players in certain characteristics according to their behavior on the field reflected in the analyzed data. The analysis and classification of footballers makes it possible to build a solid basis, which can be specific, but can be applied in different situations involving the selection and hiring of athletes by football clubs, in order to optimize such processes.

Keywords: Football, Data Science, Pre-processing, Descriptive Analysis, Correlation, Covariance, Classification, Grouping, Discretization, Performance Analysis.

LISTA DE FIGURAS

Figura 1 – <i>Boxplot</i> da característica Presença.....	34
Figura 2 – Histograma discreto da característica Presença.....	35
Figura 3 – <i>Boxplot</i> da característica Criatividade.....	35
Figura 4 – Histograma discreto da característica Criatividade.....	36
Figura 5 – <i>Boxplot</i> da característica Distribuição Quantitativa.....	37
Figura 6 – Histograma discreto da característica Distribuição Quantitativa.....	37
Figura 7 – <i>Boxplot</i> da característica Distribuição Qualitativa.....	38
Figura 8 – Histograma discreto da característica Distribuição Qualitativa.....	38
Figura 9 – <i>Boxplot</i> da característica Finalização.....	39
Figura 10 – Histograma discreto da característica Finalização.....	39
Figura 11 – <i>Boxplot</i> da característica Combatividade.....	40
Figura 12 – Histograma discreto da característica Combatividade.....	41
Figura 13 – <i>Heatmap</i> de correlação entre variáveis.....	42
Figura 14 – Gráfico de pontos: <i>DistribuiçãoQuant</i> x <i>DistribuicaoQuali</i>	42

LISTA DE QUADROS

Quadro 1 – Relação entre características, perfis e fundamentos.....	20
Quadro 2 – Informações gerais das planilhas obtidas.....	28
Quadro 3 – Variáveis levantadas após a primeira etapa de pré-processamento....	29
Quadro 4 – Novas variáveis geradas na etapa de pré-processamento.....	30
Quadro 5 – Pontos de corte e fronteira.....	32
Quadro 6 – Colunas geradas para representar características.....	33

LISTA DE TABELAS

Tabela 1 – Meio-campistas com nível 5 em Criatividade.....	36
Tabela 2 – Meio-campistas que obtiveram nível 5 em Finalização.....	40
Tabela 3 – Exemplo de resultado de busca por meio-campistas.....	43
Tabela 4 – Ranking de meio-campistas considerando o somatório dos níveis.....	44

SUMÁRIO

1. INTRODUÇÃO	13
1.1. PROBLEMA E HIPÓTESE	14
1.2.1. Problema de Pesquisa	14
1.2.2. Hipótese	14
1.2. OBJETIVOS	15
1.2.1. Objetivo Geral	15
1.2.2. Objetivos Específicos	15
1.3. ESTRUTURA DO TRABALHO	15
2. REFERENCIAL TEÓRICO	17
2.1. FUTEBOL	17
2.1.1. Meio-campista	17
2.1.2. Fundamentos	18
2.1.3. Perfis	20
2.1.4. Características	20
2.2. ANÁLISE DE DADOS	21
2.2.1. Pré-processamento	21
2.2.2. Discretização ou Data Binning	22
2.2.3. Jenks Natural Breaks	23
2.3. TRABALHOS RELACIONADOS	23
3. METODOLOGIA	25
3.1. MATERIAIS	25
3.2. MÉTODOS	26
3.2.1. Revisão Bibliográfica	26
3.2.2. Escolha da Base de Dados	27
3.2.3. Ambiente de Dados	28
3.2.4. Pré-processamento	28
3.2.5. Análise de Dados	31
4. RESULTADOS	34
4.1. PRESENÇA	34
4.2. CRIATIVIDADE	35
4.3. DISTRIBUIÇÃO QUANTITATIVA	36
4.4. DISTRIBUIÇÃO QUALITATIVA	37
4.5. FINALIZAÇÃO	38
4.6. COMBATIVIDADE	40
4.7. CORRELAÇÃO ENTRE CARACTERÍSTICAS	41
4.8. BUSCAS NOS RESULTADOS	43

5. CONCLUSÕES	44
REFERÊNCIAS BIBLIOGRÁFICAS	45
APÊNDICE A – COLUNAS DE DADOS – VARIÁVEIS	47

1. INTRODUÇÃO

O futebol é o esporte mais popular do mundo (SHVILI, 2020) com uma enorme quantidade de agremiações, praticantes e fãs, movimentando, anualmente, bilhões de dólares em investimentos, contratações, marketing, fornecimento de material, direitos de transmissão e vendas de ingressos e produtos licenciados. Além disso, o esporte tem importância social significativa ao oferecer caminhos e alternativas para jovens de periferias e atuar, através dos clubes, de maneira transformadora nas comunidades carentes.

Há uma crescente e perceptível necessidade de agremiações construírem bases financeiras sólidas para chegarem e se manterem no topo, participando de grandes competições, que oferecem visibilidade comercial e esportiva aos clubes. Por outro lado, as contratações de futebolistas se tornam, a cada temporada, mais custosas em termos de multas, salários e do valor propriamente dito das transações.

Desta forma, torna-se necessário que cada contratação seja analisada de maneira profissional, avaliando a qualidade técnica, o conhecimento e a percepção tática, o condicionamento físico, a mentalidade e o comportamento dos futebolistas, para evitar grandes prejuízos comerciais e esportivos. Também é importante conhecer o perfil do profissional contratado e avaliar o encaixe dele na equipe.

Esses fatores têm influenciado clubes a investirem em equipes de olheiros que analisam previamente o perfil e as características dos futebolistas e procuram jovens talentos para serem desenvolvidos nas categorias de base das agremiações. Grande parte deste processo de análise ocorre através da observação de treinos e jogos, entretanto, profissionais com perfil voltado para Análise de Dados vêm emergindo e ganhando espaço em grandes clubes, como o Manchester United, que recentemente nomeou John Murtough para o cargo de Diretor de Futebol (FAY, 2021).

Outro clube que investiu em tecnologia e análise no setor de recrutamento foi o Liverpool, que utilizou da Ciência de Dados para definir contratações e colheu frutos ao construir um dos times mais competitivos e vitoriosos dos últimos anos (ORTEGA, 2020).

A Ciência de Dados pode contribuir com esse processo ao adicionar dados factuais de desempenho processados e correlacionados para classificação e geração de perfis de futebolistas. A análise de dados associada à observação dos olheiros pode produzir um resultado final mais completo e eficiente e contribuir para tomadas de decisões mais certas (SIEGHARTSLEITNER *et al.*, 2019).

Neste projeto, a aplicação da Análise de Dados é proposta e realizada, como estudo de caso, na avaliação do desempenho técnico dos futebolistas meio-campistas que atuaram na *English Premier League*, na temporada 2020/21.

1.1. PROBLEMA E HIPÓTESE

1.2.1. Problema de Pesquisa

Os clubes de futebol precisam ser cada vez mais assertivos na observação contratação de futebolistas, para aumentar a sua competitividade no mercado, obter melhores resultados em campo e diminuir a possibilidade de erros que podem causar prejuízos indesejados. Como é possível otimizar este processo e realizar contratações cada vez mais objetivas baseado no desempenho histórico e atual apresentado pelos futebolistas em campo?

1.2.2. Hipótese

Através da utilização da Ciência de Dados para fundamentar a análise de desempenho dos futebolistas em dados factuais processados, comparados e exibidos de modo a gerar informações que auxiliem os observadores a realizarem análises mais completas e eficientes.

1.2. OBJETIVOS

1.2.1. Objetivo Geral

Analisar e classificar o desempenho de meio-campistas que atuaram na *English Premier League* 2020/21.

1.2.2. Objetivos Específicos

- Realizar levantamento bibliográfico de estudos relacionados.
- Identificar técnicas de Análise de Dados e suas aplicações ao futebol.
- Obter dados de desempenho de meio-campistas que atuaram na *Premier League* 2020/21.
- Realizar processamento dos dados de desempenho de meio-campistas que atuaram na *Premier League* 2020/21.
- Consolidar características de futebolistas através da composição de fundamentos.
- Utilizar da discretização de dados para classificar o nível de proficiência de futebolistas em determinadas características.

1.3. ESTRUTURA DO TRABALHO

Este documento está dividido em tópicos, compondo uma estrutura organizada para proporcionar ao leitor uma melhor compreensão do assunto abordado e do trabalho realizado.

No Referencial Teórico, o Futebol é abordado com destaque à posição de meio-campista e aos fundamentos, perfis e características considerados na análise dos dados. A seção Análise de Dados aborda as técnicas de análise estudadas e utilizadas para classificar os meio-campistas. Trabalhos Relacionados são elucidados de modo a apresentar o contexto atual da análise de dados aplicada ao futebol.

Na Metodologia, os materiais utilizados são listados e os métodos são apresentados em ordem cronológica de realização, considerando desde o estudo bibliográfico até a aplicação da discretização.

Os Resultados são então discutidos e apresentados no capítulo seguinte, sintetizados em gráficos e tabelas, para melhorar o processo de interpretação e auxiliar a compreensão por parte do leitor.

Na Conclusão, é realizada uma reflexão sobre os resultados obtidos e sua fidelidade aos objetivos propostos, como forma de avaliar o percurso. Trabalhos futuros também são considerados, os quais poderiam colher frutos deste projeto para produzir novos artefatos importantes.

2. REFERENCIAL TEÓRICO

2.1. FUTEBOL

O futebol é um esporte coletivo disputado por duas equipes de 11 jogadores (JOY *et al.*, 2020) em jogos de 90 minutos de duração, divididos em duas partes de 45 minutos. Ao final de cada parte, acréscimos são adicionados e, ao final do tempo total, pode haver prorrogação em caso de empate, dependendo do regulamento da competição (IFAB, 2020).

O principal objetivo deste esporte, conhecido como gol, é fazer com que a bola atravesse a baliza adversária no espaço entre as duas traves e o travessão. Para isso, os futebolistas devem conduzir ou passar a bola entre os companheiros de equipe, utilizando quaisquer partes do corpo que não sejam as mãos e os braços. Os únicos jogadores que possuem permissão para tocar na bola com as mãos e braços são os goleiros e só podem fazê-lo na região que corresponde à área de pênalti. Ao final de cada jogo, a equipe que tiver marcado mais gols é a vencedora (JOY *et al.*, 2020; IFAB, 2020).

O futebol atualmente é mantido e organizado a nível global pela FIFA (Fédération Internationale de Football Association). Entretanto, existem federações continentais e nacionais, através das quais os clubes organizam competições, como por exemplo, a *English Premier League* (objeto de estudo nesta pesquisa), que é a primeira divisão do futebol inglês, da qual participam, a cada temporada, 20 clubes de futebol.

2.1.1. Meio-campista

A Bundesliga (2020), liga que representa a primeira divisão do futebol alemão, relata o meio-campista como um atleta que atua principalmente na região central do campo de futebol, protegendo as zonas defensivas e contribuindo para a criação de jogadas ofensivas a partir do passe, e de progressões com a posse de bola.

Trata-se de uma das posições mais importantes do esporte, exercendo um papel crucial no comportamento geral da equipe e no controle do jogo.

A posição de meio-campista pode ser subdividida em em três funções mais específicas de acordo com as características do jogador (BUNDESLIGA, 2020):

- Meio-campista defensivo: atua em uma região mais recuada, protegendo as zonas defensivas e iniciando as jogadas ofensivas. Podem ter um perfil mais combativo, no sentido de desarmar o adversário, ou um perfil mais criativo, ditando o ritmo do jogo através da distribuição de passes.
- Meio-campista central: atua em uma região central contribuindo para a defesa e para o ataque de modo semelhante.
- Meio-campista ofensivo: atua em uma região mais avançada, contribuindo principalmente para a criação e definição de jogadas ofensivas, através de passes, dribles, infiltrações e finalizações.

O futebol inglês é conhecido por formar meio-campistas do tipo *box-to-box*, que são futebolistas que atuam produzindo uma alta taxa de trabalho dentro de campo, percorrendo grandes distâncias, pressionando a saída de bola adversária, acelerando a criação de jogadas ofensivas, cobrindo espaços e finalizando. De forma geral, são jogadores que possuem nível semelhante de desempenho tanto em situações defensivas, quanto defensivas. Neste contexto, o *box-to-box* se encaixa na posição de meio-campista central, considerando o seu nível de contribuição semelhante para a defesa e para o ataque.

Pela alta contribuição para o funcionamento do time, pela variedade de funções que o meio-campista cumpre em campo e pela quantidade de características que esses futebolistas podem ter, esta posição foi considerada para a realização deste estudo.

2.1.2. Fundamentos

A análise do desempenho técnico de um futebolista consiste, em primeiro momento, na avaliação da sua execução dos fundamentos do futebol.

Desse modo, ao analisar atuações de meio-campistas, convém considerar os fundamentos inerentes às suas funções dentro do jogo. A seguir, será realizada uma breve definição dos fundamentos que serão levados em consideração na análise do desempenho técnico dos futebolistas que será realizada nesta pesquisa:

- Desarmes: consiste na desposseção do jogador adversário que controla a bola.
- Interceptações: consiste em impedir que a bola seja recebida por um jogador adversário após a realização de um passe.
- Duelos: consiste em lutar pela posse de bola quando ela não está sob controle de nenhuma das equipes.
- Gols: consiste em atravessar a baliza adversária na região entre as duas traves e o travessão.
- Criação de Grande Chances: consiste em passar a bola para outro jogador da mesma equipe em condições de marcar.
- Assistências: consiste em passar a bola para outro jogador da mesma equipe em condições de marcar e este conseguir, efetivamente, aproveitar a oportunidade e marcar o gol.
- Finalizações: consiste na tentativa de marcação de um gol através de um chute, cabeceio ou qualquer golpe à bola que não seja realizado com os braços ou com as mãos.
- Dribles: consiste em conduzir a bola mantendo-a em posse ao mesmo tempo em que passa por um jogador adversário.
- Passes: consiste em enviar a bola para outro jogador da mesma equipe.
- Passes-chave: ocorrem quando o passe realizado contribui de forma direta para a construção de uma jogada ofensiva, atravessando as linhas defensivas adversárias e possibilitando que a equipe ganhe território, isto é, se aproxime mais da baliza adversária.
- Cruzamentos: ocorrem quando o passe é realizado da região lateral do campo para a região central, em direção à área de pênalti adversária.

Esses fundamentos serão utilizados na análise realizada nesta pesquisa, sendo úteis tanto na avaliação do desempenho quanto na classificação de perfis de futebolista de acordo com os seus desempenhos nos fundamentos.

2.1.3. Perfis

Na construção dos perfis de meio-campistas serão levados em consideração tanto o posicionamento específico do jogador em campo, quanto o seu desempenho técnico refletido na acurácia dos seus fundamentos. Inicialmente, serão considerados os seguintes perfis, levando em consideração análise de Carey (2020):

- Defensivo: meio-campista que se destaca em fundamentos defensivos, como desarmes e intercepções.
- Controlador: meio-campista que faz a distribuição das jogadas com alta taxa de passes e lançamentos.
- Criativo: meio-campista que gera chances reais de gol para os seus companheiros através de passes-chave e assistências.
- Finalizador: meio-campista que se movimenta para ocupar espaços e finalizar jogadas, quando há oportunidade.

2.1.4. Características

Cada perfil citado na seção anterior corresponde a um futebolista com determinada característica. Um futebolista com determinada característica, possui boa proficiência em um conjunto de fundamentos.

O Quadro 1 relaciona cada característica com o perfil e o conjunto de fundamentos que a representam, de modo que cada característica esteja relacionada ao bom desempenho em um conjunto de fundamentos.

Quadro 1. Relação entre características, perfis e fundamentos.

Característica	Perfil	Fundamentos
Combatividade	Defensivo	Desarmes, Intercepções e Duelos
Distribuição	Controlador	Passes e Cruzamentos
Criatividade	Criativo	Passes-chave e Assistências
Finalização	Finalizador	Gols

Tais características serão levadas em consideração para classificar os meio-campistas de acordo com o seu desempenho em cada uma delas. Dos fundamentos listados, variáveis serão consideradas para avaliá-los de forma quantitativa e qualitativa.

Também há uma característica que não está diretamente relacionada a um ou mais fundamentos técnicos, que leva em consideração a quantidade de minutos que um futebolista esteve em campo. Inicialmente, avaliou-se considerar tal característica como Disponibilidade. Entretanto, foi considerada a existência de fatores que fazem que, mesmo disponível, um futebolista não entre em campo, como por exemplo, escolha do treinador e rotatividade de elenco. Desta forma, tal característica será chamada apenas de Presença, avaliando única e exclusivamente a quantidade de minutos em que os futebolistas estiveram presentes em campo no decorrer do campeonato e sendo utilizada para normalizar as outras características por tempo de jogo.

2.2. ANÁLISE DE DADOS

A Análise de Dados é o processo que consiste na obtenção, limpeza, transformação e modelagem de dados de modo a gerar informações que possam auxiliar em tomadas de decisões importantes. Este processo inclui a etapa de pré-processamento e aplicação de técnicas de análise.

2.2.1. Pré-processamento

Após a obtenção dos dados, a primeira etapa a ser realizada é a de Pré-processamento, que consiste em preparar os dados para análise, organizando-os e estruturando-os.

Nesta etapa, é fundamental realizar a escolha correta dos tipos de dados, excluir dados que não serão considerados na análise e realizar as devidas normalizações. O processo de normalização é importante para garantir que a avaliação dos dados seja justa e consistente dentro do contexto considerado.

Na avaliação dos dados de futebolistas em um campeonato, por exemplo, é preciso considerar que um meio-campista que esteve presente em campo por mais tempo naturalmente terá um número maior de execuções de fundamentos do que um que pouco atuou. Neste contexto, é importante aplicar a normalização para considerar a quantidade de execuções por tempo de jogo.

O processo de pré-processamento também inclui a geração de novas colunas de dados a partir das anteriores e a extração de metadados através de técnicas como a Contagem de Termos e o Cálculo de Frequência.

2.2.2. Discretização ou Data Binning

O processo de discretização consiste na aplicação de métodos para transformar dados, modelos e variáveis contínuas em valores, partes, categorias ou compartimentos discretos de modo que haja um número limitado de possíveis estados (MICROSOFT, 2021), o que pode contribuir para uma interpretação mais clara e concisa do conjunto de dados.

É amplamente utilizado na matemática e na computação, sendo uma das tarefas de pré-processamento mais influentes na mineração de dados e na descoberta de conhecimento, pois colabora para uma representação concisa do conjunto de dados em categorias que colaboram efetivamente para a extração de informações, que não seria possível em dados contínuos (RAMÍREZ-GALLEGO *et al.*, 2015).

Em geral, a discretização envolve três passos:

1. Analisar o conjunto de valores contínuos de uma variável ou coluna.
2. Dividir o conjunto em segmentos.
3. Agrupar os valores segmentados em compartimentos (*bins*) ou categorias.

A divisão do conjunto de valores leva em consideração os pontos de corte (*breaks*) que determinam de qual segmento cada valor fará parte. A escolha dos pontos de corte é fundamental para uma discretização consistente, pois ao escolher pontos que não refletem o conjunto, muita informação pode ser perdida. Encontrar os melhores pontos de corte é um dos desafios do processo de discretização.

2.2.3. Jenks Natural Breaks

O método conhecido como *Jenks Optimization Method* ou *Jenks Natural Breaks Classification Method*, ou ainda *Jenks Natural Breaks Optimization* foi desenvolvido e proposto em 1967 por George Frederick Jenks, cartógrafo americano Ph.D. em Geografia Agrícola pela *Syracuse University*.

Este método busca encontrar os melhores pontos de corte para a discretização de um conjunto de dados em classes. Os pontos de corte naturais implicam em grupos, classes ou categorias de dados mais coerentes, de modo que valores parecidos sejam agrupados em uma classe e valores distintos em classes diferentes (JENKS, 1967).

Matematicamente, o método busca minimizar o desvio padrão de cada classe em relação à sua média, à medida que maximiza o desvio padrão de cada classe em relação às médias das outras classes (JENKS, 1967). Ou seja, o método minimiza a variação entre os valores de uma mesma classe enquanto maximiza a variação entre as classes.

Deste modo, é possível agrupar os valores de forma natural no processo de discretização e classificação, de modo a formar classes consistentes e minimizar perdas de informações.

2.3. TRABALHOS RELACIONADOS

Nos últimos anos, a quantidade de dados de futebol disponíveis para análise tem crescido substancialmente. De cada jogo, time e jogador, dados são coletados, organizados e armazenados para análise posterior (CINTIA; RINZIVILLO; PAPPALARDO, 2015). Este fator tem motivado agremiações a investirem em análise estatística de modo a obter vantagem competitiva com a utilização das informações e da capacidade de armazenamento e processamento disponíveis.

Por outro lado, tem crescido na academia uma motivação crescente de produzir pesquisas neste sentido (THAKKAR; SHAH, 2021).

Diversas análises foram realizadas nos últimos anos para avaliar jogadores, times e clubes de futebol no sentido técnico, tático, financeiro e organizacional.

No campo do desempenho técnico, é importante citar a análise quantitativa de ações de goleiros de futebol realizada por Berto e Magalhães (2015), que relacionou a utilização de fundamentos específicos da posição com situações de jogo e concluiu que um goleiro precisa possuir boa acurácia em todos eles.

Na análise tática, diversas pesquisas se destacam ao levar em consideração o comportamento ofensivo geral do time em campo (CASTELÃO *et al.*, 2015), a relação da posse de bola e a eficácia dos processos ofensivos (SILVA *et al.*, 2015).

Também são muito importantes as análises de futebolistas nas categorias de base relacionando seu comportamento tático com suas faixas etárias (AMÉRICO *et al.*, 2016), data de nascimento (ANDRADE; COSTA, 2015) e com situações específicas de jogo, como a eventual superioridade numérica (PRAÇA *et al.*, 2016).

Outros estudos realizados, se aprofundam no campo organizacional, e produzem contribuições importantes para o crescimento, a proteção e a longevidade das agremiações esportivas. Neste sentido, destaca-se o estudo de Koehler e Marcus (2017), que propõe uma rede de clubes de base para fortalecer o processo de retenção de jovens talentos, principalmente em agremiações de menor expressão e situação financeira menos favorecida.

Estes e tantos outros estudos têm contribuído para o fortalecimento do futebol e suas contribuições para a sociedade.

3. METODOLOGIA

O desenvolvimento deste projeto constituiu-se na realização de uma pesquisa exploratória, quantitativa e qualitativa, com base nos procedimentos técnicos abordados por Gil (2008), para analisar o desempenho de futebolistas meio-campistas que atuaram na *English Premier League* 2020/21 a partir de técnicas de aquisição, pré-processamento e análise de dados.

A análise dos dados realizada foi de natureza descritiva (BUSH, 2020), pois envolveu o processo de observar os acontecimentos em campo, relativos a cada futebolista envolvido na análise, refletidos nos dados factuais selecionados e analisá-los de modo a classificar o nível de proficiência de cada um deles em determinadas características.

3.1. MATERIAIS

Dentre os materiais utilizados, destaca-se o conjunto de dados obtido e selecionado para a pesquisa. Os dados foram representados no formato *DataFrame* da biblioteca de programação *Pandas*¹, criada para a linguagem *Python*². O formato *DataFrame* foi utilizado para o pré-processamento e para a análise de dados, pois suporta operações úteis e poderosas de normalização, transformação e relacionamento de dados.

A linguagem *Python* foi utilizada em sua versão 3.7. Além do pacote *Pandas*, também foram utilizadas bibliotecas de cálculo e análise estatística. Em destaque, os pacotes *Numpy*³ e *Jenkspy*⁴, que disponibilizam diversas funções matemáticas, operações envolvendo matrizes e vetores, cálculos de medidas de posição, dispersão e centralidade, entre outros.

¹ <https://pandas.pydata.org/>

² <https://www.python.org/>

³ <https://numpy.org/>

⁴ <https://github.com/mthh/jenkspy>

Tão importante quanto realizar a análise é exibir seus resultados de modo que sejam facilmente visualizados e interpretados. Além disso, é importante que a exibição seja correta e verdadeira quanto às escalas utilizadas.

Para tanto, as bibliotecas *Seaborn*⁵ e *Matplotlib*⁶, que também foram criadas para a linguagem *Python*, foram utilizadas para construção programática de gráficos, *heatmaps* e tabelas.

O ambiente de desenvolvimento integrado e colaborativo *Google Colab*⁷ foi utilizado para elaboração de *Notebooks Jupyter* que serão utilizados para teste de métodos e organização de conhecimento adquirido. O ambiente utilizado suporta o versionamento dos seus documentos e disponibiliza hardware para teste, execução e visualização do código desenvolvido, dos dados obtidos e dos resultados gerados.

Com os *Notebooks Jupyter*⁸ é possível integrar código-fonte, texto, anotações, comentários e resultados de execuções, incluindo elementos gráficos gerados. Desta forma, ao serem utilizados dentro do ambiente do *Google Colab*, constituem um meio rico e poderoso para realização de testes e análises.

Todos os materiais descritos nesta seção foram obtidos e utilizados de forma totalmente gratuita.

3.2. MÉTODOS

3.2.1. Revisão Bibliográfica

Inicialmente, foi realizada a revisão bibliográfica de artigos publicados entre 2015 e 2021 em periódicos disponíveis nas bases de dados da CAPES e do Google Acadêmico, de modo a construir uma fundamentação teórica sólida e construtiva.

⁵ <https://seaborn.pydata.org/>

⁶ <https://matplotlib.org/>

⁷ <https://colab.research.google.com/>

⁸ <https://jupyter.org/>

Para encontrar periódicos, os seguintes descritores foram utilizados, tanto em idioma português brasileiro quanto em inglês: dados futebol; desempenho jogadores futebol; desempenho dados futebol; desempenho dados jogadores futebol; futebol análise de dados; futebol ciência de dados. Os artigos selecionados foram estudados, fichados e organizados de modo que pudessem ser facilmente consultados posteriormente.

Através da revisão bibliográfica, foram estudadas técnicas de Análise de Dados, das quais foram escolhidas as que ofereceram aplicabilidade geral ou específica ao contexto futebolístico. A revisão bibliográfica prosseguiu nas fases subsequentes do projeto, quando necessário.

3.2.2. Escolha da Base de Dados

Em paralelo ao estudo bibliográfico, bases de dados, APIs e sites foram levantadas e detalhadas para que fosse possível escolher um meio de aquisição e análise de dados para este estudo.

Na escolha da base de dados, foram levados em consideração as seguintes informações: preço e/ou gratuidade; número máximo de requisições permitido por intervalo de tempo; disponibilidade; confiabilidade e abrangência dos dados. Não foi preciso analisar se há disponibilidade de dados em tempo real, pois a análise a ser realizada, ocorrerá sobre dados históricos de um campeonato já finalizado.

Através do levantamento, o site *Kickest*⁹ foi escolhido como o banco de dados para este estudo, por apresentar grande quantidade de informações de desempenho de todos os 498 futebolistas que foram inscritos na edição 2020/21 da *English Premier League*. Além disso, todos os dados disponíveis no site podem ser acessados de forma gratuita e ilimitada.

Em seguida, a amostra foi definida considerando futebolistas que atuaram em pelo menos 40% das rodadas da *English Premier League* 2020/21, de modo que o número mínimo de partidas que um futebolista tenha que ter atuado seja igual a 16.

⁹ <https://www.kickest.it/en/premier-league/stats/players/table/2020-2021>

A definição da quantidade mínima de partidas tem o objetivo de excluir da análise futebolistas que pouco atuaram e garantir que a análise seja mais consistente e condizente com o que foi o campeonato como um todo. Foram selecionados dados de desempenho técnico de jogadores, relacionados aos fundamentos listados no Referencial Teórico deste trabalho.

3.2.3. Ambiente de Dados

Os dados foram selecionados com o auxílio da extensão do navegador *Google Chrome*, chamada *Download table as CSV*, que converte tabelas de formato *HTML* para o formato *CSV*, ideal para ser utilizado junto ao *Pandas*. Através da extensão, foram obtidas quatro planilhas de dados, cada uma contendo informações específicas, as quais foram armazenadas em arquivo para serem utilizadas nas etapas posteriores. O Quadro 2 sumariza as planilhas obtidas, o nome dado aos arquivos e a quantidade de linhas e colunas de cada uma.

Quadro 2. Informações gerais das planilhas obtidas.

Arquivo	Dados	Quantidade de Linhas	Quantidade de Colunas
general.csv	Dados gerais	175	20
attack.csv	Dados de ataque	175	13
defense.csv	Dados de defesa	175	15
passing.csv	Dados de passes	175	10

Os nomes e a descrição do significado de cada coluna de cada planilha estão definidos no APÊNDICE A – COLUNAS DE DADOS – VARIÁVEIS. Todos os dados obtidos foram de meio-campistas que atuaram na *English Premier League 2020/2021*.

3.2.4. Pré-processamento

Após a seleção dos dados, iniciou-se o processo de pré-processamento de dados. Inicialmente, foi realizada a intercalação das planilhas, excluindo colunas repetidas.

Foi formada uma única planilha, contendo todas as colunas, sem repetições, de modo que a informação fosse centralizada, facilitando os procedimentos posteriores.

Em seguida, foram excluídas as colunas que não seriam utilizadas na análise e as restantes foram renomeadas em um formato padronizado, sem espaços e com cada palavra iniciando com a primeira letra maiúscula. Então, foi definida a coluna *PercentAccCross*, não existente no conjunto inicial.

Após a exclusão das colunas foi realizada a seleção da amostra, excluindo jogadores que participaram de menos de 40% das partidas. Ao final deste processo, a planilha resultante era formada por 129 linhas e 20 colunas. Dentre as colunas restantes, estão as variáveis que representam fundamentos relacionados a cada característica, assim como as que representam os nomes dos meio-campistas e os times pelos quais atuam.

Para a característica de Distribuição, explicada na Fundamentação Teórica deste trabalho, foram consideradas variáveis exclusivamente de cunho quantitativo e de cunho qualitativo. A análise qualitativa da característica de Distribuição foi adicionada ao escopo da pesquisa, devido a importância da acurácia de passes para a posição de meio-campista. Para as demais características, as variáveis são, em geral, quantitativas.

O Quadro 3 apresenta as variáveis levantadas após a primeira etapa de pré-processamento, relacionando cada uma delas com uma característica e explicando o seu significado. Considere que cada variável representa uma coluna do conjunto de dados.

Quadro 3. Variáveis levantadas após a primeira etapa de pré-processamento.

Característica	Variáveis	Significado
Presença	<i>Mins</i>	Minutos em campo
Criatividade	<i>KeyPass</i>	Passes-chave
	<i>Assists</i>	Assistências
	<i>BigChanceCreated</i>	Grandes chances criadas

Característica	Variáveis	Significado
Distribuição (Quantitativa)	<i>AccPass</i>	Passes certos
	<i>AccCross</i>	Cruzamentos certos
Distribuição (Qualitativa)	<i>PercentAccPass</i>	Percentual de acerto de passes
	<i>PercentAccCross</i>	Percentual de acerto de cruzamentos
Finalização	<i>Goals</i>	Gols
Combatividade	<i>RecBall</i>	Bolas recuperadas
	<i>Tackles</i>	Desarmes
	<i>Interception</i>	Interceptações
	<i>WonDuels</i>	Duelos vencidos

Em seguida, tais variáveis foram utilizadas para gerar novas colunas de dados considerando o desempenho dos futebolistas e a quantidade de minutos em que eles estiveram em campo no decorrer do campeonato.

Foi considerado que cada partida possui 90 minutos e que ao atuar tal quantidade de tempo, um futebolista atua o equivalente a um jogo completo. Então as variáveis de cunho quantitativo, à exceção de *Mins*, foram normalizadas de acordo com a quantidade de 90 minutos em que cada meio-campista atuou no campeonato inteiro. Para uma variável quantitativa *V*, a nova variável gerada *VPer90* é calculada de acordo com o que é definido pela equação (1):

$$VPer90 = \frac{V}{(Mins/90)} \quad (1)$$

O Quadro 4 apresenta as novas variáveis foram geradas e selecionadas para a análise, através da aplicação do exemplo acima a todas as variáveis de cunho quantitativo, à exceção de *Mins*.

Quadro 4. Novas variáveis geradas na etapa de pré-processamento.

Característica	Variáveis	Significado
Presença	<i>Mins</i>	Minutos em campo

Característica	Variáveis	Significado
Criatividade	<i>KeyPassPer90</i>	Passes-chave a cada 90 minutos em campo
	<i>AssistsPer90</i>	Assistências a cada 90 minutos em campo
	<i>BigChanceCreatedPer90</i>	Grandes chances criadas a cada 90 minutos em campo
Distribuição (Quantitativa)	<i>AccPassPer90</i>	Passes certos a cada 90 minutos em campo
	<i>AccCrossPer90</i>	Cruzamentos certos a cada 90 minutos em campo
Distribuição (Qualitativa)	<i>PercentAccPass</i>	Percentual de acerto de passes
	<i>PercentAccCross</i>	Percentual de acerto de cruzamentos
Finalização	<i>GoalsPer90</i>	Gols a cada 90 minutos em campo
Combatividade	<i>RecBallPer90</i>	Bolas recuperadas a cada 90 minutos em campo
	<i>TacklesPer90</i>	Desarmes a cada 90 minutos em campo
	<i>InterceptionPer90</i>	Interceptações a cada 90 minutos em campo
	<i>WonDuelsPer90</i>	Duelos vencidos a cada 90 minutos em campo

As variáveis descritas no Quadro 3 substituíram as presentes no Quadro 2 no processo de análise.

3.2.5. Análise de Dados

Após a definição final das variáveis consideradas, iniciou-se o processo de discretização de dados. Inicialmente, foram definidos rótulos para representar o nível de desempenho de cada futebolista nos fundamentos das características consideradas.

Cinco rótulos foram definidos de forma numérica, variando entre 1 e 5 e considerando que 1 categoriza o nível de desempenho mais baixo e 5 o nível de desempenho mais alto. Os níveis representados por 2, 3 e 4, estão entre 1 e 5, de forma crescente. Um meio-campista rotulado com nível 5 em uma determinada característica obteve altíssimo desempenho nos fundamentos que a determinam e, portanto, tem altíssimo nível de proficiência nela.

Após a definição dos rótulos, foi definido o método de cálculo dos pontos de corte, responsáveis por servir de fronteira entre os níveis. Para definir os pontos de corte, o algoritmo *Jenks Natural Breaks* foi utilizado.

O Quadro 5 apresenta os pontos de corte e a fronteira entre níveis (ou classes) que eles representam.

Quadro 5. Pontos de corte e fronteira.

Ponto de corte	Fronteira
$P1$	Entre os níveis 1 e 2
$P2$	Entre os níveis 2 e 3
$P3$	Entre os níveis 3 e 4
$P4$	Entre os níveis 4 e 5

O método de discretização consiste em determinar o rótulo de uma característica para todos os futebolistas do conjunto de dados. Ao aplicar o método a uma coluna, os valores dos elementos da coluna são avaliados e o elemento é rotulado com o nível calculado. Considere o valor V de um elemento E de uma coluna C . O nível N de E é dado conforme as relações (2), (3), (4), (5) e (6):

$$\min(C) \leq V < P1 \Rightarrow N = 1 \quad (2)$$

$$P1 \leq V < P2 \Rightarrow N = 2 \quad (3)$$

$$P2 \leq V < P3 \Rightarrow N = 3 \quad (4)$$

$$P3 \leq V < P4 \Rightarrow N = 4 \quad (5)$$

$$P4 \leq V \leq \max(C) \Rightarrow N = 5 \quad (6)$$

Note que é necessário representar cada característica em uma única coluna. Para que isso fosse possível, utilizou-se das colunas dos fundamentos relacionados a cada característica para formar uma única coluna responsável por representá-las.

O Quadro 6 apresenta as novas colunas geradas para representar cada característica no processo de discretização e o método utilizado para determiná-las.

Quadro 6. Colunas geradas para representar características.

Característica	Coluna Gerada	Método Utilizado
Criatividade	<i>CriatividadePer90</i>	$KeyPassPer90 + AssistsPer90 + BigChanceCreatedPer90$
Distribuição (Quantitativa)	<i>DistribuicaoQuantPer90</i>	$AccPassPer90 + AccCrossPer90$
Distribuição (Qualitativa)	<i>DistribuicaoQualiPer90</i>	$PercentAccPass * (Passes / (Passes + Crosses)) + PercentAccCross * (Crosses / (Passes + Crosses))$
Combatividade	<i>CombatividadePer90</i>	$RecBallPer90 + TacklesPer90 + InterceptionPer90 + WonDuelsPer90$

A definição da coluna *DistribuicaoQualiPer90* se dá pela média entre *PercentAccPass* e *PercentAccCross*, ponderada pela quantidade total de *Passes* e *Crosses* de cada futebolista. Para as características *Presença* e *Finalização*, não foi necessário gerar novas colunas, pois as mesmas já estavam sendo representadas cada uma por apenas uma coluna, sendo, *Mins* e *GoalsPer90*, respectivamente.

Tendo uma única coluna para cada característica, foi possível aplicar o método de discretização, determinando o valor do rótulo de cada meio-campista para cada uma das características, isto é, o nível de proficiência de cada meio-campista em cada uma das características.

Ao final da discretização uma nova coluna foi gerada para cada uma das características consideradas, onde cada coluna contém o valores dos níveis atribuídos aos futebolistas naquelas características. As colunas geradas foram as seguintes: *Presenca*, *Criatividade*, *DistribuicaoQuant*, *DistribuicaoQuali*, *Finalizacao* e *Combatividade*.

4. RESULTADOS


Após a classificação, realizada através do processo de Discretização das variáveis que representam as características, foi gerada uma planilha com os resultados dos níveis de cada característica, atribuídos a cada meio-campista. A planilha de resultados contém 129 linhas e 8 colunas e está disponível [neste link](#).

A seguir, os resultados de cada característica serão discutidos com mais detalhes através do auxílio de gráficos que contribuem para uma melhor visualização dos valores atribuídos.

4.1. PRESENÇA


A Figura 1 especifica o gráfico *boxplot* da característica Presença. É possível perceber que existe um forte equilíbrio entre os resultados atribuídos. Tais resultados ocorrem devido ao descarte de futebolistas que atuaram em menos de 40% do campeonato.

Figura 1. *Boxplot* da característica Presença.



A Figura 2 mostra o histograma discreto da característica Presença. É possível perceber que a maioria dos futebolistas obtiveram nível 2 e 4 de presença em campo.


Figura 2. Histograma discreto da característica Presença.




4.2. CRIATIVIDADE

A Figura 3 especifica o gráfico *boxplot* da característica Criatividade. É possível perceber que existe um forte desequilíbrio entre os resultados atribuídos. Metade dos futebolistas obtiveram nível 1 ou 2 nesta característica e apenas 25% obtiveram um nível maior que 3.

Figura 3. *Boxplot* da característica Criatividade.



Os resultados evidenciados na Figura 3 são confirmados na Figura 4, que demonstra que pouquíssimos futebolistas obtiveram nível 5 em Criatividade.

Figura 4. Histograma discreto da característica Criatividade.

A Tabela 1 descreve os meio-campistas que obtiveram nível 5 em Criatividade. O belga *Kevin De Bruyne*, considerado um dos melhores futebolistas do mundo nesta posição, é o principal nome do Manchester City (MCI), clube vencedor da edição 2020/21 da *English Premier League*. O inglês *Jack Grealish*, que também obteve nível 5 em Criatividade, jogou a edição pelo Aston Villa (AVL), mas foi contratado pelo Manchester City para a próxima edição em um acordo de cerca de 100 milhões de libras esterlinas (GE, 2021).


Tabela 1. Meio-campistas com nível 5 em Criatividade.

<i>Player</i>	<i>Team</i>	<i>AssistsPer90</i>	<i>BigChanceCreatedPer90</i>	<i>KeyPassPer90</i>	<i>Criatividade</i>
J. Grealish	AVL	0.411899	0.576659	3.336384	5
K. De Bruyne	MCI	0.539730	0.854573	3.598201	5

4.3. DISTRIBUIÇÃO QUANTITATIVA


A Figura 5 especifica o gráfico *boxplot* da característica Distribuição Quantitativa. É possível perceber que existe um forte equilíbrio entre os resultados atribuídos. Tais resultados são esperados, pois os meio-campistas geralmente produzem muitos passes por jogo. É esperado que alguns tenham mais destaque nesse fundamento, mas a maioria fica entre o primeiro e o terceiro quartil.

Figura 5. *Boxplot* da característica Distribuição Quantitativa.



A Figura 6 mostra o histograma discreto da característica Distribuição Quantitativa, confirmando o equilíbrio notado no *boxplot*.

Figura 6. Histograma Discreto da característica Distribuição Quantitativa.



4.4. DISTRIBUIÇÃO QUALITATIVA

A Figura 7 especifica o gráfico *boxplot* da característica Distribuição Qualitativa. O equilíbrio visto na Distribuição Quantitativa é mantido, entretanto a Figura 8 demonstra que há maior incidência de meio-campistas com níveis elevados na Distribuição Qualitativa. [OBJ]

Figura 7. *Boxplot* da característica Distribuição Qualitativa.






Figura 8. Histograma discreto da característica Distribuição Qualitativa.



4.5. FINALIZAÇÃO


A Figura 9 especifica o gráfico *boxplot* da característica Finalização. Novamente, é possível observar um forte desequilíbrio entre os valores atribuídos. A marcação de gols, através da finalização de jogadas, constitui o principal objetivo de uma partida de futebol. Entretanto, tal fundamento não é o principal ao se considerar o contexto específico dos meio-campistas, muito mais focados na distribuição e na criação de jogadas, bem como no combate e na briga pela posse de bola. Porém, alguns ainda se destacam na característica de Finalização e este pode ser um fator muito importante para a sua avaliação.

Figura 9. *Boxplot* da característica Finalização.



A Figura 10 quantifica o que foi evidenciado na Figura 9, confirmando que a maioria dos meio-campistas teve uma avaliação baixa na característica Finalização.

Figura 10. Histograma discreto da característica Finalização.



A Tabela 2 lista os meio-campistas que obtiveram nível 5 em Finalização. A maioria deles atua em posições mais avançadas que a maioria dos meio-campistas, o que contribui para que tenham um número maior de gols a cada 90 minutos em campo. Novamente, aparecem futebolistas do campeão Manchester City e também aparece desta vez o português Bruno Fernandes, do vice-campeão Manchester United (MUN), artilheiro entre os meio-campistas.


Tabela 2. Meio-campistas que obtiveram nível 5 em Finalização.

<i>Player</i>	<i>Team</i>	<i>GoalsPer90</i>	<i>Finalizacao</i>
R. Mahrez	MCI	0.414534	5
H. Barnes	LEI	0.415598	5
Ferran Torres	MCI	0.482759	5
P. Foden	MCI	0.502170	5
Bruno Fernandes	MUN	0.521739	5
A. El Ghazi	AVL	0.558313	5
J. Lingard	WHU	0.568820	5
I. Gundogan	MCI	0.576355	5
J. Willock	NEW	0.592593	5

É importante ressaltar que o meio-campista Bruno Fernandes, citado como artilheiro da edição entre os meio-campistas, não possui o melhor valor de *GoalsPer90* devido à grande quantidade de minutos que ele esteve em campo, também obtendo nível 5 em Presença.

4.6. COMBATIVIDADE


A Figura 11 especifica o *boxplot* da característica Combatividade, indicando um equilíbrio entre os valores atribuídos.

Figura 11. *Boxplot* da característica Combatividade.

Assim como a distribuição de jogadas, a briga pela posse de bola é uma ação comum e um atributo marcante entre os meio-campistas, então é esperado que haja tal equilíbrio.

A Figura 12 confirma este equilíbrio e transparece a pequena quantidade de meio-campistas com nível 1 na característica de Combatividade. Novamente, a maioria dos valores atribuídos está entre 2 e 4, mas há um número considerável de valores 5, sendo o maior dentre todas as características.

Figura 12. Histograma discreto da característica Combatividade.




4.7. CORRELAÇÃO ENTRE CARACTERÍSTICAS

A Figura 13 representa o *heatmap* de correlação entre os valores atribuídos a todas as características para cada meio-campista. Neste gráfico, o valor 1 indica máxima correlação positiva e o valor -1 indica máxima correlação negativa. Valores maiores que 0 indicam que existe alguma correlação entre variáveis.

É possível notar que a maior correlação registrada é entre as variáveis *DistribuicaoQuant* e *DistribuicaoQuali*, indicando que, em geral, uma grande quantidade de passes e cruzamentos certos por jogo está relacionada a um bom percentual de acerto de passes e de cruzamentos.


A segunda maior correlação positiva registrada foi em relação às variáveis *Criatividade* e *Finalizacao*. Também foi possível notar alguma correlação positiva entre *Combatividade* e as variáveis de *DistribuicaoQuant* e *DistribuicaoQuali*.

Figura 13. Heatmap de correlação entre as variáveis.



O gráfico da Figura 14 demonstra a correlação entre as variáveis de distribuição e dá destaque aos futebolistas que obtiveram nível 5 em ambas as características.

Figura 14. Gráfico de pontos: *DistribuiçãoQuant* x *DistribuicaoQuali*.



4.8. BUSCAS NOS RESULTADOS

Tendo a planilha de resultados, é possível realizar buscas por meio-campistas focadas em características específicas. Neste sentido, a discretização de dados contribui para que times consigam definir com clareza alvos que venham agregar em suas equipes, cobrindo lacunas específicas e elevando a qualidade disponível.

A definição de alvos depende do orçamento da equipe que está contratando. Meio-campistas com nível 5 em determinada característica são os alvos mais cobiçados, mas também são os mais caros, o que faz com que nem todas as equipes possam contratá-los. Neste caso, equipes de menor orçamento podem definir contratações de atletas com níveis 3 ou 4 em determinadas características e níveis 1 ou 2 nas características que não são tão importantes no contexto da equipe.

A Tabela 3 exemplifica uma busca por meio-campistas com foco em Criatividade e Finalização. A busca exige que os meio-campistas tenham nível pelo menos 4 em Criatividade e Finalização, pelo menos 3 em Presença e pelo menos 2 em Distribuição Quantitativa e Distribuição Qualitativa.

Tabela 3. Exemplo de resultado de busca por meio-campistas.

<i>Player</i>	<i>Team</i>	<i>Presenca</i>	<i>Criatividade</i>	<i>Distribuicao Quant</i>	<i>Distribuicao Quali</i>	<i>Finalizacao</i>
Bruno Fernandes	MUN	5	4	4	2	5
J. Grealish	AVL	3	5	2	3	4
Matheus Pereira	WBA	4	4	2	2	4
J. Maddison	LEI	3	4	3	3	4
K. De Bruyne	MCI	3	5	4	2	4
R. Mahrez	MCI	3	4	3	4	5
J. Rodriguez	EVE	3	4	3	3	4

Considerar os níveis atribuídos aos meio-campistas como valores numéricos de pontuação, possibilita a formação de um *ranking* através do somatório dos valores de níveis atribuídos. Os valores foram somados e, como resultado, a Tabela 4 mostra o *ranking* com os 10 meio-campistas que tiveram mais valores de níveis atribuídos.

Tabela 4. *Ranking* de meio-campistas considerando o somatório dos níveis.

<i>Player</i>	<i>Team</i>	<i>Total</i>
Fred	MUN	21
M. Mount	CHE	21
J. Ward-Prowse	SOU	21
Y. Tielemans	LEI	21
Thiago Alcântara	LIV	22
P. Hojbjerg	TOT	22
Bruno Fernandes	MUN	22
Jorginho	CHE	23
I. Gundogan	MCI	23
Rodri	MCI	23

Dentre os 10 melhores avaliados, em termos de níveis atribuídos, 8 meio-campistas disputaram o campeonato pelas equipes que terminaram entre os quatro primeiros colocados, sendo 2 pelo campeão *Manchester City* (MCI), 2 pelo vice-campeão *Manchester United* (MUN), 1 pelo terceiro colocado *Liverpool* (LIV) e 2 pelo quarto colocado *Chelsea* (CHE).

5. CONCLUSÕES

A revisão bibliográfica possibilitou entendimento e construção de uma base sólida de conhecimento na área de Análise de Dados, principalmente voltada para o esporte, em especial o futebol.

O estudo de técnicas pré-processamento e análise de dados proporcionaram maturidade para estar diante de um conjunto de dados consideravelmente grande e saber quais operações precisavam ser realizadas para torná-lo útil e utilizá-lo para a obtenção dos resultados.

O método de discretização, apoiado pela escolha natural e correta dos pontos de corte aumentam a confiabilidade da classificação e contribuem para que os resultados sejam consistentes e fáceis de serem interpretados.

A classificação é a base do trabalho, que possibilita realizar buscas por meio-campistas de características específicas que venham a encaixar-se em uma equipe específica, considerando tanto as necessidades da equipe, quanto o orçamento disponível para contratações. A discretização torna o processo de contratação mais simples, objetivo e inteligente. A planilha, com os dados das classificações, fica disponível [neste link](#) para ser utilizada em trabalhos futuros.

Este método pode ser generalizado e aplicado a futebolistas de demais posições e de outras ligas. Uma API poderia consumir uma base de dados com um grande conjunto de classificações e ser utilizada por uma aplicação que realiza as buscas, auxiliando no processo de seleção e contratação de futebolistas por parte das agremiações.

REFERÊNCIAS BIBLIOGRÁFICAS

GIL, Antônio Carlos. **Métodos e Técnicas de Pesquisa Social**. 6. ed. São Paulo: Editora Atlas S.A, 2008.

SHVILI, Jason. **The Most Popular Sports In The World**. 2020. Disponível em: <https://www.worldatlas.com/articles/what-are-the-most-popular-sports-in-the-world.html>. Acesso em: 25 abr. 2021.

CAREY, Mark. **A closer look into European Midfielder Playing Styles**. 2020. Disponível em: <https://careyanalytics.wordpress.com/2020/04/30/a-closer-look-into-european-midfielder-playing-styles/>. Acesso em: 25 abr. 2021.

JOY, Bernard et al. **Football**. 2020. Disponível em: <https://www.britannica.com/sports/football-soccer>. Acesso em: 25 abr. 2021.

FAY, Richard. **Who is John Murtough?**: Manchester United's inaugural football director profiled. 2021. Disponível em: <https://www.manchestereveningnews.co.uk/sport/football/football-news/who-is-john-murtough-wiki-20035334>. Acesso em: 25 abr. 2021.

ORTEGA, João. **Como a ciência de dados fez do Liverpool o melhor time de futebol do mundo**. 2020. Disponível em: <https://www.startse.com/noticia/nova-economia/ciencia-de-dados-liverpool-futebol>. Acesso em: 25 abr. 2021.

IFAB (org.). **Laws of The Game**. 2020. Disponível em: <https://resources.fifa.com/image/upload/ifab-laws-of-the-game-2020-21.pdf?cloudid=d6g1medsi8jrrd3e4imp>. Acesso em: 25 abr. 2021.

BUNDESLIGA (org.). **Soccer positions explained: names, numbers and what they do**. 2020. Disponível em: <https://www.bundesliga.com/en/bundesliga/news/soccer-positions-explained-names-numbers-what-they-do-2579-786>. Acesso em: 25 abr. 2021.

CASTELÃO, Daniel Pimenta *et al.* Análise sequencial de comportamentos ofensivos desempenhados por seleções nacionais de futebol de alto rendimento. **Revista Brasileira de Ciências do Esporte**, [S. L.], v. 37, n. 3, p. 230-236, 4 jun. 2015.

SILVA, Jorge Victor de Oliveira. Relação entre posse de bola e eficácia em processos ofensivos no futebol. **RBFF - Revista Brasileira de Futsal e Futebol**, São Paulo, v. 8, n. 29, p. 161-165, 3 mar. 2016.

BERTO, Elano Silva de Magalhães; MAGALHÃES, Flávia Costa Oliveira. Análise quantitativa das ações do goleiro de Futebol. **RBFF - Revista Brasileira de Futsal e Futebol**, São Paulo, v. 9, n. 34, p. 273-281, 8 set. 2017.

ANDRADE, Marcelo Odilon Cabral de; COSTA, Israel Teoldo da. Como a eficiência do comportamento tático e a data de nascimento condicionam o desempenho de jogadores de futebol?. **Rev. bras. educ. fís. esporte**, São Paulo, v. 29, n. 3, p. 465-473, set. 2015.

AMÉRICO, Henrique Bueno *et al.* ANÁLISE DO COMPORTAMENTO TÁTICO DE JOGADORES DE FUTEBOL DE CATEGORIA DE BASE. **J. Phys. Educ.**, Maringá, v. 27, e2710, 2016.

PRAÇA, Gilbson Moreira *et al.* COMPORTAMENTO TÁTICO EM PEQUENOS JOGOS NO FUTEBOL: INFLUÊNCIA DO CONHECIMENTO TÁTICO E DA SUPERIORIDADE NUMÉRICA. **J. Phys. Educ.**, Maringá, v. 27, e2736, 2016.

KOEHLER, Marcius; LIMA, Edmilson Oliveira. Apoio de uma Rede para Retenção de Talentos em Pequenos Clubes de Futebol. **Revista de Ciências da Administração**, Florianópolis, SC, v. 19, n. 49, p. 10-28, dez. 2017.

CINTIA, Paolo; RINZIVILLO, Salvatore; PAPPALARDO, Luca. A network-based approach to evaluate the performance of football teams. *In*: **Machine Learning and Data Mining for Sports Analytics workshop (MLSA'15), ECML/PKDD**, 2015.

THAKKAR, Poojan; SHAH, Manan. An Assessment of Football Through the Lens of Data Science. *In*: **Ann. Data. Sci.** 2021.

SIEGHARTSLEITNER, Roland *et al.* Science or Coaches' Eye? - Both! Beneficial Collaboration of Multidimensional Measurements and Coach Assessments for Efficient Talent Selection in Elite Youth Football. **J Sports Sci Med**, [S.L], v. 18 n. 1, p. 32-43, 11 fev. 2019.

BUSH, Thomas. **Descriptive Analysis: How-To, Types, Examples**. 2020. Disponível em: <https://pestleanalysis.com/descriptive-analysis/>. Acesso em: 25 abr. 2021.

RAMÍREZ-GALLEGO, Sergio *et al.* Data Discretization: Taxonomy and Big Data Challenge. **Wires Data Mining Knowl Discov**, [S.L], v. 6, n. 1, p. 5-21, 24 nov. 2015.

JENKS, George Frederick. The Data Model Concept in Statistical mapping. *In*: **International Yearbook of Cartography**. Gutersloh: C. Vertelsmans Verlag, 1967. p. 186-190.

MICROSOFT (org.). **Discretization Methods (Data Mining)**. 2022. Disponível em: <https://docs.microsoft.com/en-us/analysis-services/data-mining/discretization-methods-data-mining?view=asallproducts-allversions>. Acesso em: 15 mar. 2022.

GE (org.). **Manchester City confirma contratação de Jack Grealish, a mais cara do futebol inglês**. 2021. Disponível em: <https://ge.globo.com/futebol/futebol-internacional/futebol-ingles/noticia/manchester-city-confirma-a-contratacao-de-jack-grealish-seu-novo-camisa-10.ghtml>. Acesso em: 28 mar. 2022.

APÊNDICE A – COLUNAS DE DADOS – VARIÁVEIS

Dados Gerais (<i>general.csv</i>)	
Variável	Descrição
<i>Player</i>	Nome do futebolista
<i>Pos</i>	Posição do futebolista
<i>Team</i>	Time do futebolista
<i>Apps</i>	Quantidade de atuações
<i>Starter</i>	Quantidade de partidas em que foi titular
<i>Mins</i>	Quantidade de minutos em campo
<i>Goals</i>	Gols marcados
<i>Shots</i>	Finalizações
<i>On Tar. Shots</i>	Finalizações no alvo
<i>Pen Goals</i>	Gols de pênalti
<i>Successful Dribbles</i>	Dribles bem-sucedidos
<i>Ast</i>	Assistências
<i>Acc Pass</i>	Passes certos
<i>Key Pass</i>	Passes-chave
<i>Fouls</i>	Faltas cometidas
<i>Was Fouled</i>	Faltas sofridas
<i>YC</i>	Cartões amarelos
<i>RC</i>	Cartões vermelhos
<i>Rec Ball</i>	Bolas recuperadas
<i>Tackles</i>	Desarmes
Dados de Ataque (<i>attack.csv</i>)	
Variável	Descrição
<i>Player</i>	Nome do futebolista
<i>Goals</i>	Gols marcados
<i>Shots</i>	Finalizações
<i>On Tar. Shots</i>	Finalizações no alvo

Variável	Descrição
<i>Woods</i>	Finalizações na trave
<i>Headed Goals</i>	Gols de cabeça
<i>Pen Goals</i>	Gols de pênalti
<i>Freekick Goals</i>	Gols de falta
<i>Big Chance Missed</i>	Grandes chances perdidas
<i>Goal/Min</i>	Minutos a cada gol
<i>Shot Con Rate</i>	Taxa de conversão de finalizações
<i>Total Dribbles</i>	Tentativas de dribles
<i>Sucessful Dribles</i>	Dribles bem-sucedidos
Dados de Defesa (<i>defense.csv</i>)	
Variável	Descrição
<i>Player</i>	Nome do futebolista
<i>Fouls</i>	Faltas cometidas
<i>Was Fouled</i>	Faltas sofridas
<i>YC</i>	Cartões amarelos
<i>2nd YC</i>	Segundo cartão amarelo
<i>RC</i>	Cartões vermelhos
<i>Err leading to Gol</i>	Erros que levaram à gols adversários
<i>OG</i>	Gols contra
<i>Interception</i>	Interceptações
<i>Rec Ball</i>	Bolas recuperadas
<i>Won Duels</i>	Duelos vencidos
<i>Lost Duels</i>	Duelos perdidos
<i>Aer. Duels Won</i>	Duelos aéreos vencidos
<i>Aer. Duels Lost</i>	Duelos aéreos perdidos
<i>Tackles</i>	Desarmes
Dados de Passes (<i>passing.csv</i>)	
Variável	Descrição
<i>Player</i>	Nome do futebolista

Variável	Descrição
<i>Assists</i>	Assistências
<i>Passes</i>	Passes
<i>Acc Pass</i>	Passes certos
<i>Acc Pass %</i>	Percentual de acerto de passe
<i>Key Pass</i>	Passes-chave
<i>Big Chance Created</i>	Grandes chances criadas
<i>Cross</i>	Cruzamentos
<i>Acc Cross</i>	Cruzamentos certos
<i>Cross no Corner</i>	Cruzamentos sem contar escanteios