

Resultados

Durante os experimentos de modelagem preditiva, dois algoritmos de aprendizado supervisionado foram utilizados para prever o desfecho clínico (EVOLUCAO) de pacientes com Síndrome Respiratória Aguda Grave (SRAG): o modelo CART (árvore de decisão) e o modelo Random Forest (floresta aleatória). Ambos os modelos foram treinados com a base de dados tratada e balanceada por meio da técnica SMOTE, e avaliados com validação cruzada estratificada (5-fold), utilizando como principal métrica o F1-score.

Modelo	F1-score (óbito)	AUC ROC	Precision (óbito)	Recall (óbito)	Tempo de treino
----- ----- ----- ----- ----- -----					
CART	0.50	0.818	0.41	0.62	3.6 segundos
Random Forest	0.52	0.838	0.44	0.64	18.7 segundos

Discussão

A análise dos resultados demonstrou que o modelo Random Forest apresentou melhor desempenho em comparação ao modelo CART, tanto em termos de F1-score quanto na área sob a curva ROC (AUC). O F1-score da classe minoritária (óbito) foi de 0.52 para o Random Forest, ligeiramente superior ao 0.50 obtido pelo CART. Embora ambos os valores indiquem um desafio em lidar com o desbalanceamento da base, os resultados são satisfatórios considerando a natureza do problema e as limitações do dataset.

A AUC de 0.838 obtida pelo Random Forest revela que o modelo possui boa capacidade de separação entre as classes (cura e óbito), superando os 0.818 do CART. O aumento nos valores de precision e recall para a classe de óbitos reforça que o Random Forest é mais eficaz em identificar pacientes com maior risco de evolução desfavorável, um aspecto essencial no contexto clínico.

Além disso, o tempo de processamento mostrou-se aceitável para ambos os modelos, com o CART sendo consideravelmente mais rápido, embora em detrimento da performance preditiva.

Conclusão

Os resultados obtidos confirmam a viabilidade do uso de algoritmos de aprendizado de máquina para a predição de desfechos clínicos em pacientes com SRAG. O modelo Random Forest, em especial, destacou-se por oferecer melhor equilíbrio entre sensibilidade e especificidade, sendo capaz de identificar corretamente cerca de 64% dos óbitos reais com uma AUC superior a 0.83. Esses achados são promissores para futuros sistemas de apoio à decisão clínica baseados em dados, contribuindo para intervenções mais precisas e oportunas no atendimento a pacientes em risco.